



Druhé cvičenie z predmetu

Strojové učenie a neurónové siete

Príprava dát a ANN ako blackbox

25. september 2026

I-SUNS seminár 2

Agenda na dnes

- Zadanie 1
- Príprava dát
 - Čistenie
 - Kódovanie
 - Škálovanie
- EDA
- Postup riešenia demonštrovaný na datasete zo zdroja, využité knižnice numpy, pandas, plotly, sklearn, keras (tensorflow)



Dáta pre ML

Principiálne:

1. **Robustné** - čím viac dát, tým lepší model.
2. **Konzistentné** z rovnakého zdroja.
3. **Dostupné** aj počas testovacieho módu.
4. **Správne** bez chybných záznamov a outlierov.
5. **Reprezentatívne** problému.
6. S **prediktívnou** silou .

Prakticky:

1. Neprázdne
2. Číselné
3. V rovnakom rozsahu



Príprava dát

- Chýbajúce hodnoty
 - Nahrádzam nulou
 - Predpokladám hodnotu (*imputation*)
 - Ignorujem príznak/vzorku
- Nečíselné (textové) hodnoty
 - Dajú sa hodnoty mapovať na čísla?
 - yes/no - true/false
 - good/better/the best
- Kontrola správnosti dát
 - Duplikáty, outliers
 - Somariny sa ťažko modelujú
- Numerická stabilita
 - Normalizácia/štandardizácia/škálovanie príznakov

Entity	Code	Year	Death rate...	Birth rate, ...	Total population ...	Continent
Afghanistan	AFG	2007	9.287	42.944	27100542.0	
Afghanistan	AFG	2008	8.932	41.949	27722281.0	
Afghanistan	AFG	2009	8.584	40.903	28394806.0	
Afghanistan	AFG	2010	8.25	39.829	29185511.0	
Afghanistan	AFG	2011	7.936	38.75	30117411.0	
Afghanistan	AFG	2012	7.645	37.69	31161378.0	
Afghanistan	AFG	2013	7.38	36.67	32269592.0	
Afghanistan	AFG	2014	7.141	35.706	33370804.0	
Afghanistan	AFG	2015	6.929	34.809	34413603.0	Asia
Afghanistan	AFG	2016	6.742	33.981	35383028.0	
Afghanistan	AFG	2017	6.575	33.211	36296111.0	
Afghanistan	AFG	2018	6.423	32.487	37171922.0	
Afghanistan	AFG	2019	6.285	31.802	38041757.0	
Afghanistan	AFG	2020			38928341.0	
Afghanistan	AFG	2021			39835428.0	
	AFG	2022				
	AFG	2023				
	AFG	2024				



Textové hodnoty



- Identifikácie (ani ak sú číselné) a názvy do siete ďalej neposielame.
- Inak pre textové hodnoty - Label Encoding ▪, Dummy Encoding ▪ (OneHot encoding)

continent	labelEncoding	Africa	Asia	Europe	North America	Oceania	South America
Europe	2	0	0	1	0	0	0
Africa	0	1	0	0	0	0	0
Africa	0	1	0	0	0	0	0
Africa	0	1	0	0	0	0	0
South America	5	0	0	0	0	0	1
Oceania	4	0	0	0	0	1	0
Asia	1	0	1	0	0	0	0
Asia	1	0	1	0	0	0	0
Asia	1	0	1	0	0	0	0
South America	5	0	0	0	0	0	1
Europe	2	0	0	1	0	0	0
Europe	2	0	0	1	0	0	0
Europe	2	0	0	1	0	0	0
Europe	2	0	0	1	0	0	0
Asia	1	0	1	0	0	0	0



Normalizácia dát

Entity	Year	Urban population	Individuals using the Internet (% of population)
Jamaica	2016	1601281.0	44.36685637
Kiribati	2011	50519.0	10.0
Japan	2011	116416235.0	79.05411352
Guatemala	2015	7779195.0	28.80594156
Sri Lanka	2014	3785336.0	25.8
Ghana	2014	14543045.0	25.51773743
Cameroon	2010	10487738.0	4.3
Kyrgyzstan	2011	1949521.0	17.5
Estonia	2010	906655.0	74.1
Australia	2011	19056040.0	79.48769771
Montenegro	2010	397301.0	37.5
Cameroon	2016	13202430.0	23.20297197
Uruguay	2018	3288346.0	74.3831762
Mali	2014	6637534.0	7.0
Hungary	2012	6912310.0	70.57999815
Finland	2017	4699884.0	87.46892907



Škálovanie dát

- Normalizácia

- Mení rozsah (obv. medzi $\langle 0,1 \rangle$, $\langle -1,1 \rangle$)
- Ak sa premenná neriadi Gaussovým rozdelením
- Min-max, ...

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$



- Štandardizácia

- Mení rozsah aj distribúciu
- z-score
- Ak sa premenná riadi Gaussovým rozdelením

(povedzme)


$$x_{norm} = \frac{x - \mu}{\sigma}$$

- Pre modely využívajúce gradientný zostup aj založené na vzdialenostiach
- Diskusia - vstupné a výstupné veličiny



Neurónové siete - dáta

- Delenie trénovacia/validačná/testovacia množina (napr. 8:1:1)
 - Trénovacia množina - vstup do trénovania
 - Validačná množina - počas trénovania overuje schopnosť generalizovať na nevidených dátach
 - Testovacia - vyhodnocovanie výsledkov



Exploratory Data Analysis

- Wikipedia:
 - *In statistics, exploratory data analysis is an approach to analyzing data sets to summarize their main characteristics, often with visual methods.*
 - *Analýza dat explorační – Sociologická encyklopedie*
- Začiatok práce s datasetom - hľadá vzory, odpovedá na otázky o dátach, odhaľuje skryté vzťahy, pomáha pri *feature engineering*
- Príklady:
 - [R] Suicide Rates (in-depth) - Stats & Insights
 - Exploring Youtube Trending Statistics EDA
 - EDA with Plotly
 - EDA - Tweets during Cavaliers vs Warriors
 - EDA - The Cure discography
 - Gun violence in the US: EDA and RShiny app

