Siedme cvičenie z predmetu

Strojové učenie a neurónové siete

Redukcia dimenzie a zhlukovanie

23.10.2026

I-SUNS cvičenie 6



Redukcia dimenzie

Redukcia dimenzie

- "*Curse of dimensionality*":
  - Počet vzoriek potrebných na natrénovanie ML algoritmov stúpa exponenciálne s počtom príznakov na vzorku
  - Náchylné na pretrénovanie
  - Vysoké dimenzie vytvárajú "sparse" data
  - Veľa priestoru a veľa výpočtovej sily
- Využitie redukovania dimenzie:
  - Feature engineering
  - Vizualizácia a pochopenie dát
- Mapovanie vzoriek do nového priestoru (nižšie rozmerného)
  - Nové dimenzie už obvykle nevieme popísať ľudským konceptom
  - Snaha zachovať čo najviac vlastností z vyšších dimenzií
- Príklady: PCA, TsNE, UMAP



PCA - jednoduchý príklad

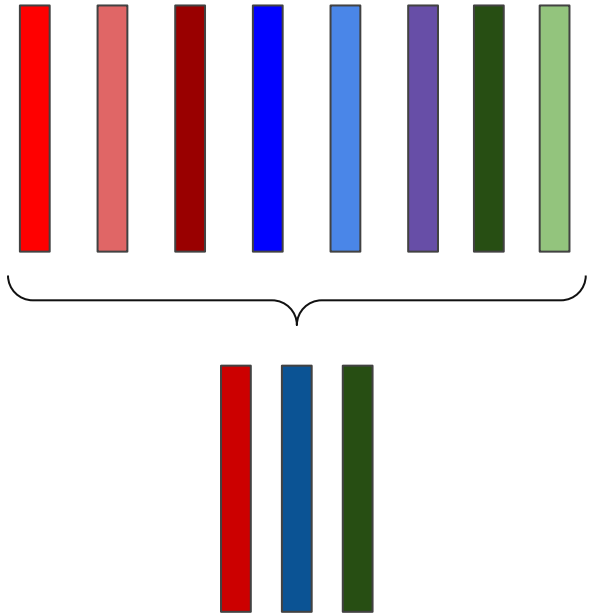
-Máme 8 rôznych farbičiek

- Ale stačilo by mať iba 3 nové farby, ktoré by ti dali podobný výsledok, ako keby si mal všetky pôvodné farbičky.

- PCA vezme pôvodné farbičky a povie: "Poďme zmiešať tieto farby do jednej novej farby, potom tieto do druhej novej farby, atď."

-Teraz máme len 3 farby, ktoré vieme použiť namiesto všetkých pôvodných 8, ale stále nám umožnia vymaľovať obrázok veľmi podobne.

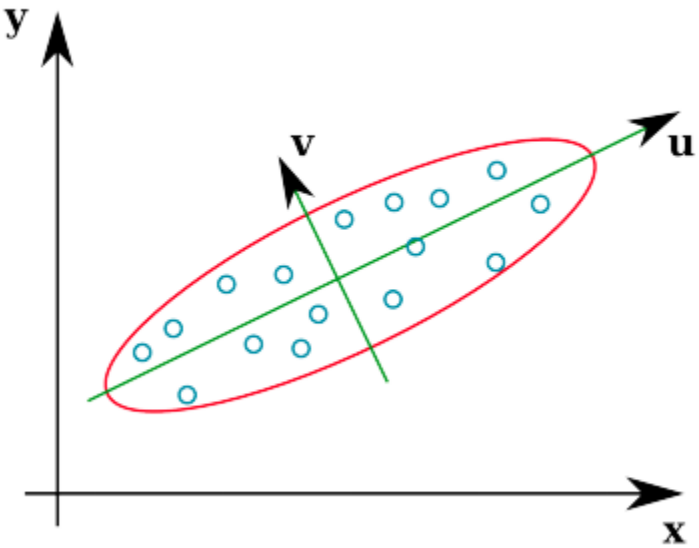
-PCA **zjednoduší dáta**, ale zachová čo najviac z pôvodnej informácie.



Zdroj:
http://www.math.union.edu/~jaureguj/PCA.pdf

Principal Component Analysis - Analýza hlavných komponentov

- Príklad: https://setosa.io/ev/principal-component-analysis/
- Lineárna projekcia
- PCA:
  1. Štandardizácia dát
  2. Kovariačná matica
  3. Vypočítanie vlastných čísel a vlastných vektorov
  4. Vypočítanie hlavných komponentov
  5. Transformácia dát podľa hlavných komponentov



Zdroje obrázkov:
https://apandre.wordpress.com/visible-data/cluster-analysis/

PCA - príklad

- Databáza ľudí:
  - Výška
  - Hmotnosť
  - Vek

Osoba	Výška [cm]	Hmotnosť [kg]	Vek [roky]
A	160	54	19
B	165	62	24
C	170	66	23
D	175	69	29
E	180	77	27
F	185	80	33

- Kovariančná matica:

	Výška [cm]	Hmotnosť [kg]	Vek [roky]
Výška [cm]	87.50	89.00	42.50
Hmotnosť [kg]	89.00	92.40	42.40
Vek [roky]	42.50	42.40	24.16

Známa tabuľka (matica) ?

	Výška [cm]	Hmotnosť [kg]	Vek [roky]
Výška [cm]	1.00	0.99	0.92
Hmotnosť [kg]	0.99	1.00	0.90
Vek [roky]	0.92	0.90	1.00

Zdroj:
http://www.math.union.edu/~jaureguj/PCA.pdf



PCA - príklad

- Vlastné čísla

	Eigenvalue	ExplainedVarianceRatio
PC1	2.87	0.96
PC2	0.12	0.04
PC3	0.01	0.00

- Vlastné vektory

	PC1	PC2	PC3
Výška [cm]	-0.59	-0.29	-0.76
Hmotnosť [kg]	-0.58	-0.50	0.64
Vek [roky]	-0.57	0.82	0.12

- Vlastný vektor 1 zodpovedá za 96% variancie dát
- PC1 - celkový vzrast človeka
- PC2 - oddeľuje mladších od starších pri rovnakej postave
- PC3 - vzťah medzi výškou a váhou



PCA - príklad

- Záver: Z daných vlastností sa dá človek popísať aj pomocou 2 stĺpcov:
  - Celková veľkosť
  - Vplyv veku na postavu
- Dokážeme tieto dáta zredukovať aj na 1 stĺpec pri zachovaní variancie 96%
- Po transformácii vieme každého človeka popísať pomocou týchto vlastností

- Môžeme si určiť, koľko vlastných vektorov chceme zobrať do úvahy pri ďalšom spracovaní:
  - Aby sme si uchovali nejaké percento variancie (feature engineering)

Zdroj:
http://www.math.union.edu/~jaureguj/PCA.pdf



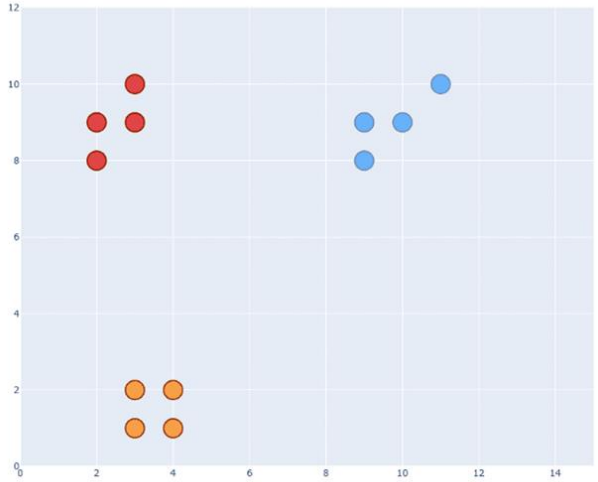
t-SNE

- Na rozdiel od PCA nie lineárna metóda
- Veľmi zjednodušene: Body, ktoré sú susedia vo vysoko dimenzionálnom priestore by mali byť susedia aj v nízko dimenzionálnom priestore
- Iteratívna metóda:
  1. V pôvodnom (vysoko-dimenzionálnom priestore) modelujeme distribúciu pravdepodobnosti, že dvojice bodov budú “susedia” (Gaussovo rozdelenie)
  2. V novom (nízko-d) priestore náhodne “rozhodíme” dáta a vypočítame im rozdelenie pravdepodobnosti, že sú susedia (t-student rozdelenie)
  3. Iterujeme, kým si tieto dve pravdepodobnosti nebudú čo najpodobnejšie (Kullback-Leiber divergencia) - gradientný zostup

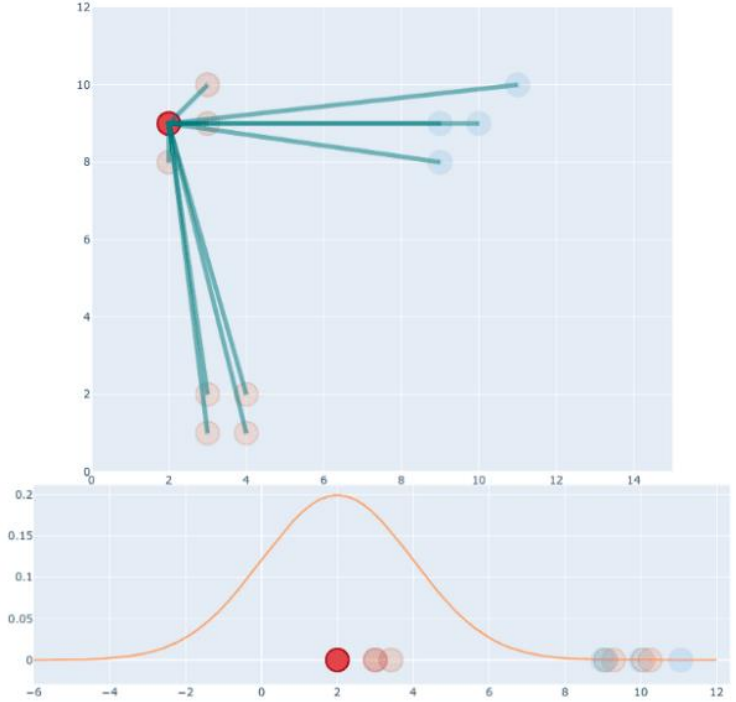


t-SNE - príklad

1. Dáta v 2D priestore

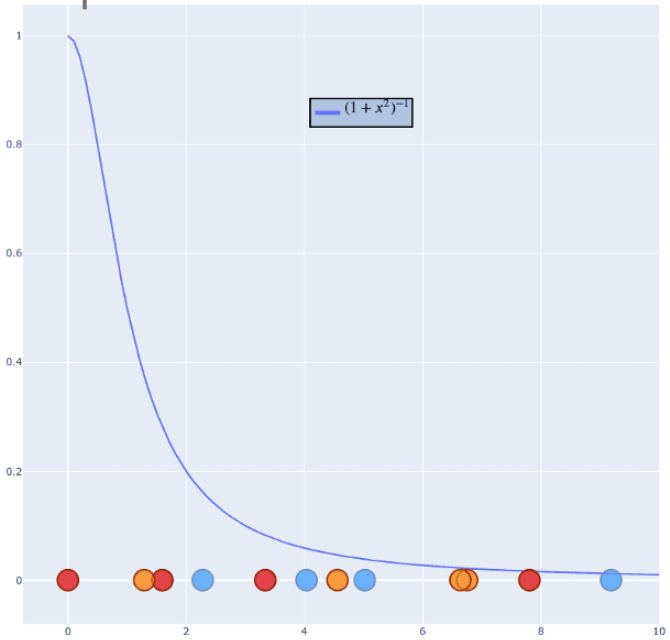


1. Vysoká dimenzia - Euklidova vzdialenosť modelovaná Gaussovým rozdelením pravdepodobnosti



t-SNE -príklad

2. Náhodne rozhodené dáta v 1D priestore



3. Gradientný zostup





t-SNE poznámky

- Hyperparametre:
  - Gradientný zostup - learning rate, počet iterácií...
  - perplexita - koľko susedov by mal bod ideálne mať? (medzi 5-50)
  - Early compression/early exaggeration - regularizácia

- Nedeterministický
- Nedá sa použiť na nevidené dáta
- Výpočtovo náročný

- Pozor:
  - Výsledné vzdialenosti v 2/3D priestore nereprezentujú úplne tie z vyšších-d priestorov

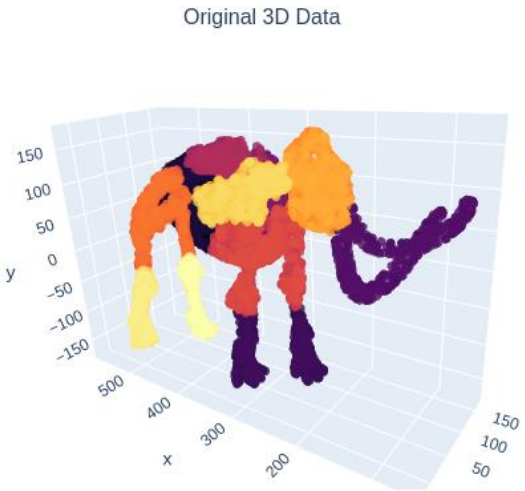


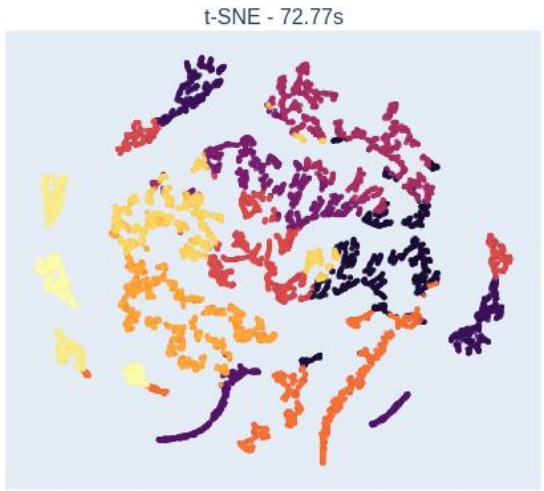
UMAP

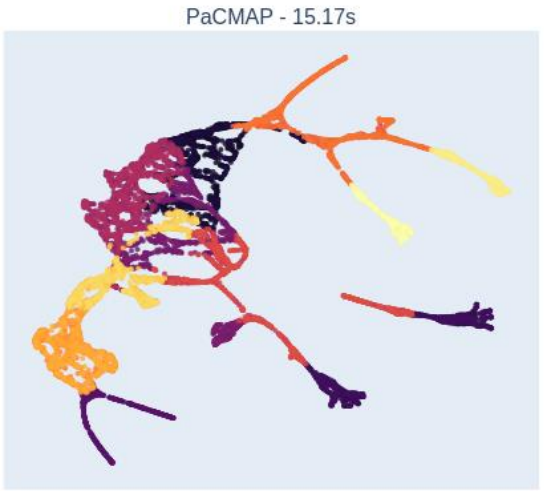
- Vylepšené t-SNE - rýchlejší, lepšie zachytáva globálne vzťahy
- Nevyužíva Euklidovu vzdialenosť na meranie vzdialenosti, nenormalizuje pravdepodobnosti
- Zostrojenie váhovaných grafov (dva hyperparametre: počet susedov, min. vzdialenosť)
- Graf sa snaží zduplikovať v nižšej dimenzii, aby sa čo najlepšie zachovali dôležité vzťahy.

- Príklad: https://pair-code.github.io/understanding-umap/









Zdroj:
https://towardsdatascience.com/why-you-should-not-rely-on-t-sne-umap-or-trimap-f8f5dc333e59/

Učenie bez učiteľa - zhlukovanie

Učenie bez učiteľa

- Hľadá vzory v dátach
- Definujeme vstupnú množinu a parametre modelu
- Ako výstup získavame napríklad:
  - Príslušnosti ku zhlukom (“prirodzené“ triedy)
  - Lepšie pochopenie dát/vzťahov
  - Iná reprezentácia dát
- Využitie učenia bez učiteľa:
  - Nedostatok označených dát na trénovanie
  - Data mining - nevieme koľko/aké dáta (triedy) máme
  - Pochopenie dát - napr. Exploratory Data Analysis
  - “Feature engineering”
- Oproti učeniu s učiteľom:
  - \+ Ľahšie získať dáta
  - \- Obvykle výpočtovo komplexnejšie
  - \- Ako vyhodnocujem úspešnosť?



- Príklady:
  - Zhlukovacie algoritmy
  - Anomálie
  - Autoenkódery

Učenie bez učiteľa



How many clusters?



Six Clusters



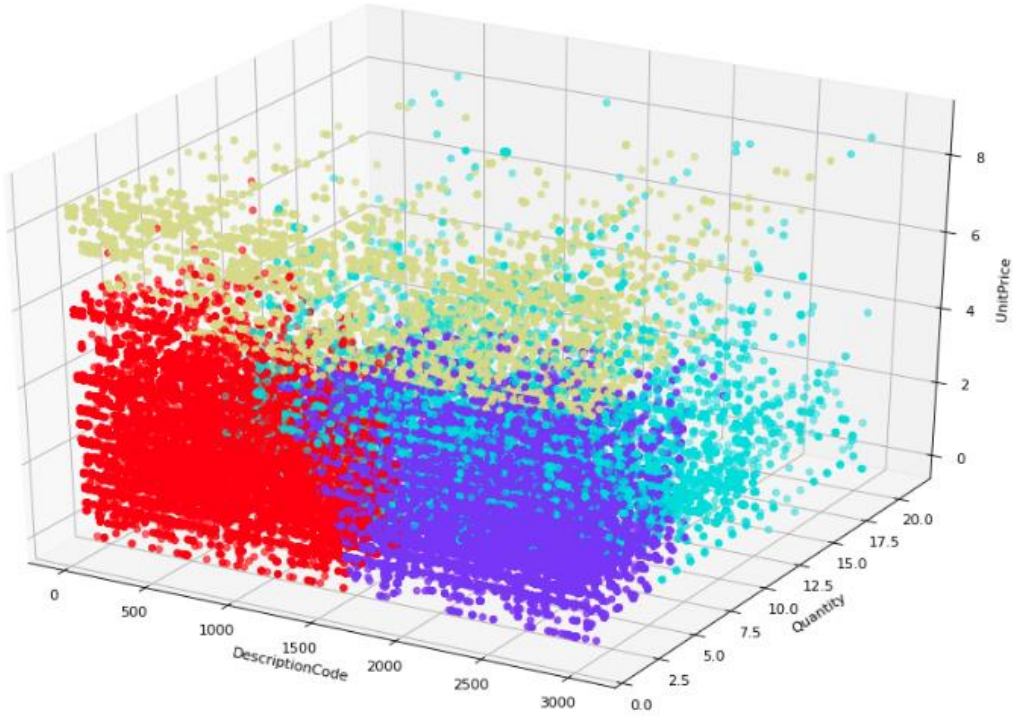
Two Clusters



Four Clusters

Zdroje obrázkov:
https://apandre.wordpress.com/visible-data/cluster-analysis/

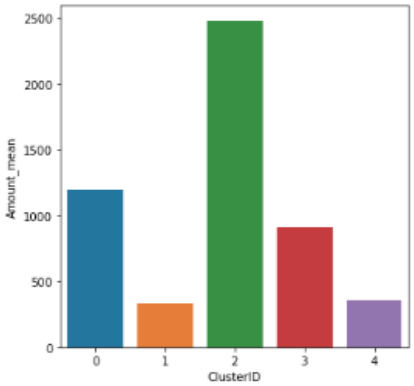
Učenie bez učiteľa - clustering

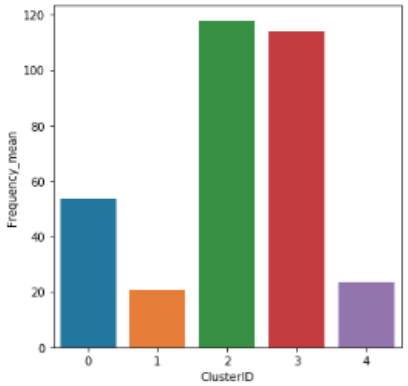


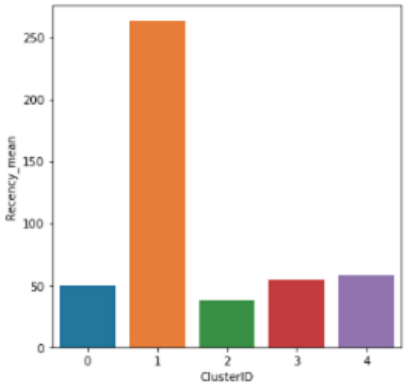
4 zhluky (triedy):

- Cluster 0: Less Quantity, Mid Unit Price, Description Code High
- Cluster 1: More Quantity, Low Unit Price, Description Code Mid
- Cluster 2: Less Quantity, High Unit Price, Description Code Mid
- Cluster 3: Less Quantity, Mid Unit Price, Description Code low

Učenie bez učiteľa - clustering







- Triedy (typy zákazníkov) neboli určené dopredu, analýza bola spravená po natrénovaní modelu
- Zhluky boli vytvorené pomocou všetkých kategórií zo vstupu
- Zhlukovanie vyberá (malo by) vyberať tie triedy tak, aby:
  - Vzorky v rámci jedného zhluku si navzájom boli čo najpodobnejšie (intratriedna vzdialenosť)
  - Zhluky medzi sebou (intertriedna vzdialenosť) sú si čo najmenej podobné

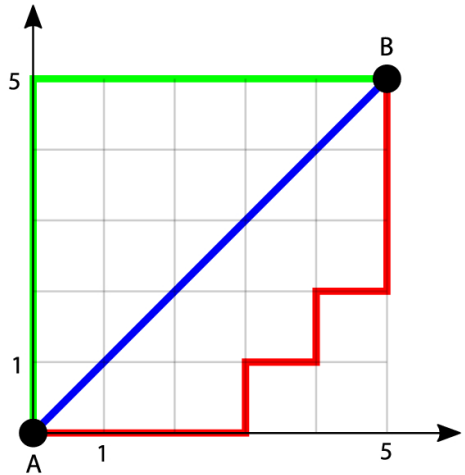
1. Ako určím podobnosť medzi vzorkami?
2. Aký je správny počet zhlukov?

Meranie vzdialeností

- Opäť potrebujeme číselné reprezentácie pre vstup
- Minkowski vzdialenosť:

$$d = \left(\sum_{i=1}^{n} |A_i - B_i|^p \right)^{1/p}$$

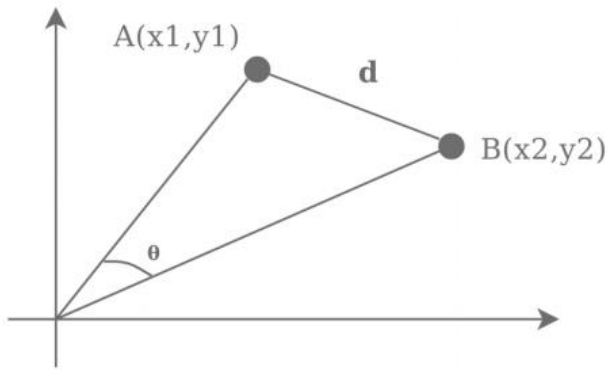
  - Manhattanská vzdialenosť $p = 1$
  - Euklidovská vzdialenosť $p = 2$



- Kosínusová vzdialenosť:

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2} \sqrt{\sum_{i=1}^{n} B_i^2}}$$

- Mahalanobis, Hamming ...

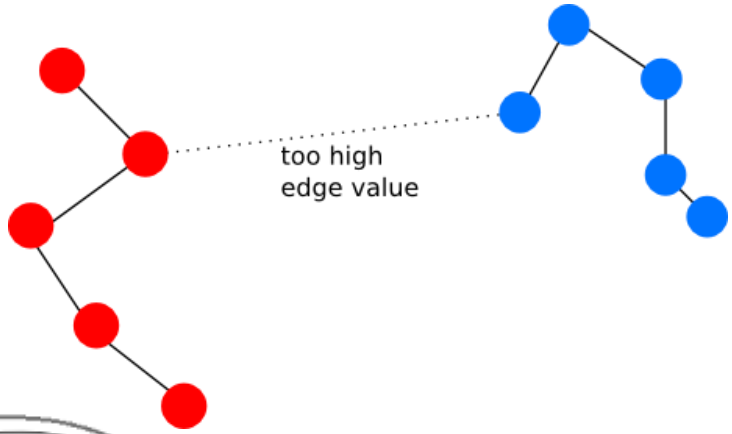


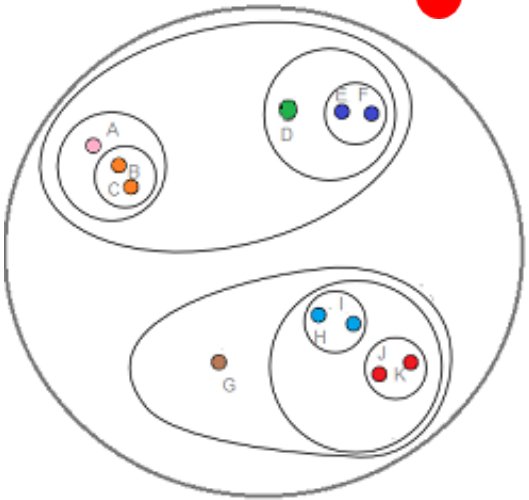
Zdroje obrázkov:
https://link.springer.com/article/10.1007/s10462-019-09712-9/figures/3
https://cmry.github.io/notes/euclidean-v-cosine

Zhlukovanie

Zdroje obrázkov:
https://eugenfunk.files.wordpress.com/2013/09/clustering_scheme1.png?w=640
https://www.statisticshowto.com/hierarchical-clustering/

- **Connectivity models**
  - Hierarchické modely
  - Nevhodná pre veľké datasety
  - AHC, Chinese Whispers
- Centroid models
  - Počet zhlukov určený predom
  - Citlivé na inicializáciu a outliers
  - K-means
- Distribution models
  - Založené na pravdepodobnosti
  - Náchylné na pretrénovanie
  - Gaussian Mixture Models
- Density models
  - Hľadajú “husto obsadené” podpriestory
  - DBSCAN

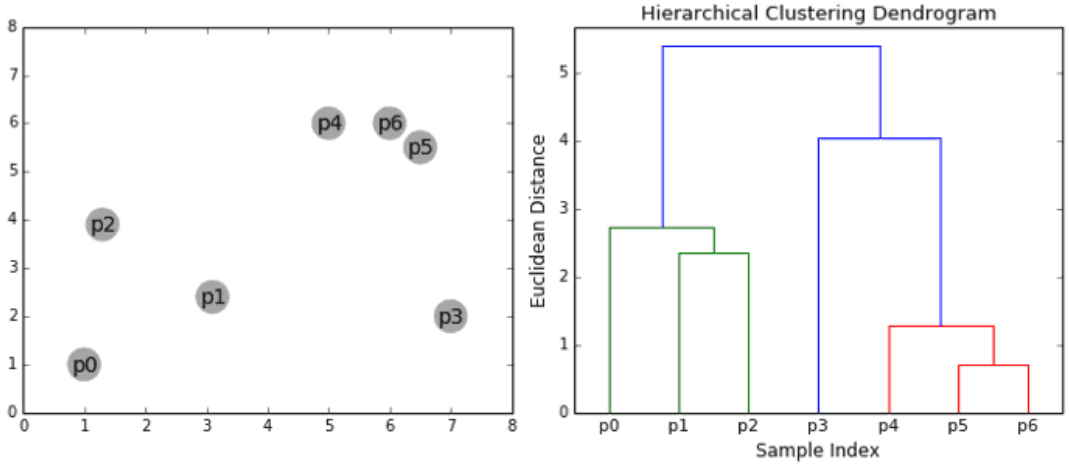






Agglomerative Hierarchical Clustering

1. Každý bod je vlastným zhlukom.
2. Skombinujeme 2 najbližšie zhluky do jedného. (Vyberáme akým spôsobom počítame vzdialenosti medzi zhlukmi).
3. Opakujeme bod 2, kým nie sú všetky body v jednom zhluku.

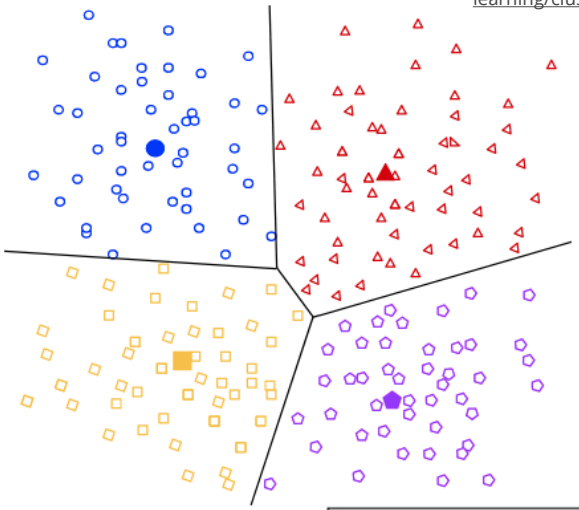


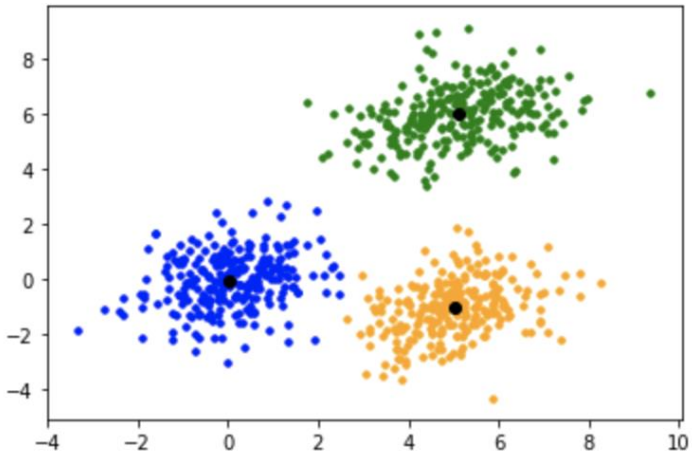
Zdroje obrázkov:
https://towardsdatascience.com/the-5-clustering-algorithms-data-scientists-need-to-know-a36d136ef68

Zhlukovanie

Zdroje obrázkov:
https://www.geeksforgeeks.org/ml-k-means-algorithm/
https://developers.google.com/machine-learning/clustering/clustering-algorithms

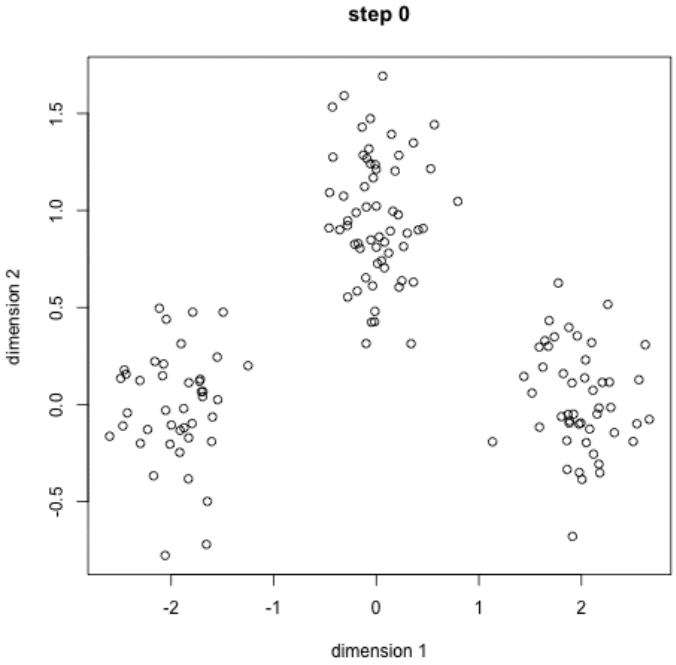
- Connectivity models
  - Hierarchické modely
  - Nevhodná pre veľké datasety
  - Chinese whispers
- **Centroid models**
  - Počet zhlukov určený predom
  - Citlivé na inicializáciu a outliers
  - K-means
- Distribution models
  - Založené na pravdepodobnosti
  - Náchylné na pretrénovanie
  - Gaussian Mixture Models
- Density models
  - Hľadajú “husto obsadené” podpriestory
  - DBSCAN





K-means clustering

1. Zvoľme počet clusterov, každému prislúcha jeden centroid zvolený náhodne
2. Každý bod priradíme ku tomu zhluku, ktorého centroid je mu najbližšie
3. Každému zhluku vypočítame nový centroid ako priemer bodov priradených zhluku
4. Opakujeme bod 2-3 do konvergencie alebo zastavujúcej podmienky



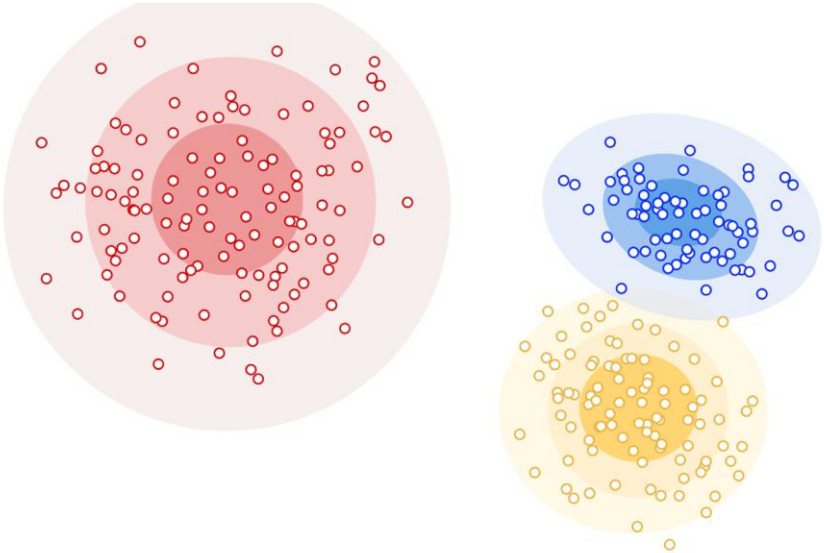
Príklad:
https://www.naftaliharris.com/blog/visualizing-k-means-clustering/

Zdroje obrázkov:
https://towardsdatascience.com/the-5-clustering-algorithms-data-scientists-need-to-know-a36d136ef68

Zhlukovanie

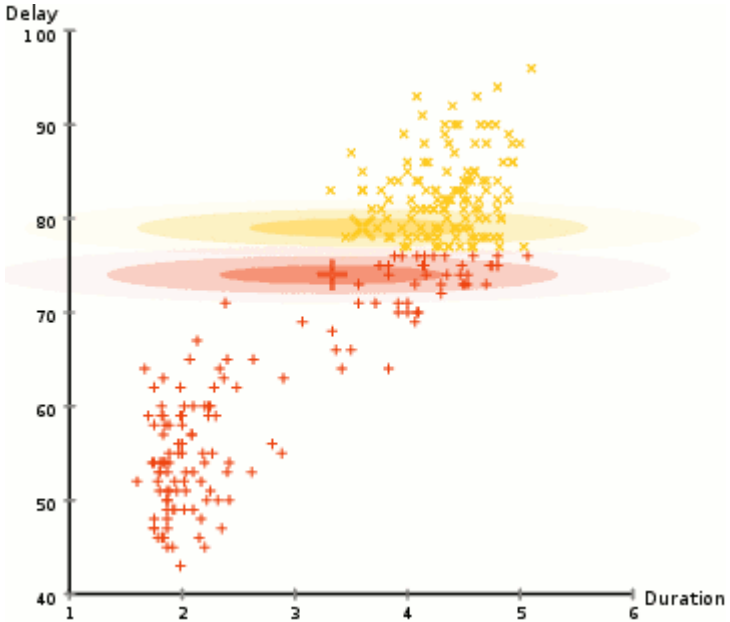
Zdroje obrázkov:
https://developers.google.com/machine-learning/clustering/clustering-algorithms

- Connectivity models
  - Hierarchické modely
  - Nevhodná pre veľké datasety
  - Chinese whispers
- Centroid models
  - Počet zhlukov určený predom
  - Citlivé na inicializáciu a outliers
  - K-means
- **Distribution models**
  - Založené na pravdepodobnost
  - Náchylné na pretrénovanie
  - Gaussian Mixture Models
- Density models
  - Hľadajú “husto obsadené” podpriestory
  - DBSCAN



Gaussian Mixture Models

1. Vyberieme počet zhlukov a náhodne inicializujeme parametre pre Gaussovo rozdelenie pravdepodobnosti
2. Vypočítame pravdepodobnosť, že bod patrí do zhluku
3. Upravíme parametre tak, aby sme maximalizovali pravdepodobnosti, že body patria k zhluku
4. Opakujeme bod 2-3 do konvergencie alebo zastavujúcej podmienky

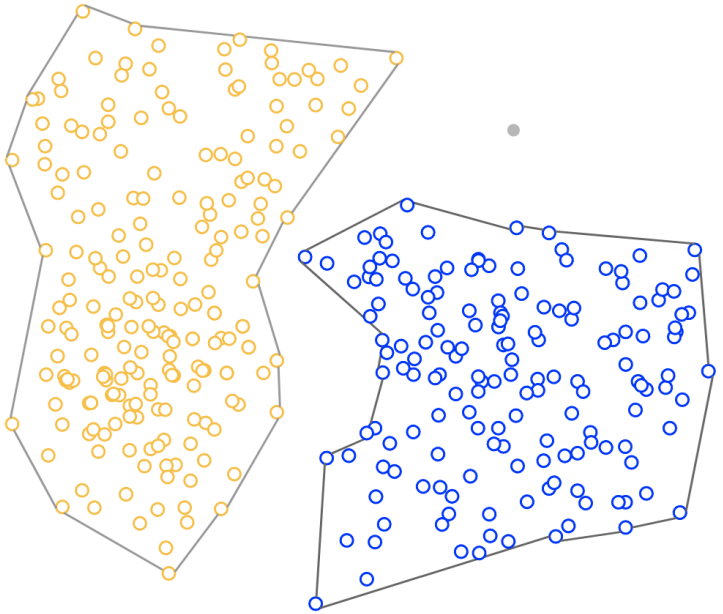


Zdroje obrázkov:
https://towardsdatascience.com/the-5-clustering-algorithms-data-scientists-need-to-know-a36d136ef68

Zhlukovanie

Zdroje obrázkov:
https://developers.google.com/machine-learning/clustering/clustering-algorithms

- Connectivity models
  - Hierarchické modely
  - Nevhodná pre veľké datasety
  - Chinese whispers
- Centroid models
  - Počet zhlukov určený predom
  - Citlivé na inicializáciu a outliers
  - K-means
- Distribution models
  - Založené na pravdepodobnosti
  - Náchylné na pretrénovanie
  - Gaussian Mixture Models
- **Density models**
  - Hľadajú “husto obsadené” podpriestory
  - DBSCAN



DBSCAN

1. Vyberme bod, ktorý ešte nebol navštívený.
2. Ak má v okolí (d<hyperparameter ε) dostatočný počet bodov (hyperparameter minPoints), stáva sa z neho počiatok clustra. Body z okolia pridáme do clustra. Označíme ho ako navštívený.
3. Pre každý nenavštívený bod v clustri, pridáme všetky body z jeho okolia do clustra a označíme ho ako navštívený.
4. Opakujeme bod 3, kým je čo pridať.
5. Opakujeme bod 1-4 do konvergencie alebo zastavujúcej podmienky.

Príklad: Visualizing DBSCAN Clustering

