



Tretie cvičenie z predmetu

Strojové učenie a neurónové siete

Trénovanie neurónových sietí, nastavovanie hyperparametrov a *babysitting* trénovacieho procesu

Agenda na dnes

- Strojové učenie všeobecne
- Umelé neurónové siete
- Vyhodnotenie neurónových sietí - klasifikácia
- Nastavenie hyperparametrov
- Podtrénovanie/pretrénovanie
- Zadanie 1 - otázky a odpovede
- Ukážky zdrojových kódov





Strojové učenie všeobecne

- Vyberieme rovnicu - model
 - **Neurónové siete**, SVM, náhodné lesy...
- Parametre pre rovnicu sa nájdu z dát (budeme ich volať váhy):
 - Začíname z náhodných hodnôt,
 - Určíme kritérium, podľa ktorého sa má model zlepšovať (kritériálna al. chybová funkcia),
 - Postupne sa váhy upravujú tak, aby klesala chyba na tréningových dátach (proces učenia),
 - Iteratívne po krokoch pomocou výpočtov gradientov.



Umelé neurónové siete - slovníček





- Neurón:
 - Váhy
 - Prah
 - Aktivačná funkcia
- Architektúra:
 - Vstupná vrstva
 - Výstupná vrstva
 - Skryté vrstvy
- Trénovanie:
 - Kriteriálna funkcia
 - Spätné šírenie chyby (nabudúce)
 - Solver
 - Parameter rýchlosti učenia
 - Zastavovacia podmienka

Zdroje obrázkov:

Bre, Facundo & Gimenez, Juan & Fachinotti, Víctor. (2017). Prediction of wind pressure coefficients on building surfaces using Artificial Neural Networks. Energy and Buildings. 158. 10.1016/j.enbuild.2017.11.045.


<http://cs231n.stanford.edu/>

Umelé neurónové siete - Neurón



- **x** - vstupy
 - pri kosatcoch
([sepal_width, sepal_height, petal_width])
- **f(·)** - aktivačná funkcia
 - Nechceme len lineárne rozdeľovacie hranice - pridáva nelinearitu
 - Napr. sigmoida:

$$\frac{1}{1 + e^{-\sum_i w_i x_i + b}}$$





- **w** - vektor váh
- **b** - prah
- **w** a **b** trénujeme




Umelé neurónové siete - Architektúra


- Veľkosti vrstiev (počty neurónov vo vrstvách):
 - Vstupná - podľa veľkosti vzorky
 - Výstupná - jeden (regresia, binárny problém) alebo počtom kategórii (multiclass)
 - Skryté - vyberáme my a sledujeme správanie siete počas tréovania; možno:
 - Čím hlbšie tým lepšie (min. pri CNN) - ale je ťažké dobre natrénovať
- S architektúrou veľmi úzko súvisí parameter rýchlosti učenia
- Aktivačná funkcia:
 - Sigmoid, logaritmická
 - ReLU



-Softmax



-TanH







Umelé neurónové siete - Kriteriálna funkcia

Chybová funkcia, loss function, error function, cost function, objective function

Trénovanie =[dopredná propagácia → **výpočet kriteriálnej funkcie** → spätná propagácia → (dopredná propagácia)] x počet iterácií

- Hodnotí ako dobre sieť ohodnocuje vstupy vzhľadom na skutočné výstupy, najčastejšie:

Least squared error	Logistic loss	Hinge loss	Cross-entropy
$\frac{1}{2}(y - z)^2$	$\log(1 + \exp(-yz))$	$\max(0, 1 - yz)$	$-\left[y \log(z) + (1 - y) \log(1 - z)\right]$
			
Linear regression	Logistic regression	SVM	Neural Network

y - skutočný výstup
z - predikovaný výstup




Umelé neurónové siete - Kriteriálna funkcia - príklady

Binary Cross Entropy

$$y * \log(f(x)) + (1 - y) * \log(1 - f(x))$$

- Binárna klasifikácia
- y je 0 alebo 1
- Normalizované pravdepodobnosti príslušnosti ku triede




Cross Entropy (log loss, softmax)

$$-\log \frac{e^{f_{y_i}}}{\sum_j e^{f_j}}$$

- Rozšírenie BCE pre viacero tried
- Softmax - normalizácia do sumy 1

$$\frac{e^{z_j}}{\sum_k e^{z_k}}$$

$$L = -[0 \log(0, 016) + 0 \log(0, 631) + 1 \log(0, 353)]$$



Zdroje obrázkov:

<https://towardsdatascience.com/understanding-binary-cross-entropy-log-loss-a-visual-explanation-a3ac6025181a>

<http://cs231n.stanford.edu/>


Umelé neurónové siete - Solvery

Optimalizátory

Gradient descent (GD)

$$\theta_{i+1} = \theta_i + \alpha \nabla_{\theta} L(\theta_i)$$


- α - pamater rýchlosti učenia
- θ - váhy
- i - čas (iterácia)



Zdroje obrázkov:
<https://shashank-ojha.github.io/ParallelGradientDescent/>
[https://golden.com/wiki/Stochastic_gradient_descent_\(SGD\)](https://golden.com/wiki/Stochastic_gradient_descent_(SGD))

Stochastic gradient descent (SGD)

- Posielam dáta do trénovania po častiach - dávkach (batchoch)
- Jeden výpočet úpravy gradientu - 1 iterácia
- Úprava pre celú trénovaciu množinu - 1 epocha
- počet iterácií v jednej epoche?




Umelé neurónové siete - Solvery

GD with momentum

$$v_{i+1} = \gamma v_i + \alpha \nabla_{\theta} L(\theta_i)$$


$$\theta_{i+1} = \theta_i - v_{i+1}$$

- Gamma γ je hyperparameter (obvykle 0.9)
- Úprava váh - lineárna kombinácia aktuálneho stochastického gradientu a zmeny v predchádzajúcom kroku




Adaptive moment estimation (ADAM)

- Takisto momentová metóda
- využíva pohyblivé priemery z viacerých minulých iterácií
- Tri hyperparametre: $\beta_1, \beta_2, \epsilon$
- Postupne znižuje α



Umelé neurónové siete - Solvery




Zdroje obrázkov:

<https://towardsdatascience.com/complete-guide-to-adam-optimization-1e5f29532c3d>

<https://medium.com/@LayanSA/complete-guide-to-adam-optimization-1e5f29532c3d>


Umelé neurónové siete - Parameter rýchlosti učenia

- angl. learning rate
- Určuje veľkosť kroku pre optimalizačný algoritmus v každej iterácii tréningového procesu pri hľadaní minima kritériálnej funkcie
- $<0,1>$
- Môže byť:
 - Konštantný
 - Meniaci sa podľa kroku/exponenciálny
 - Adaptívny (Adam, Adagrad, RMSprop,...)



Umelé neurónové siete - Zastavovacia podmienka

- Určuje kedy bude tréning ukončený:
 - Počet epoch
 - Čas tréningu
 - Metrika (chyba, úspešnosť, ...) - Early Stopping:





Vyhodnotenie neurónových sietí - klasifikácia

- Úspešnosť na trénovacej a testovacej množine
- Konfúzna matica pre trénováciu a testováciu množinu
- Priebeh trénovania (chyba a úspešnosť) pre trénováciu a validačnú množinu

Konfúzna matica (test) ACC - 1.0





Priebeh trénovania




Hyperparametre v sieťach (nastavujete v zadanií)

- Neurón:
 - Aktivačná funkcia
 - skryté vrstvy - tanh, sigmoid, ReLU
 - výstupná - sigmoid, softmax, lineárna
- Neurónová sieť:
 - Skryté vrstvy - počet a neuróny vo vrstve
- Trénovanie:
 - Kritečná funkcia - binary-crossentropy, categorical crossentropy, OLS, ...
 - Solver - SGD, ADAM, AdaGrad, ...
 - Parametre solvera - min. parameter rýchlosti učenia 0-1
 - Zastavovacia podmienka
- Niektoré podľa problému:
 - **regresné problémy** - vo výstupnej vrstve lineárne aktívácie, kriter. f-cia napr OLS
 - **viactriedna klasifikácia** - vo výstupnej vrstve softmax, kriter. f-cia categorical crossentropy
 - **binárna klasifikácia** - dva prístupy:
 - 1 neurón na výstupe so sigmoidálnou aktivačnou funkciou + binary crossentropy
 - 2 neuróny na výstupe so softmax + categorical crossentropy



Zdroje obrázkov:
Bre, Facundo & Gimenez, Juan & Fachinotti, Víctor. (2017). Prediction of wind pressure coefficients on building surfaces using Artificial Neural Networks. Energy and Buildings. 158. 10.1016/j.enbuild.2017.11.045.
<http://cs231n.stanford.edu/>

Pretrénovanie a podtrénovanie - ilustrácia



Pretrénovanie a podtrénovanie - opravy

- Podtrénovanie:
 - Zastavovacia podmienka
 - Iný model
 - Viac príznakov
 - Väčšia sieť
- Pretrénovanie:
 - Zastavovacia podmienka
 - Viac tréningových dát
 - Menej príznakov
 - Menšia sieť
 - Regularizácia

