Siedme cvičenie z predmetu

Strojové učenie a neurónové siete

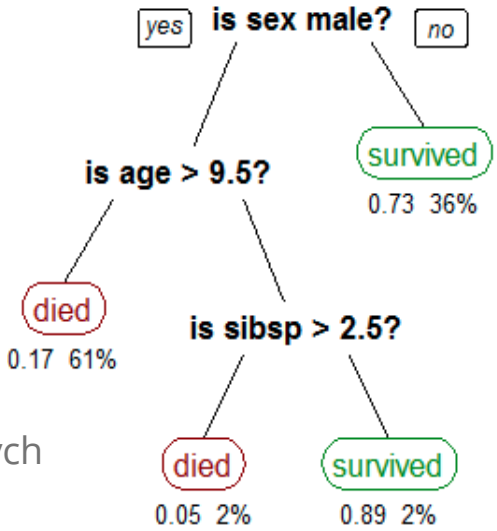
Súborové učenie a SVM

29. október 2026

I-SUNS cvičenie 7

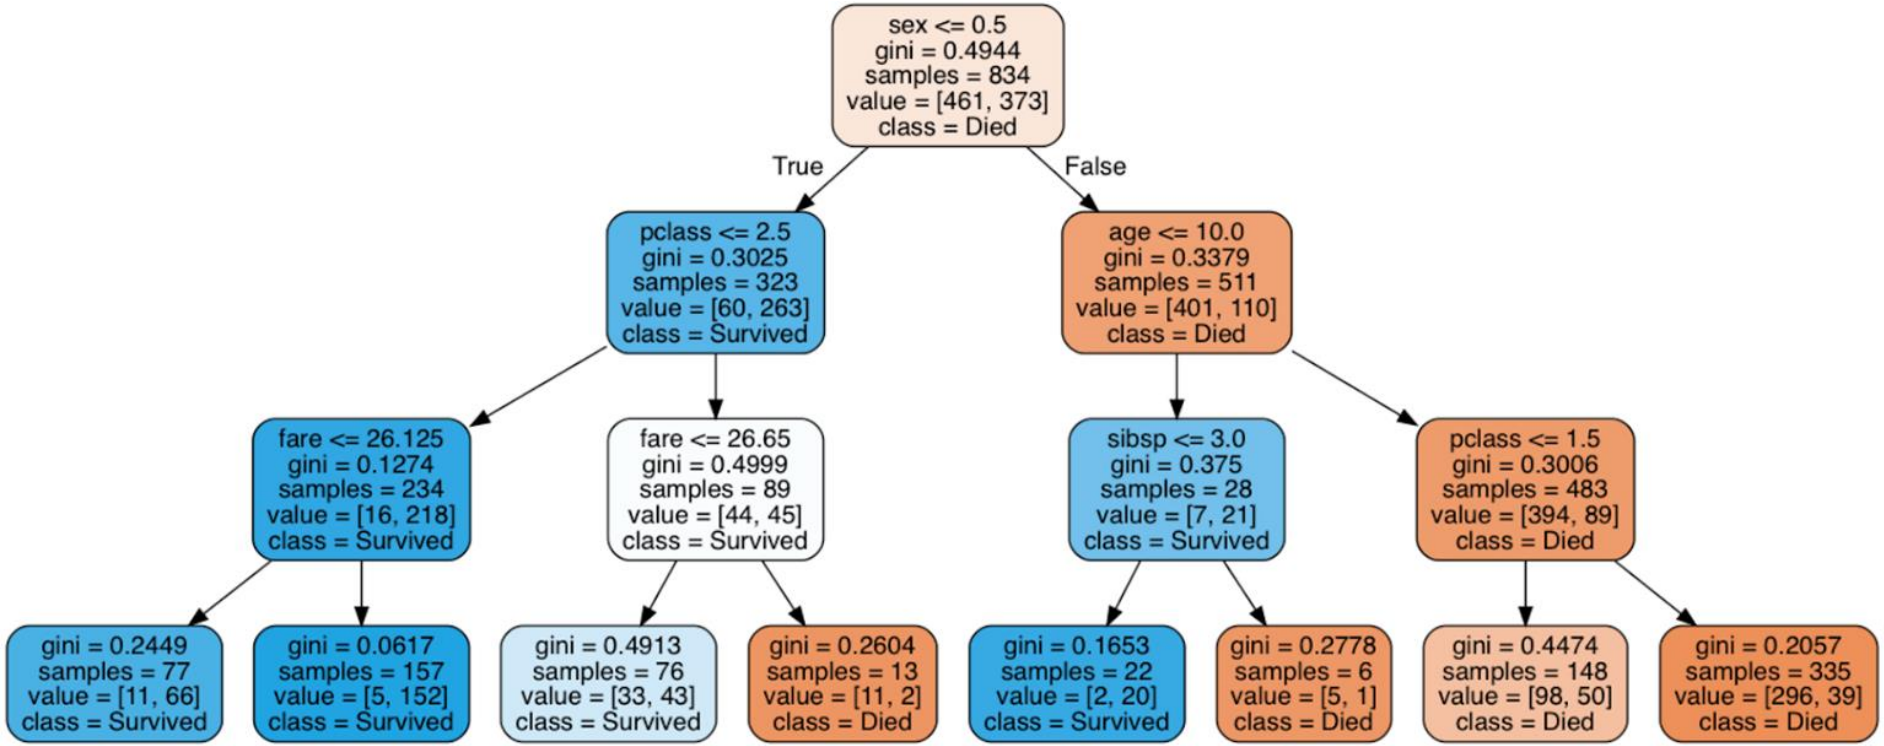
Rozhodovacie stromy

- Učenie s učiteľom
- Regresia aj klasifikácia
- Výhody:
  - Potrebuje málo predspracovania vstupov (nemusíme ani normalizovať)
  - Ľahko interpretovateľný - vyplývajú z neho if-else pravidlá
  - Zvláda multi-output problémy
    - každý list obsahuje informáciu o viacerých sledovaných premenných
- Nevýhody:
  - Ťažšie generalizuje (nevidené dáta; pretrénovanie)
  - Nestabilný (citlivé na vstupné dáta, malá zmena môže úplne zmeniť štruktúru)
  - Ťažko sa hľadá optimum (heuristický algoritmus - v každom kroku si vyberieme najlepšiu možnosť, ale neberieme do úvahy následky)



Zdroje obrázkov:
https://en.wikipedia.org/wiki/Decision_tree_learning

Rozhodovacie stromy – *príklad Titanic*



Rozhodovacie stromy - *pruning*

- Pre-pruning:
  - Zastavovacia podmienka:
    - max. hĺbka stromu
    - min. počet vzoriek v liste
    - min. IG

- Post-pruning
  - Najskôr sa vytvorí celý strom - cieľom je zachytiť čo najviac detailov
  - Odstránenie nadbytočných uzlov - vyhodnocovanie chyby na validačných dátach
    - Minimum error - odstránením pretrénovania znížime chybu na nevidených dátach
    - Smallest tree - najmenší strom s dostatočnou presnosťou





Súborové učenie

Súborové učenie

- Rozhodovacie stromy - obvykle slabý klasifikátor
- Súborové učenie - spojením viacerých klasifikátorov získame lepší model
- Slabé klasifikátory sa môžu líšiť v:
  - Dátach
  - Hypotézach
  - Modeloch
  - Inicializácii
- Tri typy:
  - Bagging
  - Boosting
  - Stacking



Bagging - Bootstrap AGGregatING

- Kombinuje viacero slabých modelov do jedného silného - často sú homogénne (rovnaký algoritmus ML)
- Každý model sa trénuje samostatne a spájajú sa:
  - Priemerovaním (regresia)
  - Hlasovaním (klasifikácia):
    - Najčastejšia trieda (hard-voting)
    - Priemer z pravdepodobností (soft-voting)
- Znižuje varianciu
  - Priemerovanie modelov “vyhladzuje” pretrénovanie niektorých samostatných modelov - menej senzitívne na zmeny v dátach
- Reprezentatívnosť a nezávislosť
  - Každý model vidí reprezentatívnu vzorku
  - Modely sú nezávislé -> lepšia generalizácia



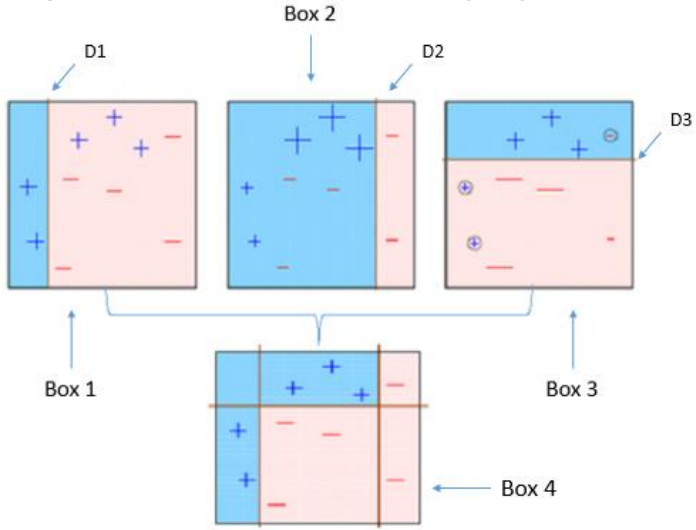
Bagging - napr. Random forest

- Zabezpečím nezávislosť:
  - Náhodne vyberám množinu pre každý strom (a môžu sa opakovať)
  - Náhodne sa pre stromy vyberá podmnožina vstupných príznakov
- Sklearn:
  - https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html
  - https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html
- Hyperparametre:
  - Počet stromov
  - Kriteriálna funkcia (gini/entrópia...)
  - Zastavovacia podmienka



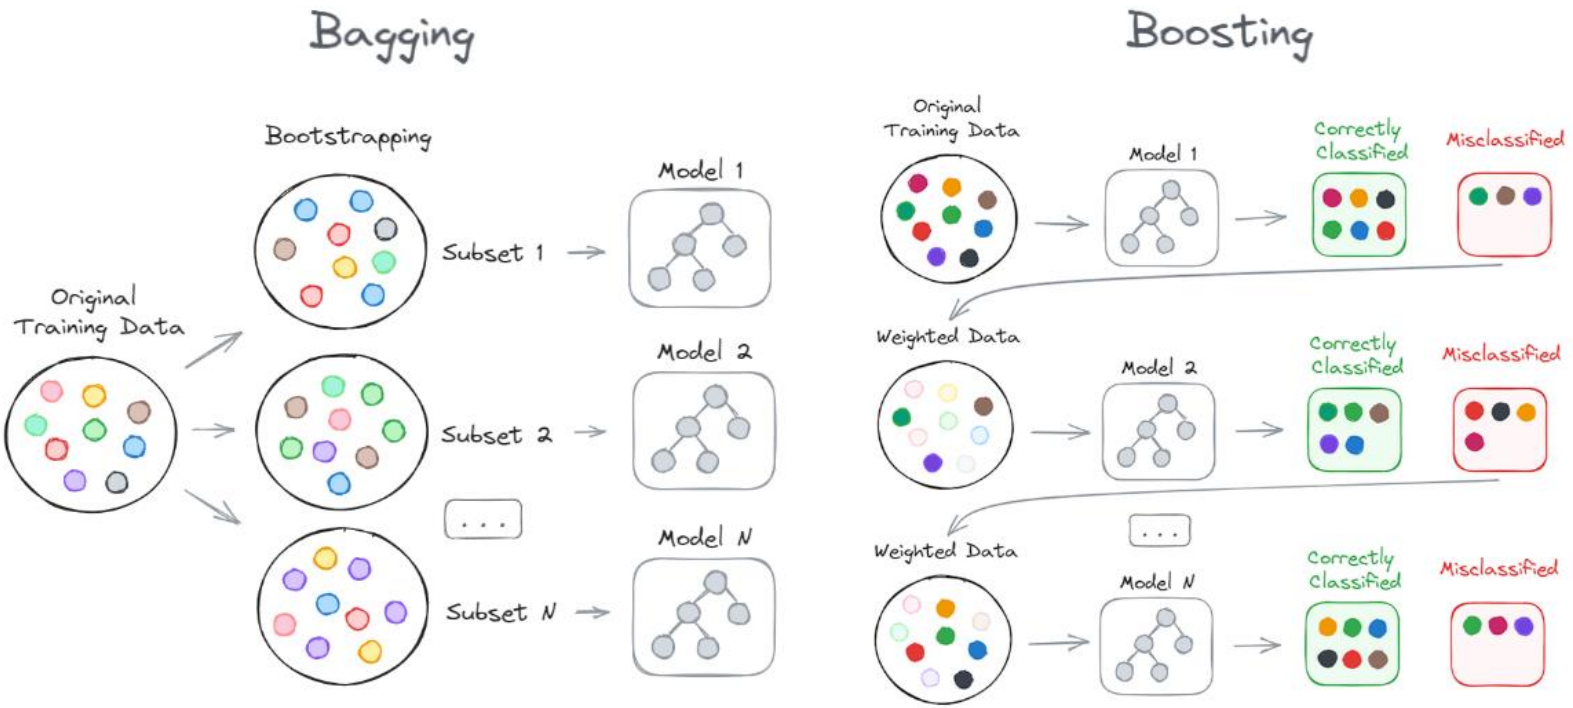
Boosting

- Kombinuje viacero slabých modelov do jedného silného
- Modely sa trénujú jeden za druhým - snažia sa opraviť vzniknuté chyby
- Spájajú sa váhovaním alebo priemerovaním
  - Modely s nižšou chybovosťou maju dôležitejší hlas
- Znižuje bias (aj varianciu)
  - Opravovaním chýb predošlých modelov sa zabezpečí komplexné zachytenie vzorov v dátach
  - Kombinuje viacero modelov



Zdroje obrázkov:
Schapire, R. E. and Freund, Y. (2012).Boosting: Foundations and Algorithms.MIT Press.

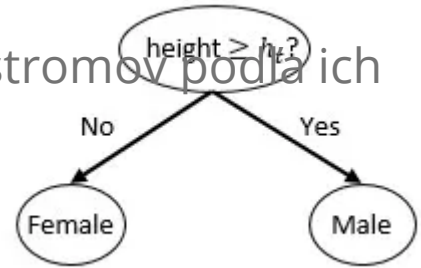
Bagging vs. Boosting



Zdroje obrázkov:
https://miro.medium.com/v2/resize:fit:1153/1*XzaoQxMf4uLD5DIHz8JwbA.png

Boosting - napr. AdaBoost

- Využíva rozhodovacie stromy hĺbky 1 ako slabé klasifikátory
- Prikladá váhy pre pne aj vzorky:
  1. Inicializujú sa váhy pre každú vzorku (rovná sa 1/počet vzoriek)
  2. Vytvorí sa rozhodovací stromy hĺbky 1
  3. Vypočíta sa chyba a váha daného stromu
  4. Prepočítajú sa váhy pre vzorky - ak boli klasifikované zle, ich váha sa zväčší
  5. Späť na krok 1 po zastavovaciu podmienku
  6. Konečné rozhodnutie - váhovaný priemer zo stromov podľa ich presnosti

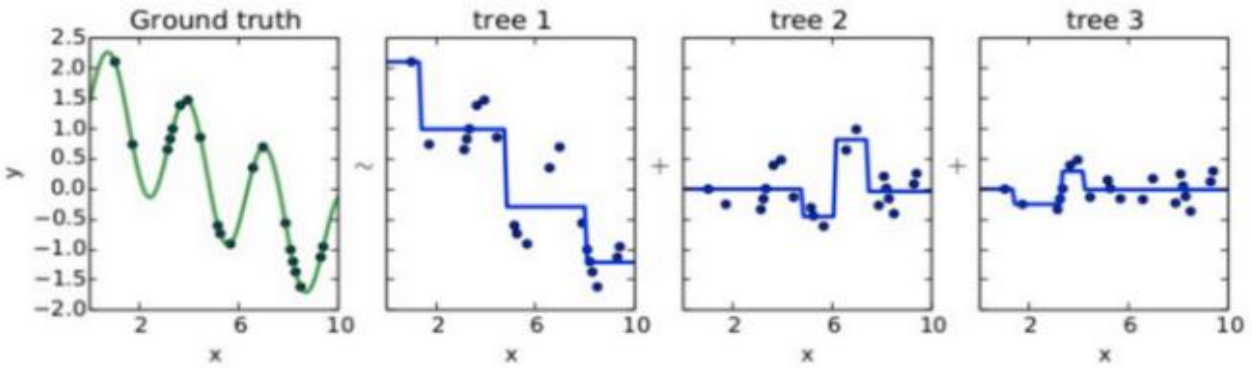


Zdroje obrázkov:
https://sefiks.com/2018/11/02/a-step-by-step-adaboost-example/

Boosting - napr. Gradient Boosting (XGBoost a pod.)

- Podobne ako AdaBoost, ale snaží sa opraviť reziduály nie zle klasifikované vzorky
- Nové stromy sú pridávané aditívne - matematicky
- Výsledná predikcia je súčet všetkých parciálnych modelov

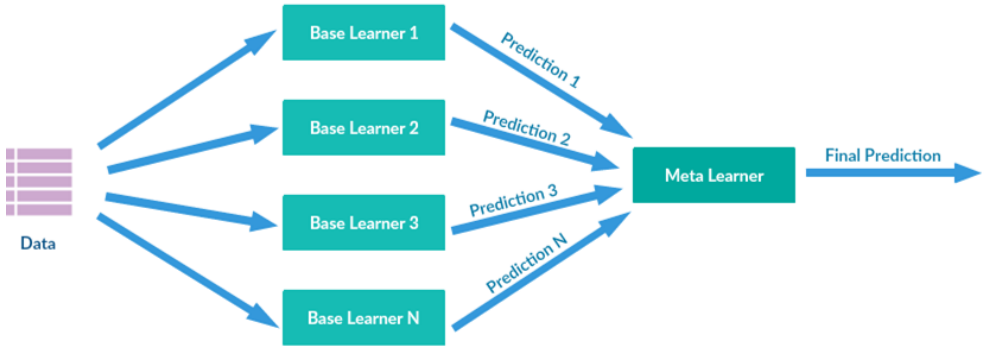
(optima kciu straty)



Zdroje obrázkov:
https://www.quora.com/How-would-you-explain-gradient-boosting-machine-learning-technique-in-no-more-than-300-words-to-non-science-major-college-students

Stacking

- Stacked generalization
- Spája silné klasifikátory
- Typy modelov:
  - Level 0 - silné klasifikátory/regresory pre problém - akýkoľvek model (strom, SVM, neurónová sieť, ...)
  - Level 1 - model naučený spájať klasifikátory (meta model)



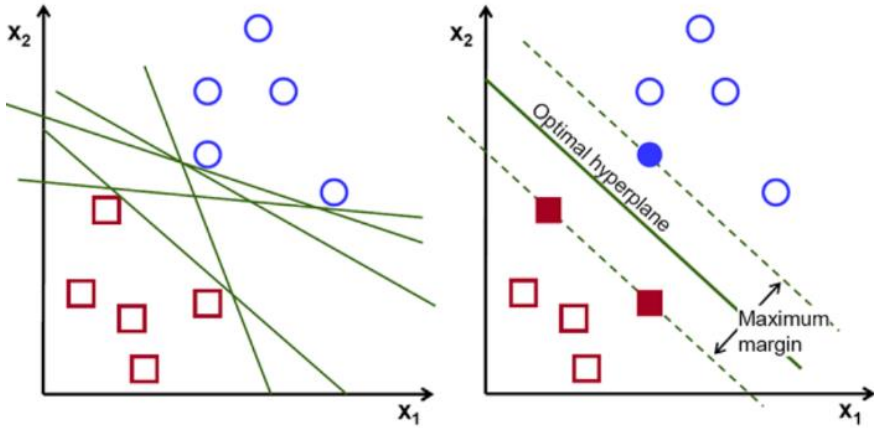
Zdroje obrázkov:
https://mc.ai/icu-survival-prediction-using-ensemble-learning-stacking/



Support Vector Machines

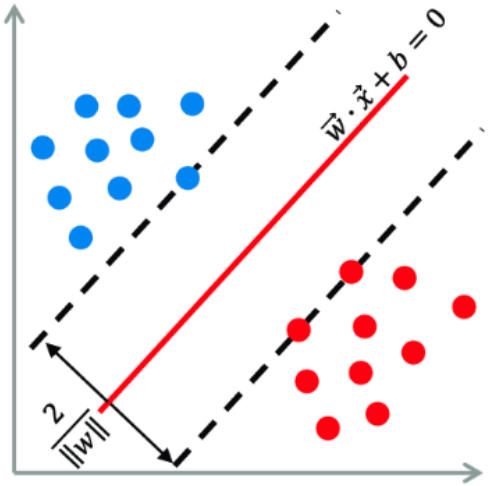
Metóda podporných vektorov - intuícia

- Učenie s učiteľom
- Hľadá hyperroviny oddeľujúce triedy (klasifikácia) / približnú funkciu (regresia) - podobné neurónkam
- Hľadá váhy *w* pre rovnice, ktorých kombinácia so vstupmi predikuje výstup - podobné neurónkam
- Predstavuje koncept podporných vektorov, ktoré pomáhajú hľadať dobré hyperroviny - optimalizujem pre “ťažké” vstupy, nie pre všetky
- Vyberáme hyperparametre:
  - Druh kernelu
  - C
  - Gamma
  - Stupeň (pri polynomiálnom kerneli)



Zdroje obrázkov:
https://towardsdatascience.com/svm-feature-selection-and-kernels-840781cc1a6c

Trénovanie a kriteriálna funkcia



- SVM hľadá najlepšiu čiaru (hyperrovinu), ktorá oddelí triedy
- Maximalizuje vzdialenosť (margin) od najbližších bodov
- Penalizuje body, ktoré sú príliš blízko hranici alebo na nesprávnej strane
- Hinge loss: $L(\boldsymbol{w}, b) = \sum_{i}^{n} max(0, 1 - y_i(\boldsymbol{w}^T \boldsymbol{x_i} + b)) + \lambda \|w\|^2$;

  $y = \pm 1$

- správne klasifikovaný bod mimo marginu → strata = 0
- bod v margine alebo zle klasifikovaný → strata rastie

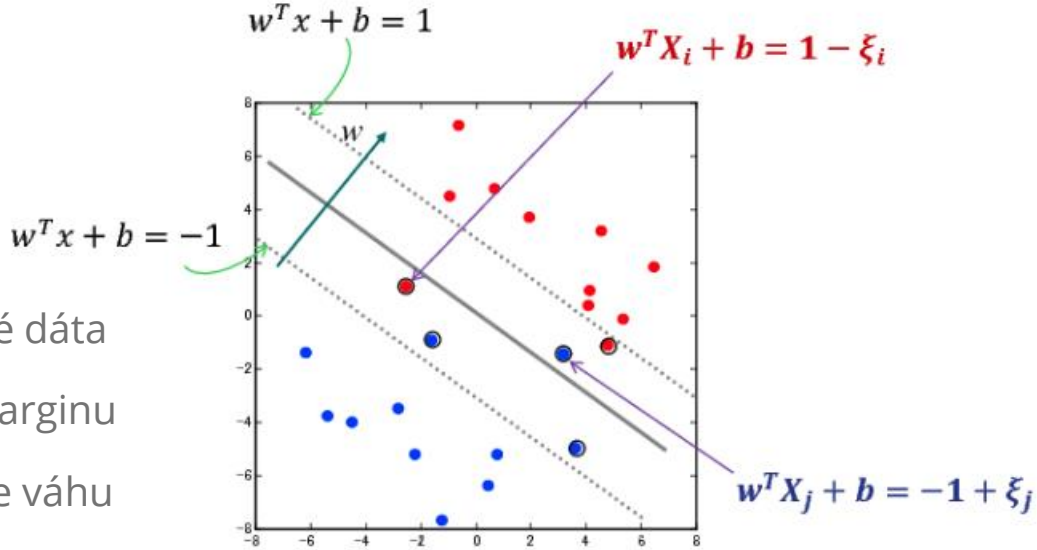
Hard a soft margin

Hard margin:

- Lineárne separovateľné dáta
- Oddelenie hyperplochou

Soft margin:

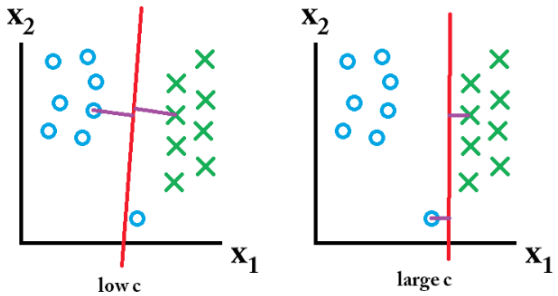
- Nedokonalo separovateľné dáta
- ξ_i - tolerancia porušenia marginu
- C - parameter, ktorý určuje váhu penalizácie chýb

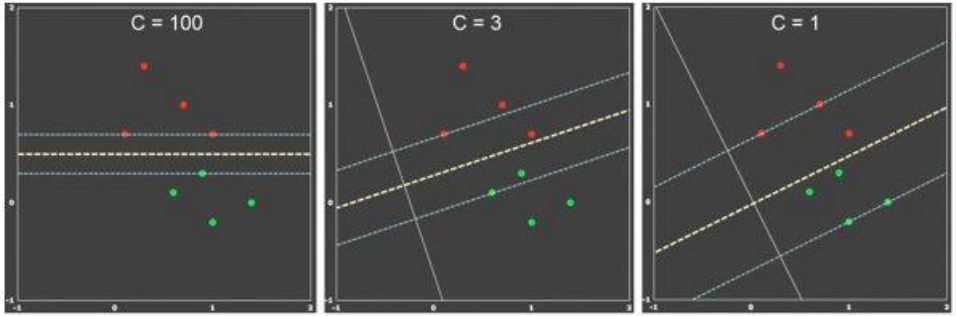


Zdroje obrázkov:
http://yosinski.com/mlss12/MLSS-2012-Fukumizu-Kernel-Methods-for-Statistical-Learning/

Hyperparametre - C

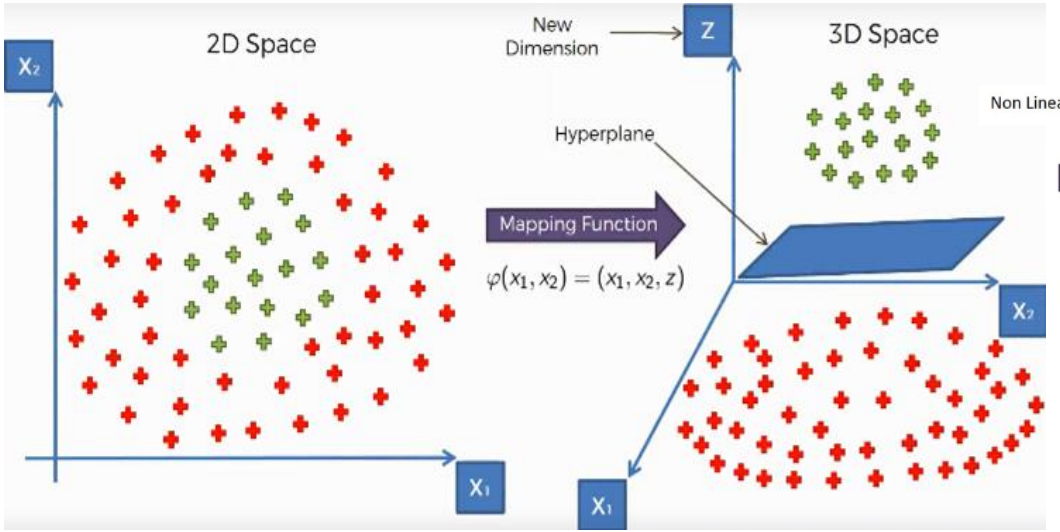
- Určuje počet správne klasifikovaných vzoriek vs maximalizovanie rozdeľovacej hranice
- Intuitívne - “Ako veľmi nám záleží na správnej klasifikácii všetkých vzoriek?”
- Vysoká hodnota C = malá hranica, menej chýb
- Nízka hodnota C = veľká hranica, viac chýb

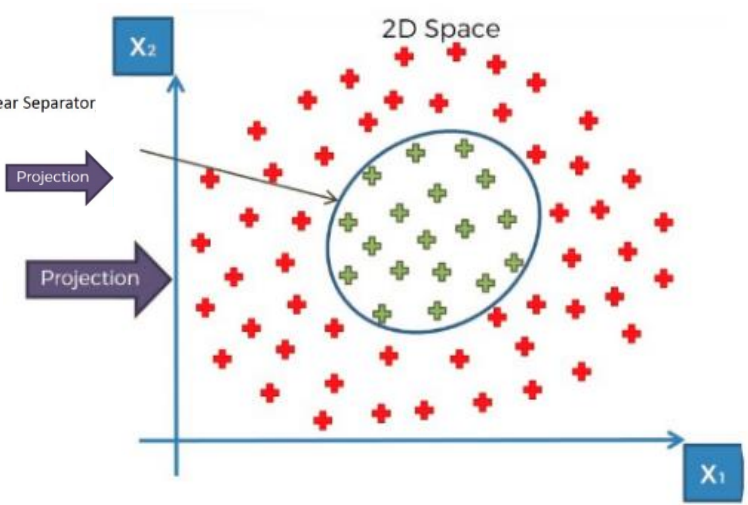




Zdroje obrázkov:
https://stats.stackexchange.com/questions/31066/what-is-the-influence-of-c-in-svms-with-linear-kernel
https://medium.com/@pushkarmandot/what-is-the-significance-of-c-value-in-support-vector-machine-28224e852c5a

Kernelový trik

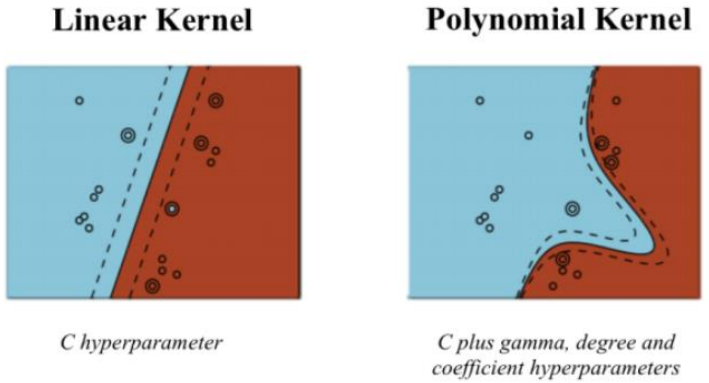




Zdroje obrázkov:
https://www.aionlinecourse.com/tutorial/machine-learning/kernel-svm

Hyperparametre - druh kernelu

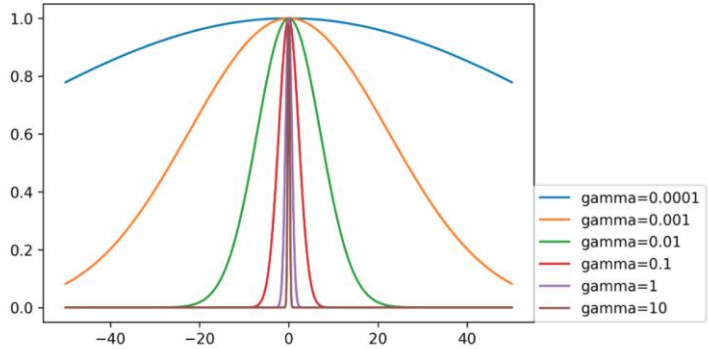
- Lineárny kernel
- Polynomiálny kernel
- RBF kernel



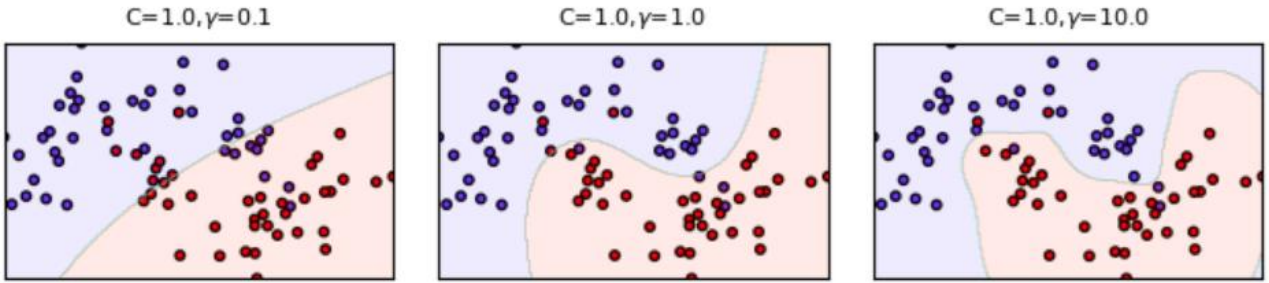
Zdroje obrázkov:
https://scikit-learn.org/stable/auto_examples/svm/plot_svm_kernels.html

Hyperparametre - γ

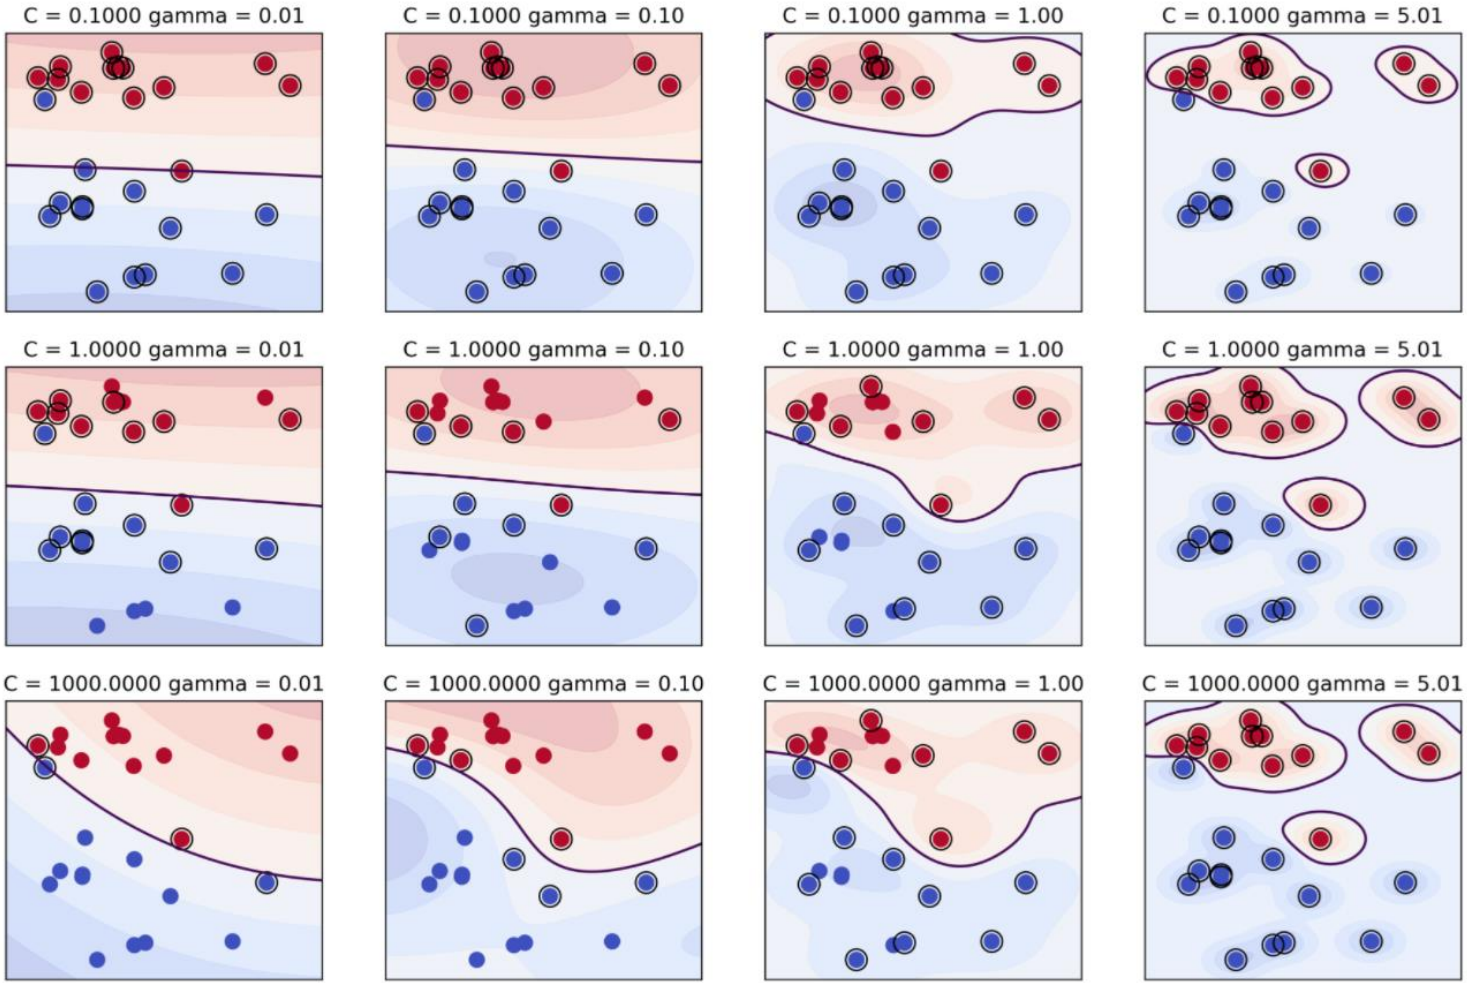
- Súvisí so šírku RBF funkcií
- Určuje, aký “ďaleký dosah” má jedna vzorka
- Čím nižšia hodnota γ, tým väčší dosah majú vzorky
- Ovplyvňuje mieru zakrivenia



$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



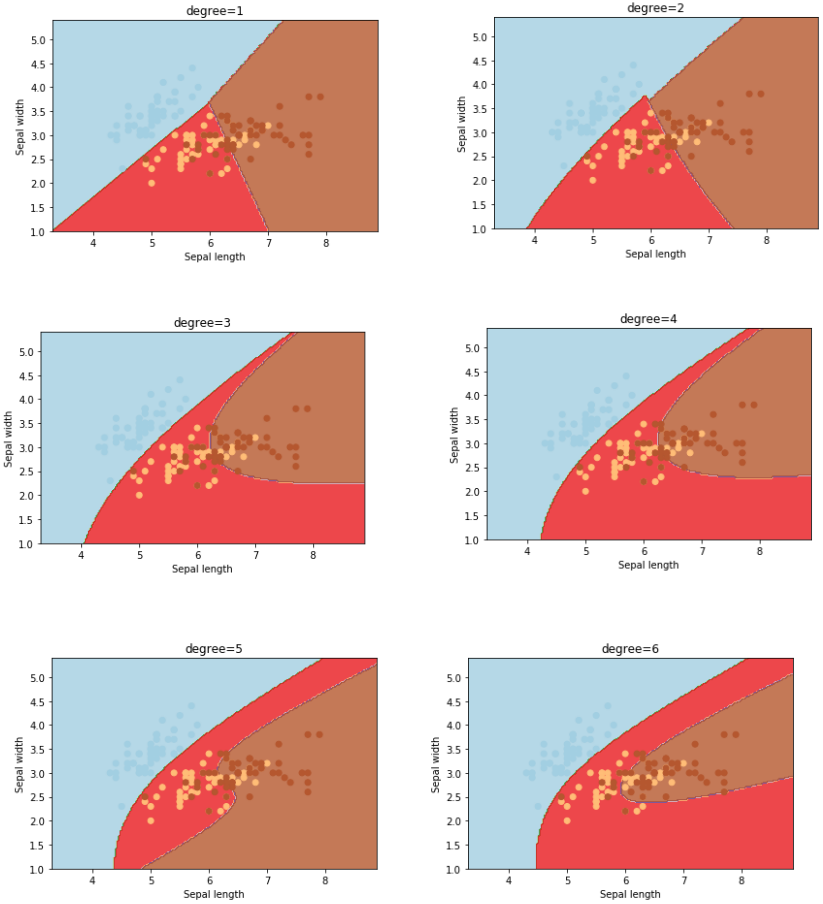
Zdroje obrázkov:
https://phyblas.hinaboshi.com/20180712
https://amueller.github.io/COMS4995-s18/slides/aml-09-021418-support-vector-machines/#17



Zdroje obrázkov:
https://amueller.github.io/COMS4995-s18/slides/aml-09-021418-support-vector-machines/#1

Hyperparameter - stupeň

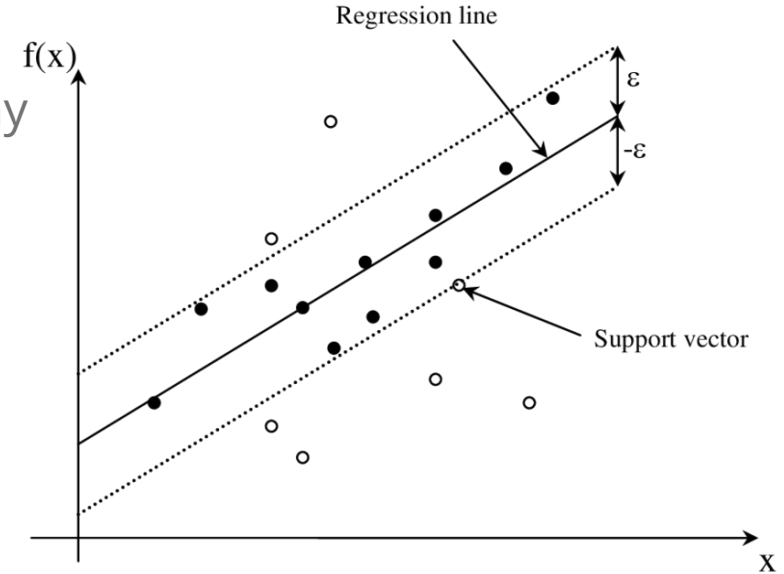
- Pri polynomiálnom kerneli
- Vyšší stupeň - dlhší čas trénovania, väčšia komplexnosť



Zdroje obrázkov:
https://medium.com/all-things-ai/in-depth-parameter-tuning-for-svc-758215394769

Poznámky

- Čím komplexnejší model, tým dlhší čas trénovania a tým väčšia možnosť pretrénovania
- SVM sa dá lepšie trénovať na malej množine ako NN (pretrénovanie) -
- SVM - citlivý na outliers a nereprezentatívnu množinu
- Výpočtová náročnosť
- Takisto vie riešiť aj regresné problémy



Zdroje obrázkov:
https://www.researchgate.net/publication/316351306_Advanced_Methods_for_the_Processing_and_Analysis_of_Multidimensional_Signals_Application_to_Wind_Speed/figures?lo=1&utm_source=google&utm_medium=organic