

SUNS (Strojové učenie a neurónové siete)

pre odbor Aplikovaná informatika,
1. semester Ing. štúdia

Prednášateľ:
prof. Dr. Ing. Miloš Oravec, ÚIM (C7 INOLab)

Vedúci cvičení:
Ing. Samuel Gibala, ÚIM (C7 INOLab)

Cieľ predmetu

Cieľom predmetu je oboznámiť študentov s teóriou a aplikáciami strojového učenia.

Predmet poskytuje systematický pohľad na najznámejšie nástroje strojového učenia s dôrazom na **neurónové siete, boosting, jadrové (kernelové) metódy, stroje s podpornými vektormi, zhľukovanie, hlboké učenie**.

Po zvládnutí teoretických základov je študent schopný využiť tieto moderné nástroje v najrôznejších oblastiach informačných a komunikačných technológií.

V predmete sa uvádzajú aj aplikácie strojového učenia v týchto oblastiach (rozpoznávanie vzorov, biometria, komunikačné siete, spracovanie signálov a pod.).

Obsah predmetu

- Pojmy a princípy (umelá inteligencia, strojové učenie, výpočtová inteligencia, inteligentné systémy, objavovanie znalostí, neurónová sieť)
- Učenie s učiteľom, učenie bez učiteľa, teória učenia, reinforcement učenie
- Neurocomputing, rozdiely voči klasickým prístupom, možnosti aplikácií, analógia a rozdiely biologických a umelých neurónových sietí (NS)
- Modely neurónu, aktivačná funkcia, architektúry NS, proces učenia, NS a mapovanie
- Viacvrstvový perceptrón, algoritmus spätného šírenia, generalizácia, aproximácia funkcií
- RBF (radial-basis function) siete, regularizačná teória
- Samoorganizujúce sa systémy založené na súťažnom učení a na Hebbovom učení
- Rekurentné siete
- Súbory - boosting, silné a slabé učenie, AdaBoost
- Rozmedzia, jadrové (kernel) metódy, stroje s podpornými vektormi
- Zhlukovanie
- Deep learning (hlboké učenie, hlboké NS)
- Aplikácie strojového učenia

Literatúra 1/2

■ **AI (artificial intelligence, umelá inteligencia):**

- Russel, S., Norvig, P.: [Artificial Intelligence – A Modern Approach](#), 4th edition, global edition, Pearson Education, 2022
 - „The authoritative, most-used AI textbook, adopted by over 1500 schools“

Dá sa stiahnuť zo STUBA
(alebo z VPN STUBA)

■ **hlboké učenie (deep learning)**

- Aggarwal, C., C.: [Neural Networks and Deep Learning: A Textbook](#) (Second Edition), Springer, 2018, <https://www.charuaggarwal.net/neural.htm>
- Goodfellow, I., Bengio, Y., Courville, A.: Deep Learning, MIT Press book, 2016 online <http://www.deeplearningbook.org/>
- Li Deng, Dong Yu: Deep Learning: Methods and Applications, Now Publishers, 2014
- UFLDL (Unsupervised Feature Learning and Deep Learning) Tutorial, <http://ufldl.stanford.edu/tutorial/>

Literatúra 2/2

■ **„klasika“, (konvenčné siete, plytké siete):**

- ❑ Marsland,S.: Machine Learning: An Algorithmic Perspective, CRC Press, New Jersey, USA, 2009
- ❑ Mitchell,T: Machine Learning, McGraw Hill, 1997
- ❑ Kecman,V.: Learning and Soft Computing - Support Vector Machines, Neural Networks and Fuzzy Logic Models, The MIT Press, Cambridge, MA, 2001
- ❑ Haykin,S.: Neural Networks: A Comprehensive Foundation, Macmillan College Publishing Company, New York, 1994
- ❑ Bishop,C.M.: Neural Networks for Pattern Recognition, Clarendon Press, Oxford, 1996

Podmienky absolvovania

- Získanie zápočtu aktívnou účasťou na cvičeniach a úspešným zvládnutím úloh. Úspešné absolvovanie písomnej skúšky.
 - počet bodov z cvičení: max 45
 - počet bodov z písomnej skúšky: max 55
- K úspešnému absolvovaniu skúšky je potrebné dosiahnuť:
 - min 20 bodov z cvičení
 - min 20 bodov zo skúšky

Podmienky absolvovania

- Hodnotenie predmetu podľa klasifikačnej stupnice platného Študijného poriadku STU (čl. 16, bod 3):
 - Kritériá úspešnosti (percentuálne vyjadrenie výsledkov pri hodnotení predmetu zaokrúhlené na celé číslo) sú pre klasifikačné stupne nasledovné:
 - a) A – 92 až 100 %
 - b) B – 83 až 91 %
 - c) C – 74 až 82 %
 - d) D – 65 až 73 %
 - e) E – 56 až 64 %
 - f) FX – 0 až 55 %

Odporúčania STU o AI

- Opatrenie číslo: 1/2024 – O
 - Používanie umelej inteligencie na Slovenskej technickej univerzite v Bratislave
 - https://www.stuba.sk/buxus/docs/stu/pracoviska/rektorat/odd_pravne_organizacne/28.11.2024%20opatrenie_AI-signed.pdf

Cvičiaci

- **Ing. Samuel Gibala**

- samuel.gibala@stuba.sk (C7 INOLab)
- **vedúci cvičení**

- Ing. Azad Aliyev, azad.aliyev@stuba.sk (C725)
- Ing. Artur Andriichenko, artur.andriichenko@stuba.sk (C726)
- Ing. Matúš Vaňo, matus.vano@stuba.sk (C727)

Cvičenia

- Prezentácie a zadania budú zdieľané v AIS a discorde - <https://discord.gg/BcZHGAWUs5>
- Organizácia:
 - 2h prednáška
 - 2h cvičenie
- Podmienky získania zápočtu:
 1. Aktívna účasť na cvičeniach (max. 2 ospravedlnené neúčasti).
 2. Vypracovanie a odovzdanie **všetkých** zadanií do konca semestra:
 - Odovzdanie kódu a dokumentácie do AIS.
 - Obhajoba zadania cvičiacemu (prezenčne / hybridne), kde bude zadanie skontrolované aj obodované.
 - Súčasťou odovzdávania je aj preverenie technických a odborných vedomostí študenta. Prípadné nedostatky budú penalizované adekvátnou stratou bodov. V prípade nedostatočného preukázania, že študent vypracoval zadanie samostatne, bude hodnotený 0 bodmi.
 - Pri vypracovaní sa riadte aj smernicou o používaní AI na STU: <https://bitly.cx/OC8xm>
 3. Individuálne vypracovanie zadanií
 - Nie je povolená práca v skupinách.
 - Pri online zdrojoch je treba do komentára alebo dokumentácie uviesť min. adresu zdroja.
 4. Získanie **minimálne 20** bodov počas semestra (zo 45).

Cvičenia

Obsah cvičení - harmonogram


Cvičenia	Téma	Zadania	Dátum
1.	Úvod do predmetu, strojového učenia a neurónových sietí, IRIS dataset - práca s dátami, knižnice		18.09.2026
2.	Jednoduché neurónové siete, predspracovanie a príprava dát, metódy vyhodnocovania úspešnosti, EDA Trénovanie neurónových sietí I. - spätná propagácia, gradientný zostup Trénovanie neurónových sietí II. - solvery, babysitting trénovacieho procesu	Predstavenie Z1	25.09.2026
3.			02.10.2026
4.			9.10.2026
5.	Odovzdávanie Z1	Deadline Z1, Predstavenie Z2	16.10.2026
6.	Učenie bez učiteľa - redukcia dimenzie a zhlukovanie		23.10.2026
7.	Priebežný test Stroje s podpornými vektormi , súborové učenie		30.10.2026
8.	Odovzdávanie Z2	Deadline Z2, Predstavenie Z3	6.11.2026
9.	Hlboké konvolučné siete		13.11.2026
10.	Transfer learning, regularizácia v neurónových sieťach		20.11.2026
11.	Transformery		27.11.2026
12.	Odovzdávanie Z3	Deadline Z3	4.12.2026
13.	Uzatvorenie semestra - Dodatočné odovzdávanie a pod.		11.12.2026

Podmienky získania zápočtu

- 1. Aktívna účasť na cvičeniach (max. 2 ospravedlnené neúčasti)
- 2. Vypracovanie a odovzdanie všetkých zadaní do konca semestra:
 - Odovzdanie kódu a dokumentácie do AIS + dostupnosť na konzultovanie
- 3. Individuálne vypracovanie zadaní:
 - Nie je povolená práca v skupinách
 - Pri online zdrojoch je treba do komentára alebo dokumentácie uviesť min. adresu zdroja
- 4. Získanie minimálne 20 bodov počas semestra (zo 45).

Info a materiály

- AIS STU: Syllabus predmetu, informačný list predmetu
- potrebné podklady k predmetu:
 - AIS: dokumentový server
 - + tabuľa



Pojmy, princípy, koncepty...

Pojmy

- ❑ umelá inteligencia (artificial intelligence)
- ❑ soft computing
 - výpočtová inteligencia (computational intelligence)
- ❑ strojové učenie (machine learning)
- ❑ hlboké učenie (deep learning)
- ❑ neurónová sieť (neural network)
 - neurocomputing, programmed computing
- ❑ distribuovaný systém (distributed system)
- ❑ connectionism
- ❑ ...
 - aj postupne počas semestra

Pojmy

- umelá inteligencia (artificial intelligence)
 - tento pojem opisuje stroje (počítače), ktoré napodobňujú kognitívne funkcie človeka (jeho mysle), ako napr. učenie, riešenie problémov a pod.

Pojmy

- umelá inteligencia (artificial intelligence)
 - slabá (artificial narrow (weak) intelligence)
 - všeobecná (artificial general (strong, full) intelligence)

Pojmy

- umelá inteligencia (artificial intelligence)

- Koľko typov? 😊

- tu sú príklady webstránok:

- 4 typy

- [Understanding the Four Types of Artificial Intelligence \(govtech.com\)](http://govtech.com)

- 7 typov

- [7 Different Types of Artificial Intelligence](#)

- 2 typy – jeden 4 podtypy a druhý 3 podtypy 😊

- [Types of Artificial Intelligence | Understanding The Main Two Types of AI \(educba.com\)](http://educba.com)

Pojmy


- umelá inteligencia (artificial intelligence)
 - z iného pohľadu
 - explainable AI
 - [Draft NISTIR 8312 - Four Principles of Explainable Artificial Intelligence](#)

Pojmy

- ❑ soft computing
 - nevyžaduje/nie je možné získať presné riešenie – postačuje aproximácia riešenia
 - ❑ neurónové siete, fuzzy systémy, evolučné systémy

- ❑ výpočtová inteligencia (computational intelligence)
 - zaoberá sa aplikovaním soft computingu do oblasti umelej inteligencie

nejde nám o presné definície...



Strojové učenie (Machine Learning)

- extrakcie užitočnej informácie z komplexných dát
 - napr. projekcia do menej rozmerov
- učenie
 - stroje – učenie z dát (learning from data)
 - človek – učenie skúsenosťou (learning by experience)
 - pamätanie si, adaptácia, zovšeobecnenie (generalizovanie)

Strojové učenie (Machine Learning)

- strojové učenie:
 - zmeny, adaptácia činnosti počítača tak, aby činnosť bola presnejšia
 - spojenie myšlienok z neurovedy, biológie, štatistiky, matematiky, fyziky za účelom učenia počítačov
 - neurónové siete (neural networks)
 - data mining („dolovanie“ užitočnej informácie z dát)
 - zaujímavá je výpočtová zložitosť
 - stroje pracujú podľa algoritmov ...
 - zložitosť pri trénoch – náročné algoritmy, ale tréning nie je neustále
 - zložitosť pri testovaní - treba rýchle algoritmy, je to hlavná práca strojov
- typy učenia (budeme mať podrobne neskôr):
 - supervised learning
 - unsupervised learning
 - reinforcement learning
 - evolutionary learning


- ako naučiť stroje učiť sa
 - cieľom sú stroje (počítače), ktoré svoju činnosť zlepšujú automaticky získavaním skúseností
 - aby stroje (počítače) vedeli reagovať bez toho, aby sme ich explicitne naprogramovali

- strojové učenie prinieslo mnoho aplikácií
 - napr. efektívne prehľadávanie webu, skúmanie ľudského genómu, autá, ktoré nepotrebujú vodiča, systémy na rozpoznávanie obrazu a reči, ...

Hlboké učenie (deep learning)



- podmnožina strojového učenia
 - využitie hlbokých NS

umelá inteligencia-strojové učenie-hlboké učenie



<https://www.tes.com/lessons/GEEqZxqx4uPD1g/deep-learning>

strojové učenie - hlboké učenie



<https://www.tes.com/lessons/GEEqZxqx4uPD1g/deep-learning>

neuróny

■ mozgová kôra človeka:

- obrovské množstvo neurónov
 - desiatky ~~biliónov~~ ($10 * 10^9 = 10^{10}$)
- masívne prepojenie neurónov
 - 60 ~~triliónov~~ ($60 * 10^{12}$)

■ Pozn.: názvy *bilión* a *trilión* sú z literatúry USA

-
- **bilión:**
 - milión miliónov, čiže 10^{12} ; v USA, bývalom ZSSR a v minulosti vo Francúzsku sa toto číslo nazýva **trilión**
 - v USA, bývalom ZSSR a v minulosti vo Francúzsku: **(stredoeurópska) miliarda**; čiže 10^9
 - **trilión:**
 - milión biliónov, čiže 10^{18} ; v USA, bývalom ZSSR a v minulosti vo Francúzsku sa toto číslo nazýva **kvintilión**
 - v USA, bývalom ZSSR a v minulosti vo Francúzsku: **(stredoeurópsky) bilión**; čiže 10^{12}

- mozgová kôra človeka:
 - toľko neurónov, ako je hviezd v Mliečnej dráhe
- názory na mozog:
 - starí Egypťania – zbytočný orgán, pri balzamovaní faraónov ho zahadzovali
 - Aristoteles – duša sídli v srdci, mozog iba chladí kardiovaskulárny systém

Michio Kaku: The Future of the Mind, Penguin Books, 2015

- hmotnosť iba 3 libry (1,36 kg)
 - ale je to najkomplexnejší objekt v slnečnej sústave
- má 2% z hmotnosti tela, ale spotrebúva 20% telesnej energie
 - pri novorodencoch 65%
- 80% našich génov je kódovaných pre mozog

Michio Kaku: The Future of the Mind, Penguin Books, 2015

2 revolučné vynálezy – teleskop a MRI

- teleskop (objavený pred 400 rokmi)
 - počas 15 rokov po objave teleskopu sme sa o svete (vesmíre) dozvedeli viac ako za celú dovtedajšiu históriu ľudstva
- magnetická rezonancia (MRI, magnetic resonance imaging)
 - podobne cca od 1995 do 2010 zmenilo neurovedu
 - počas 15 rokov po objave MRI sme sa o mozgu dozvedeli viac ako za celú dovtedajšiu históriu ľudstva

Michio Kaku: The Future of the Mind, Penguin Books, 2015

2 revolučné vynálezy - teleskop a MRI

- magnetická rezonancia (MRI, magnetic resonance imaging)
 - E.R.Kendel, nositeľ Nobelovej ceny, Inštitút Maxa Plancka v Tubingene:
 - najhodnotnejšie poznatky o ľudskej mysli za spomínaných 15 rokov nepriniesli tradičné vedy o myslení (filozofia, psychológia, psychoanalýza), ale ich fúzia s biológiou mozgu

Michio Kaku: The Future of the Mind, Penguin Books, 2015

neurónová sieť

- (umelá) neurónová sieť
 - (artificial) neural network, ANN, NN
- **neuróny** (milisekundová oblasť) – pomalšie o 5-6 rádov voči **kremíkovým logickým hradlám** (nanosekundová oblasť), ale:
 - obrovské množstvo neurónov
 - masívne prepojenie neurónov
- NS vhodná pre:
 - zle definované úlohy
 - úlohy s enormným množstvom operácií

mozog vs. počítač

	Supercomputer	Personal Computer	Human Brain
Computational units	10^6 GPUs + CPUs 10^{15} transistors	8 CPU cores 10^{10} transistors	10^6 columns 10^{11} neurons
Storage units	10^{16} bytes RAM 10^{17} bytes disk	10^{10} bytes RAM 10^{12} bytes disk	10^{11} neurons 10^{14} synapses
Cycle time	10^{-9} sec	10^{-9} sec	10^{-3} sec
Operations/sec	10^{18}	10^{10}	10^{17}

Figure 1.2 A crude comparison of a leading supercomputer, Summit (?); a typical personal computer of 2019; and the human brain. Human brain power has not changed much in thousands of years, whereas supercomputers have improved from megaFLOPs in the 1960s to gigaFLOPs in the 1980s, teraFLOPs in the 1990s, petaFLOPs in 2008, and exaFLOPs in 2018 (1 exaFLOP = 10^{18} floating point operations per second).

Neurocomputing vs. Programmed Computing

neurocomputing

- bez dopredu daného presného postupu (algoritmu)
- veľa operácií súčasne (paralelizmus)
- *napr. ľudský vizuálny systém (human vision)*

programmed computing

- dopredu daný presný postup (algoritmus)
- sekvenčné spracovanie operácií
- *napr. riešenie systému lin. rovníc*

neurónová sieť


■ neurónové siete

- plytké (shallow)
 - klasické, konvenčné
- hlboké (deep)

HLBOKÉ siete - vývoj

- Echo State Neural Networks, rekurentná sieť, 1990
- Long Short-Term Memory (LSTM), rekurentná sieť, 1997
- konvolučné siete:
 - LeNet5, 1995
 - AlexNet, 2012
 - VGG net (16/19), 2014
 - GoogLeNet/Inception-V1, 2014
 - Generative Adversarial Network (GAN), 2014
 - Inception (V2/V3), 2015
 - ResNet, 2015
 - Inception (V4), 2016
 - SqueezeNet, 2016
 - DenseNet, 2016
 - Capsule Network (CapsNet), 2017
 - ...

Neurónové siete - vývoj




<https://www.tes.com/lessons/GEEqZxqx4uPD1g/deep-learning>

Míľníky vývoja NS

Rok	Míľník	Význam
1943	McCulloch–Pittsov neurón	Warren McCulloch a Walter Pitts vytvorili matematický model umelého neurónu. Jeden zo základov neurónových sietí.
1949	Hebbovo učenie	Donald Hebb formuloval princíp učenia založený na posilňovaní spojení medzi súčasne aktívnymi neurónmi.
1957–1958	Perceptrón – Frank Rosenblatt	Jeden z prvých praktických modelov neurónovej siete schopný učiť sa z dát.
1969	Kritika perceptrónov	Marvin Minsky a Seymour Papert ukázali limity jednovrstvových perceptrónov, napr. problém XOR. Záujem o neurónové siete následne výrazne poklesol.
1982	Hopfieldove siete	John Hopfield ukázal možnosti rekurentných neurónových sietí ako asociatívnej pamäte.
1986	Backpropagation	Rumelhart, Hinton a Williams popularizovali spätné šírenie chyby ako efektívny spôsob tréningu viacvrstvových neurónových sietí.
1989–1998	Konvolučné siete – LeNet	Yann LeCun a ďalší rozvíjali CNN pre rozpoznávanie obrazu a rukou písaných číslíc. LeNet-5 sa stal významným predchodcom moderných CNN.
1997	LSTM	Hochreiter a Schmidhuber predstavili LSTM, architektúru schopnú efektívnejšie pracovať s dlhodobými závislosťami v sekvenciách.
2006	Nástup deep learningu	Geoffrey Hinton a spolupracovníci ukázali nové postupy tréningu hlbokých sietí. Obnovil sa intenzívny záujem o viacvrstvé neurónové siete.
2009–2012	GPU + veľké datasety	Výpočty na GPU a datasety ako ImageNet umožnili trénovať podstatne väčšie siete.
2012	AlexNet	Alex Krizhevsky, Ilya Sutskever a Geoffrey Hinton dosiahli výrazný úspech v ImageNet súťaži pomocou hlbokoj CNN a GPU. Jeden z kľúčových momentov modernej éry deep learningu.
2014	GAN	Ian Goodfellow a spolupracovníci predstavili Generative Adversarial Networks, ktoré umožnili generovať realistické syntetické dáta.
2015	ResNet	Residual connections umožnili efektívne trénovať siete so stovkami vrstiev.
2017	Transformer	Práca Attention Is All You Need predstavila architektúru Transformer založenú na attention mechanizme. Stala sa základom väčšiny moderných jazykových modelov.
2018	BERT	Google predstavil BERT, ktorý výrazne posunul spracovanie prirodzeného jazyka pomocou predtrénovaných Transformerov.
2018–2020	GPT → GPT-3	Generatívne predtrénované Transformerové modely ukázali, že zväčšovanie modelov a množstva tréningových dát vedie k výraznému rastu schopností.
2020–2022	Diffusion models	Difúzne modely sa stali veľmi úspešným prístupom ku generovaniu obrazov a postupne začali konkurovať či nahrádzať GAN v mnohých úlohách.
2022–2023	Generatívna AI a LLM	ChatGPT a ďalšie veľké jazykové modely priniesli neurónové siete do masového používania a ukázali možnosti konverzačných AI systémov.
2023–súčasnosť	Multimodálne a reasoning modely	Modely začali spoločne spracovávať text, obraz, zvuk a ďalšie modalitty; zároveň sa výrazne rozvíjajú modely optimalizované na komplexnejšie uvažovanie, používanie nástrojov a agentné úlohy.

Príklad aplikácie

■ NS pre rozpoznávanie obrazov tvárí - vývoj



Wang, M., Weihong D.: Deep Face Recognition: A survey, arXiv preprint arXiv:1804.06655 (2018)

Klasické metódy spracovania signálov

- 3 predpoklady:

1. linearita
2. stacionárnosť
3. štatistika druhého rádu s dôrazom na gaussovske signály

- tieto predpoklady – pre ľahšie matematické spracovanie

NS + iné techniky strojového učenia

- väčšina reálnych signálov
 1. nelineárne
 2. nestacionárne
 3. negaussovské
- čiže klasické metódy sú suboptimálne

neurónová sieť

- Neurónová sieť je zariadenie pre modelovanie činnosti, ktorou mozog vykonáva čiastočnú úlohu, funkciu
 - sieť je zvyčajne implementovaná
 - pomocou elektronických prvkov
 - alebo softwarovo simulovaná na číslicovom počítači
- Užitočné výpočty sieť robí na základe **procesu učenia**. Neurónová sieť zahŕňa **masívne prepojenie** jednotlivých výpočtových prvkov (neurónov).


neurónová sieť

- Neurónová sieť je **masívne paralelný distribuovaný procesor**, ktorý má schopnosť uchovávať poznatky získané skúsenosťou a mať ich k dispozícii pre použitie. Podobá sa mozgu v dvoch ohľadoch:
 - poznatky získava sieť **procesom učenia**
 - na uchovanie poznatkov sa používajú medzineurónové spojenia známe ako **synaptické váhy**

Definícia neurónovej siete z hľadiska teórie grafov

- Neurónová sieť je štruktúra pre paralelné a distribuované spracovanie informácií v tvare **orientovaného grafu** s nasledujúcimi subdefiníciami a obmedzeniami:
 - **uzly grafu** sa nazývajú **výpočtové prvky**
 - **hrany grafu** sa nazývajú **spojenia**
 - každý výpočtový prvok môže obsahovať ľubovoľný počet **vstupných spojení**
 - každý výpočtový prvok môže mať ľubovoľný počet **výstupných spojení**, ale signály pre ne musia byť rovnaké - v skutočnosti má každý prvok jediné výstupné spojenie, ktoré sa môže rozvetvovať a vytvoriť viacnásobné výstupné spojenia obsahujúce rovnaký signál
 - výpočtové prvky môžu mať **lokálnu pamäť**
 - každý výpočtový prvok obsahuje **prenosovú (aktivačnú) funkciu**, ktorá môže využiť lokálnu pamäť, vstupné signály a ktorá vytvorí výstupný signál výpočtového prvku.

Zjednodušená schéma neurónov



$N_{1,2}$ - jadrá neurónov D - dendrity
 SO - somy A - axóny S - synapsy

Zjednodušená schéma neurónov





Figure 1.1 The parts of a nerve cell or neuron. Each neuron consists of a cell body, or soma, that contains a cell nucleus. Branching out from the cell body are a number of fibers called dendrites and a single long fiber called the axon. The axon stretches out for a long distance, much longer than the scale in this diagram indicates. Typically, an axon is 1 cm long (100 times the diameter of the cell body), but can reach up to 1 meter. A neuron makes connections with 10 to 100,000 other neurons at junctions called synapses. Signals are propagated from neuron to neuron by a complicated electrochemical reaction. The signals control brain activity in the short term and also enable long-term changes in the connectivity of neurons. These mechanisms are thought to form the basis for learning in the brain. Most information processing goes on in the cerebral cortex, the outer layer of the brain. The basic organizational unit appears to be a column of tissue about 0.5 mm in diameter, containing about 20,000 neurons and extending the full depth of the cortex (about 4 mm in humans).

Nelineárny model neurónu

- neurón k niekde v sieti:




$$u_k = \sum_{j=1}^p w_{kj} x_j$$

$$y_k = \varphi(u_k - \theta_k)$$

$$v_k = u_k - \theta_k$$

v_k je úroveň vnútornej aktivity
("internal activity level") neurónu k

Nelineárny model neurónu



Ekvivalentný zápis:

$$v_k = \sum_{j=0}^p w_{kj} x_j$$
$$y_k = \phi(v_k)$$

V rovnici je nová synapsa, vstup ktorej je

$$x_0 = -1$$


a váha ktorej je

$$w_{k0} = \theta_k \text{ (predpätie, threshold)}$$

Nelineárny model neurónu

Podobne:

- predpätie b_k nahradené konšt. vstupom $x_0 = +1$ a váhou $w_{k0} = b_k$ (predpätie, bias)
- všetky 3 modely matematicky ekvivalentné



Aktivačná funkcia

- rozsah hodnôt
 - od 0 do +1
 - od -1 do +1
- prahová
- (po častiach) lineárna
- sigmoidálna
 - napr. logistická


Aktivačná funkcia z rozsahu $<0,1>$

Prahová funkcia

$$\varphi(v) = \begin{cases} 1 & \text{pre } v \geq 0 \\ 0 & \text{pre } v < 0 \end{cases}$$

Výstup neurónu k


$$y_k = \begin{cases} 1 & \text{pre } v_k \geq 0 \\ 0 & \text{pre } v_k < 0 \end{cases}$$



Aktivačná funkcia z rozsahu $<0,1>$

Po častiach lineárna funkcia

$$\varphi(v) = \begin{cases} 0 & \text{pre } v \leq -\frac{1}{2} \\ v + 0.5 & \text{pre } -\frac{1}{2} < v < \frac{1}{2} \\ 1 & \text{pre } v \geq \frac{1}{2} \end{cases}$$




Aktivačná funkcia z rozsahu (0,1)

Sigmoidálna funkcia ("sigmoid function")

- monotónne rastúca, hladká a ohraničená funkcia
- napr. *logistická funkcia* ("logistic function")

$$\varphi(v) = \frac{1}{1 + \exp(-av)}$$

a - parameter strmosti



Aktivačná funkcia z rozsahu $\langle -1, 1 \rangle$

signum




$$\varphi(v) = \begin{cases} -1 & \text{pre } v < 0 \\ 0 & \text{pre } v = 0 \\ 1 & \text{pre } v > 0 \end{cases}$$

sigmoid – napr. hyperbolický tangens

$$\varphi(v) = \operatorname{tgh}\left(\frac{v}{2}\right) = \frac{1 - \exp(-v)}{1 + \exp(-v)}$$

pre hlboké siete: ReLU (Rectified Linear Unit)

- kvôli derivácii – pre plytké siete vhodná, pre hlboké nie (malý rozsah derivácie)



Referenčná karta aktivačných funkcií

(zdroj: LinkedIn)

- aktivačných funkcií je veľa...


Activation Functions: A Reference Card for Neural Networks

Formulas, derivatives, ranges, and shapes for the nine functions you actually need to know.

Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$f'(x) = \sigma(x)(1 - \sigma(x))$$




Range: (0, 1)

Tanh

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

$$f'(x) = 1 - \tanh^2(x)$$



Range: (-1, 1)


Softmax

$$\text{softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

$$f'(x_i) = \text{softmax}(x_i)(\delta_{ij} - \text{softmax}(x_j))$$

Note: applied to vectors, not scalars.

Softmax applied to input vector $[x, 0, 0]$




Range: (0, 1), sums to 1

ReLU

$$f(x) = \max(0, x)$$

$$f'(x) = \begin{cases} 1 & \text{if } x > 0 \\ 0 & \text{else} \end{cases}$$




Range: $[0, \infty)$

Leaky ReLU

$$f(x) = \max(\alpha x, x), \text{ where } \alpha \text{ is typically } 0.01.$$

$$f'(x) = \begin{cases} 1 & \text{if } x > 0 \\ \alpha & \text{else} \end{cases}$$




Range: $(-\infty, \infty)$

ELU

$$f(x) = \begin{cases} x & \text{if } x > 0 \\ \alpha(e^x - 1) & \text{else} \end{cases}$$

$$f'(x) = \begin{cases} 1 & \text{if } x > 0 \\ \alpha e^x & \text{else} \end{cases}$$



Range: $(-\alpha, \infty)$


GELU

$$f(x) = x \cdot \Phi(x), \text{ where } \Phi \text{ is the standard normal CDF.}$$

$$\text{Approximation: } 0.5x \left(1 + \tanh \left(\sqrt{\frac{2}{\pi}} (x + 0.044715x^3) \right) \right)$$

$$f'(x) = \Phi(x) + x \cdot \phi(x)$$

where ϕ is the standard normal PDF.




Range: approximately $(-0.17, \infty)$

SiLU (Swish)

$$f(x) = x \cdot \sigma(x)$$

$$f'(x) = \sigma(x) + x \cdot \sigma(x)(1 - \sigma(x))$$




Range: approximately $(-0.28, \infty)$

SwiGLU

$$\text{SwiGLU}(x, W, V, b, c) = (\text{Swish}(xW + b)) \otimes (xV + c)$$

Note: gated activation, requires two linear projections. Used in modern LLMs (Llama, PaLM, GPT-4 family).



Gated activation: two linear projections, Swish on the gate, elementwise product.

Range: depends on inputs

Prof. Ali Al Bataineh, PhD.