

Aproximácia funkcií neurónovými sietami

TÉMY

- *aproximácia funkcií („mapping“, „mapovanie“)*
- *meranie presnosti aproximácie funkcií*
- *trénovanie a pretrénovanie*
- *underfitting a overfitting, bias-variance tradeoff*
- *Selekcia modelu a optimalizácia, vzájomné overovanie („cross validation“)*
- *k-násobné vzájomné overovanie („k-fold cross validation“)*
- *regularizácia, selekcia príznakov, ladenie hyperparametrov*
- *Kolmogorovova existenčná teoréma o aproximácii neurónovými sieťami*

PREDNÁŠKA

- aproximácia funkcií pomocou neurónových sietí
 - približná implementácia ohraničeného mapovania (funkcie) $f: A \subset R^p \rightarrow R^q$
 - pomocou učenia s príkladmi $(\mathbf{x}_1, \mathbf{d}_1), (\mathbf{x}_2, \mathbf{d}_2), \dots, (\mathbf{x}_k, \mathbf{d}_k), \dots$
 - príklady mapovania f sú generované výberom vektorov $\mathbf{x}_k$ náhodne z množiny A podľa danej hustoty pravdepodobnosti $P(\mathbf{x})$
 - $\mathbf{d}_k = f(\mathbf{x}_k)$

- meranie presnosti aproximácie funkcií

- prostredie: $\mathbf{x}, P(\mathbf{x})$
 - učiteľ: $(\mathbf{x}_1, \mathbf{d}_1), (\mathbf{x}_2, \mathbf{d}_2), \dots, (\mathbf{x}_k, \mathbf{d}_k), \dots$, kde $\mathbf{d}_k = f(\mathbf{x}_k)$
 - výstupný vektor siete: $\mathbf{y} = h(\mathbf{x}, \mathbf{w})$
 - miera chyby: $J(\mathbf{d}, h(\mathbf{x}, \mathbf{w}))$
 - J vedie k chybovému povrchu
-

- h je hypotéza, je jednou z možností priestoru hypotéz $\mathcal{H}$
- analýza priestoru hypotéz $\mathcal{H}$ – pomocou vychýlenosti (bias), a rozptylu (variance)

- predpojatosť – nezávisle od trénovacej množiny
- rozptyl – pri rôznych trénovacích množinách

bias – vychýlenosť, zaujatosť,
predpojatosť, predsudky

variance – odchýlka, rozdiel,
rozptyl

$$h(x) = w_1x + w_0$$

$$h(x) = w_1x + \sin(w_0x)$$

po častiach lin. funkcia

$$h(x) = \sum_{i=0}^{12} w_i x^i$$





Linear

Sinusoidal

Piecewise linear

Degree-12 polynomial

Data set 1



Data set 2








Figure 19.1 Finding hypotheses to fit data. **Top row:** four plots of best-fit functions from four different hypothesis spaces trained on data set 1. **Bottom row:** the same four functions, but trained on a slightly different data set (sampled from the same $f(x)$ function).

- horný rad – trénovacia množina, 13 bodov, rovnaká pre všetky 4 grafy
- spodný rad – iná trénovacia množina, 13 bodov, rovnaká pre všetky 4 grafy
 - obe množiny sú ale reprezentatívne pre neznámu funkciu $f(x)$



hypotézy,
generalizácia

- bias - predpojatosť – nezávisle od trénovacej množiny
 - tendencia hypotézy líšiť sa od očakávanej hodnoty, keď je spriemerovaná cez rôzne tréningové súbory- napr. priestor hypotéz lineárnych funkcií vnáša silný bias, lineárna funkcia nevystihne zvlnené trénovacie dáta - **underfitting**
- rozptyl (variance) – pri rôznych trénovacích množinách
 - miera zmeny v hypotézach v dôsledku zmien v trénovacích dátach (pozri predchádzajúci obr., stačilo vziať inú podmnožinu trénovacích dát a výsledok vpravo je úplne odlišný)
 - polynóm 12. rádu má priveľký rozptyl – spôsobí **overfitting**
- **bias-variance tradeoff** - kompromis medzi predpojatosťou a rozptylom
 - výber medzi komplexnejšími hypotézami s nízkou predpojatosťou (ktoré dobre vystihnú dáta) a jednoduchšími hypotézami s nízkym rozptylom (ktoré ale môžu lepšie generalizovať)
 - Einstein - výber najjednoduchšej hypotézy, Occamova britva - oholí pochybné vysvetlenia



https://cs.wikipedia.org/wiki/Occamova_b%C5%99itva

- budeme mať aj takýto obrázok:




Selekcia modelu a optimalizácia:

- chybovosť (error rate)
 - výber hypotézy, ktorá minimalizuje chybovosť
 - pri jednej hypotéze stačí rozdelenie dát na 2 množiny:
 - **trénovacia a testovacia množina** stačí
 - trénovacia na vytvorenie modelu, testovacia na jeho vyhodnotenie
- ak ale máme viac hypotéz:
 - napr. chceme porovnať 2 úplne odlišné modely strojového učenia
 - chceme vyhodnotiť rozličné parametre, ktoré majú vplyv na správanie sa modelu, tzv. hyperparametre (hyperparameters)
 - (napr. rozličné stupne polynómov voči parametru pri rozhodovacích stromoch)
 - **trénovacia, validačná a testovacia množina**

- pretrénovanie: overtraining, overfitting

DOSTUPNÉ DÁTA		
TRÉNOVACIA MNOŽINA trénovanie modelov	VALIDAČNÁ MNOŽINA (aj development set, dev set) vyhodnotenie každého modelu a výber najlepšieho	TESTOVACIA MNOŽINA konečné nevychýlené vyhodnotenie najlepšieho modelu




je to:

- jav (fenomén)
- kritérium zastavenia učenia!!! – názov má vzájomné overovanie („cross validation“)
- nazýva sa aj „early stopping“


○ k -násobné vzájomné overovanie („ k -fold cross validation“)

- generovanie rozdielnych trénovacích množín
- k -násobné delenie dát (k -fold data split)
 - k rôznych podmnožín



Polikar, R.: Ensemble Based Systems in Decision Making IEEE Circuits and Systems Magazine, vol.6, no.3, pp. 21-45, 2006

- zložitosť (komplexnosť) modelu



pozor, na vodorovnej osi už nie sú
cykly, príp. iterácie...

Figure 19.9 Error rates on training data (lower, green line) and validation data (upper, orange line) for models of different complexity on two different problems. MODEL-SELECTION picks the hyperparameter value with the lowest validation-set error. In (a) the model class is decision trees and the hyperparameter is the number of nodes. The data is from a version of the restaurant problem. The optimal size is 7. In (b) the model class is convolutional neural networks (see Section ??) and the hyperparameter is the number of regular parameters in the network. The data is the MNIST data set of images of digits; the task is to identify each digit. The optimal number of parameters is 1,000,000 (note the log scale).

- vľavo: v minime je rovnováha medzi podtrénovaním a pretrénovaním (underfitting a overfitting), niektoré modely sa už pridaním kapacity nezlepšia, zostanú v overfittingu, memorizujú – interpolujú tréningové dáta (napr. rozhodovacie stromy)
- vpravo: najprv podobne ako vľavo, potom ale ďalší pokles chyby – pridávanie kapacity znamená vytvorenie vhodnejšej reprezentácie dát (napr. hlboké NN, kernelové metódy, boostované súbory - ensembles)

nemýliť si s normalizáciou dát, kde sa v každej dimenzii vektora vypočíta str. hodnota a štand.odchýlka - každá dimenzia vektora sa preškáluje: namiesto $x_{j,i}$ máme $(x_{j,i} - \mu_i)$

- regularizácia:
 - alternatíva ku vzájomnému overovaniu
 - hľadanie hypotézy, ktorá priamo minimalizuje zložitosť hypotéz (explicitne penalizuje zložité hypotézy), čiže hľadá regulárne hypotézy
 - treba zvoliť:
 - stratová funkcia (loss function) - L_1 alebo L_2
 - miera zložitosti - regularizačná funkcia

empirická strat. fun. je odhadom generalizačnej strat. fun.

$$Cost(h) = EmpLoss(h) + \lambda Complexity(h)$$

kritériálna funkcia = empirická stratová (chybová) funkcia + λ zložitosť

kde λ - hyperparameter, určuje, ako silno regularizujeme (ak nulový, neregularizujeme 😊)

ak zložitosť závisí od váh, tak

$$Complexity(h_w) = L_q(\mathbf{w}) = \sum_i |w_i|^q$$

- $q=1$: L_1 regularizácia, minimalizuje sumu absolútnych hodnôt
- $q=2$: L_2 regularizácia, minimalizuje sumu kvadrátov

Pozn.: pre stratové funkcie aj regularizačné funkcie sa používa označenie L_1 a L_2 . Nemusia sa používať vo dvojiciach: môže sa použiť strat. fun. L_2 s regularizáciou L_1 alebo naopak.

- L_1 regularizácia – vedie k riedkym modelom - nastaví množstvo váh na nulu (výhoda) – zodpovedajúce atribúty označí za irelevantné (vzťah k selekcii príznačkov)
- minimalizácia $Loss(\mathbf{w}) + \lambda Complexity(\mathbf{w})$ znamená minimalizovať $Loss(\mathbf{w})$ vzhľadom na podmienku $Complexity(\mathbf{w}) \leq c$, kde konštanta c sa vzťahuje na λ




Figure 19.14 Why L_1 regularization tends to produce a sparse model. Left: With L_1 regularization (box), the minimal achievable loss (concentric contours) often occurs on an axis, meaning a weight of zero. Right: With L_2 regularization (circle), the minimal loss is likely to occur anywhere on the circle, giving no preference to zero weights.

- selekcia príznakov (feature selection)-ďalšia možnosť získania jednoduchšieho modelu
 - zahodenie irelevantných príznakov
- ladenie hyperparametrov (hyperparameter tuning)
 - hand-tuning, odhad, intuícia
 - grid search
 - random search
 - Bayesovská optimalizácia

- **Kolmogorovova existenčná teoréma o aproximácii neurónovými sieťami**

Ak je daná ľubovoľná spojitá funkcia $f: (0,1)^p \rightarrow R^q$

$$(0,1)^p = \{x = (x_1, x_2, \dots, x_p) \in R^p, 0 \leq x_i \leq 1, \text{pre} \forall 1 \leq i \leq p\}, f(x) = y,$$

tak f môže byť presne implementovaná trojvrstvovou doprednou neurónovou sieťou, ktorá má p prvkov vo vstupnej vrstve, $(2p + 1)$ prvkov v skrytej vrstve a q prvkov vo výstupnej vrstve.

Vstupná vrstva: distribuuje vstupný vektor x

Skrytá vrstva: prvky implementujú aktivačnú funkciu:

$$z_k = \sum_{j=1}^p \lambda^k \psi(x_j + k\varepsilon) + k$$

kde λ - reálna konštanta

ψ - spojitá reálna monotónne rastúca funkcia

ε - racionálne číslo $0 < \varepsilon \leq \delta$

δ - ľubovoľne zvolená kladná konštanta

Výstupná vrstva: prvky majú aktivačnú funkciu

$$y_i = \sum_{k=1}^{2p+1} g_i(z_k)$$

kde funkcie g_i $i = 1, 2, \dots, q$ sú reálne a spojité

- funkcia $\psi = ?$ konštanta $\varepsilon = ?$ funkcia $g = ?$
- existenčná teoréma
- účinnejší výsledok $\rightarrow$ univerzálna aproximačná teoréma