pokračovanie

Perceptrón a viacvrstvový perceptrón

vrstvové dopredné siete (layered NN) - jednovrstvové (single-layer) a viacvrstvové (multilayer),
úplne prepojené siete (FCN, fully connected networks)

TÉMY

- ***Viacvrstvový perceptrón (MLP, multilayer perceptron)***
  - *tipy pre lepšiu činnosť BP algoritmu*
  - *generalizácia*
  - *aproximácia funkcií*
  - *univerzálna aproximačná teoréma*
  - *univerzálna aproximácia*
  - *MLP s viacerými skrytými vrstvami*
  - *teorémy o aproximačných schopnostiach MLP*
  - *návrh MLP*
    - *napr. veľkosť trénovacej množiny pre binárny klasifikátor*
  - *ďalšie spôsoby trénovania MLP*
    - *premenlivá rýchlosť učenia, konjugovaný gradient, Levenberg–Marquardt, ...,*
  - *ďalšie optimalizačné algoritmy aj pre hlboké siete*
    - *SGD, Adam, Adabound, ...*

  - *prídavky:*
    - *NN training (black art), 1st order gradient descent methods, 2nd order gradient descent methods*

- ***zjednodušovanie sietí - network pruning:***
    - *používa sa aj pre iné siete, nielen pre MLP*

1. *rast siete (network growing)*
    - *kaskádová korelácia (cascade correlation)*
2. *zmenšovanie siete (network pruning)*
    - *útlm váh (weight decay)*
    - *eliminácia váh (weight elimination)*
    - *optimal brain damage*
3. *iné*
    - *evolučné algoritmy (evolutionary computing)*
        - *genetické algoritmy*

Tipy pre lepšiu činnosť BP algoritmu

- sigmoidálna **aktivačná funkcia** - napr. *tgh* namiesto logistickej

- hodnoty žiadaných odpovedí pre neuróny výstupnej vrstvy môžu byť z intervalu, ktorý má hranice posunuté o hodnotu μ od hraníc pôvodného rozsahu
  - napr. pre logistickú funkciu **namiesto (0,1) využijeme (μ ,1- μ)**

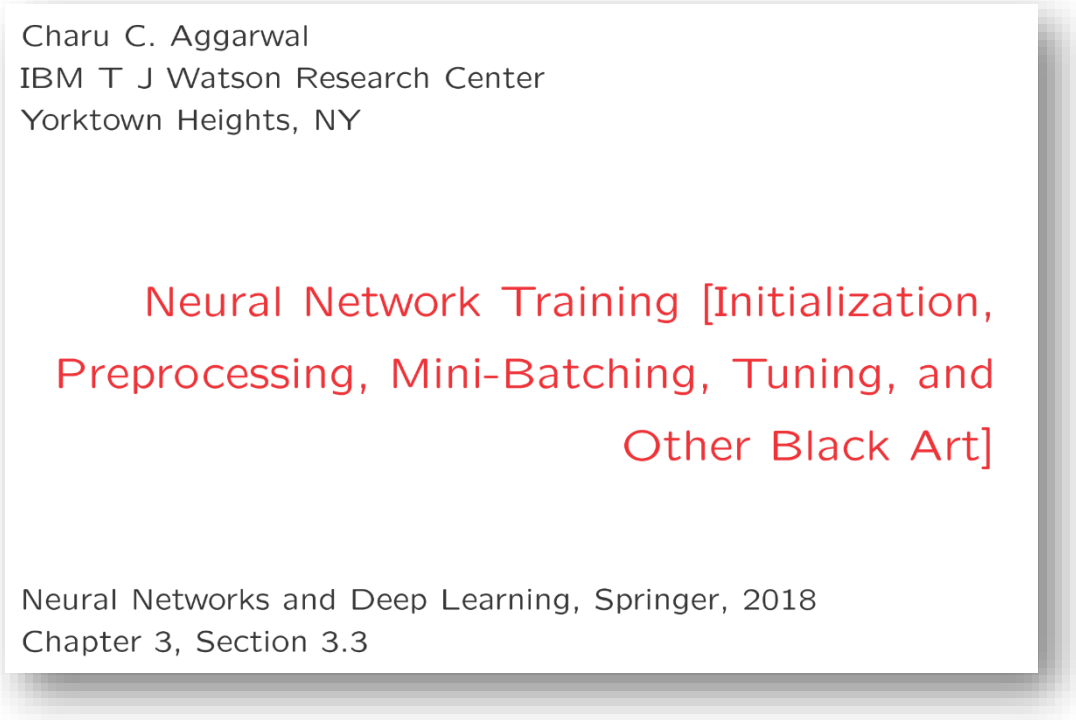
- **inicializácia váh a prahov** siete - rovnomerne rozložené hodnoty v malom rozsahu

- **parameter rýchlosti učenia** η môže mať menšiu hodnotu pre posledné vrstvy siete
  - platí tiež, že neuróny s mnohými vstupmi by mali mať menšiu hodnotu η ako neuróny s malým počtom vstupov

- pre on-line činnosť veľkých sietí je vhodnejší **vzorkový mód činnosti** - rýchlejšie trénovanie
- náhodné poradie vzoriek pre jednotlivé epochy trénovania

Pozri:

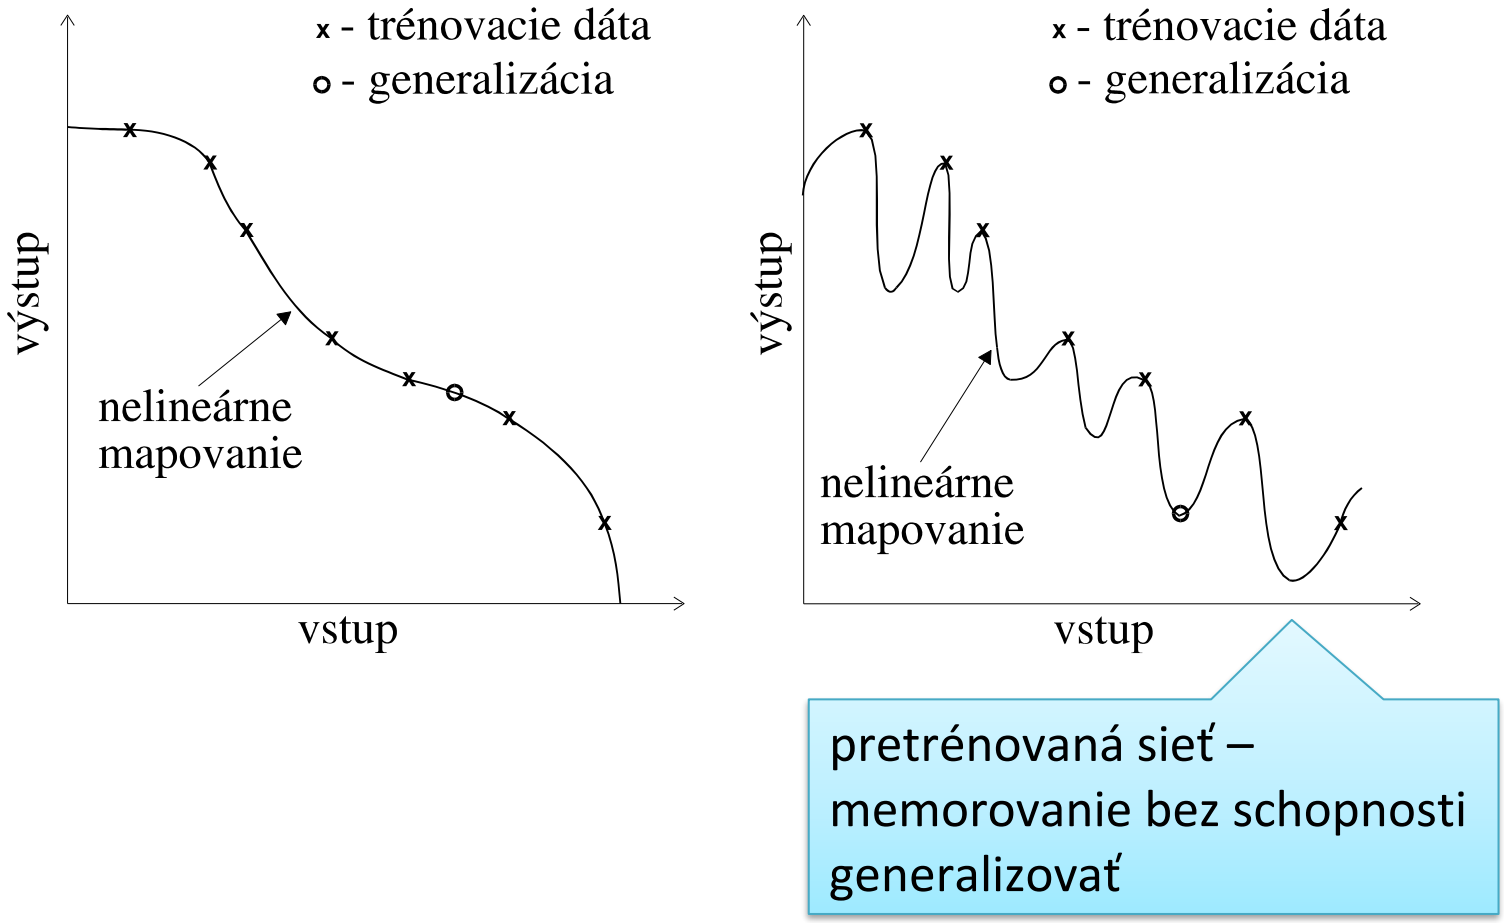
[04-MLP pridavok2-Neural Network Training [Initialization,Preprocessing, Mini-Batching, Tuning, and Other Black Art].pdf]



Aggarwall,C.,C.: Neural Networks and Deep Learning: A Textbook (Second Edition),Springer, 2018

Generalizácia

- správanie siete bude správne pre vstupno-výstupné testovacie dáta, ktoré neboli použité počas trénovania
- neurónová sieť - nelineárne vstupno-výstupné mapovanie
- správna generalizácia a negeneralizovanie:



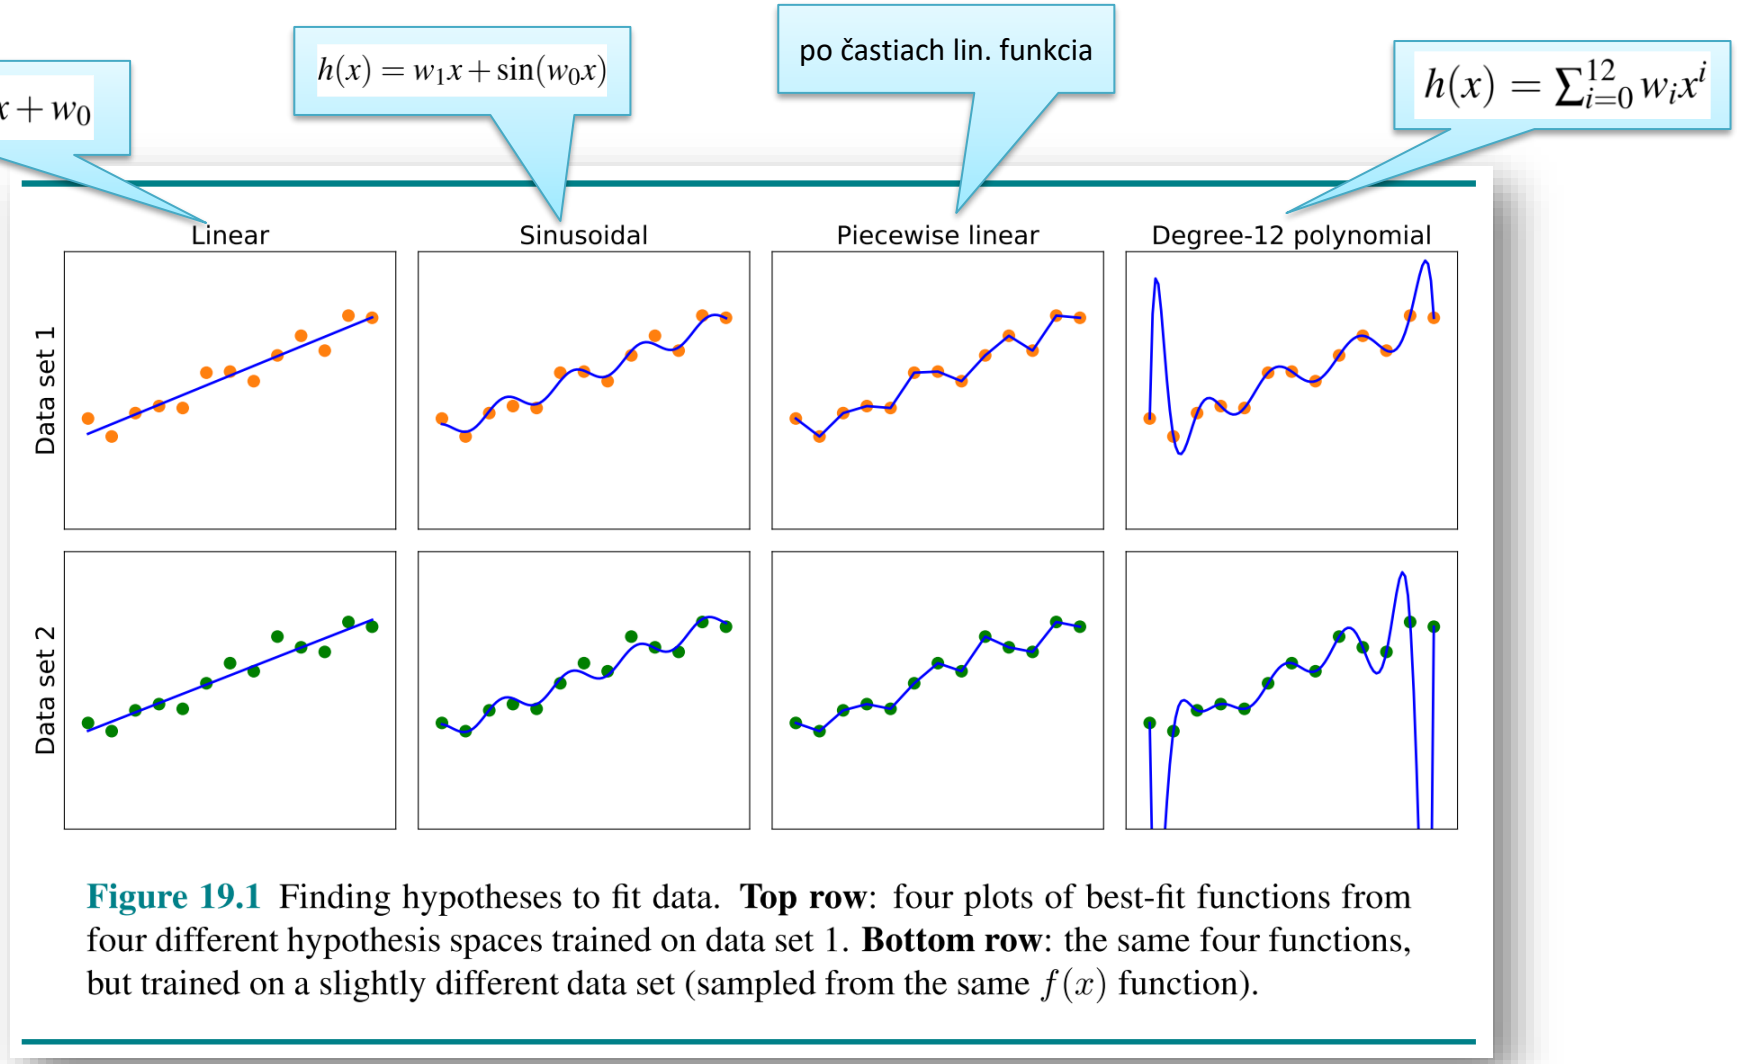


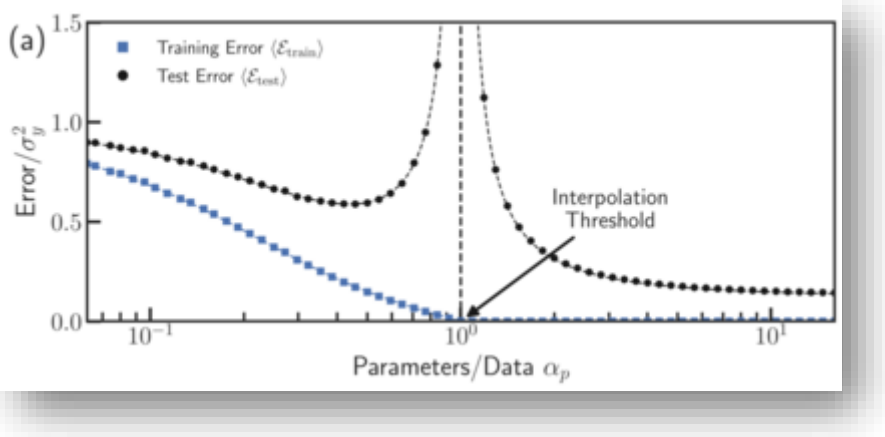
Figure 19.1 Finding hypotheses to fit data. **Top row**: four plots of best-fit functions from four different hypothesis spaces trained on data set 1. **Bottom row**: the same four functions, but trained on a slightly different data set (sampled from the same $f(x)$ function).

pripomeňme si

- horný rad – trénovacia množina, 13 bodov, rovnaká pre všetky 4 grafy
- spodný rad – iná trénovacia množina, 13 bodov, rovnaká pre všetky 4 grafy
  - obe množiny sú ale reprezentatívne pre neznámu funkciu *f(x)*

Russel,S., Norvig.P.: Artificial Intelligence – A Modern Approach, 4th edition, global edition, Pearson Education, 2022

Zaujímavý jav – **dvojitý zostup (double descent)**



An example of the double descent phenomenon in a two-layer neural network: When the ratio of parameters to data points is increased, the test error falls first, then rises, then falls again.[1] The vertical line marks the boundary between the **underparametrized regime** (more data points than parameters) and the **overparameterized regime** (more parameters than data points).

- Double descent (Wikipedia)
- Deep double descent (OpenAI)
- Deep Double Descent: Where Bigger Models and More Data Hurt (článok z r. 2019)

Univerzálna aproximačná teoréma

Nech $\varphi(\cdot)$ je nekonštantná, ohraničená, monotónne rastúca, spojitá funkcia. Nech I_p je p-rozmerná jednotková hyperkocka $[0,1]^p$. Nech $C(I_p)$ znamená priestor spojitých funkcií na I_p. Potom ak je daná ľubovoľná funkcia $f \in C(I_p)$ a $\varepsilon > 0$, tak existuje celé číslo M a množina reálnych konštánt $\alpha_i, \theta_i, w_{ij}$, kde $i = 1,\ldots,M$ a $j = 1,\ldots,p$ takých, že môžeme definovať

$$F(x_1,\ldots,x_p) = \sum_{i=1}^{M} \alpha_i \varphi\left(\sum_{j=1}^{p} w_{ij} x_j - \theta_i \right) \qquad (*)$$

ako aproximáciu funkcie $f(\cdot)$; t.j.

$$\left| F(x_1,\ldots,x_p) - f(x_1,\ldots,x_p) \right| < \varepsilon$$

pre všetky $\{x_1,\ldots,x_p\} \in I_p$.

- Táto teoréma je priamo aplikovateľná na viacvrstvový perceptrón.
- Logistická funkcia $1/[1+\exp(-v)]$ použitá ako nelinearita pre model neurónu viacvrstvového perceptrónu je nekonštantná, ohraničená, monotónne rastúca, spojitá funkcia - spĺňa podmienky kladené na funkciu $\varphi(\cdot)$.

- Rovnica (*) reprezentuje výstup viacvrstvového perceptrónu opísaného nasledovne:
  - sieť má *p* vstupných prvkov, jednu skrytú vrstvu s *M* neurónmi, vstupy sú $\{x_1,\ldots,x_p\}$
  - skrytý neurón *i* má synaptické váhy $\{w_{i1},\ldots,w_{ip}\}$ a prah θ_i
  - výstup siete je lineárna kombinácia výstupov skrytých neurónov, kde $\alpha_1,\ldots,\alpha_M$ definujú koeficienty tejto kombinácie

Univerzálna aproximačná teoréma – existenčná teoréma

- *jedna skrytá vrstva pre MLP postačuje na takúto aproximáciu*
- *je jedna skrytá vrstva optimálna? (vzhľadom na trénovanie alebo jednoduchosť implementácie)*
- *ako skonštruovať (naučiť) MLP pre takúto aproximáciu?*
- *predpokladá, že funkcia, ktorú ideme aproximovať, je daná*
- *predpokladá, že je k dispozícii neohraničené množstvo skrytých neurónov*

- **MLP s viacerými skrytými vrstvami**

- MLP s 1 skrytou vrstvou:
  - globálna interakcia neurónov - je ťažké vylepšiť aproximáciu v jednom bode bez zhoršenia aproximácie v inom bode

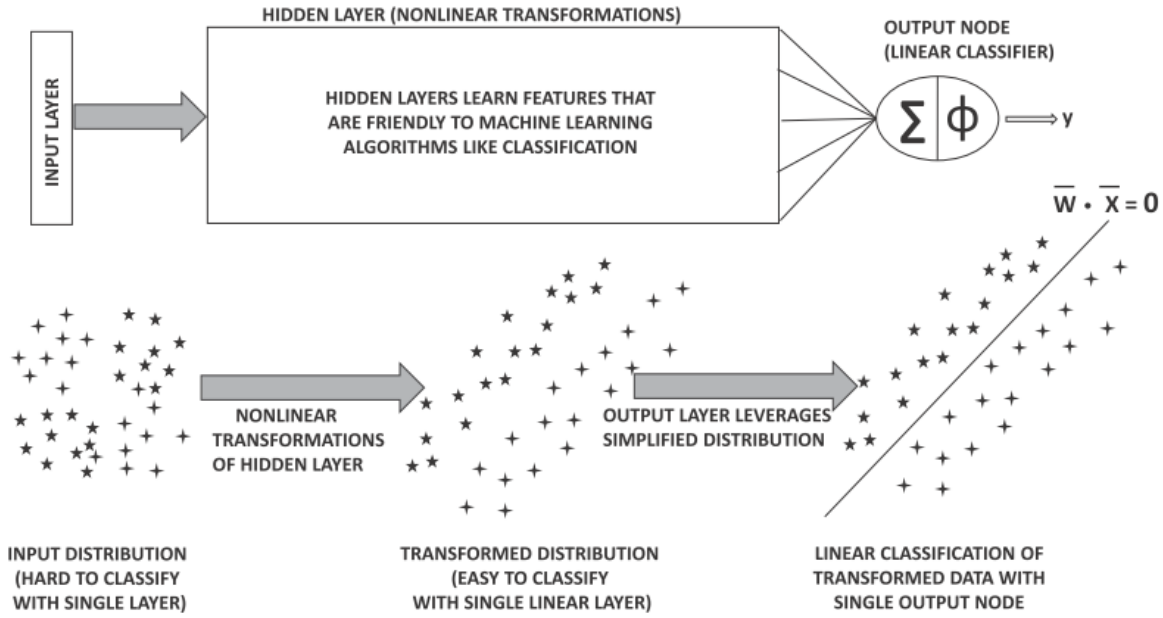
- MLP s 2 skrytými vrstvami:
  - Prvá skrytá vrstva – extrakcia lokálnych príznakov

Niektoré neuróny prvej skrytej vrstvy delia vstupný priestor do oblastí (podpriestorov) a iné neuróny tejto vrstvy sa učia lokálne príznaky charakterizujúce tieto regióny.

  - Druhá skrytá vrstva – extrakcia globálnych príznakov

Neuróny druhej skrytej vrstvy kombinujú výstupy neurónov prvej skrytej vrstvy pracujúcich na podpriestore vstupných dát a učia sa globálne príznaky pre tento podpriestor; mimo neho nereagujú.

The Feature Engineering View of Hidden Layers



- Early layers play the role of feature engineering for later layers.

Aggarwall,C.,C.: Neural Networks and Deep Learning: A Textbook (Second Edition),Springer, 2018

Univerzálna aproximácia

Aproximácia funkcie pomocou viacvrstvového perceptrónu trénovaného algoritmom spätného šírenia s jediným výstupným prvkom sa môže zapísať v nasledovnom kompaktnom tvare:

$$F(\mathbf{x},\mathbf{w}) = \varphi\left(\sum_j w_{oj}\varphi\left(\sum_k w_{jk}\varphi\left(\ldots\varphi\left(\sum_i w_{li}x_i\right)\ldots\right)\right)\right)$$

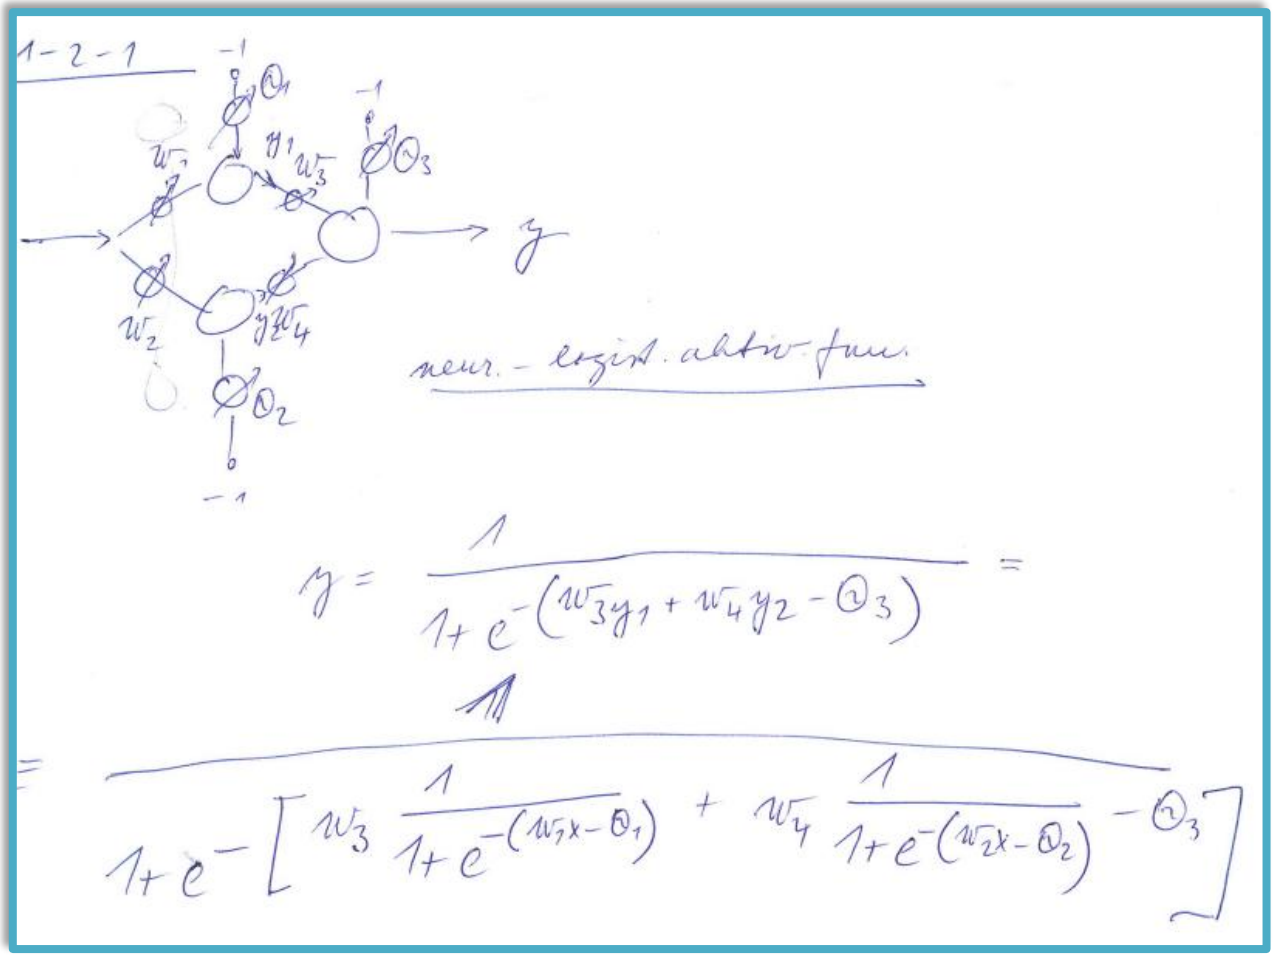
Schéma do seba vnorených nelineárnych funkcií, v prípade sigmoidálnych funkcií sa nazýva "**nested sigmoidal scheme**"

- $\varphi(\cdot)$ je sigmoidálna aktivačná funkcia
- w_{oj} je synaptická váha z neurónu j v poslednej skrytej vrstve do výstupného neurónu o a tak ďalej pre iné synaptické váhy
- x_i je *i*-ty prvok vstupného vektora $\mathbf{x}$

Váhový vektor $\mathbf{w}$ sa vzťahuje na celú množinu synaptických váh zoradených podľa vrstvy, potom podľa neurónov vo vrstve, a potom podľa poradového čísla váhy v neuróne.

Takáto schéma je *univerzálnym aproximátorom* - viacvrstvový perceptrón trénovaný algoritmom spätného šírenia môže aproximovať ľubovoľnú spojitú funkciu do požadovaného stupňa presnosti za predpokladu, že k dispozícii je dostatočne veľa skrytých neurónov.

Výstup MLP konfigurácie 1-2-1



Teorémy o aproximačných schopnostiach MLP

- any continuous function (1 variable or more) on a compact set can be approximated to any accuracy by a linear combination ofsigmoids
  - -> function approximation
    - [for example: K.Hornik et al. Multilayer Feedforward Networks are Universal Approximators, Neural Networks, Vol. 2, pp 359-366 (1989)]

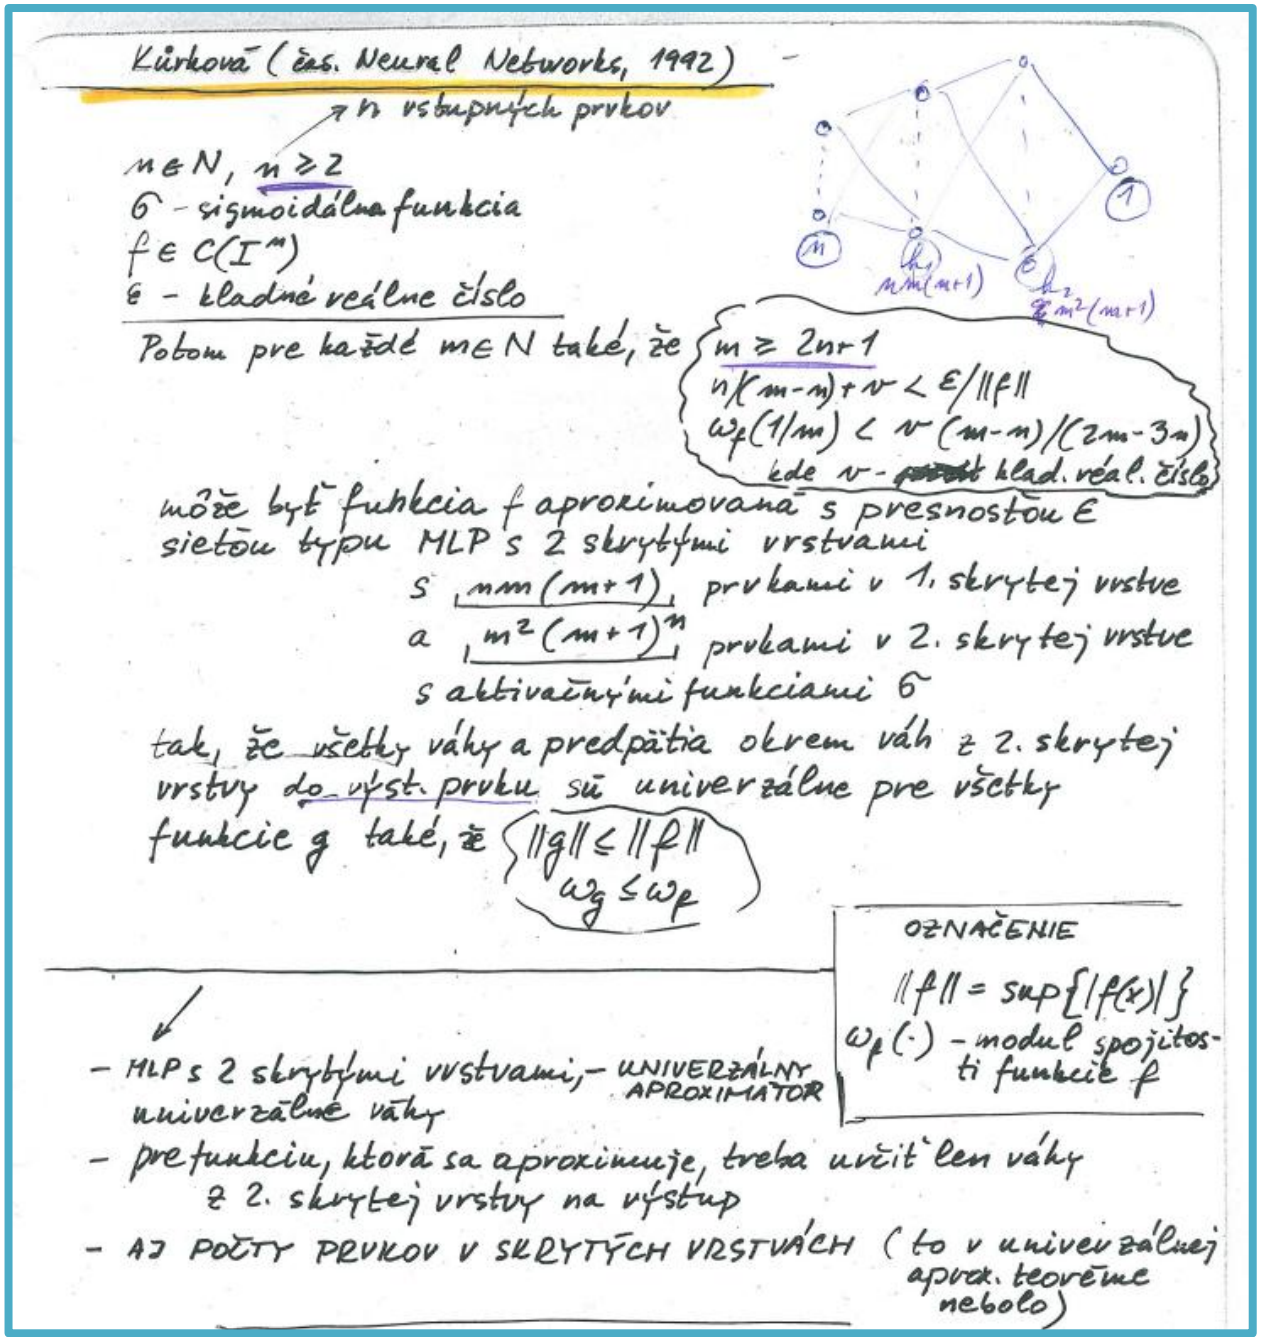
- trained with f(x) = 1 for signal and = 0 for background, the NN function approximates the probability of signal knowing x
  - -> classification (cf Neyman-Pearson test)
    - [for example: D.W.Ruck et al. The Multilayer Perceptron as an Approximation to a Bayes Optimal Discriminant Function, IEEE Transactions on Neural Networks, Vol. 1, nr 4, pp 296-298 (1990)]

http://atlas.web.cern.ch/Atlas/GROUPS/SOFTWARE/INFO/Workshops/9905/slides/thu.7/talk_mai99.pdf

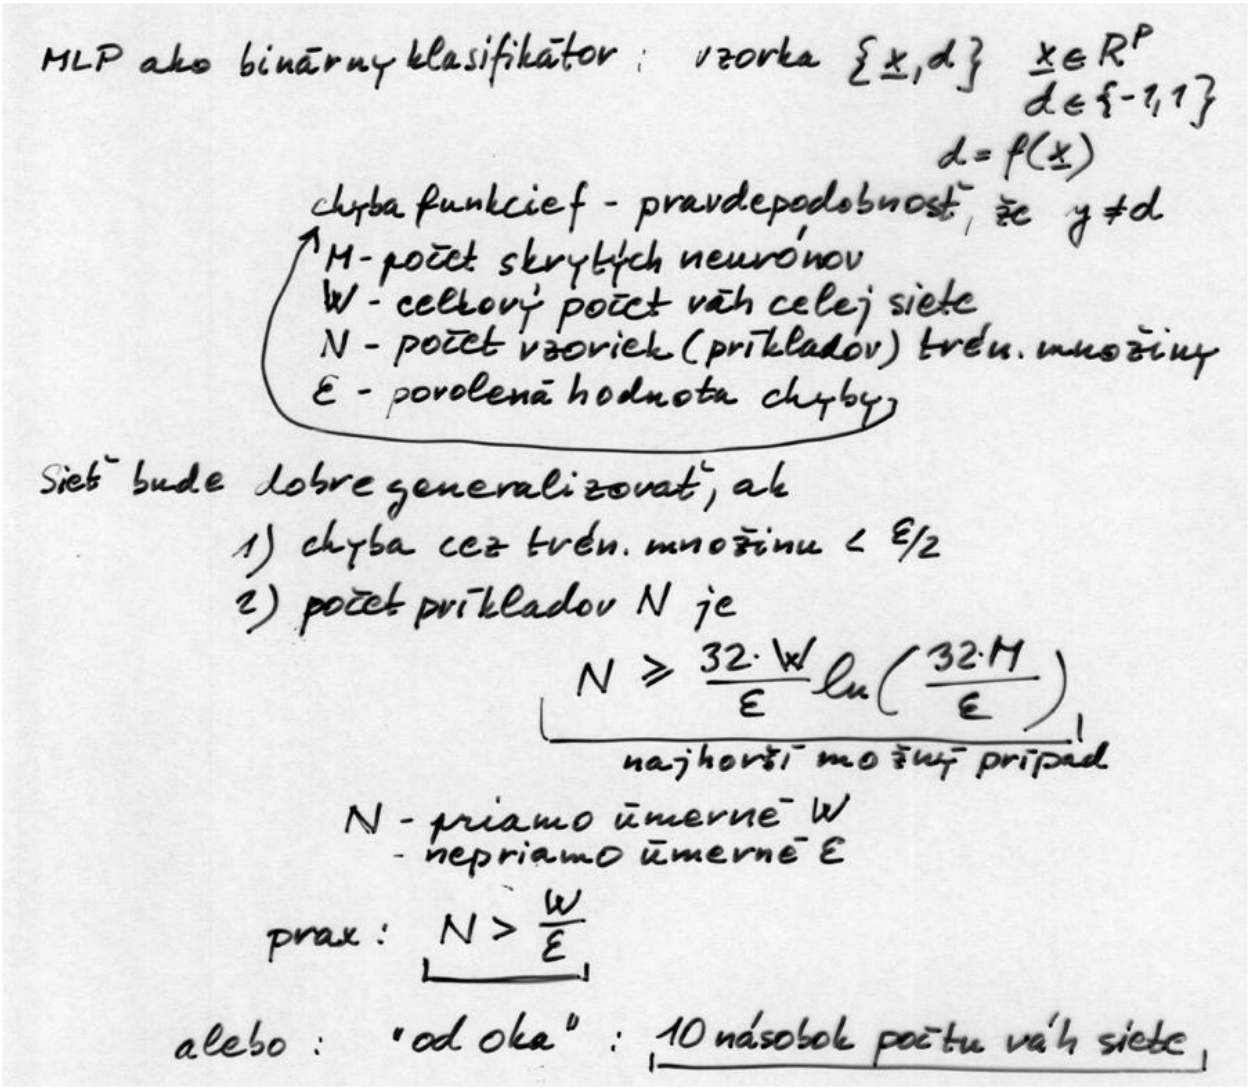
Teorémy o aproximačných schopnostiach MLP

pozri aj napr. Approximation Capabilities of Feedforward Neural Networks for Continuous Functions

V. Kůrková:
Kolmogorov's theorem and multilayer neural networks,
Neural Networks 5: 501-506, 1992



Návrh MLP – „viac hranie sa ako veda“ - napr. veľkosť trénovacej množiny



PREHĽAD:
Gradientový zostup GD, stochastický gradientový zostup SGD, Adam, Adabound, ...

- **gradientový zostup** - štandardný, dávkový (batch)
  - úprava váh po privedení všetkých vzoriek

- **stochastický gradientový zostup SGD**
  - stochastická aproximácia gradientového zostupu (náhrada skutočného gradientu gradientom vypočítaným z náhodne zvolenej podmnožiny trénovacích dát, príp. po privedení každej jednej vzorky)
  - vylepšením bola momentová technika pre backpropagation alg.

- **Adam (adaptive moment estimation)**

  - 2015, článok "Adam: A Method for Stochastic Optimization"
  - optimalizačný algoritmus pre hlboké siete

  - SGD – konšt. rýchlosť učenia, rovnaká úprava všetkých parametrov (váh)

  - Adam – adaptívne rýchlosti učenia pre rôzne váhy počítané odhadmi prvých a druhých momentov (stredných hodnôt a rozptylov) gradientov
    - Adam = Adagrad + RMSprop
      - **AdaGrad (adaptive gradient algorithm)** – „základnú" rýchlosť učenia upravuje pre rôzne parametre (váhy)

      - **RMSProp (Root Mean Square Propagation**) – tiež rôzne úpravy pre rôzne parametre, berie do úvahy priemery magnitúd predchádzajúcich gradientov

    - Pozn.: v Matlabe funkcia *adamupdate*

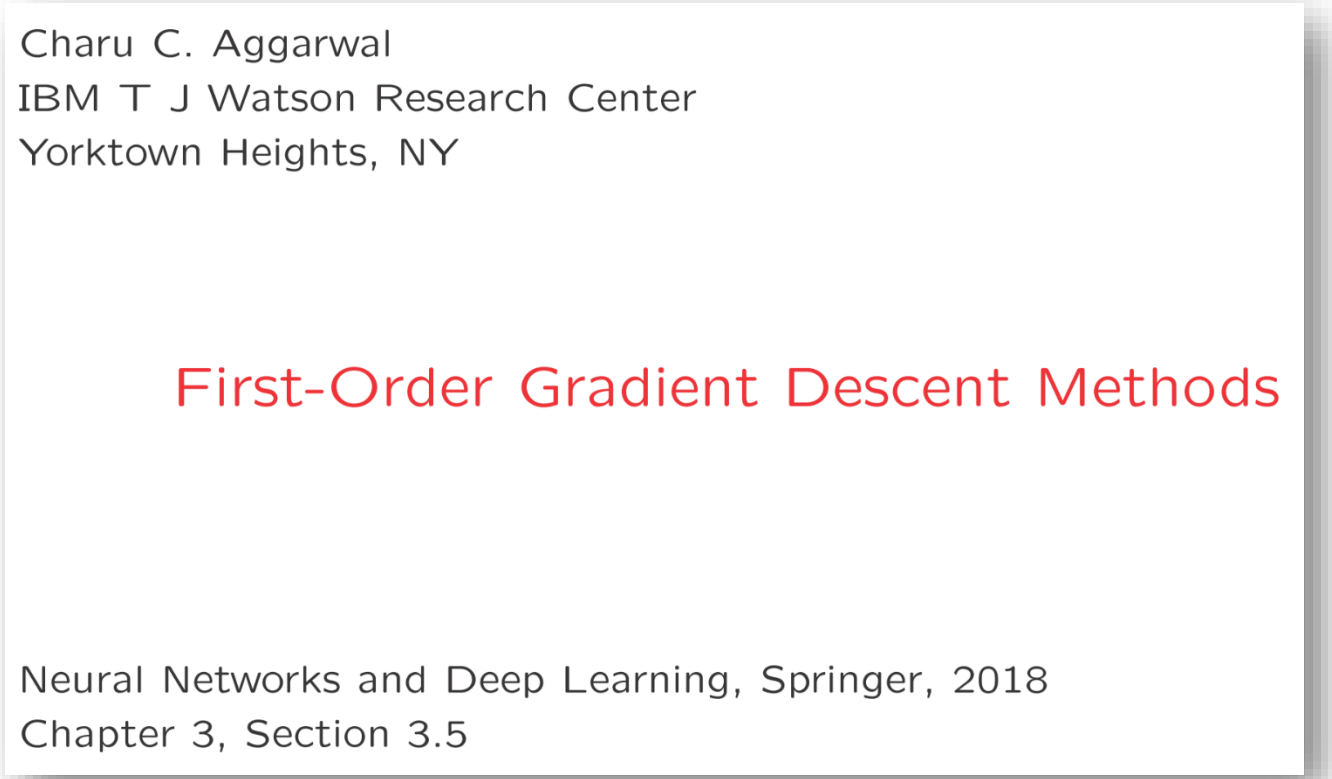
- **AMSGrad**
  - na úpravu parametrov používa maximum predchádzajúcich kvadrátov gradientov namiesto exponenciálneho priemerovania

- **Adabound, AMSBound**
  - 2019, článok „Adaptive Gradient Methods with Dynamic Bound of Learning Rate“
    - „new variants of Adam and AMSGrad, called AdaBound and AMSBound respectively, which employ dynamic bounds on learning rates to achieve a gradual and smooth transition from adaptive methods to SGD and give a theoretical proof of convergence“

Pre predstavu - vizualizácia algoritmov: pozri obr. 5 a obr. 6 v An overview of gradient descent optimization algorithms

Pozri:

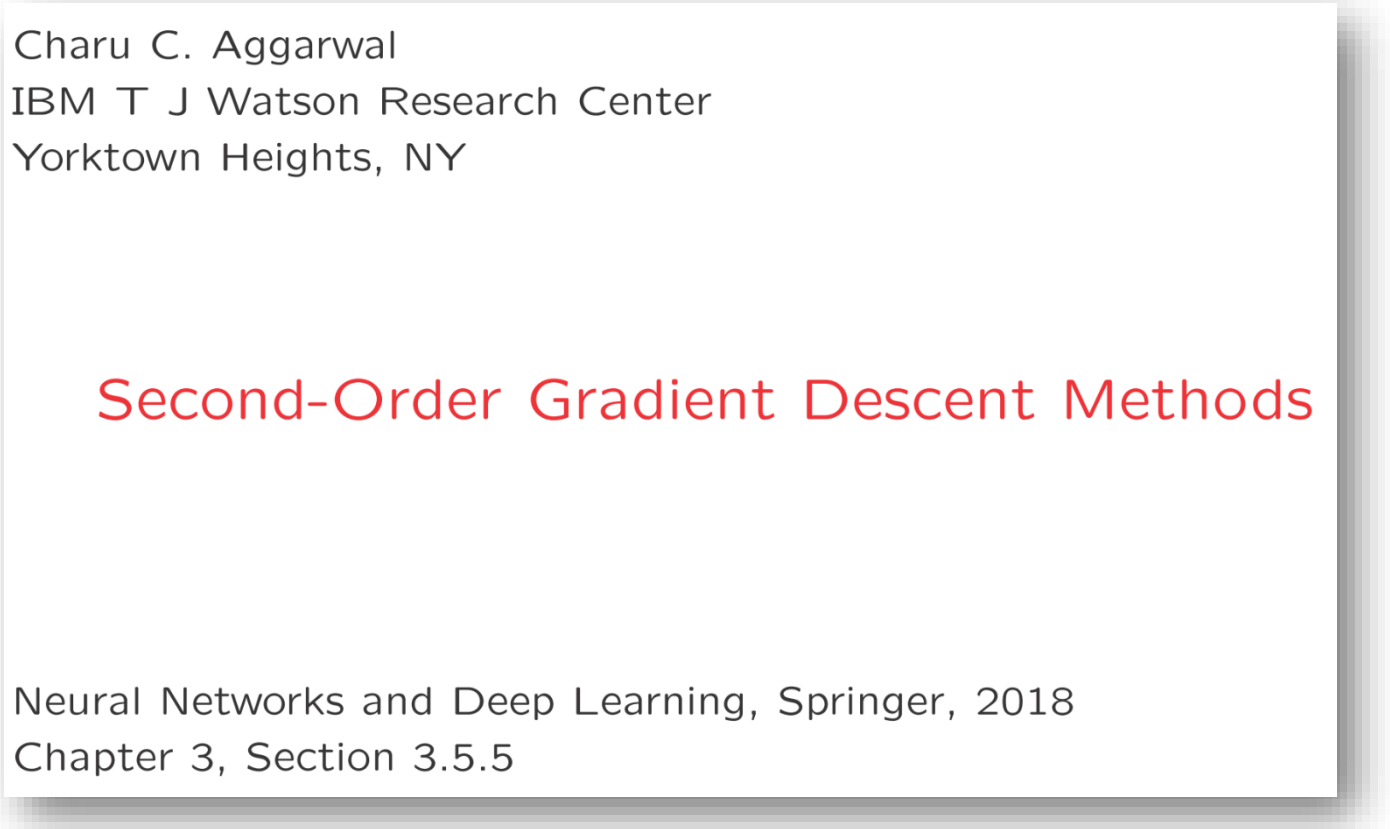
[04-MLP pridavok3-First-Order Gradient Descent Methods.pdf]



Aggarwall,C.,C.: Neural Networks and Deep Learning: A Textbook (Second Edition),Springer, 2018

Pozri:

[04-MLP pridavok4-Second-Order Gradient Descent Methods.pdf]



Aggarwall,C.,C.: Neural Networks and Deep Learning: A Textbook (Second Edition),Springer, 2018

Zjednodušovanie sietí - network pruning:

- používa sa aj pre iné siete, nielen pre MLP
- cieľ – minimalizovať veľkosť siete pri zachovaní správnej činnosti
  - menšia sieť lepšie generalizuje

1. rast siete (network growing)
   - začína sa s min. konfiguráciou, potom pridanie nových neurónov alebo vrstiev
   - napr. kaskádová korelácia (cascade correlation)
     - začína sa s min. konfiguráciou (iba vst. a výst. vrstva), potom postupné pridávanie skrytých neurónov
     - nie do vrstiev, ale kaskádovanie – pridaný neurón dostáva vstupy zo vstupnej vrstvy a aj od všetkých dovtedy pridaných neurónov
     - vstupné váhy pridaného neurónu sa zmrazia, trénujú sa iba výstupné váhy

2. zmenšovanie siete (network pruning)
   - útlm váh (weight decay)
     - niektorým váham v sieti sú vnútené hodnoty blízke nule, iným je dovolené mať veľké hodnoty
     - váhy sa rozdelia na „užitočné“ a „prebytočné“
     - zmenšuje sa počet váh, nie neurónov
   - eliminácia váh (weight elimination)
     - najprv trénovanie, potom odstránenie neurónov
   - optimal brain damage ☺
     - využívajú sa druhé derivácie chybového povrchu

decay – zánik, úpadok, hnitie, rozklad, útlm

3. iné
   - evolučné algoritmy (evolutionary computing)
     - genetické algoritmy
       - ✓ napr. pre určenie počtu parametrov, na ktoré sa má pruning aplikovať (počas učenia podľa vývoja váh a vývoja generalizácie siete)