Siete s radiálnymi bázovými funkciami

(konvenčné aj hlboké)

TÉMY

- *mnohorozmerná interpolácia a aproximácia radiálnymi bázovými funkciami*
- *interpolácia*
- *RBF prístup k interpolácii*
- *radiálne bázové funkcie (RBF)*
- *aproximácia*
- *RBF sieť*
- *učenie RBF siete – 3 kroky*
- *regularizačná teória*
- *porovnanie RBF siete a MLP*

- *hlboké RBF siete*

RBF SIEŤ - sieť s radiálnymi bázovými funkciami (RBF network, radial-basis function network)

Mnohorozmerná interpolácia a aproximácia radiálnymi bázovými funkciami

- RBF sieť - navrhnutá z pohľadu *aproximačného problému* v mnohorozmernom priestore

- skryté neuróny - reprezentujú množinu funkcií, ktoré tvoria bázu pre transformáciu vstupných vektorov do priestoru skrytých neurónov

    - tieto funkcie sa nazývajú *RBF - radiálne bázové funkcie ("radial basis function")*

Interpolácia

Ak je daná množina N *rôznych bodov* $\{\boldsymbol{x}_i \in R^p | i = 1, \dots, N\}$ *a* N *reálnych čísel* $\{d_i \in R | i = 1, \dots, N\}$, *potom nájdi funkciu* $f: R^p \to R$ *spĺňajúcu podmienky:*

$$f(\boldsymbol{x}_i) = d_i, \forall i = 1, \dots, N$$

funkcia *f* musí prechádzať všetkými bodmi trénovacích dát

RBF prístup k interpolácii:

- *N* radiálnych bázových funkcií ϕ_i

$$\phi_i: R^p \to R, \phi_i = \phi(\|\boldsymbol{x} - \boldsymbol{c}_i\|), \quad i = 1, \dots, N$$

  - $\varphi: R_0^+ \to R$
  - $\mathbf{x} \in R^p$
  - $\|\cdot\|$ - norma na R^p (zväčša euklidovská)
  - $\mathbf{c}_i \in R^p$ - stredy (centrá) RBF
  - funkcie $\phi_i, i = 1, \dots, N$ tvoria bázu lineárneho priestoru funkcií, a teda interpolačná funkcia *f* bude ich lineárnou kombináciou:

centrá radiálnych bázových funkcií sa nastavia do daných bodov $\mathbf{x}_i$, t.j. $\mathbf{c}_i = \mathbf{x}_i \in R^p, i = 1, \dots, N$

$$f(\boldsymbol{x}) = \sum_{j=1}^{N} w_j \phi_j = \sum_{j=1}^{N} w_j \phi(\|\boldsymbol{x} - \boldsymbol{c}_j\|)$$

zároveň chceme, aby
$f(\mathbf{x}_i) = d_i, \qquad \forall i = 1,\ldots,N$
(tak dosaďme ☺)

$$f(\mathbf{x}_i) = \sum_{j=1}^{N} w_j \phi(\|\mathbf{x} - \mathbf{c}_j\|) = d_i, \quad i = 1,\ldots N$$

sústava lineárnych rovníc pre neznáme koeficienty w_j

prvky matice sú
$\phi_{ij} = \phi(\|\mathbf{x}_i - \mathbf{c}_j\|)$

$$\begin{bmatrix} \phi_{11} & \cdots & \phi_{1N} \\ & & \\ \phi_{N1} & \cdots & \phi_{NN} \end{bmatrix} \begin{bmatrix} w_1 \\ \\ w_N \end{bmatrix} = \begin{bmatrix} d_1 \\ \\ d_N \end{bmatrix}$$

, označme to: $\boldsymbol{\Phi}\,\mathbf{w} = \mathbf{d}$

ak matica $\boldsymbol{\Phi}$ je regulárna

RIEŠENIE: $\mathbf{w} = \boldsymbol{\Phi}^{-1}\mathbf{d}$

Ale kde je neurónová sieť?
Tu ju vôbec netreba!

RBF - radiálne bázové funkcie ("radial basis functions")

lokalizované bázové funkcie

$\phi \to 0$ pre $|x| \to \infty$

$$\phi(x) = \exp\left(-\frac{x^2}{2\sigma^2}\right)$$

gaussovská funkcia, σ je parameter (*šírka*)

$\phi_i: R^p \to R, \phi_i = \phi(\|\boldsymbol{x} - \boldsymbol{c}_i\|)$,
čiže $\phi_i = exp\left(-\frac{\|\boldsymbol{x}-\boldsymbol{c}_i\|^2}{2\delta^2}\right)$

$$\phi(x) = \left(x^2 + \sigma^2\right)^{-\alpha}, \alpha > 0$$

iný príklad lokalizovanej RBF

nelokalizované bázové funkcie

$\phi \to \infty$ pre $|x| \to \infty$

$\phi(x) = x^2 \ln(x)$ thin-plate spline

$\phi(x) = \left(x^2 + \sigma^2\right)^{\beta}, 0 < \beta < 1$

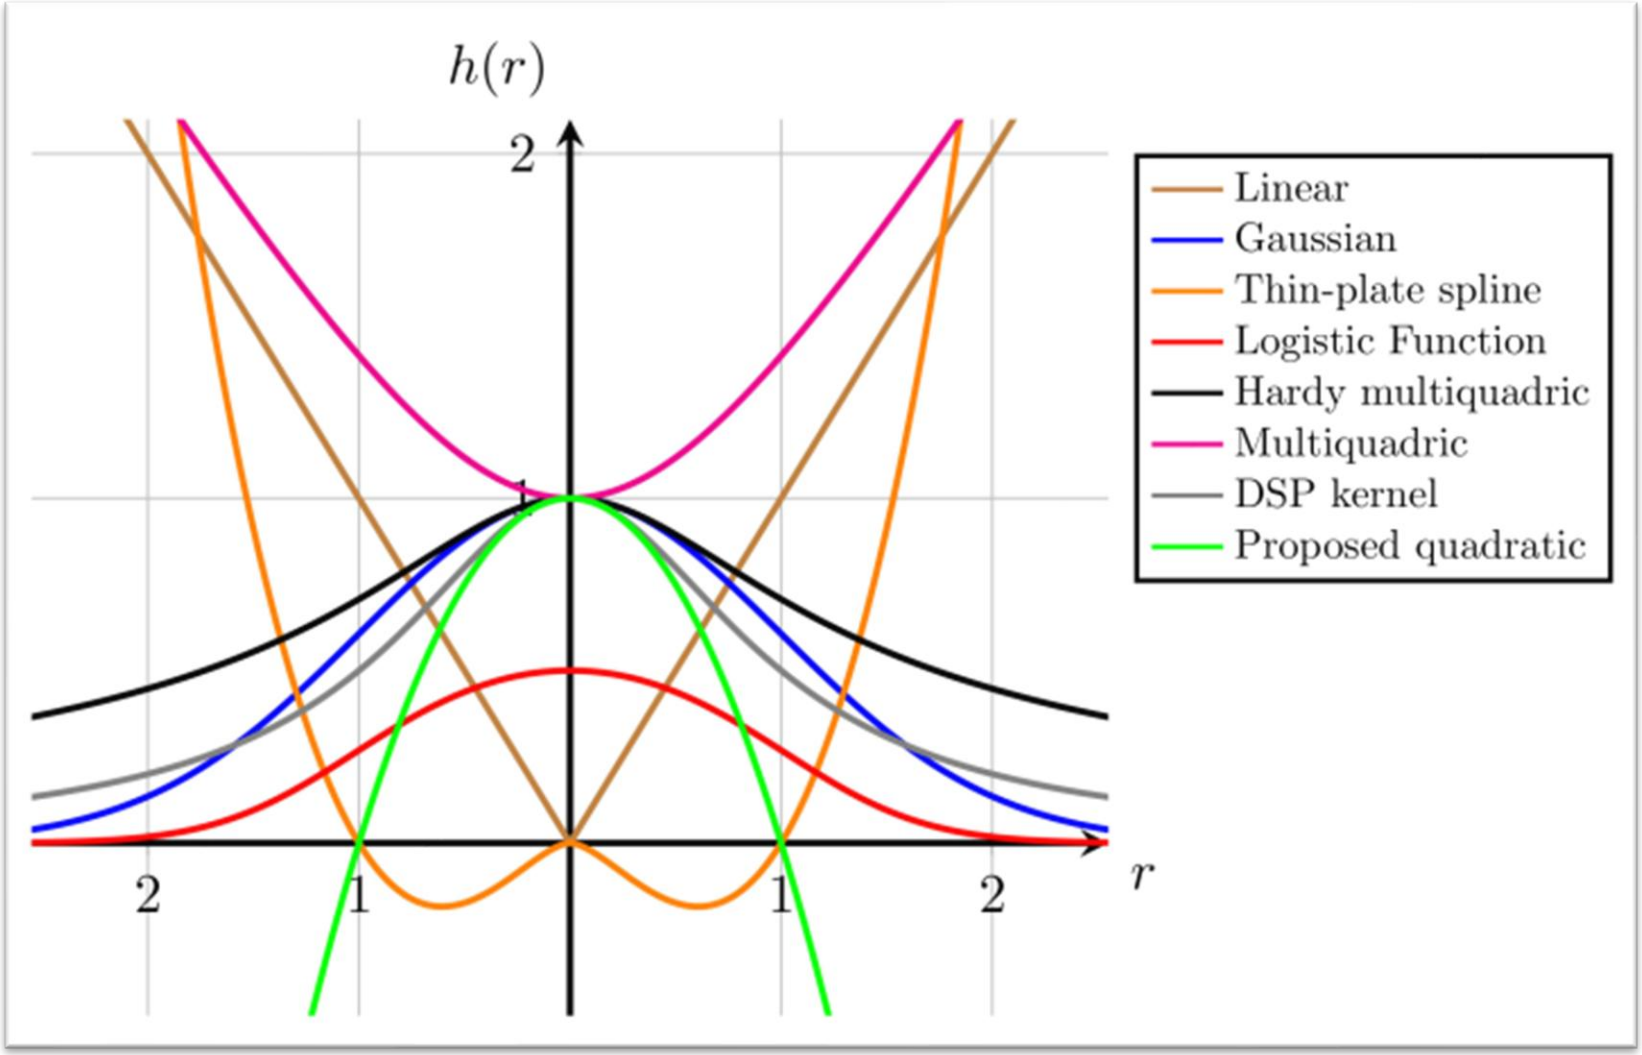
ak $\beta = 1/2$, tzv. multikvadratická funkcia (multiquadrics)

$\phi(x) = x^3$ kubická funkcia

$\phi(x) = x$ lineárna funkcia

$\phi_i : R^p \to R, \ \phi_i = \phi\left(\left\|\mathbf{x} - \mathbf{c}_i\right\|\right)$,

čiže $\phi_i = \left\|\mathbf{x} - \mathbf{c}_i\right\|$



M. Amirian and F. Schwenker, "Radial Basis Function Networks for Convolutional Neural Networks to Learn Similarity Distance Metric and Improve Interpretability," in *IEEE Access*, vol. 8, pp. 123087-123097, 2020, doi: 10.1109/ACCESS.2020.3007337

- máme teda interpolačnú schému, ale nevýhoda:
  - počet radiálnych bázových funkcií ϕ_i sa rovná počtu bodov, ktoré máme interpolovať
  - typickým prípadom však je, že počet daných bodov je značne väčší (*aproximačný problém*)

Aproximácia

- máme N bodov a n_0 funkcií ϕ, pričom platí $n_0 < N$

- <u>problémy</u>:
  - ? určenie centier $\mathbf{c}_i$, $i = 1,\ldots,n_0$
  - ? matica $\mathbf{\Phi}$ už nie je štvorcová (je typu *N* x n_0), a teda neexistuje jej inverzia

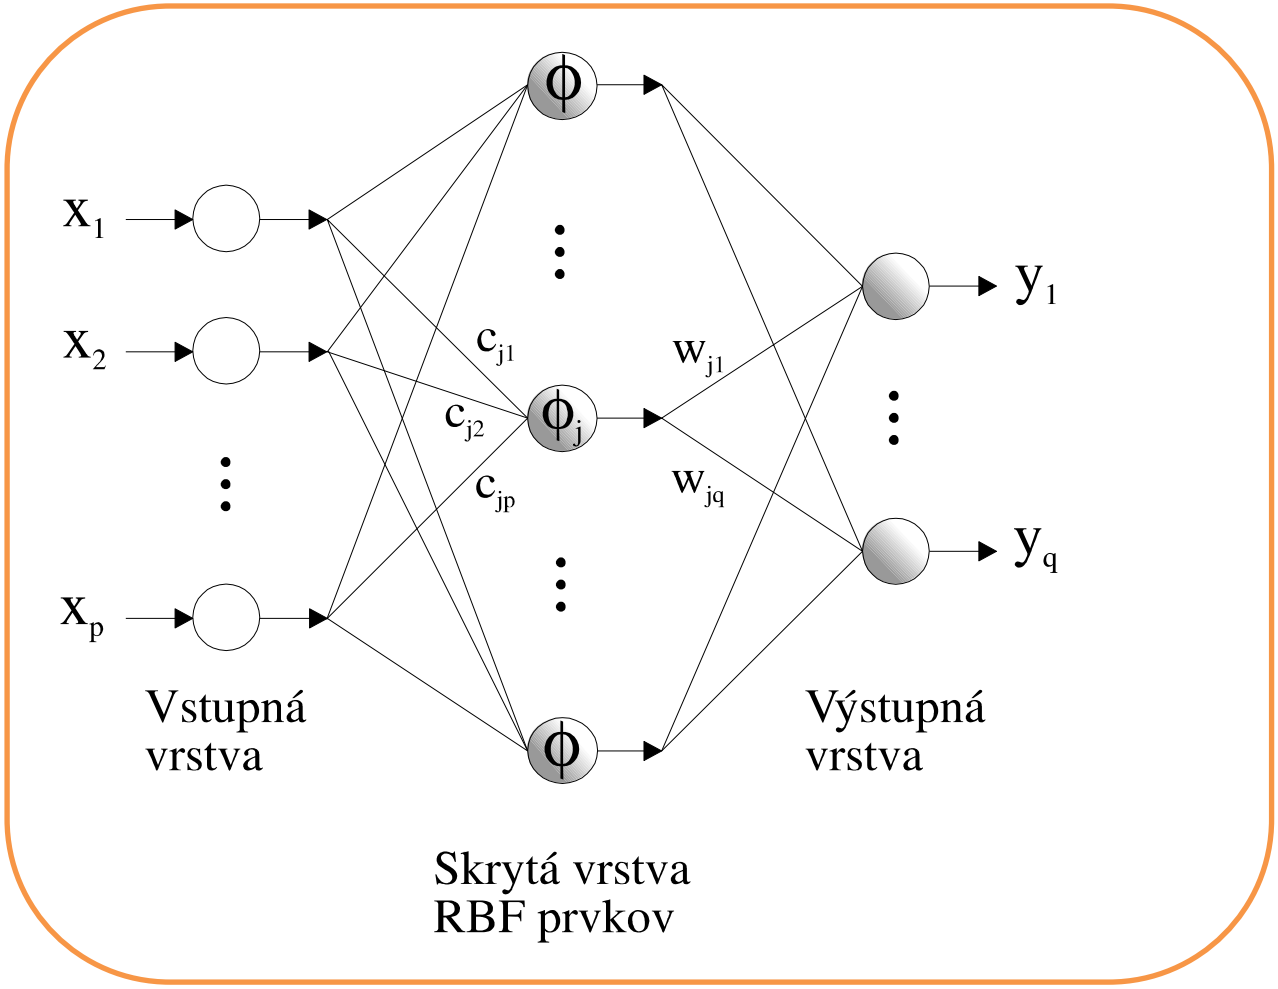
- <u>RIEŠENIA</u>:
  1) lineárna optimalizácia (metóda najmenších štvorcov)
  2) pseudoinverzná matica $\mathbf{\Phi}^+$

     riešením je $\mathbf{w} = \mathbf{\Phi}^+ \mathbf{d}$
  3) neurónová sieť – RBF sieť

$\mathbf{\Phi}^+$ má vlastnosť $\mathbf{\Phi}^+\mathbf{\Phi} = \mathbf{I}_{n0}$, kde $\mathbf{I}_{n0}$ je jednotková matica typu $n_0 \times n_0$ a hodnosť $\mathbf{\Phi}$ je n_0

počíta sa ako $\mathbf{\Phi}^+ = (\mathbf{\Phi}^T\mathbf{\Phi})^{-1}\mathbf{\Phi}^T$

RBF sieť (je pre aproximáciu, konfigurácia $p - n_0 - q$)



Trénovacia množina pre RBF sieť pozostáva zo vstupno-výstupných párov $(\mathbf{x}_k, \mathbf{d}_k), k = 1, \ldots, N$, kde $\mathbf{x}_k \in R^p$ je vstup a $\mathbf{d}_k \in R^q$ je žiadaná odpoveď

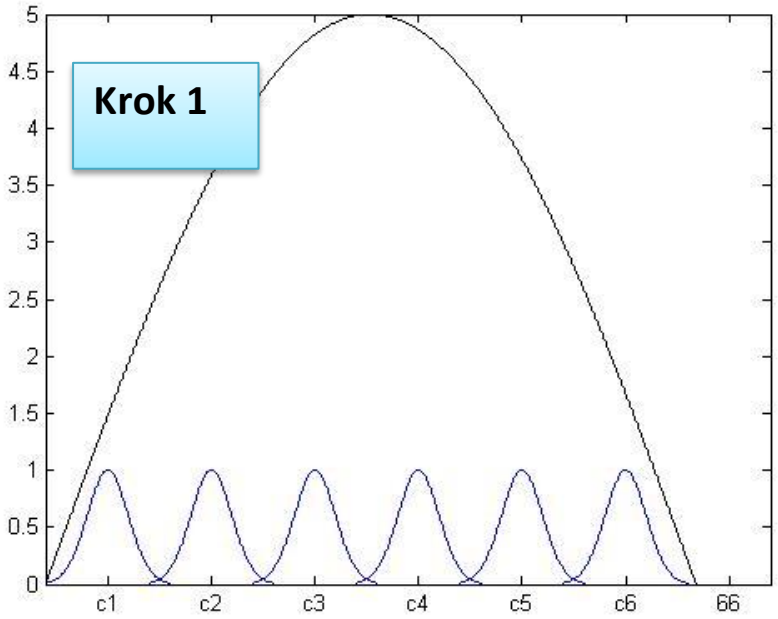
RBF sieť pre aproximačný problém

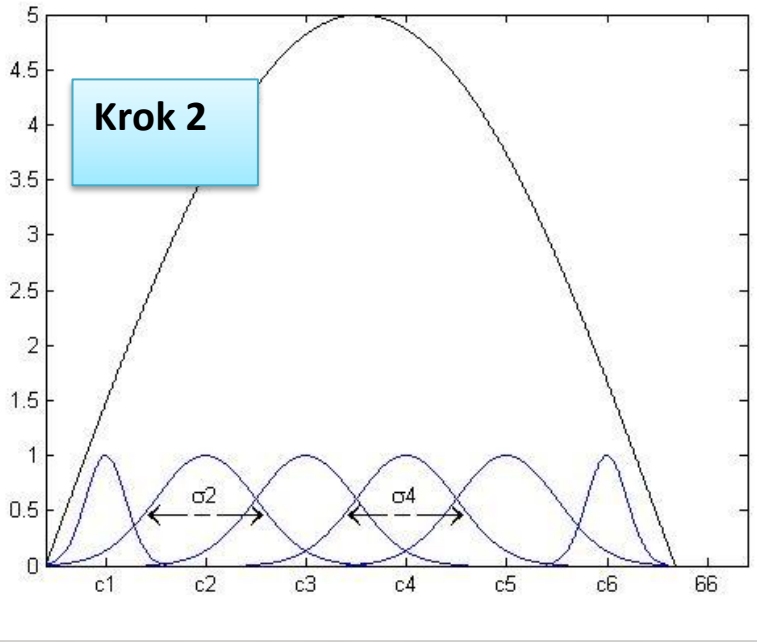
- Počet bázových funkcií n_0 sa nemusí rovnať počtu daných bodov N, pričom platí $n_0 < N$.

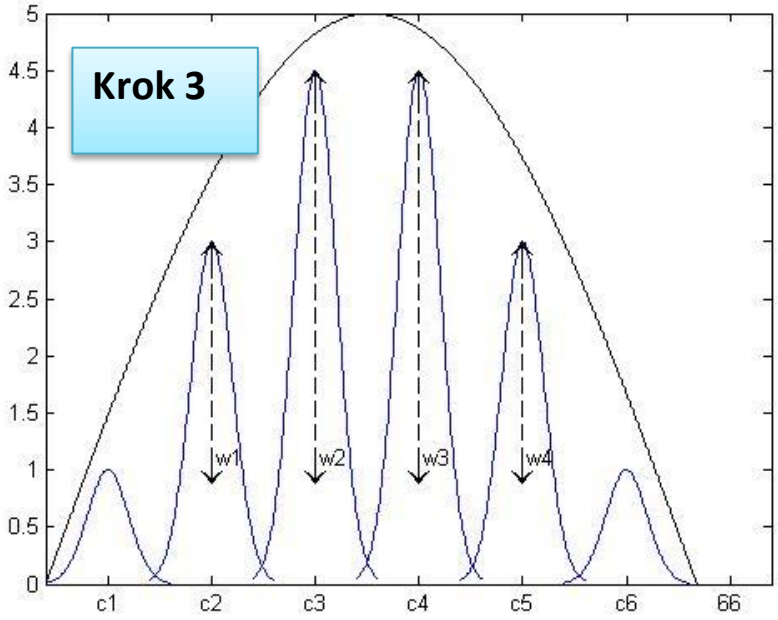
- Centrá bázových funkcií nemusia byť nastavené do daných vstupných bodov. Určenie centier sa tak stáva súčasťou procesu učenia.

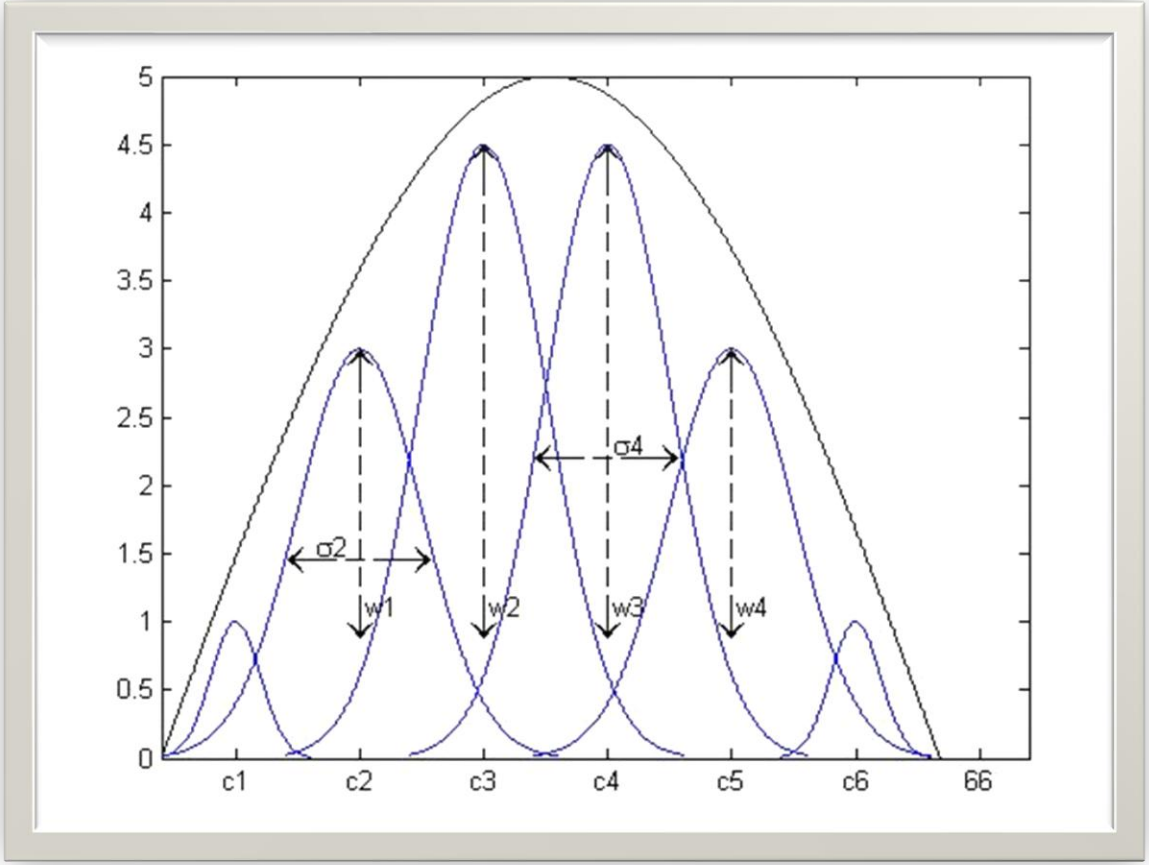
- Namiesto rovnakého parametra σ má každá bázová funkcia svoj vlastný parameter σ_j, ktorý sa tiež určí počas učenia siete.

- Pre lineárnu kombináciu robenú vo výstupnej vrstve sa pridá prah pre každý výstupný neurón. Prahy kompenzujú rozdiel medzi priemernou hodnotou aktivácií bázových funkcií a korešpondujúcou priemernou hodnotou žiadaných odpovedí.

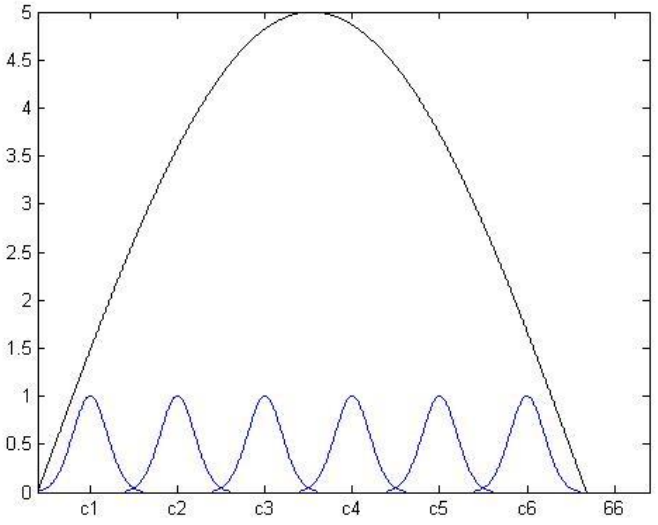

Krok 1
5
4.5
4
3.5
3
2.5
2
1.5
1
0.5
0
c1
c2
c3
c4
c5
c6
66


Krok 2
σ2
σ4
5
4.5
4
3.5
3
2.5
2
1.5
1
0.5
0
c1
c2
c3
c4
c5
c6
66


Krok 3
w1
w2
w3
w4
5
4.5
4
3.5
3
2.5
2
1.5
1
0.5
0
c1
c2
c3
c4
c5
c6
66


σ2
σ4
w1
w2
w3
w4
5
4.5
4
3.5
3
2.5
2
1.5
1
0.5
0
c1
c2
c3
c4
c5
c6
66

UČENIE RBF SIETE - 3 kroky



1. určenie centier skrytých prvkov

- náhodný výber n_0 bodov z daných vstupov, ktoré nastavíme ako hodnoty centier
- rovnomerné rozdelenie centier vo vstupnom priestore
- samoorganizované učenie (jednoduché zhlukovanie, Kohonenova samoorganizujúca sa mapa)
  - napr. k-priemerovací zhlukovací algoritmus ("k-means clustering algorithm")

$$E_1\left(\mathbf{c}_1,\ldots,\mathbf{c}_{n_0}\right)=\sum_{i=1}^{N}\sum_{j=1}^{n_0}\delta_{ij}\left\|\mathbf{x}_i-\mathbf{c}_j\right\|^2$$

  - δ_{ij} je funkcia ("cluster membership function") reprezentovaná maticou núl a jednotiek typu $N\times n_0$ s jedinou jednotkou v každom riadku
  - ak $\mathbf{x}_i$ patrí do zhluku (klastra) okolo centra $\mathbf{c}_j$, potom $\delta_{ij}=1$

- k-priemerovací zhlukovací algoritmus:

1) Distribuuj centrá $\mathbf{c}_j$ náhodne v priestore vstupov.
2) V čase n rob nasledovné:
   a) Nájdi centrum $\mathbf{c}_c(n)$, ktoré je najbližšie vstupu $\mathbf{x}(n)$
   b) Posuň centrum $\mathbf{c}_c(n)$ smerom k $\mathbf{x}(n)$ podľa vzťahu

$$\mathbf{c}_c(n+1) = \mathbf{c}_c(n) + \theta(n)\left\|\mathbf{x}(n) - \mathbf{c}_c(n)\right\|$$

kde $\theta(n)$ je parameter rýchlosti učenia s hodnotou z intervalu od 0 po 1. Zvyčajne má veľkú hodnotu na začiatku a postupne klesá k nule.

2. nastavenie prídavných parametrov RBF

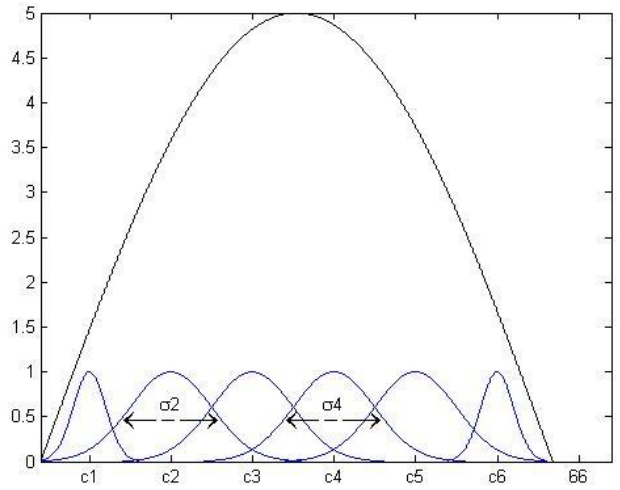
$$E_2(\sigma_1,\ldots,\sigma_{n_0}) = \frac{1}{2}\sum_{r=1}^{n_0}\left[\sum_{s=1}^{n_0}\left(\frac{\|c_s - c_r\|}{\sigma_r}\right)^2 \exp\left[-\left(\frac{\|c_s - c_r\|}{\sigma_r}\right)^2\right] - P\right]^2$$

- minimalizácia E_2 vzhľadom na σ_r
- parameter P riadi prekrytie oblastí prislúchajúcich rôznym prvkom

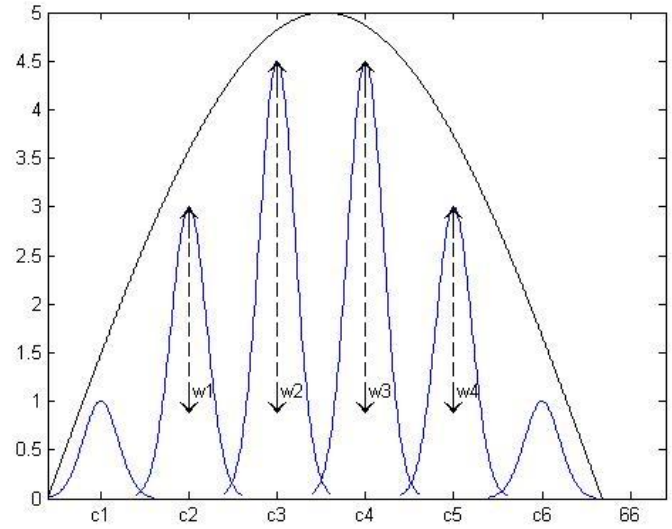
- väčšinou sa táto minimalizácia obchádza rôznymi heuristickými postupmi, napr. šírka gaussovskej RBF:

  - ➢ šírka funkcie pre nejaký prvok sa nastaví na druhú odmocninu strednej kvadratickej hodnoty vzdialeností prvku od jeho najbližších susedov

  - ➢ nastavenie rovnakej šírky pre všetky RBF prvky



3. nastavenie váh $\mathbf{w}_{sr}$



$$E_3(\mathbf{W}) = \frac{1}{2}\sum_{l=1}^{N}\left\|\mathbf{d}_l - f(\mathbf{x}_l)\right\|^2 = \frac{1}{2}\sum_{l=1}^{N}\sum_{k=1}^{q}\left(d_{kl} - f_k(\mathbf{x}_l)\right)^2$$

- $f(\mathbf{x}_l) = \mathbf{y}_l$, $f_k(\mathbf{x}_l) = y_{kl}$, $\mathbf{W}$ je matica $[w_{sr}]$, $w_{sr}, s = 1,\ldots,q$ a $r = 1,\ldots,n_0$
- riešenie:

$$\frac{\partial E_3}{\partial w_{sr}} = 0 \implies w_{sr} = \sum_{j=1}^{n_0}\left[\Phi^+\right]_{jr}\left(\sum_{l=1}^{N}\phi_j(\mathbf{x}_l)d_{kl}\right)$$

kde matica $\mathbf{\Phi}$ je definovaná ako $[\Phi]_{jr} = \sum_{l=1}^{N}\phi_j(\mathbf{x}_l)\phi_r(\mathbf{x}_l)$ a $\mathbf{\Phi}^+$ je pseudoinverzná matica

Regularizačná teória

- regularizačná teória reguluje hladkosť mapovania (mapovanie má byť hladké)

$$E_3'(\mathbf{W}) = E_3 + \gamma E_R$$

parameter γ riadi pomer medzi E_3 a E_R

$$E_R(\mathbf{W}) = \frac{1}{2}\sum_{l=1}^{N}\sum_{k=1}^{q}\sum_{i=1}^{p}\left(\frac{\partial^2 f_k(\mathbf{x}_l)}{\partial x_i^2}\right)^2$$

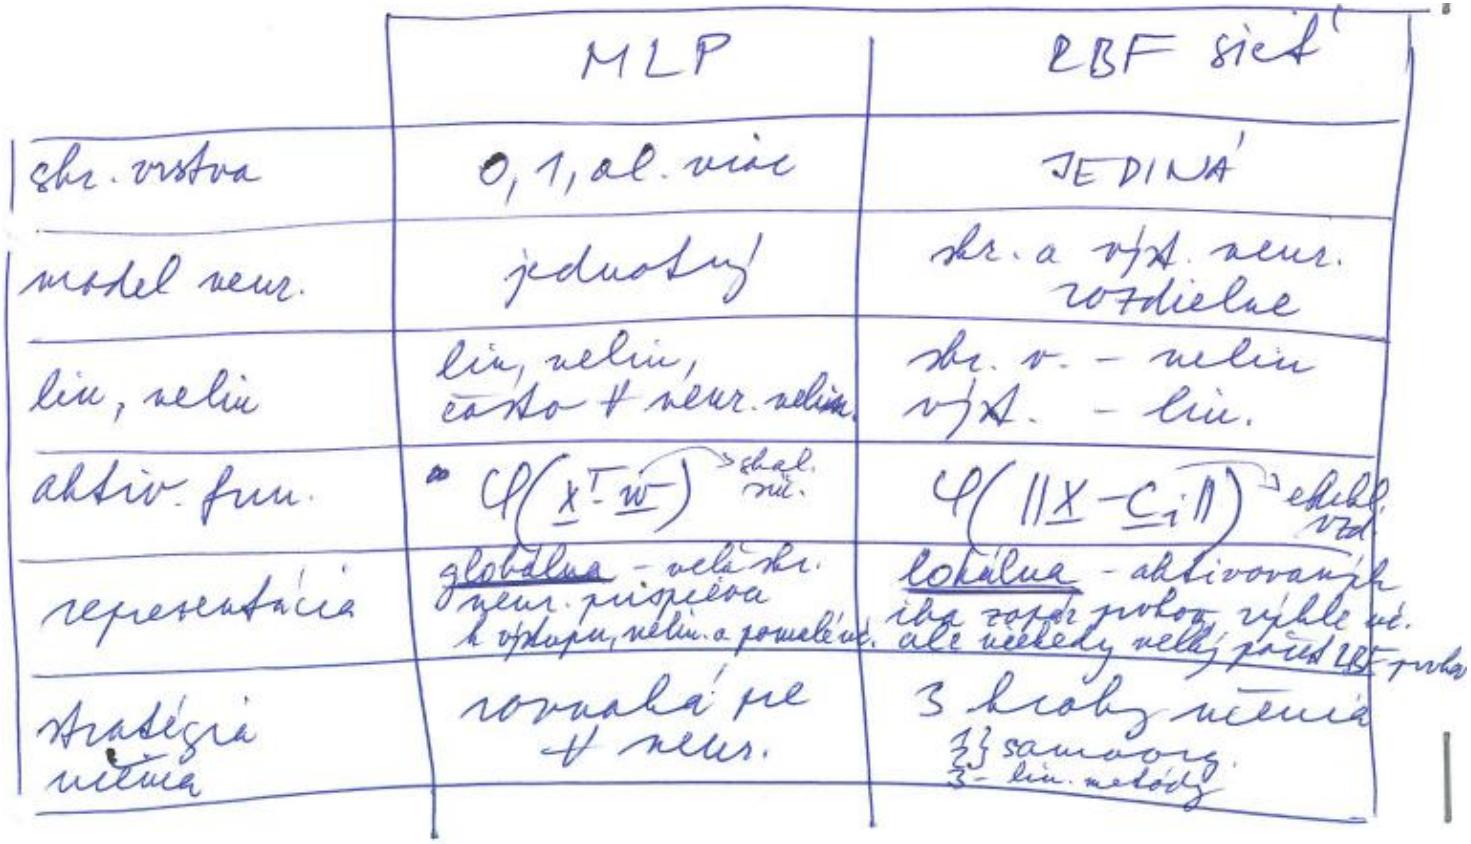
regularizačný člen E_R sa volí tak, aby bol veľký pre neželané vlastnosti, ako sú napríklad veľké oscilácie

- riešenie:

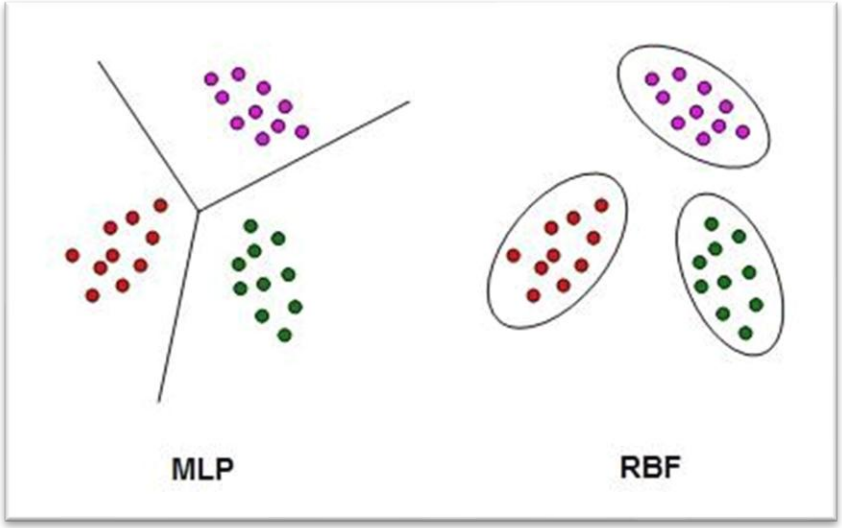
$$\frac{\partial E_3'}{\partial w_{sr}} = 0 \implies w_{sr} = \sum_{j=1}^{n_0}\left[\Psi^+\right]_{jr}\left(\sum_{l=1}^{N}\phi_j(\mathbf{x}_l)d_{kl}\right)$$

kde matica Ψ má tvar $\left[\Psi\right]_{jr} = \sum_{l=1}^{N}\left[\phi_j(\mathbf{x}_l)\phi_r(\mathbf{x}_l) + \gamma\sum_{i=1}^{p}\frac{\partial^2\phi_j(\mathbf{x}_l)}{\partial x_i^2}\frac{\partial^2\phi_r(\mathbf{x}_l)}{\partial x_i^2}\right]$

porovnanie RBF siete a MLP



- pekná sumarizácia RBF sietí:
  - *Radial Basis Functions Neural Networks — All we need to know*



Hlboké RBF siete

- M. Amirian and F. Schwenker, "Radial Basis Function Networks for Convolutional Neural Networks to Learn Similarity Distance Metric and Improve Interpretability," in *IEEE Access*, vol. 8, pp. 123087-123097, 2020, doi: 10.1109/ACCESS.2020.3007337.

„embeddings“ = príznaky, vstupy do RBF siete

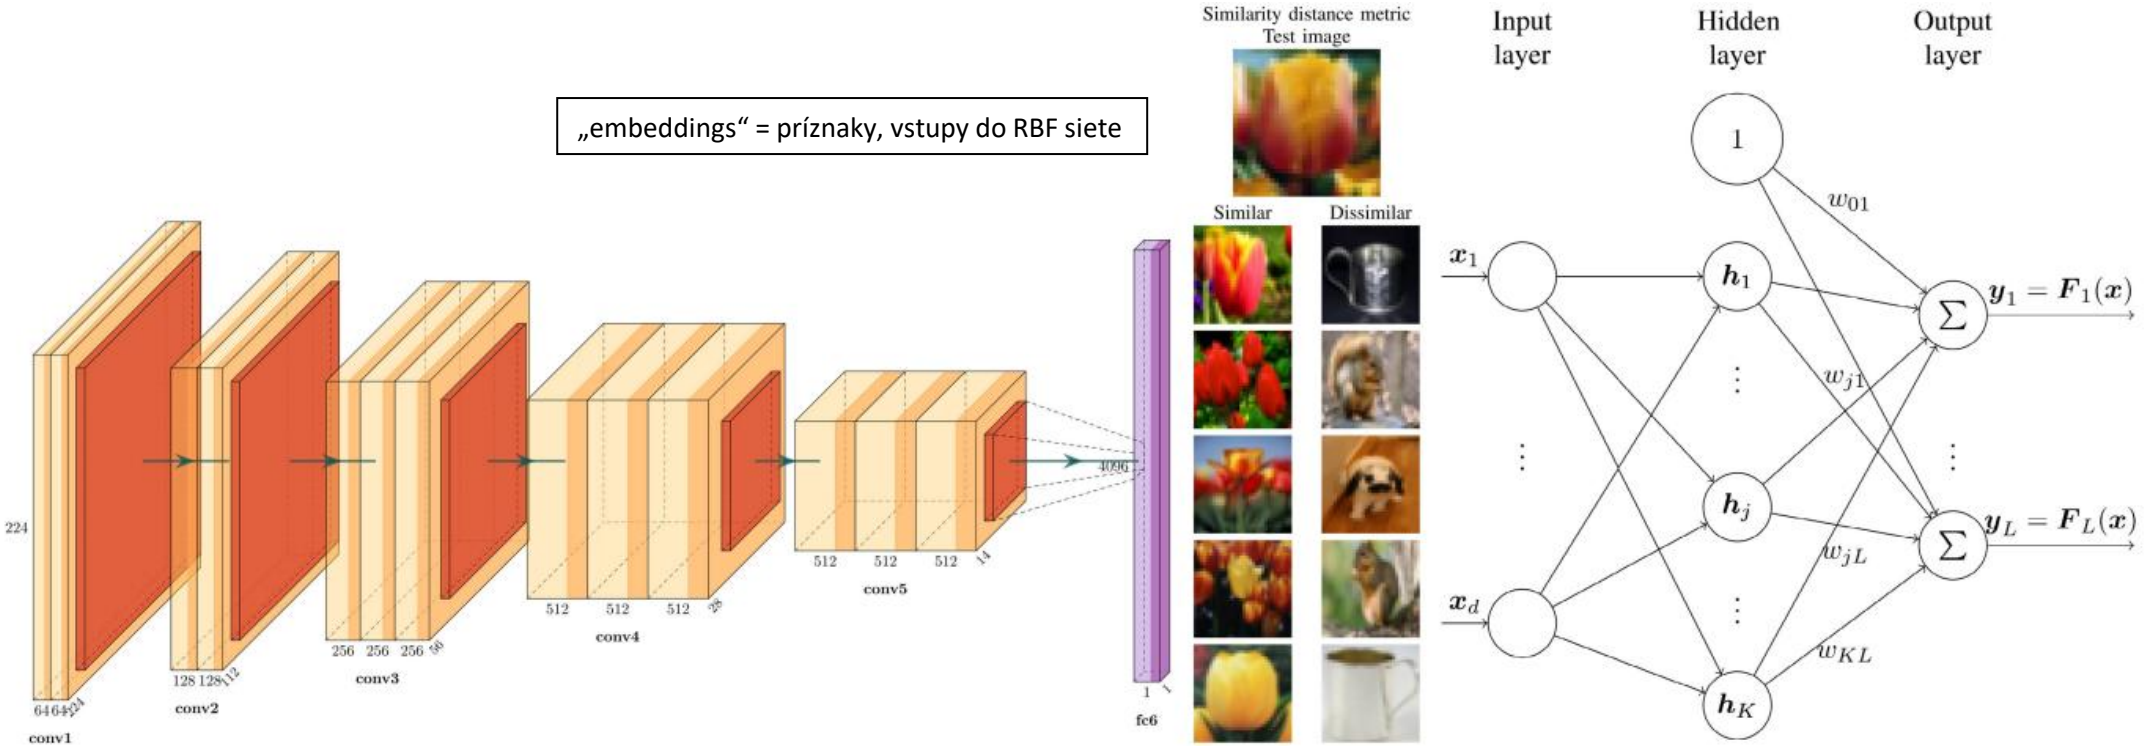


FIGURE 1. A visual summary of the paper: Figures on the top and bottom rows visualize the position of a test image in the unsupervised clusters. The output of a CNN backbone is connected to the input of an RBF through a fully connected layer. The input features of the RBFs are referred to as embeddings in this research work. The embeddings of each image are compared to cluster centers with a trainable similarity distance metric. The same distance metric can be used to find images similar to a test sample amongst training images (visualized in the table in the middle row). The RBFs apply an activation function to the distance of the training images from the cluster centers to compute activation values. The output layer of the RBF is optimized for classification based on these activation values. We train the entire CNN-RBF architecture end-to-end.

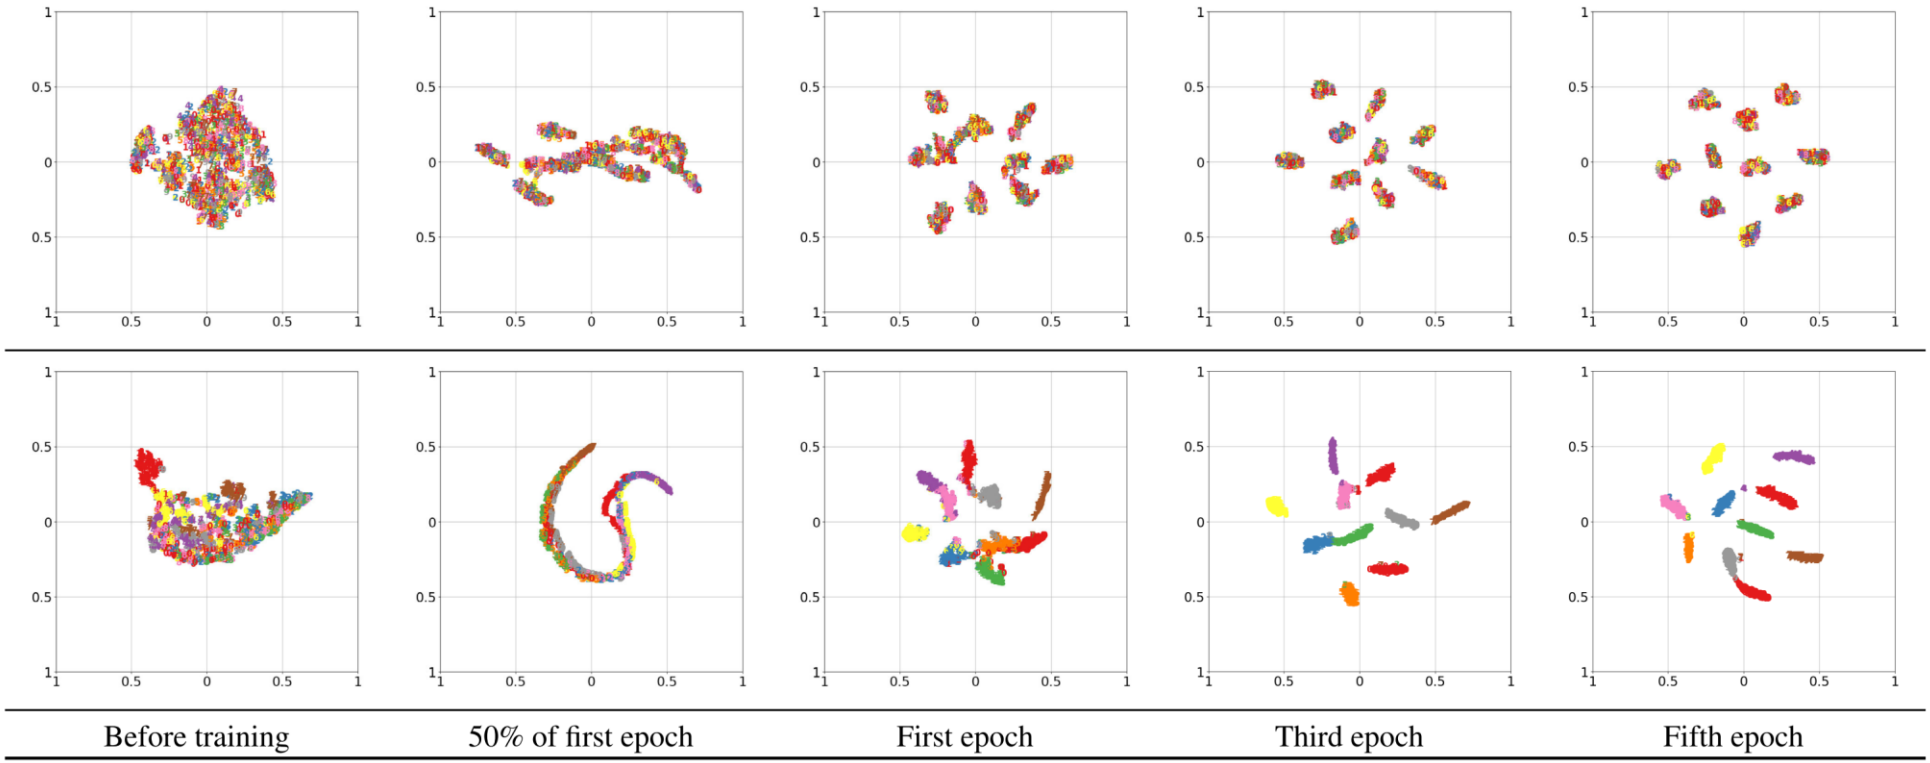


FIGURE 4. The two-dimensional representation of the training process. The figure presents the embeddings of the convolutional backbone (top row) and the activations of the RBFs (bottom row) and then maps them to a two-dimensional space using t-SNE [33]. The vertical and horizontal axes depict the normalized values; however, the unit value is the same in all sub-figures.

- **Iné práce o hlbokých RBF sieťach:**

  - Zadeh, Pourya & Hosseini, Reshad & Sra, Suvrit. (2018). Deep-RBF Networks Revisited: Robust Classification with Rejection

    - autori riešia zraniteľnosť hlbokých NS voči adverzariálnym útokom
      - One of the main drawbacks of deep neural networks, like many other classifiers, is their vulnerability to adversarial attacks. An important reason for their vulnerability is assigning high confidence to regions with few or even no feature points. By feature points, we mean a nonlinear transformation of the input space extracting a meaningful representation of the input data. On the other hand, deep-RBF networks assign high confidence only to the regions containing enough feature points,…

    - LeNet5 z r. 1998 (ktorá bola inšpirovaná Neocognitronom z r. 1975) bola prvou hlbokou RBF sieťou
      - „As far as we know, LeNet5 is the only form of the deep-RBF networks introduced in the literature of deep learning.“

Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner. Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11):2278–2324, 1998.

K. Fukushima and S. Miyake, “Neocognitron: A new algorithm for pattern recognition tolerant of deformations and shifts in position,” Pattern Recognit., vol. 15, no. 6, pp. 455–469, Nov. 1982

- Andrew Hryniowski, Alexander Wong: DeepLABNet: End-to-end Learning of Deep Radial Basis Networks with Fully Learnable Basis Functions (2019)
  - In this work, we present a novel approach that enables end-to-end learning of deep RBF networks with fully learnable activation basis functions in an automatic and tractable manner. We demonstrate that our approach for enabling the use of learnable activation basis functions in deep neural networks, which we will refer to as DeepLABNet, is an effective tool for automated activation function learning within complex network architectures.

- ďalšie práce o deep RBF:
  - napr. Google Scholar od r. 2025