Kohonenova samoorganizujúca sa mapa

aj hlboké SOM

TÉMY

- *modifikácia stimulu laterálnou spätnou väzbou*
- *topológia siete*
- *usporiadanie neurónov (pravouhlé, hexagonálne)*
- *meradlo zhody*
- *víťaz*
- *topologické okolie (susedstvo)*
- *učenie*
  - *priestorovo korelované*
  - *všeobecné pravidlá učenia*
- *ilustrácie mapovania pomocou SOM*
- *hlboké SOM*

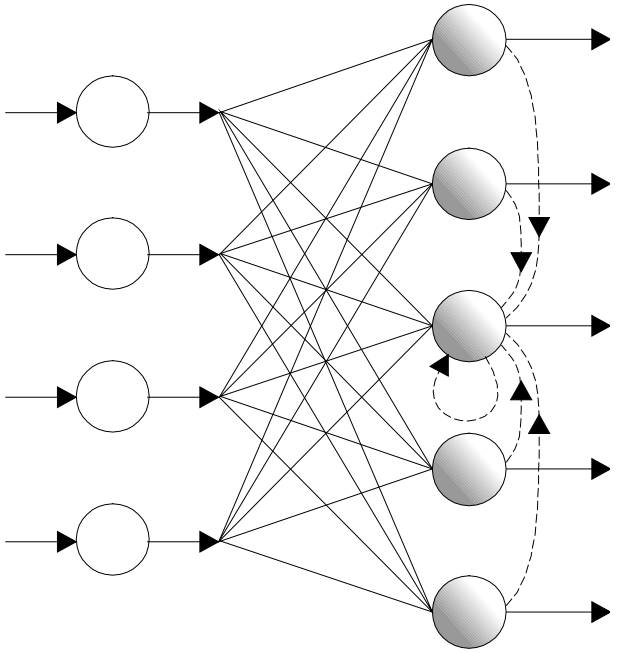
Kohonenova samoorganizujúca sa mapa

- patrí medzi:
  - ✓**SAMOORGANIZUJÚCE SA SYSTÉMY ZALOŽENÉ NA SÚŤAŽNOM UČENÍ**

- samoorganizované učenie
  - t.j. učenie bez učiteľa
- SOM, Self-Organizing Map

Modifikácia stimulu laterálnou spätnou väzbou

- laterálna spätná väzba - závisí od laterálnej vzdialenosti z bodu jej pôsobenia
- jednorozmerná mriežka neurónov s doprednými spojeniami a laterálnymi spätnoväzbovými spojeniami (laterálne sú zobrazené iba pre stredný neurón):

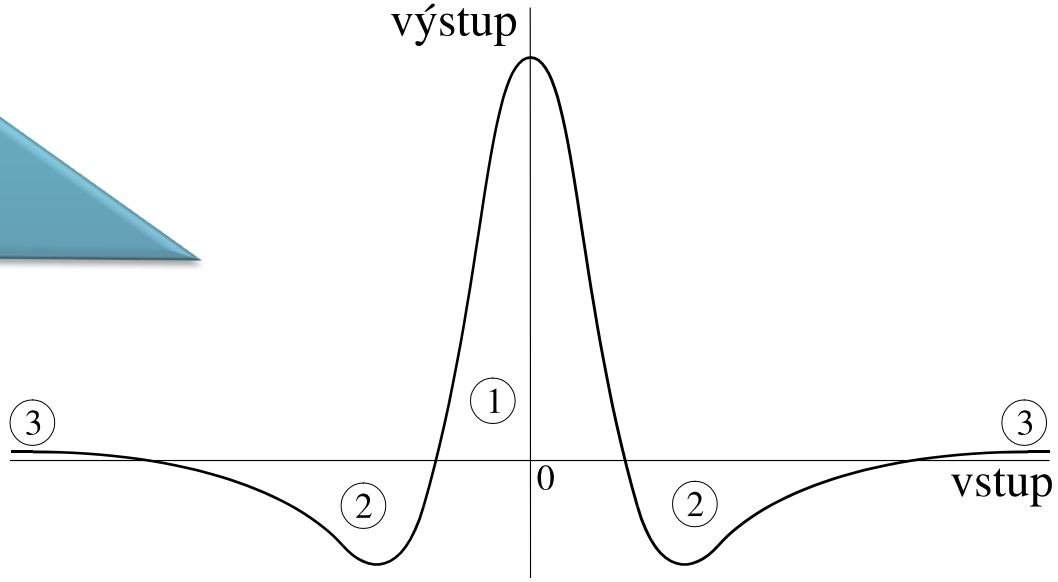


Modifikácia stimulu laterálnou spätnou väzbou

- laterálna spätná väzba - zvyčajne vyjadrená funkciou mexického klobúka (“Mexican hat function”)

Tri typy laterálnych interakcií medzi neurónmi:

1) úzka oblasť laterálnej excitácie
2) oblasť laterálnej inhibície
3) oblasť slabšej excitácie, ktorá obklopuje inhibičné pásmo (táto oblasť sa zvyčajne zanedbáva)



Účinky laterálnej spätnej väzby opísanej funkciou mexického klobúka sa nahrádzajú zavedením *topologického okolia* (“topological neighborhood”) aktívnych neurónov

SOM

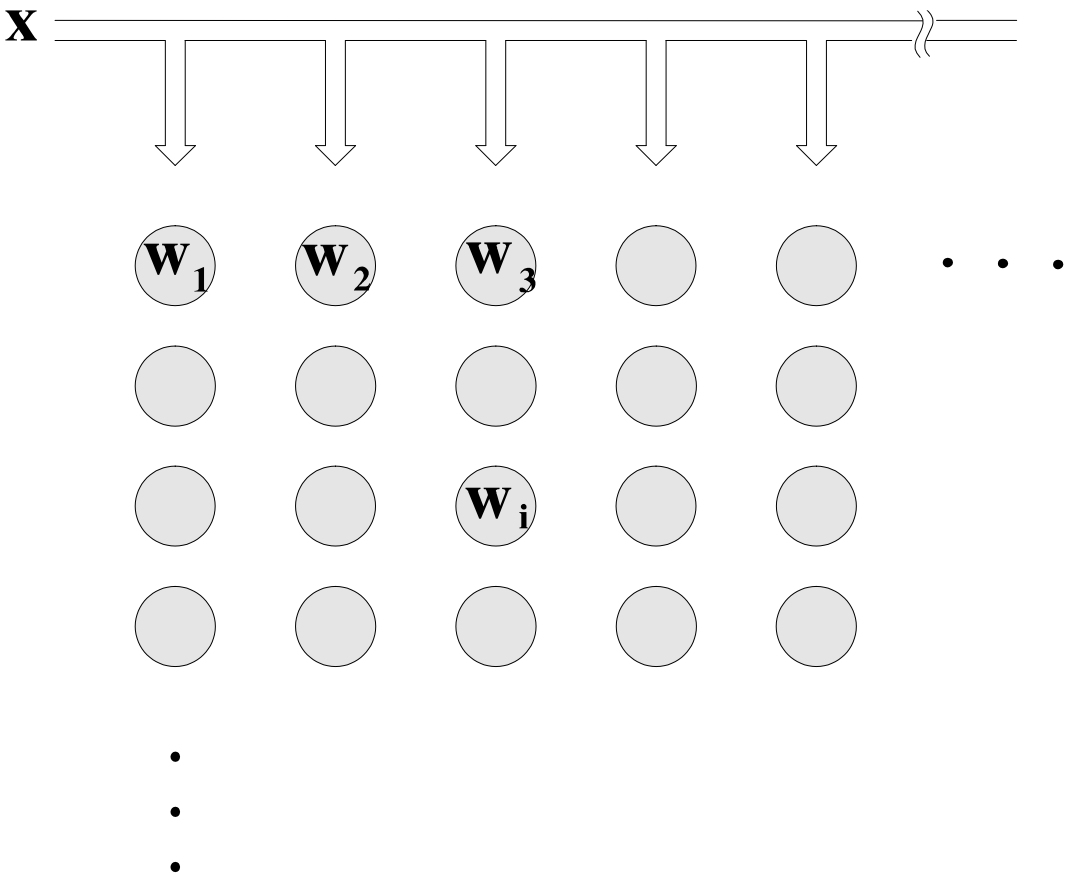
- Princíp vytvorenia *topografickej mapy:*
  - poloha výstupného neurónu korešponduje s príznakom vstupných dát

- 1D, 2D, 3D, ..., mriežka
  - umožňuje mať susediace neuróny
  - pravouhlé al. hexagonálne usporiadanie neurónov

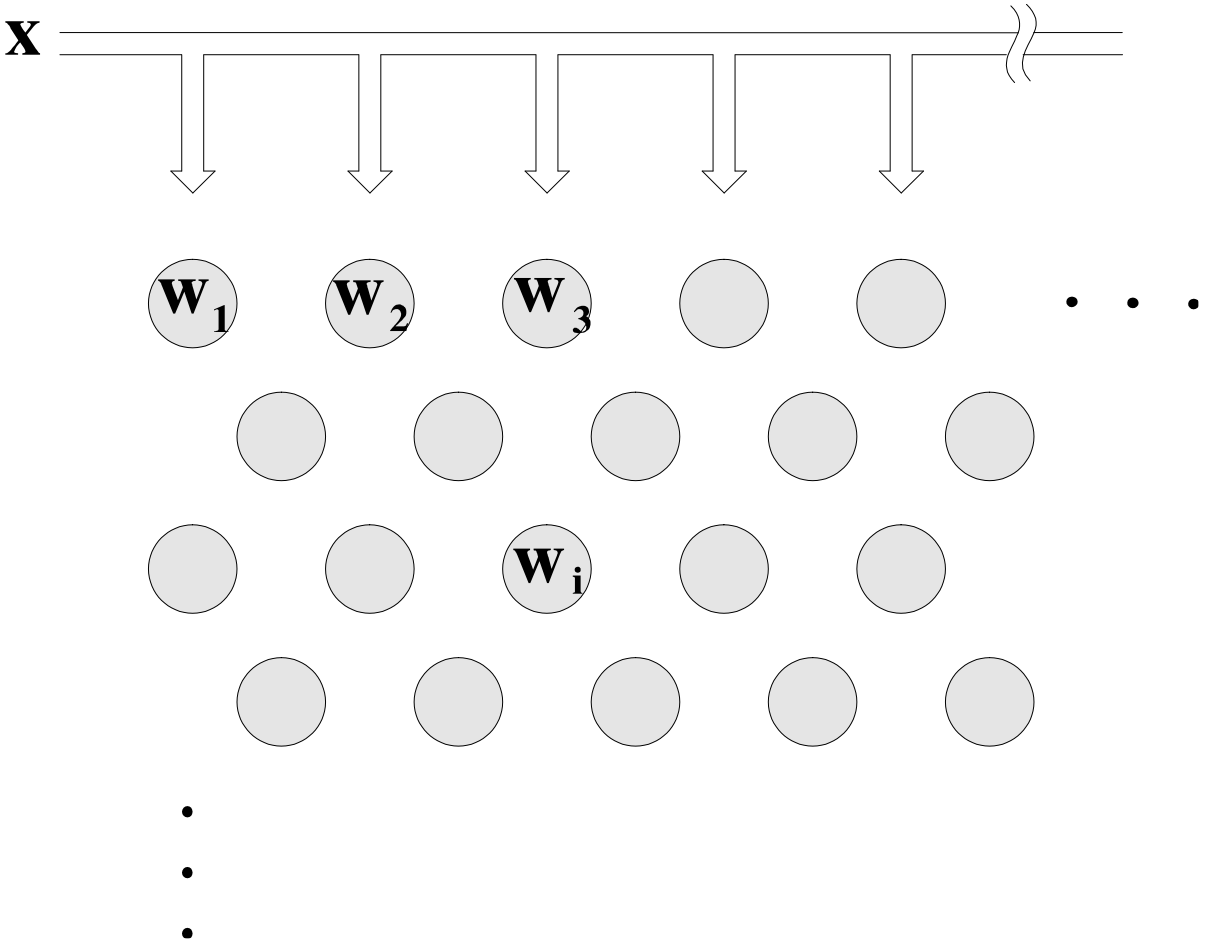
$\mathbf{x} = [x_1, x_2, ..., x_p]^T \in R^p$ - vstupný vektor, ktorý je spojený paralelne so všetkými prvkami i v sieti

$\mathbf{w}_i = [w_{i1}, w_{i2}, ..., w_{ip}]^T \in R^p$ - váhový vektor prvku i

Pravouhlé usporiadanie prvkov samoorganizujúcej sa mapy



Hexagonálne usporiadanie prvkov samoorganizujúcej sa mapy



SOM

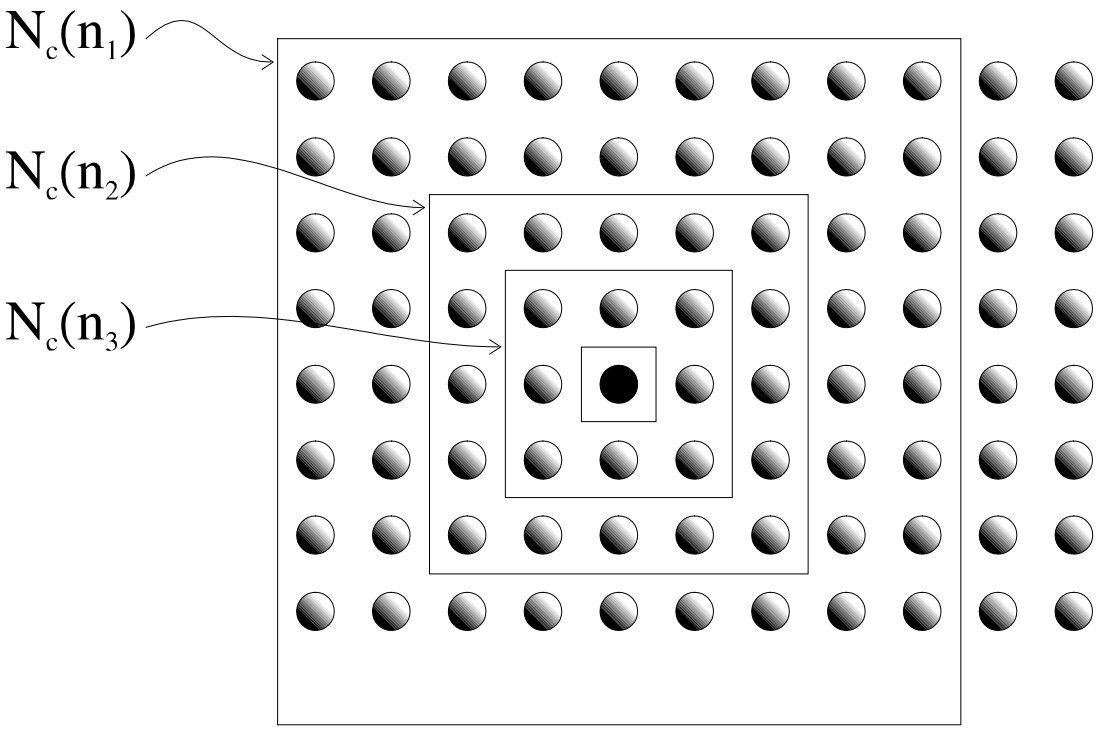
- meradlo zhody
  - skalárny súčin
  - euklidovská vzdialenosť
- víťaz
  - minimálna vzdialenosť definuje "víťaza" $\mathbf{w}_c$
- priestorovo korelované učenie
  - učiace sa neuróny nepracujú od seba nezávisle, ale ako podmnožiny neurónov vo vzájomnom topologickom vzťahu
- topologické okolie (susedstvo) $N_c(n)$

$$\|\mathbf{x} - \mathbf{w}_c\| = \min_i \{\|\mathbf{x} - \mathbf{w}_i\|\}$$

N je z angl. neighborhood

Topologické okolie

Príklady topologického okolia $N_c(n)$, *kde* $n_1 < n_2 < n_3$

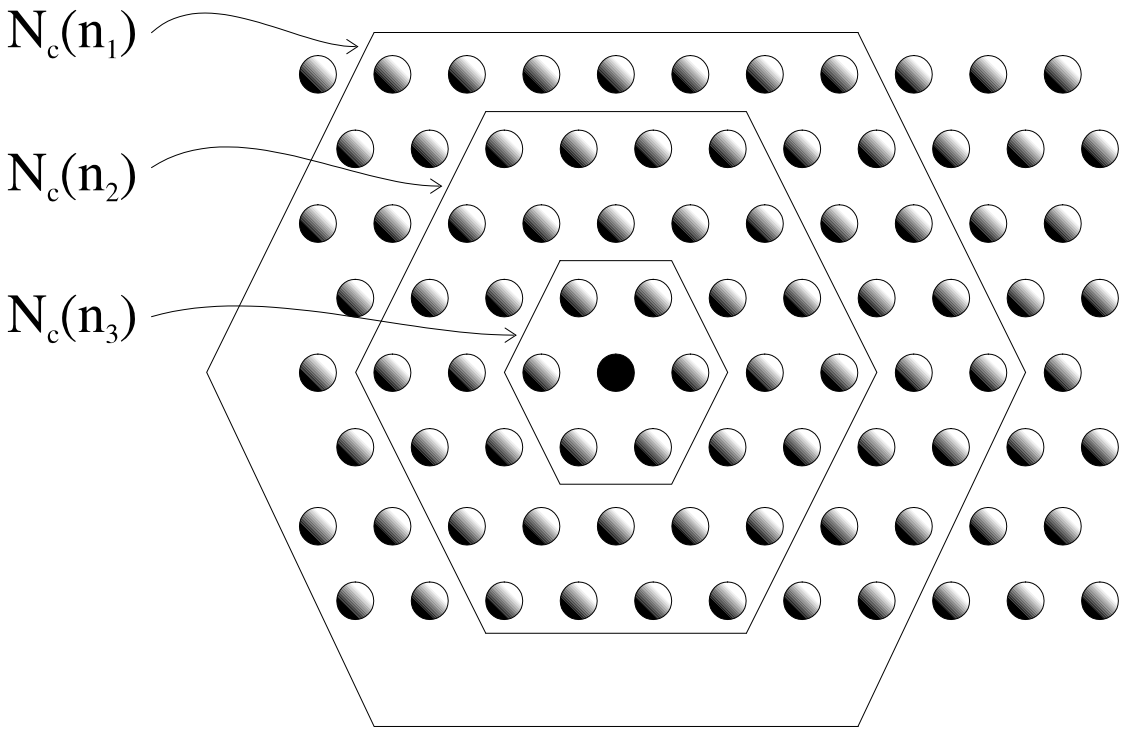


Okolie je veľmi široké na začiatku a s časom sa monotónne zmenšuje.

Začiatočné široké okolie dovolí mape približné, "hrubé" globálne zoradenie siete, potom zmenšenie okolia zlepší priestorovú rozlíšiteľnosť mapy, pri ktorom však získané globálne zoradenie nie je narušené

Topologické okolie

Príklady topologického okolia $N_c(n)$, *kde* $n_1 < n_2 < n_3$



Učenie SOM

$\eta(n)$ je parameter rýchlosti učenia

$0 < \eta(n) < 1$, $\eta(n)$ má s časom klesať

$$\mathbf{w}_i(n+1) = \begin{cases} \mathbf{w}_i(n) + \eta(n)\left[\mathbf{x}(n) - \mathbf{w}_i(n)\right] & \text{ak } i \in N_c(n) \\ \mathbf{w}_i(n) & \text{ak } i \notin N_c(n) \end{cases}$$

$h_{ci}(n)$ - skalárna kernelová funkcia

$$\mathbf{w}_i(n+1) = \mathbf{w}_i(n) + h_{ci}(n)\left[\mathbf{x}(n) - \mathbf{w}_i(n)\right]$$

- $h_{ci}(n)$:
  - $h_{ci}(n) = \eta(n)$ vnútri okolia $N_c(n)$ a $h_{ci}(n) = 0$ mimo okolia N_c
  - $h_{ci}(n) = h_0(n)\exp\left(-\|\mathbf{r}_i - \mathbf{r}_c\|^2 / \sigma^2(n)\right)$

vektory $\mathbf{r}_c$ a $\mathbf{r}_i$ sú súradnice prvkov c a i

kde $h_0 = h_0(n)$ a $\sigma = \sigma(n)$ sú vhodné klesajúce funkcie času

Učenie SOM

- všeobecné pravidlá pre učenie mapy:
  - inicializácia váh
  - počet krokov učenia
  - parameter rýchlosti učenia
    - fáza globálneho zoradenia mapy
    - fáza jemného ladenia mapy
  - topologické okolie
    - fáza globálneho zoradenia mapy
    - fáza jemného ladenia mapy

Učenie SOM

- ***Inicializácia váh***:
  - náhodný výber inicializačných váh $\mathbf{w}_i(0)$, jediným obmedzením je, že by mali byť rôzne
- ***Počet krokov učenia***:
  - počet krokov (krokom rozumieme privedenie jednej vstupnej vzorky) aspoň 500 krát väčší ako počet prvkov siete
  - ak je k dispozícii iba malý počet vzoriek, musia byť opakované, aby sa splnil požadovaný počet krokov

Učenie SOM

- ***Parameter*** $\eta(n)$:
  - pre približne prvých 1000 krokov môže byť hodnota $\eta(n)$ blízko 1, potom musí monotónne klesať
  - presné pravidlo nie je dôležité, $\eta = \eta(n)$ môže byť lineárnou alebo exponenciálnou funkciou, alebo môže byť nepriamo úmerné *n*
  - napr. $\eta(n) = 0.9(1 - n/1000)$
  - Počas tejto úvodnej fázy prebehne zoraďovanie $\mathbf{w}_i$, ostatné kroky sú potrebné pre jemné vylepšenie mapy
  - po procese zoradenia môže $\eta = \eta(n)$ nadobúdať malé hodnoty (napr. 0,01) počas dlhej doby učenia

Učenie SOM

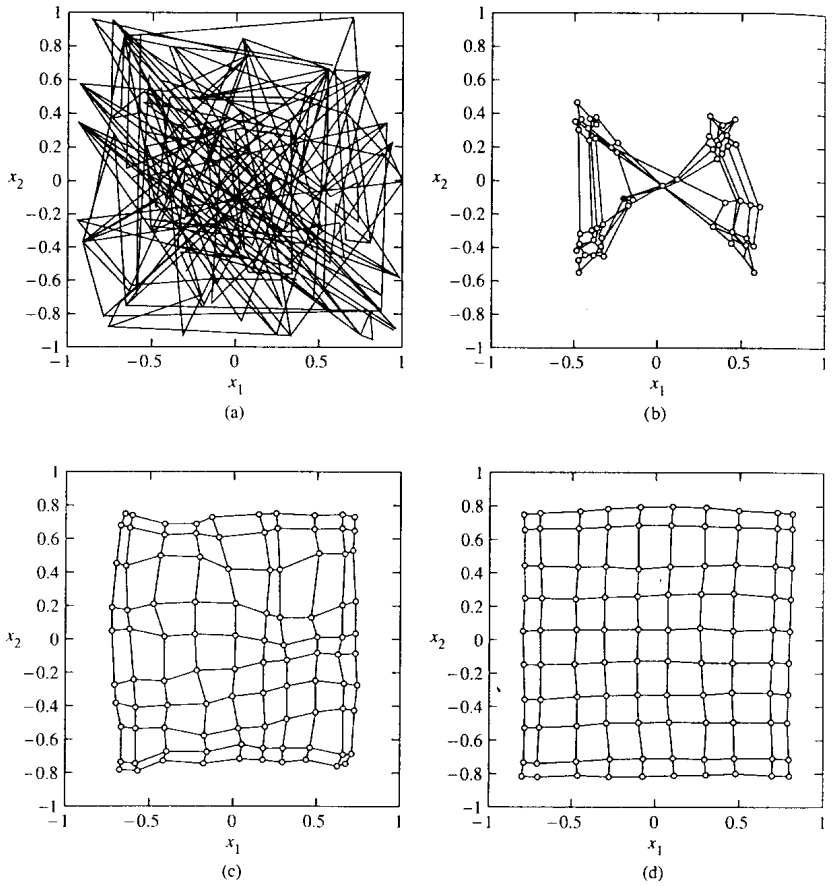
- ***Topologické okolie*** $N_c(n)$:
  - Ak je okolie na začiatku učenia príliš malé, mapa nebude zoradená globálne. Namiesto toho bude rôzne "rozparcelovaná".
  - Tomuto javu môžeme predísť, ak na začiatku bude okolie $N_c = N_c(0)$ dostatočne široké, a potom sa s časom zmenšuje.
  - Začiatočný polomer N_c môže byť dokonca väčší ako polovica priemeru siete.
  - Počas približne prvých 1000 krokov, keď nastáva správne *zoradenie siete* a $\eta = \eta(n)$ je dostatočne veľké, sa môže polomer N_c zmenšovať lineárne, až bude obsahovať iba jeden prvok mapy.
  - Počas procesu *jemného vylepšenia* môže N_c ešte stále obsahovať najbližšie susedné prvky prvku c.

Poznámka

- SOM netrpí pretrénovaním

ILUSTRÁCIE MAPOVANIA POMOCOU SOM

2D priestor vstupov -> 2D mapa

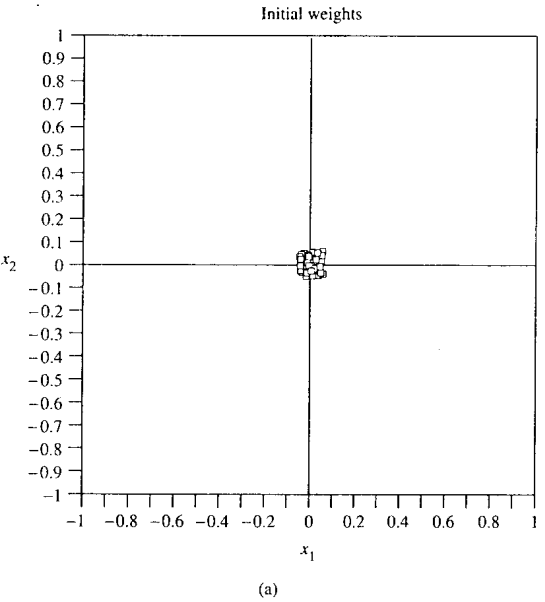


mapa **10x10**
2D rovnomerne rozdelené vstupy
vstupy **x** = [x_1, x_2]
$-1<x_1<1$
$-1<x_2<1$

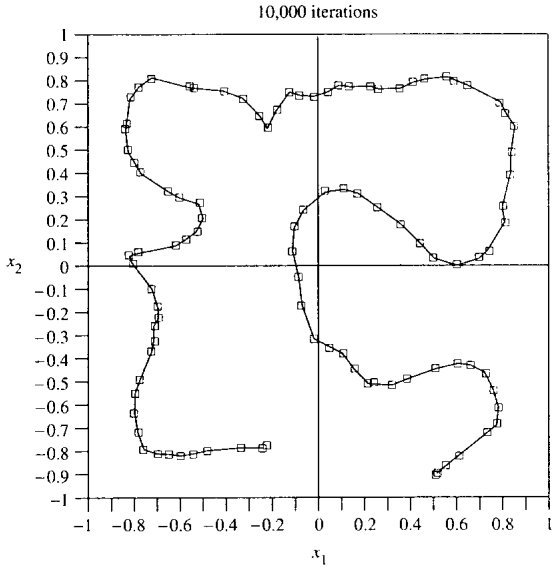
a) náhodne inicializované váhy
b) SOM po 50 iteráciách
c) SOM po 1000 iteráciách
d) SOM po 10000 iteráciách

Kohonen,T.: The Self-Organizing Map, Proc. of the IEEE, Vol.78, No.9, 1990, str. 1464-1480

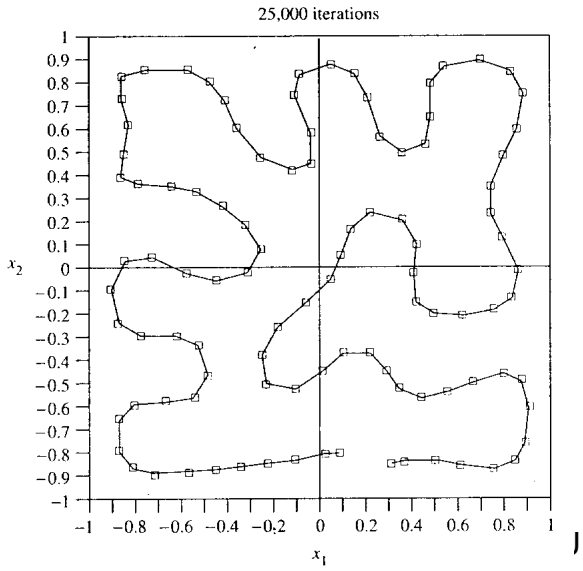
2D priestor vstupov -> 1D mapa



(a)



(b)



(c)

mapa **1x100**
2D rovnomerne rozdelené vstupy
vstupy $\mathbf{x} = [x_1, x_2]$
$-1<x_1<1$
$-1<x_2<1$

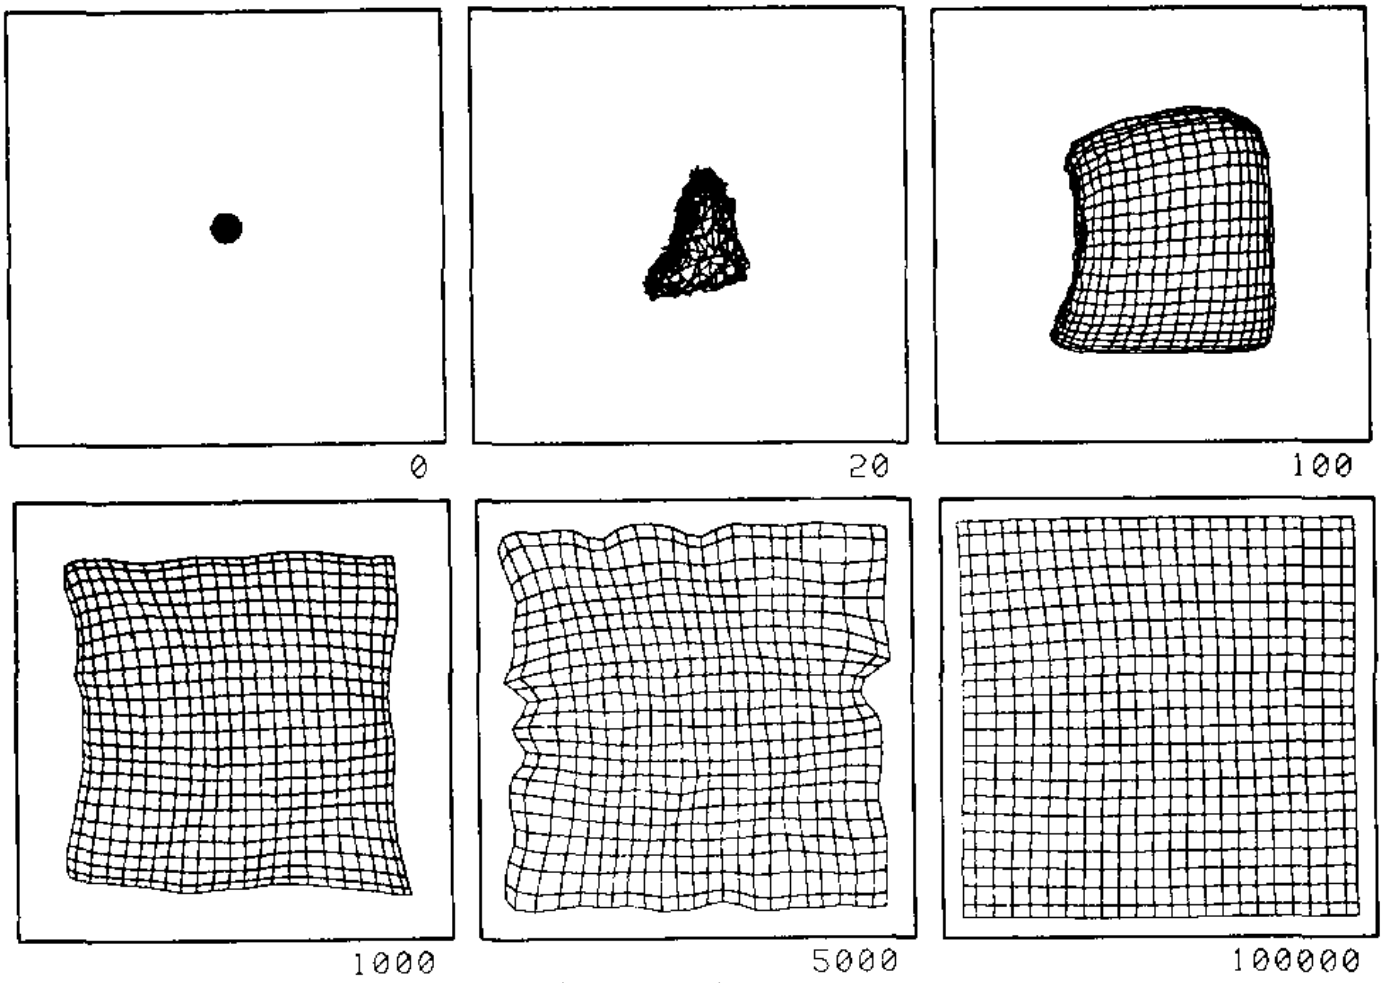
a) náhodne inicializované váhy
b) SOM po 10000 iteráciách
c) SOM po 25000 iteráciách

Kohonen,T.: The Self-Organizing Map, Proc. of the IEEE, Vol.78, No.9, 1990, str. 1464-1480

Kohonen,T.: The Self-Organizing Map, Proc. of the IEEE, Vol.78, No.9, 1990, str. 1464-1480

2D priestor vstupov -> 2D mapa

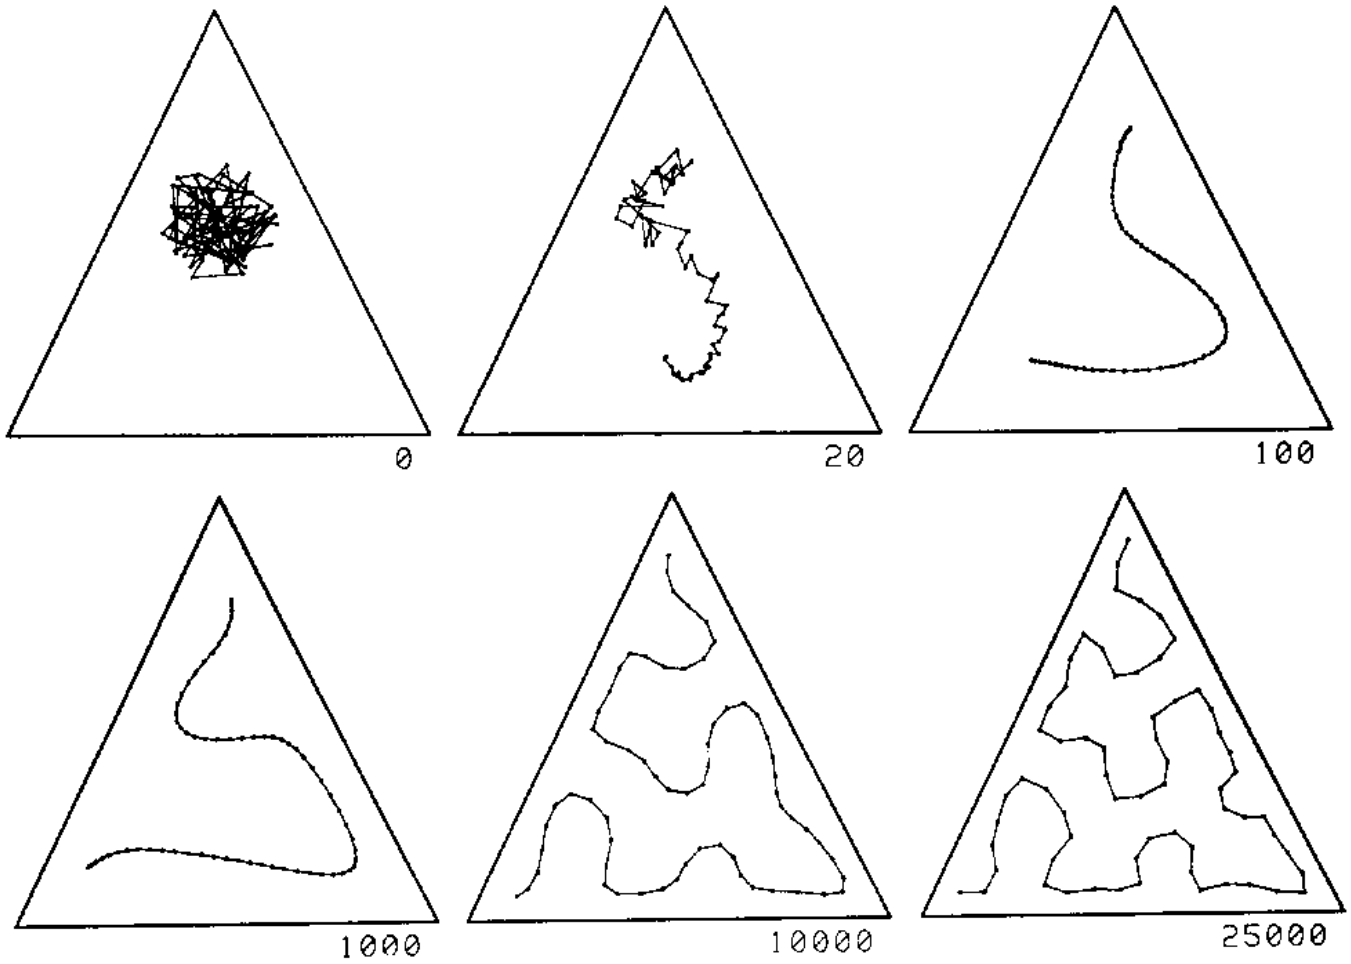
2D rovnomerne rozdelené vstupy
vstupy $\mathbf{x} = [x_1, x_2]$, $-1<x_1<1$, $-1<x_2<1$



Kohonen,T.: The Self-Organizing Map, Proc. of the IEEE, Vol.78, No.9, 1990, str. 1464-1480

2D priestor vstupov -> 1D mapa

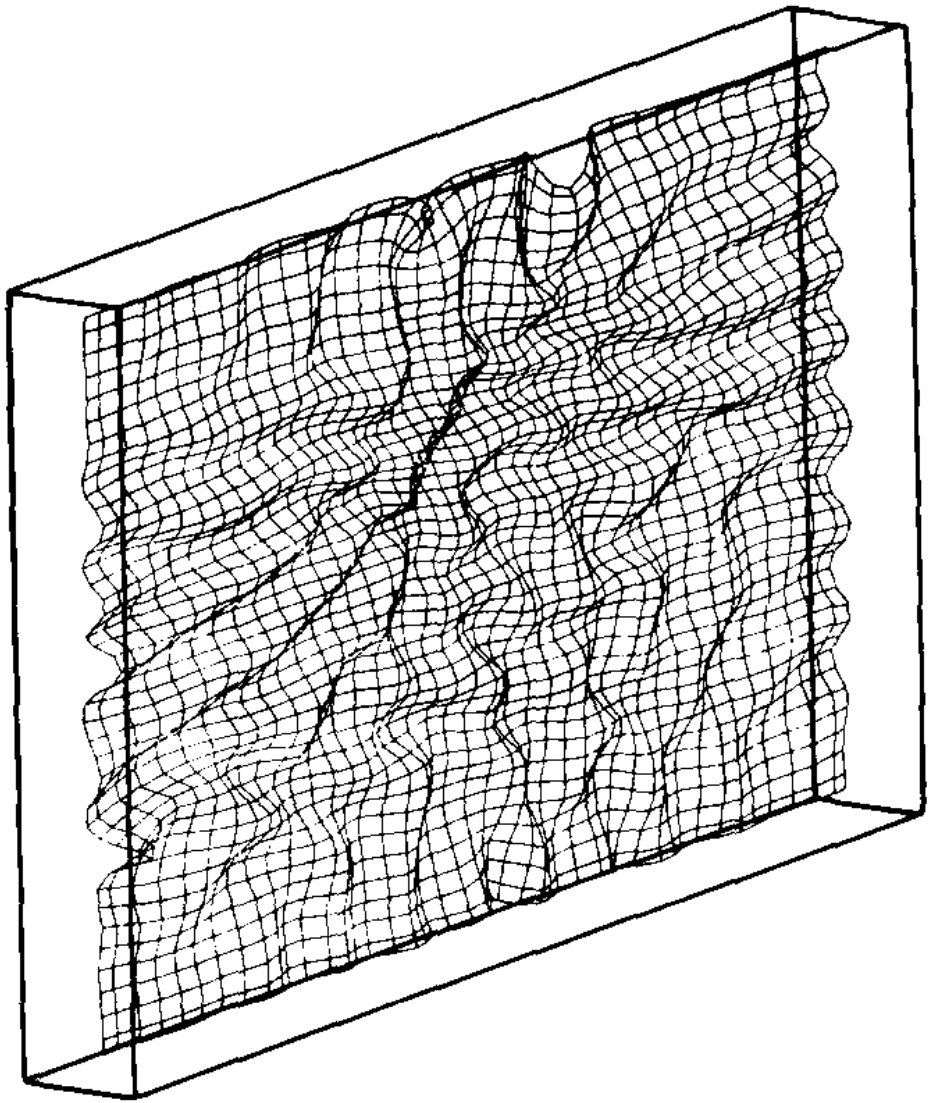
2D rovnomerne rozdelené vstupy
vstupy $\mathbf{x} = [x_1, x_2]$



Kohonen,T.: The Self-Organizing Map, Proc. of the IEEE, Vol.78, No.9, 1990, str. 1464-1480

3D priestor vstupov -> 2D mapa

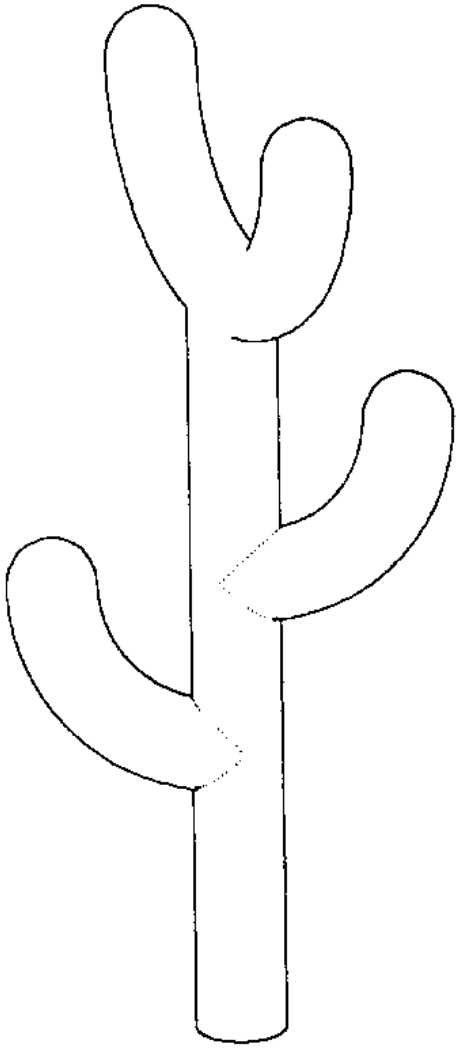
3D vstupy $\mathbf{x} = [x_1, x_2, x_3]$

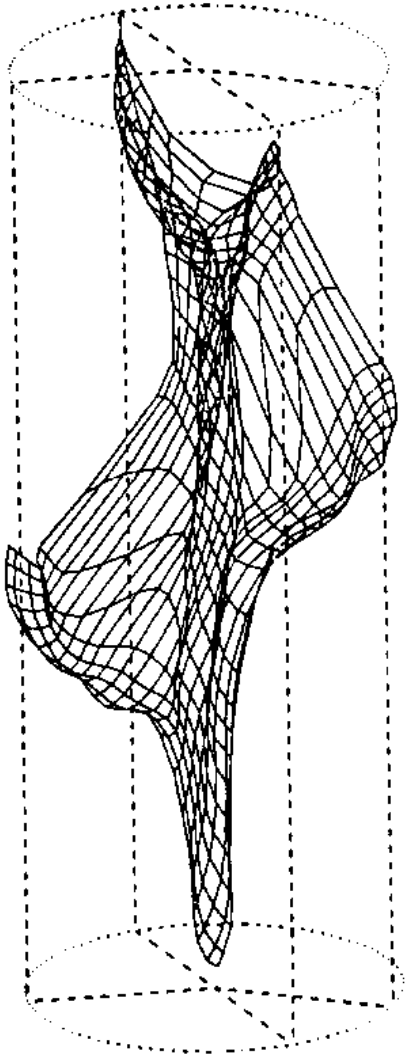


Kohonen,T.: The Self-Organizing Map, Proc. of the IEEE, Vol.78, No.9, 1990, str. 1464-1480

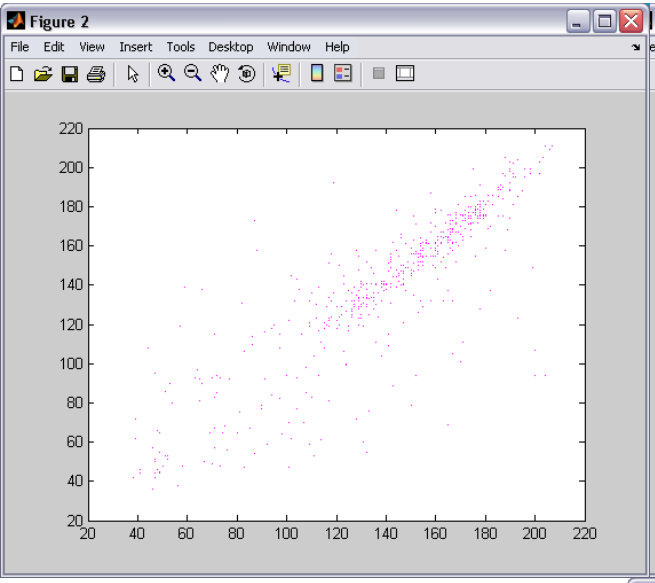
3D priestor vstupov -> 2D mapa

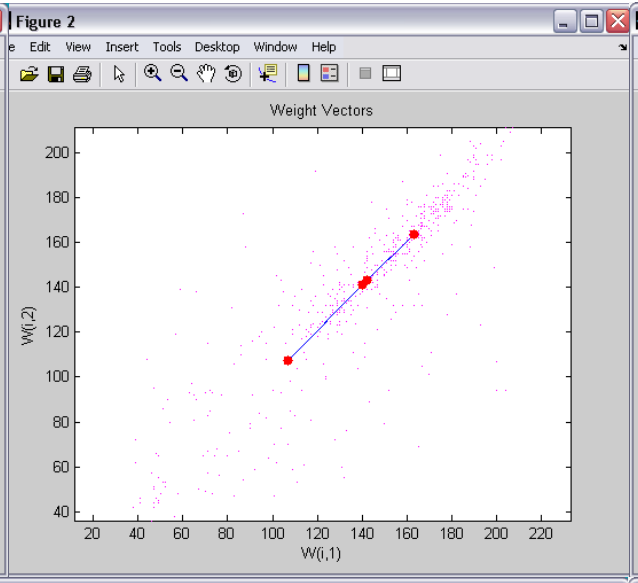
3D vstupy $\mathbf{x} = [x_1, x_2, x_3]$

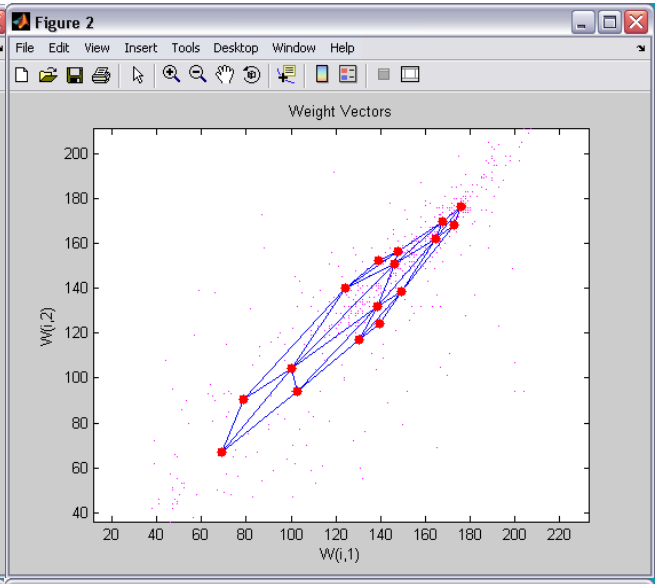


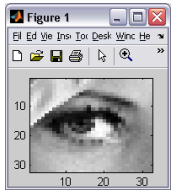


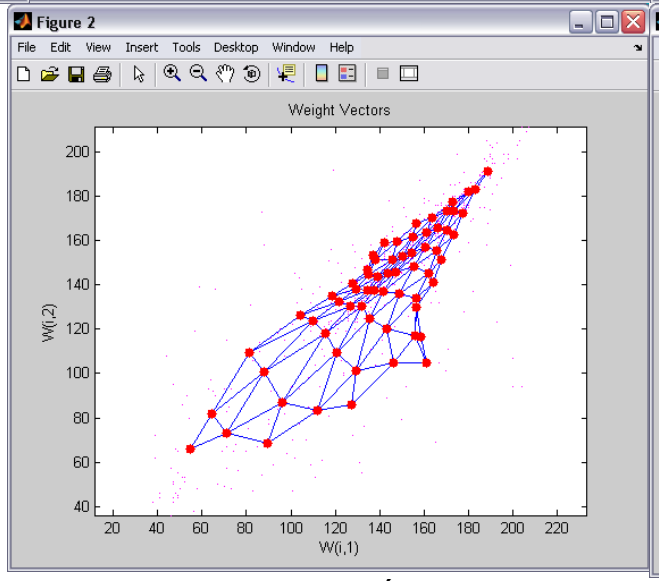
Ilustrácie máp:
Oko: bloky 2x1, SOM 2x2, 4x4, 8x8, 16x16

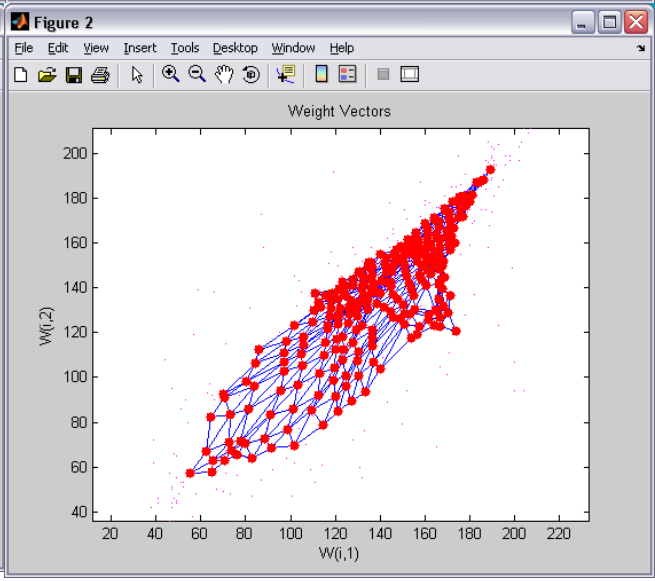




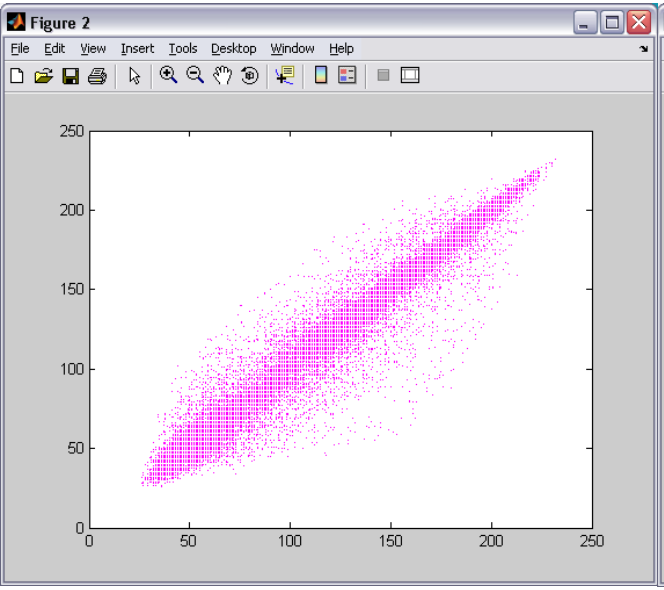


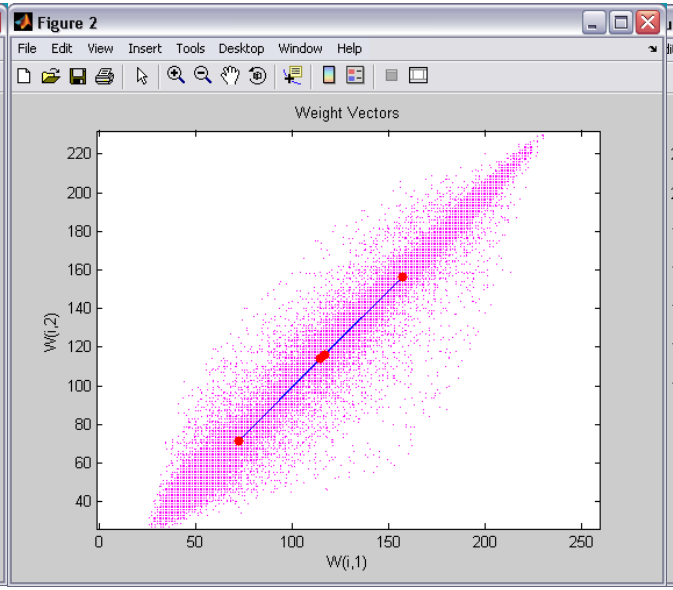


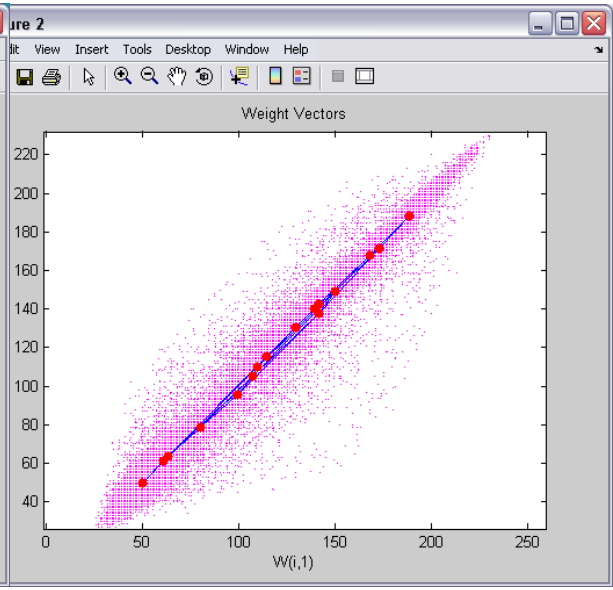


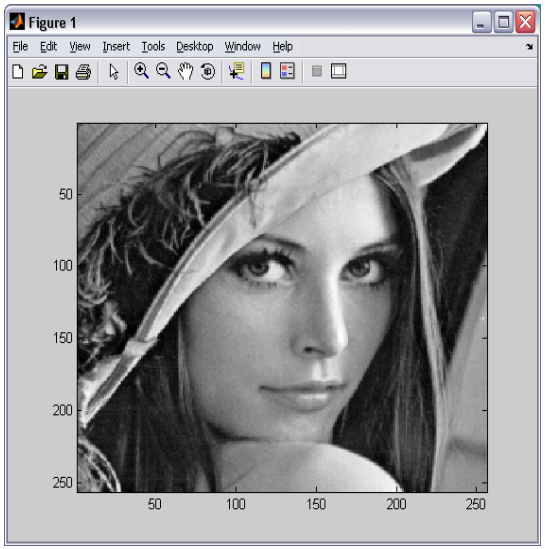


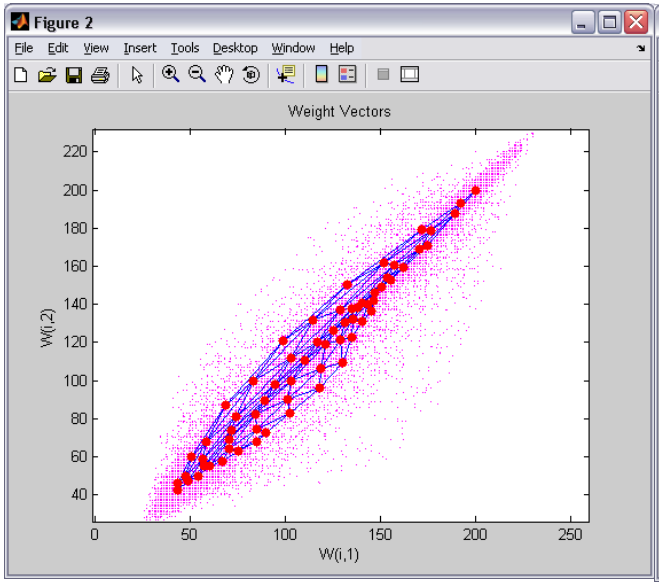
Ilustrácie máp
Nella: bloky 2x1, SOM 2x2, 4x4, 8x8, 16x16

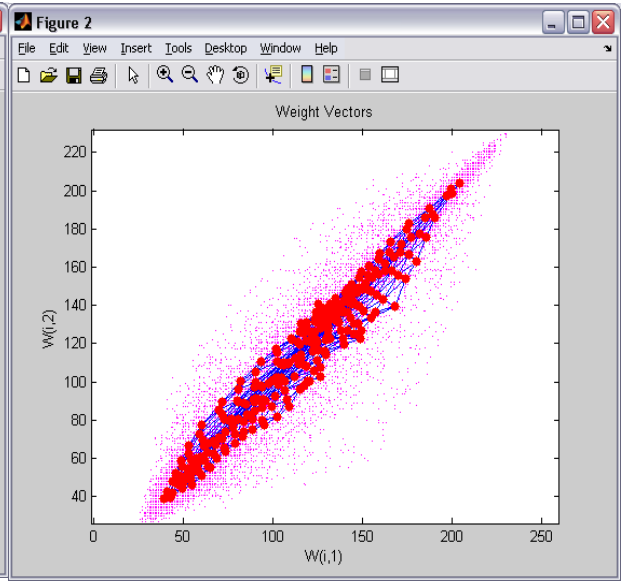




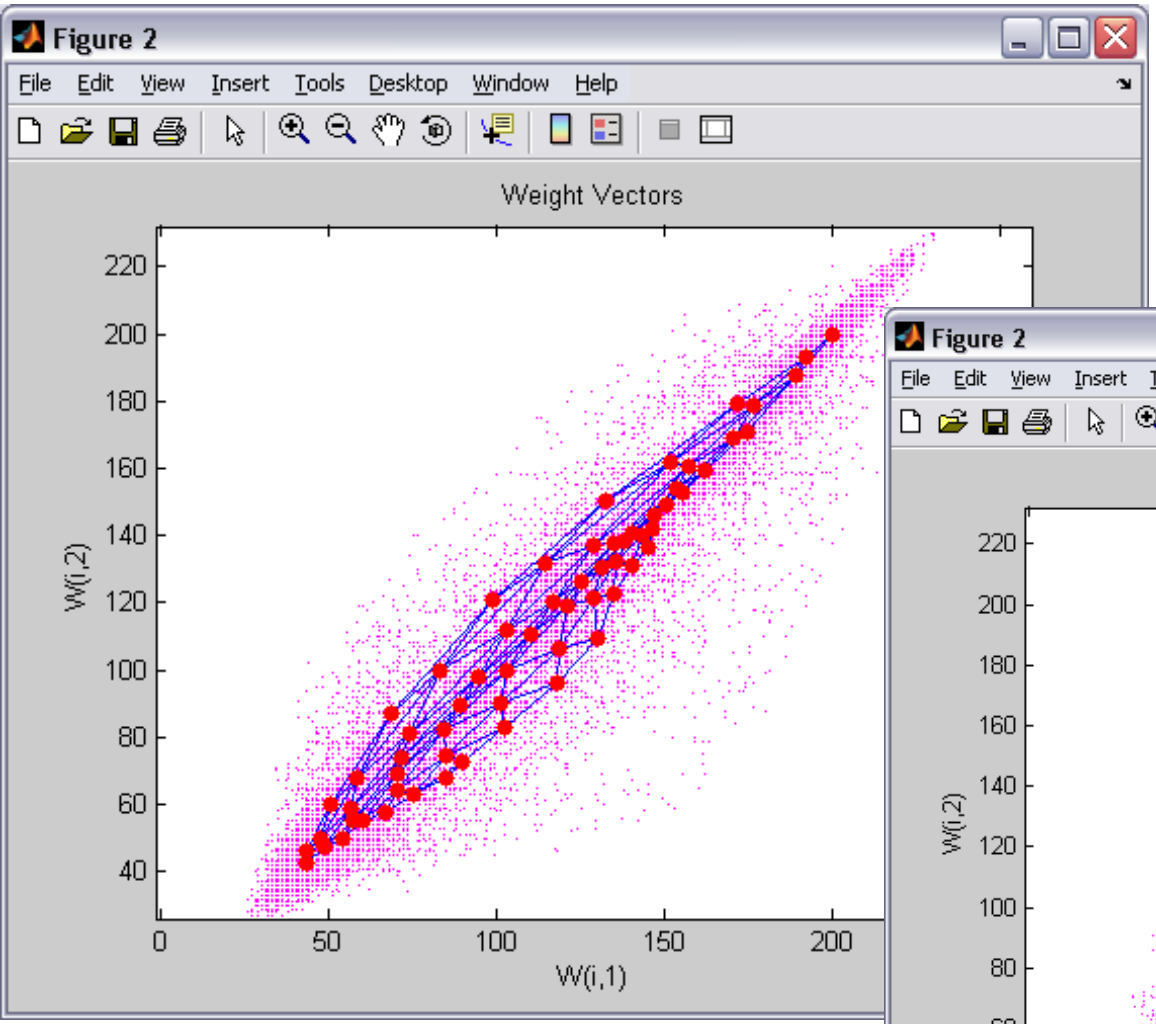


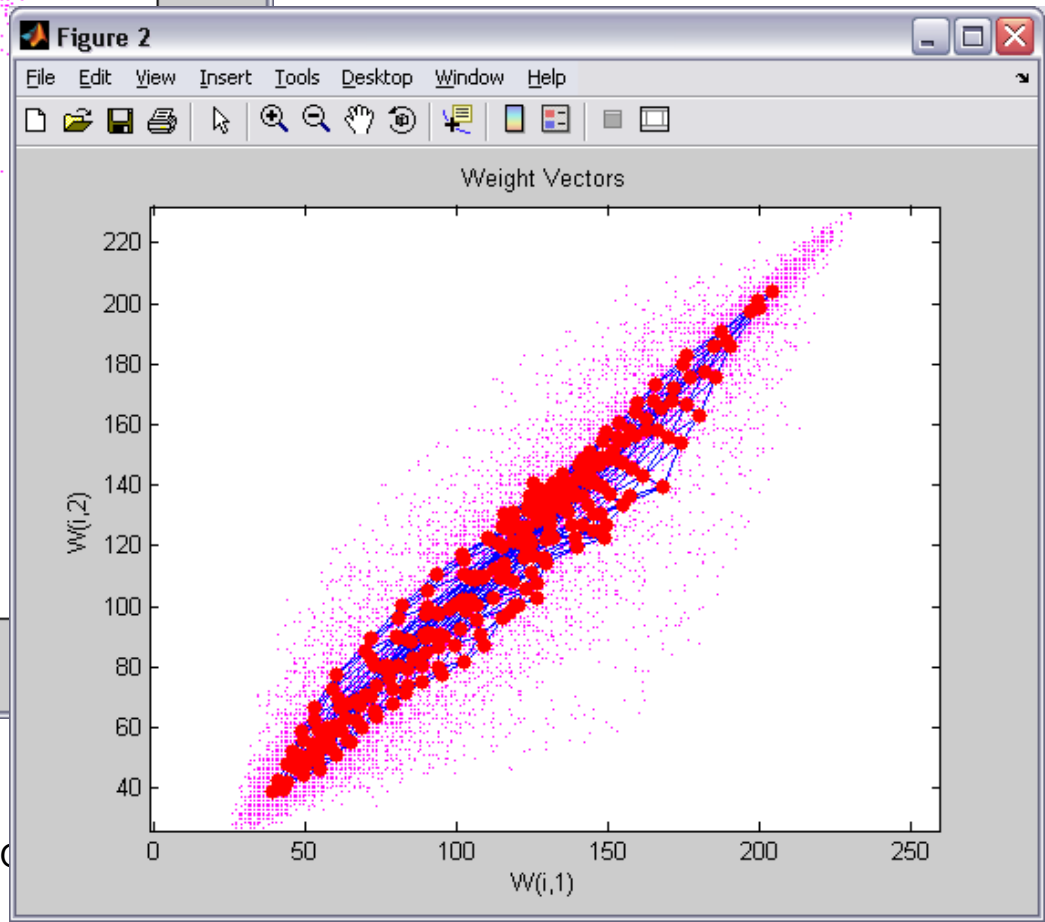




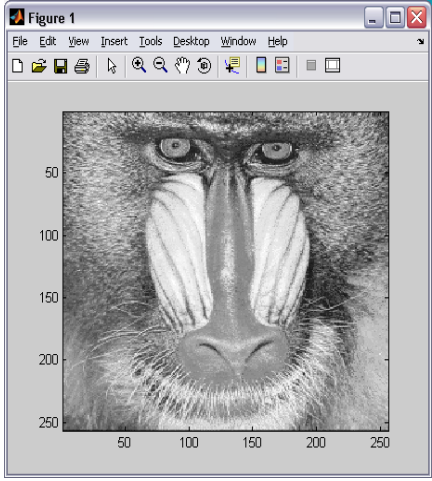


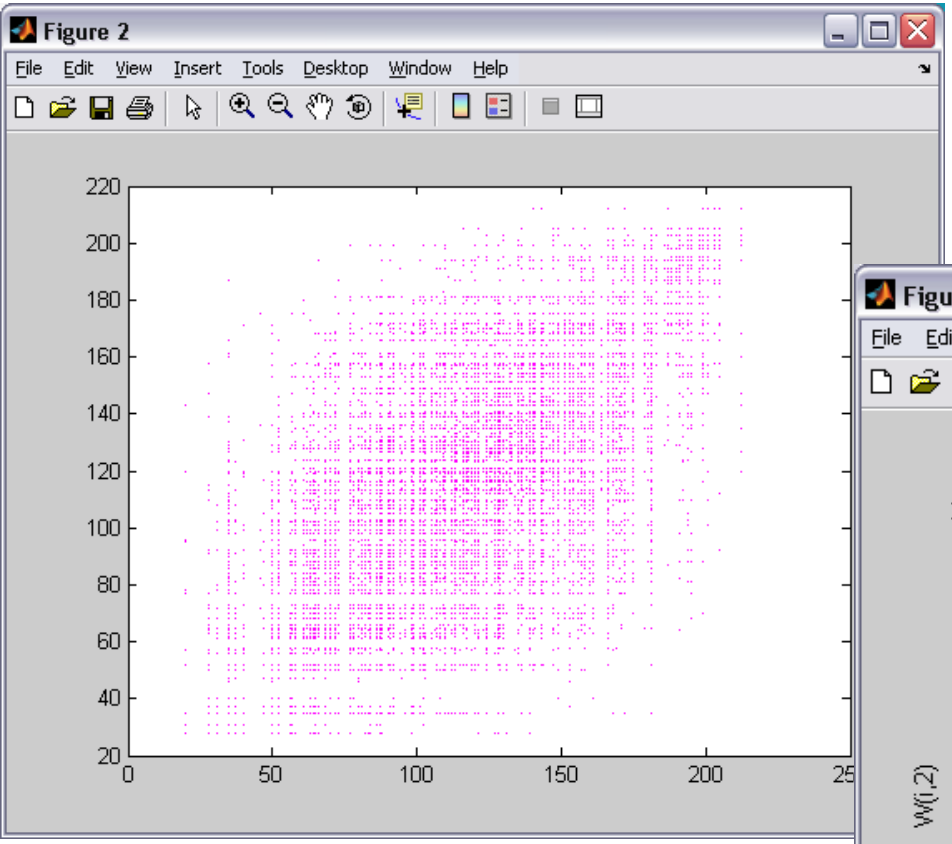
Ilustrácie máp:
Nella: bloky 2x1, SOM 8x8, 16x16 – zväčšené

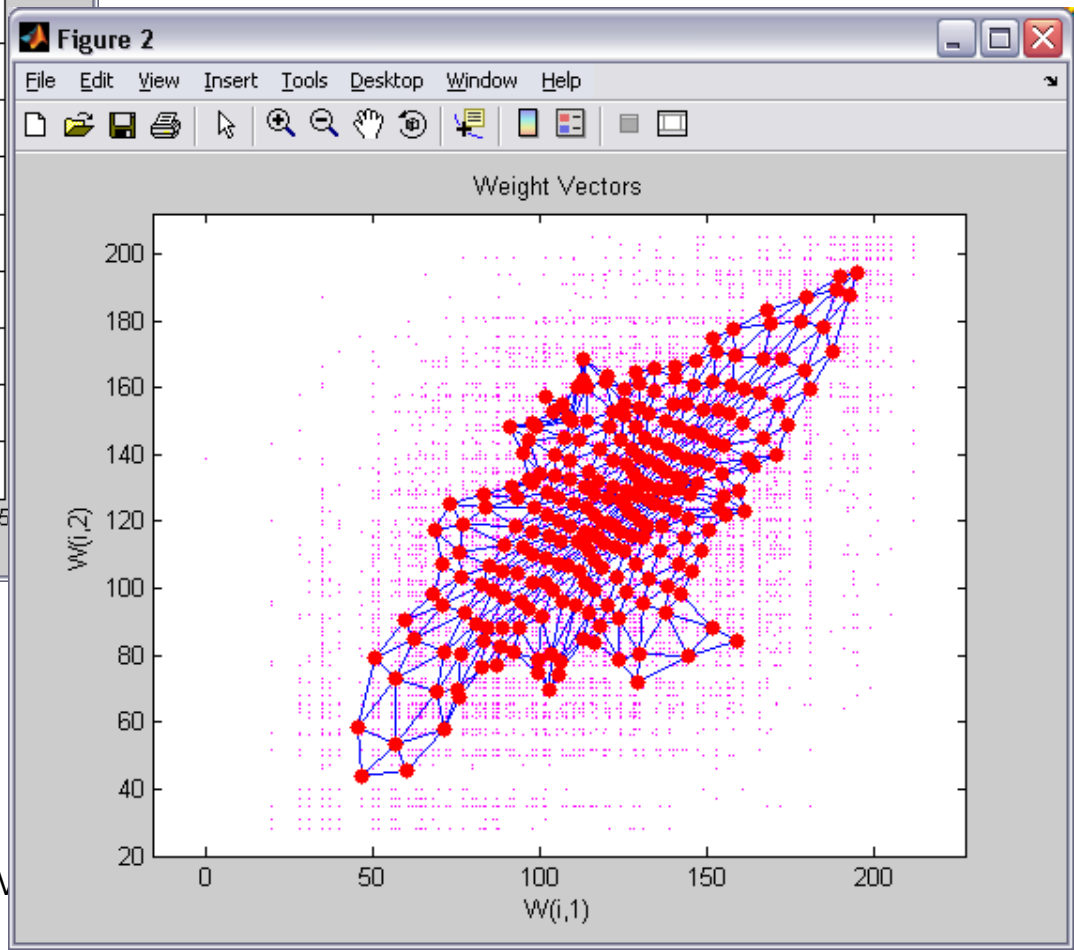




Ilustrácie máp:
baboon: bloky 2x1, SOM 16x16







SUNS, M

Dajte do vyhľadávača

- web traffic self-organizing map
- social behaviour self-organizing map
- customer behaviour self-organizing map
- …

HLBOKÉ SOM

Deep self-organizing maps

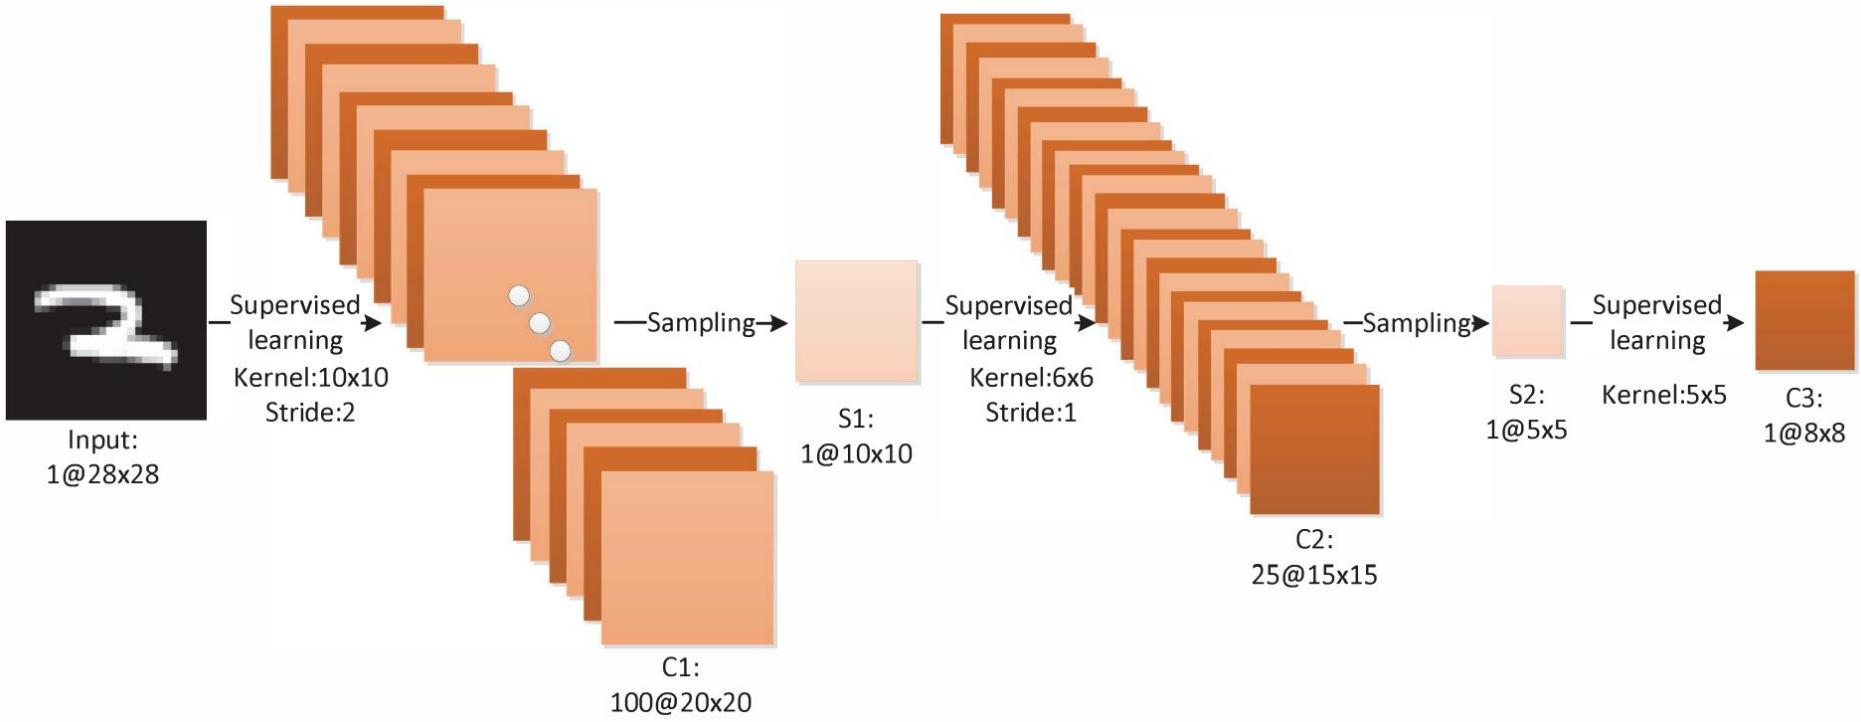
DSOM, Deep Self-Organizing Map for Visual Classification, 2015

- proposal of a Deep Self-Organizing Map (DSOM) algorithm

- It consists of
  - layers of alternating self-organizing map
    - The self-organizing layer is made up of certain numbers of SOMs, with each map only looking at a local region block on its input.
  - sampling layers.
    - The winning neuron's index value from every SOM in self-organizing layer is then organized in the sampling layer to generate another 2D map, which could then be fed to a second self-organizing layer.

» N. Liu, J. Wang and Y. Gong, "Deep Self-Organizing Map for visual classification," *2015 International Joint Conference on Neural Networks (IJCNN)*, Killarney, 2015, pp. 1-6, doi: 10.1109/IJCNN.2015.7280357.

DSOM architecture



A DSOM architecture for handwritten digits recognition. This architecture consists of 3 self-organizing layers (C1, C2, C3) and 2 sampling layers (S1, S2).

C1, C2, and C3 contains 100, 25 and 1 SOMs respectively. Each map in the self-organizing layer models a sub-region of its input. Every sampling layer is formed by the wining neurons in its previous self-organizing layer.

N. Liu, J. Wang and Y. Gong, "Deep Self-Organizing Map for visual classification," *2015 International Joint Conference on Neural Networks (IJCNN)*, Killarney, 2015, pp. 1-6, doi: 10.1109/IJCNN.2015.7280357

DSOM self-organizing layer

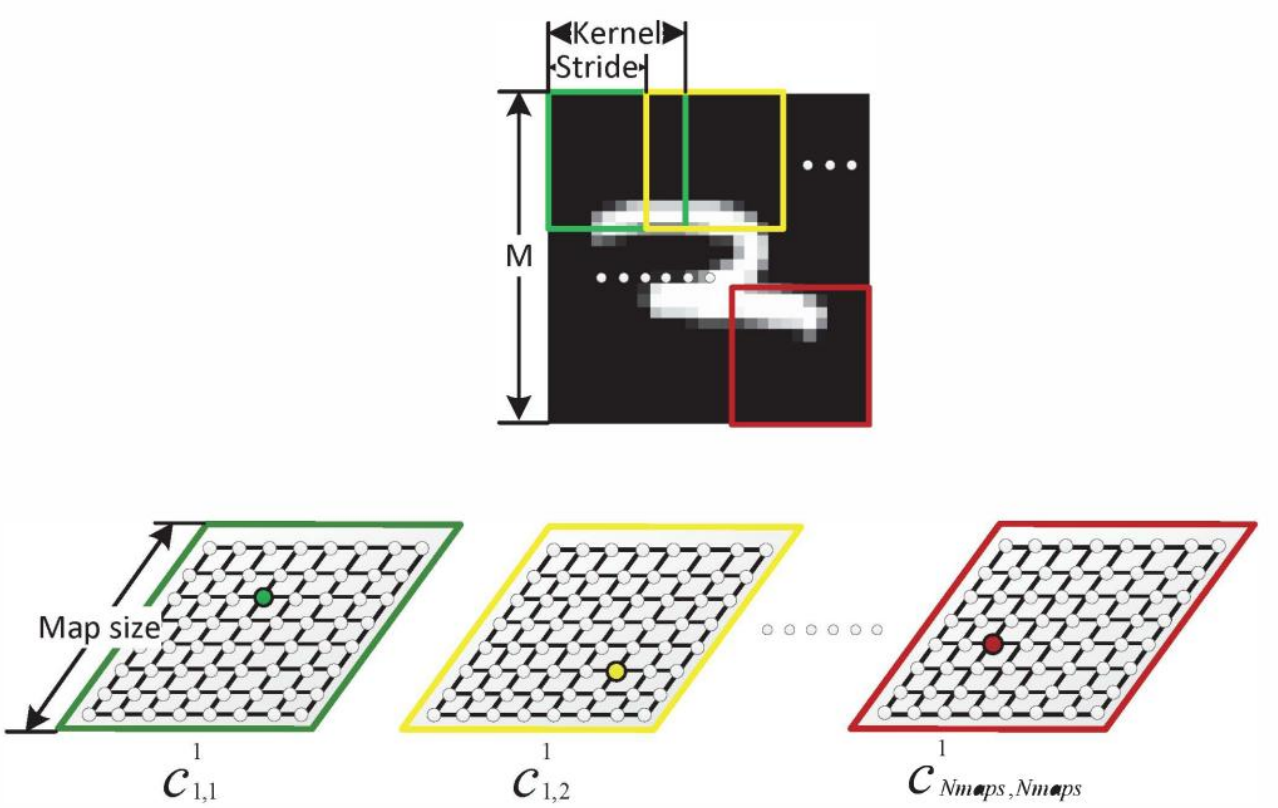


Illustration of the self-organizing layer. There are Nmap x Nmap SOMs in the layer, each focusing on a different sub-region on the original input.

N. Liu, J. Wang and Y. Gong, "Deep Self-Organizing Map for visual classification," *2015 International Joint Conference on Neural Networks (IJCNN)*, Killarney, 2015, pp. 1-6, doi: 10.1109/IJCNN.2015.7280357

DSOM sampling layer

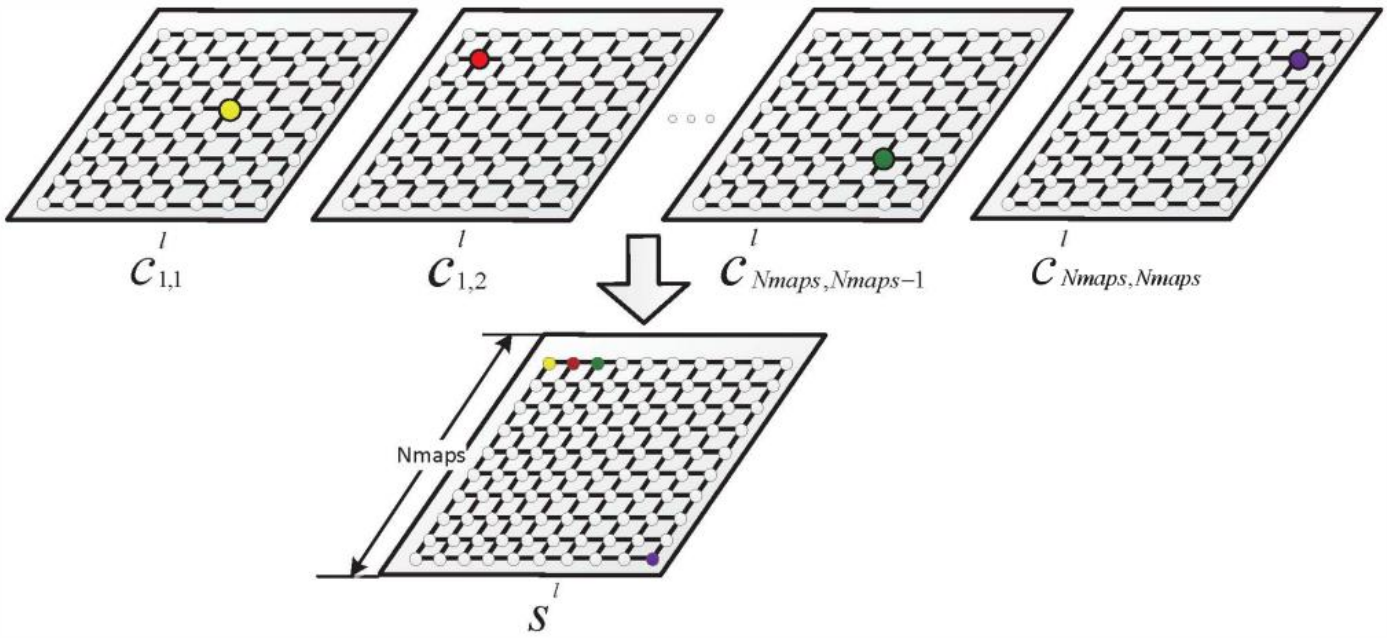


Illustration of the sampling layer. The color nodes highlight the winning neurons on each map. The Nmap x Nmap winners are organized on a two-dimensional map.

N. Liu, J. Wang and Y. Gong, "Deep Self-Organizing Map for visual classification," *2015 International Joint Conference on Neural Networks (IJCNN)*, Killarney, 2015, pp. 1-6, doi: 10.1109/IJCNN.2015.7280357

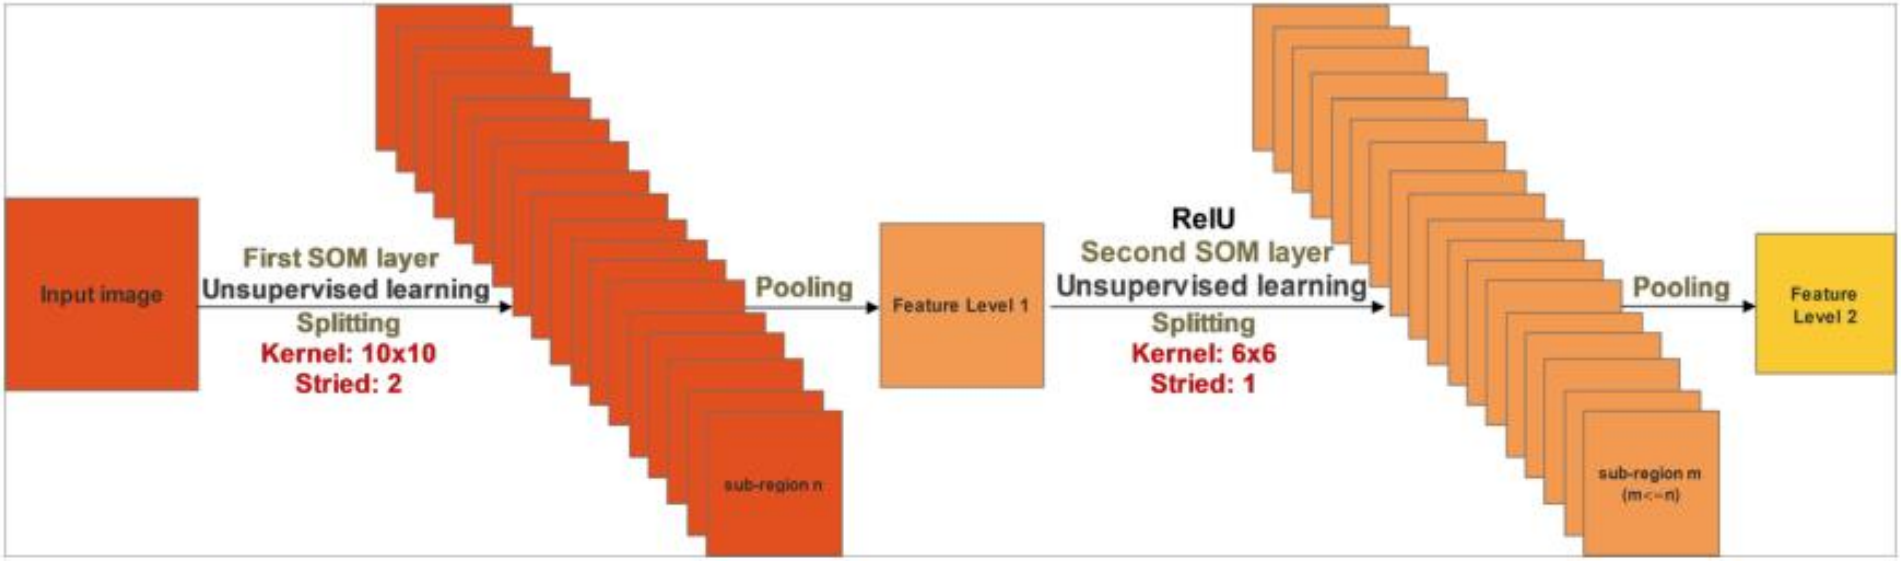
UDSOM, 2020

- Unsupervised Deep Self-Organizing Map (UDSOM) algorithm for feature extraction

» Sakkari, Mohamed & Zaied, Mourad. (2020). A Convolutional Deep Self-Organizing Map Feature extraction for machine learning. Multimedia Tools and Applications. 79. 10.1007/s11042-020-08822-9.

UDSOM

- Feature extraction algorithm:



- UDSOM consists of layers of an alternating self-organizing layer, a sampling layer and a ReLU function

Sakkari, Mohamed & Zaied, Mourad. (2020). A Convolutional Deep Self-Organizing Map Feature extraction for machine learning. Multimedia Tools and Applications. 79. 10.1007/s11042-020-08822-9.

UDSOM

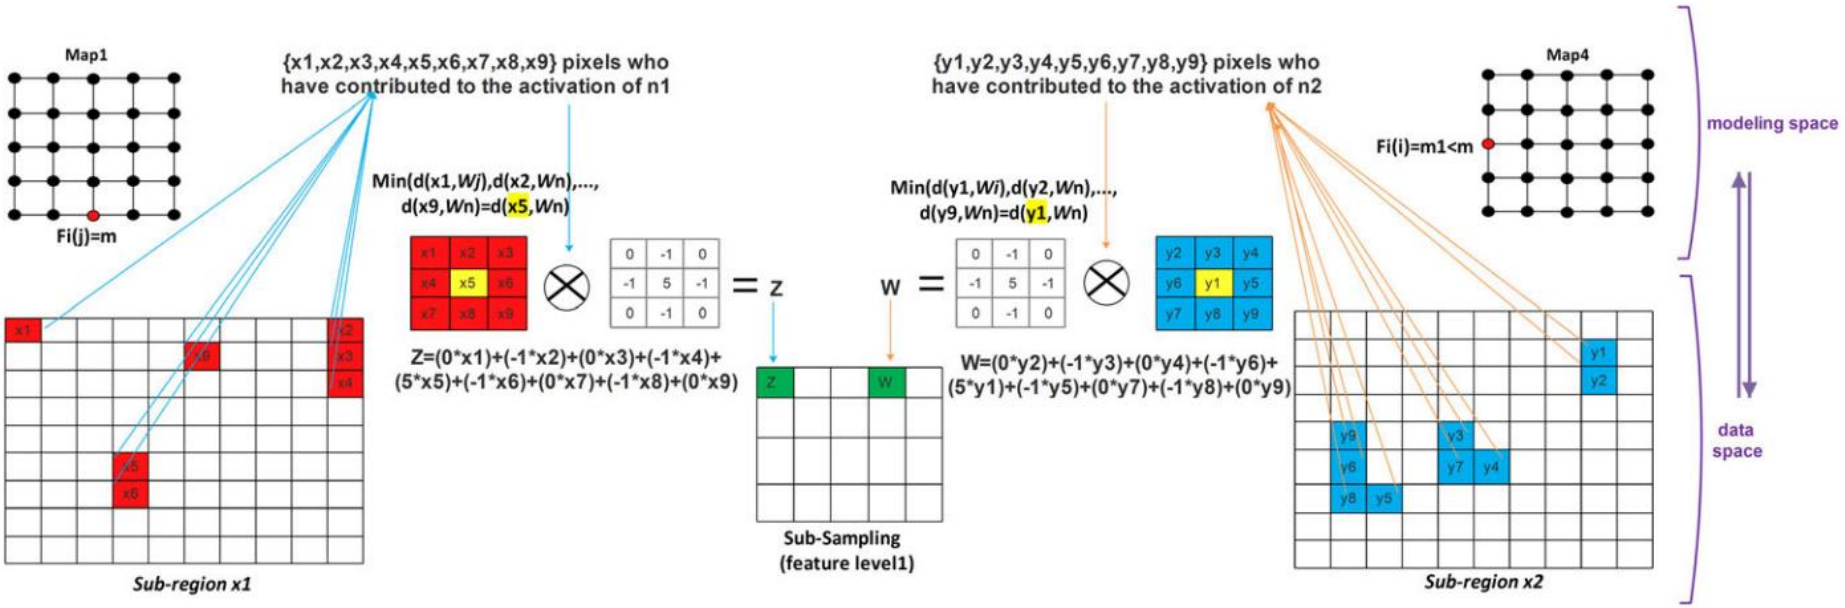
- The self-organizing layer is composed of some numbers of 2D maps, with each map focusing on modelling a local sub-region of the input space.

- Algorithm:
  - 1. Split the input image into N sub-regions according to a first parameter setting.
  - 2. Build N SOMs with each map focusing on modelling a local sub-region.
  - 3. Do Sub-sampling (Convolution and pooling).
  - 4. ReLU.
  - 5. Get the image abstraction provided in 3.
  - 6. Spread the weights to the top layer.
  - 7. Repeat the procedure (1,2,3,4,5 and 6) applying the new settings.

Sakkari, Mohamed & Zaied, Mourad. (2020). A Convolutional Deep Self-Organizing Map Feature extraction for machine learning. Multimedia Tools and Applications. 79. 10.1007/s11042-020-08822-9.

UDSOM

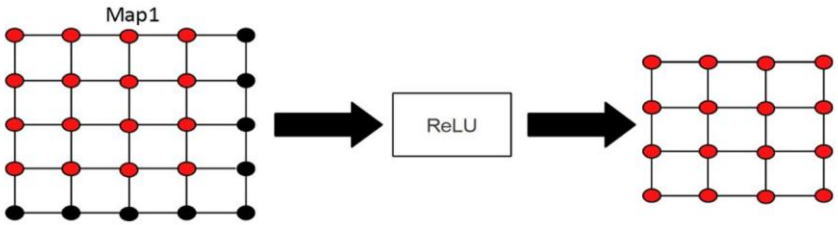
- Sampling module:



Sakkari, Mohamed & Zaied, Mourad. (2020). A Convolutional Deep Self-Organizing Map Feature extraction for machine learning. Multimedia Tools and Applications. 79. 10.1007/s11042-020-08822-9.

UDSOM

- ReLu module:
  - ReLU: neurons in black have never been activated so they will have crushed



Sakkari, Mohamed & Zaied, Mourad. (2020). A Convolutional Deep Self-Organizing Map Feature extraction for machine learning. Multimedia Tools and Applications. 79. 10.1007/s11042-020-08822-9.

UDSOM

- Why not using a CNN and what is the difference between UDSOM and CNN?

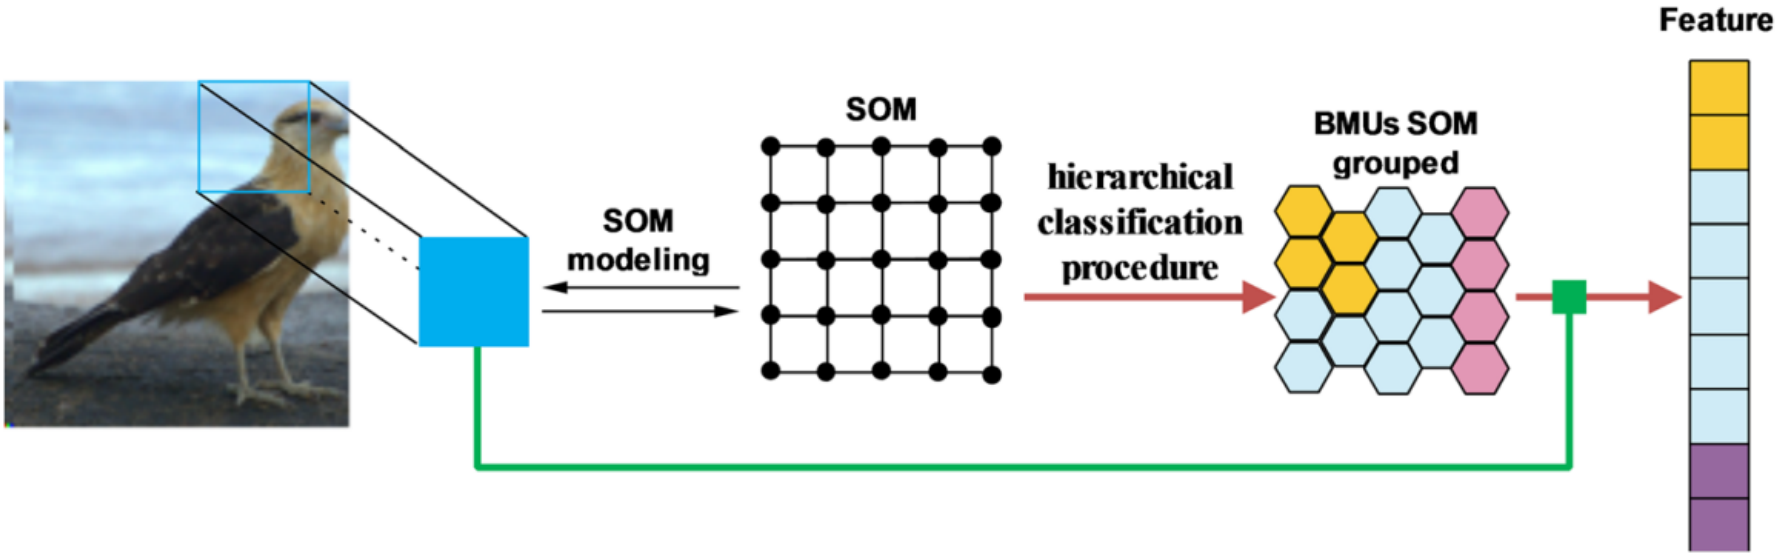
  - the deep architecture of UDSOM uses local receptive fields as CNN,
  - the function of hidden layers, based on a non-linear projection of high-dimensional data over a small space using Kohonen maps, is completely different from CNN

    - The **CNN** hidden layer consist of a convolution function followed by a pooling operation allows to generate a feature map for the top-level layer. In the **UDSOM**, the hidden layer process local sub-region with SOM map and aggregate the BMUs to generate a feature abstraction level based a bottom-up hierarchical classification procedure. The neurons on the SOM map are grouped in such a way to give a more global view of the map, by grouping the closest neurons, then the closest groups. The bottom-up method proposed is based on the principle of minimization of inter-class inertia.

Sakkari, Mohamed & Zaied, Mourad. (2020). A Convolutional Deep Self-Organizing Map Feature extraction for machine learning. Multimedia Tools and Applications. 79. 10.1007/s11042-020-08822-9.

UDSOM

- Feature extraction based BMUs clustering
  - BMU=Best Matching Unit = winning neuron



The only similarity between the deep SOM proposed and the CNN architecture is the notion of the local receptive field.

Sakkari, Mohamed & Zaied, Mourad. (2020). A Convolutional Deep Self-Organizing Map Feature extraction for machine learning. Multimedia Tools and Applications. 79. 10.1007/s11042-020-08822-9.

UDSOM

- Computational complexity:
  - The computational complexity of the UDSOM is much lower than the CNN.
    - » Since, in any CNN the maximum time of training goes in the Back-Propagation of errors in the Fully Connected Layer (depends on the image size). Also, the maximum memory is also occupied by them.
    - » Contrairwise, the UDSOM do not require any Back-Propagation process.

Sakkari, Mohamed & Zaied, Mourad. (2020). A Convolutional Deep Self-Organizing Map Feature extraction for machine learning. Multimedia Tools and Applications. 79. 10.1007/s11042-020-08822-9.