data load and EDA

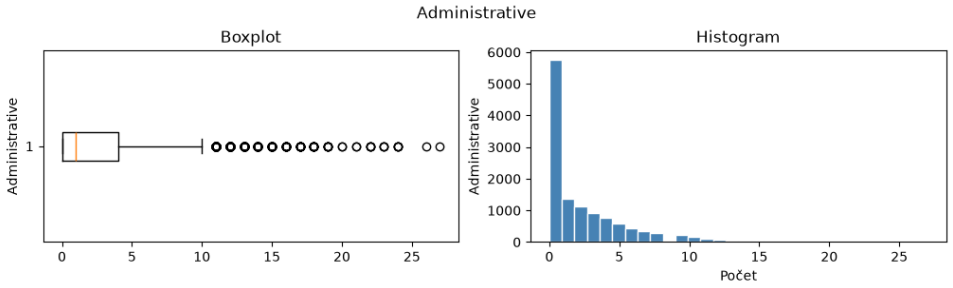
	0	1	2
SessionID	S-100000	S-100001	S-100002
Administrative	0	0	0
Administrative_ Duration	0.0	0.0	0.0
Informational	0	0	0
Informational_ Duration	NaN	0.0	NaN
ProductRelated	1.0	2.0	1.0
ProductRelated_ Duration	0.000000	64.000000	0.000000
BounceRates	0.20	0.00	0.20
ExitRates	0.20	0.10	0.20
PageValues	0.0	0.0	0.0
SpecialDay	0.0	0.0	0.0
Month	Feb	Feb	Feb
OperatingSystems	1	2	4
Browser	1	2	1
Region	1	1	9
TrafficType	1	2	3
VisitorType	Returning_ Visitor	Returning_ Visitor	Returning_ Visitor
Weekend	False	False	False
Revenue	False	False	False

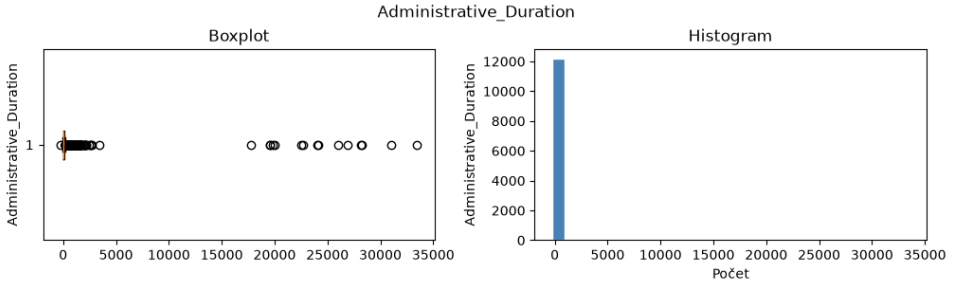
	3	4
SessionID	S-100003	S-100004
Administrative	0	0
Administrative_ Duration	0.0	0.0
Informational	0	0
Informational_ Duration	NaN	NaN
ProductRelated	2.0	10.0
ProductRelated_ Duration	2.666667	627.500000
BounceRates	0.05	0.02
ExitRates	0.14	0.05
PageValues	0.0	0.0
SpecialDay	0.0	0.0

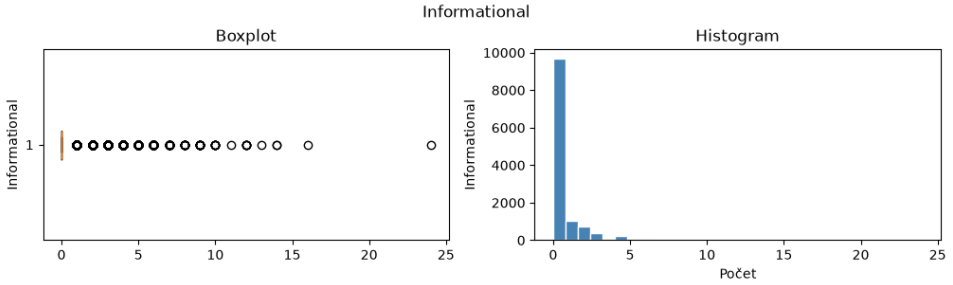
	3	4
Month	Feb	Feb
OperatingSystems	3	3
Browser	2	3
Region	2	1
TrafficType	4	4
VisitorType	Returning_Visitor	NaN
Weekend	False	True
Revenue	False	False

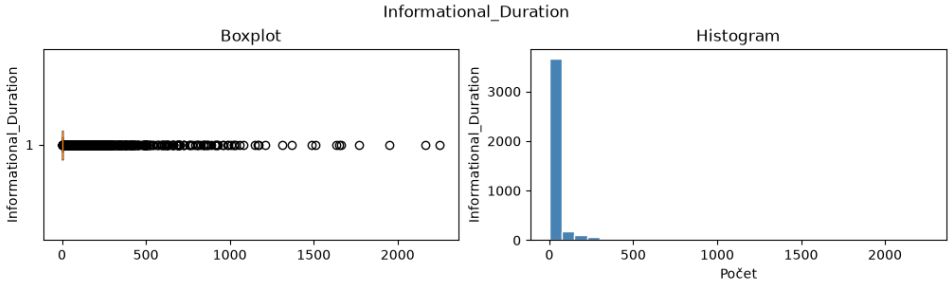
Administrative, Administrative_Duration, Informational, Informational_Duration, ProductRelated, ProductRelated_Duration, BounceRates, ExitRates, PageValues, SpecialDay, OperatingSystems, Browser, Region, TrafficType.

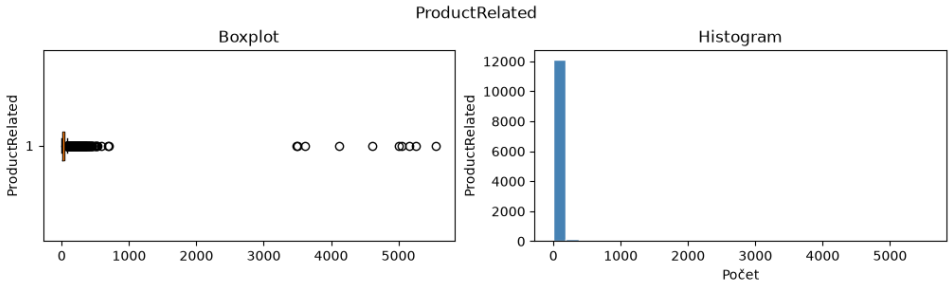
Typ údajov: str.

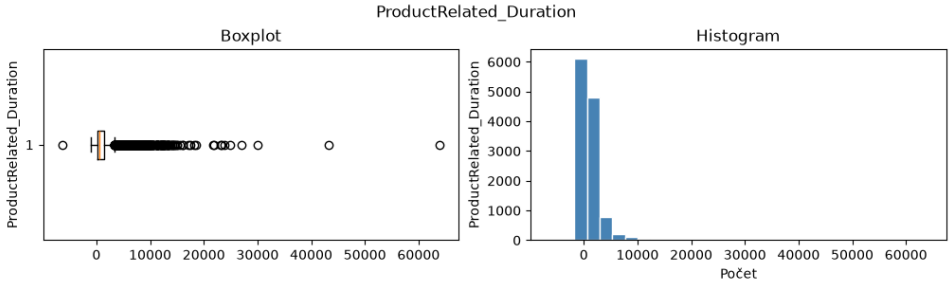


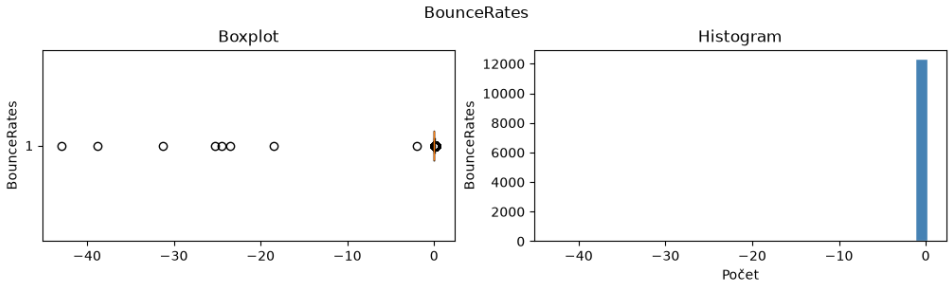


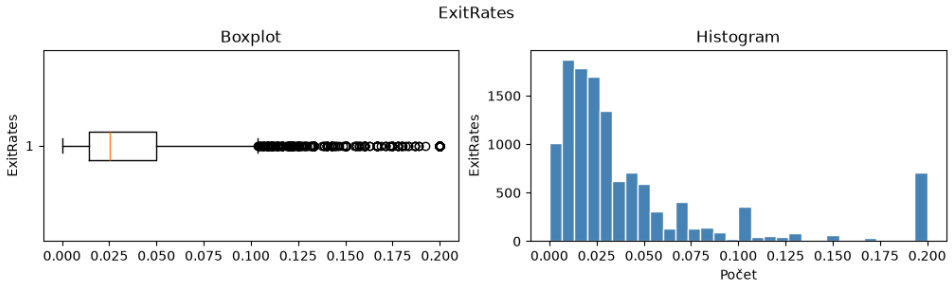


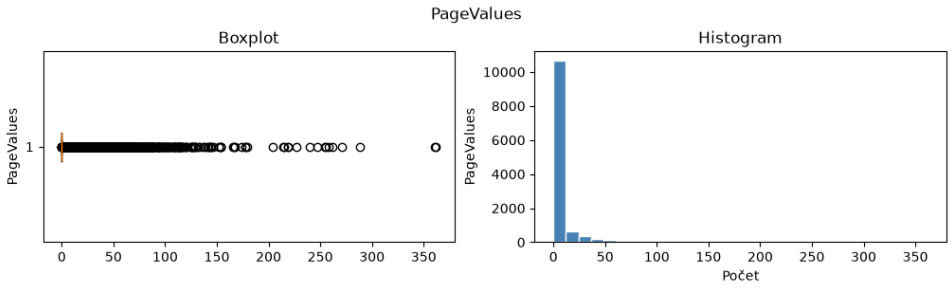

Informational_Duration
Boxplot
Histogram
Informational_Duration
Počet

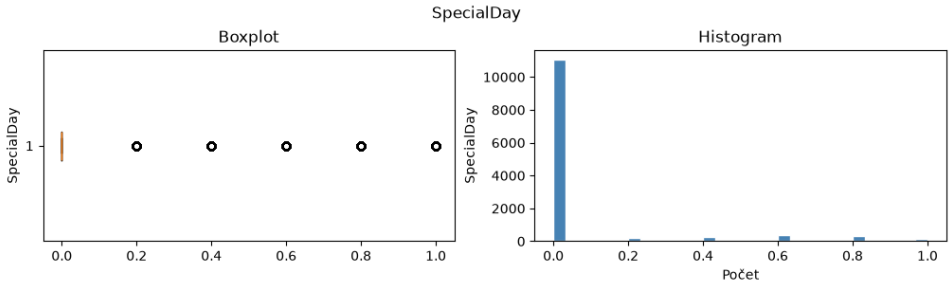

ProductRelated
Boxplot
Histogram
ProductRelated
Počet

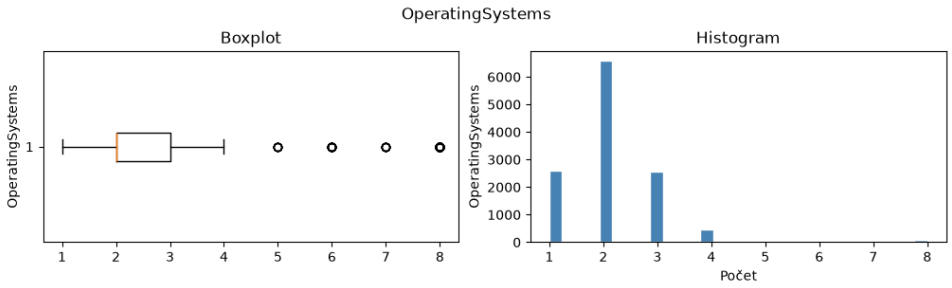

ProductRelated_Duration
Boxplot
Histogram
ProductRelated_Duration
Počet

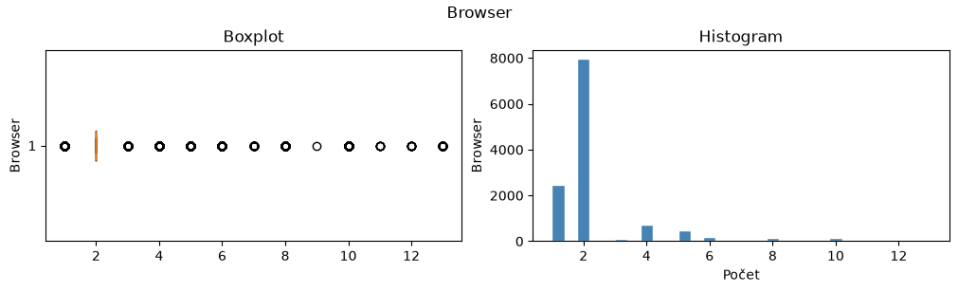

BounceRates
Boxplot
Histogram
BounceRates
Počet

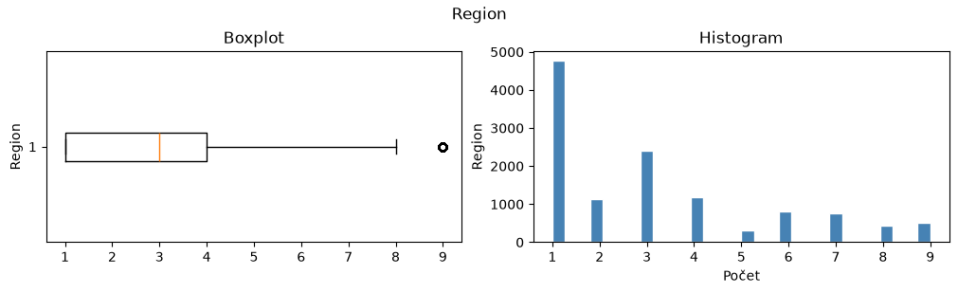

ExitRates
Boxplot
Histogram
ExitRates
1
0.000 0.025 0.050 0.075 0.100 0.125 0.150 0.175 0.200
0 500 1000 1500
Počet

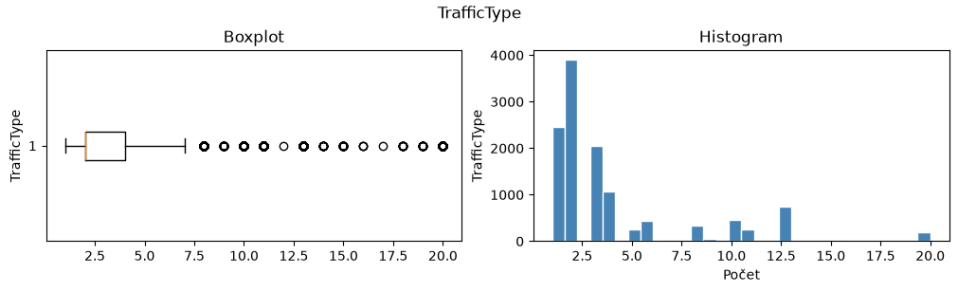

PageValues
Boxplot
Histogram
PageValues
1
0 50 100 150 200 250 300 350
0 2000 4000 6000 8000 10000
Počet

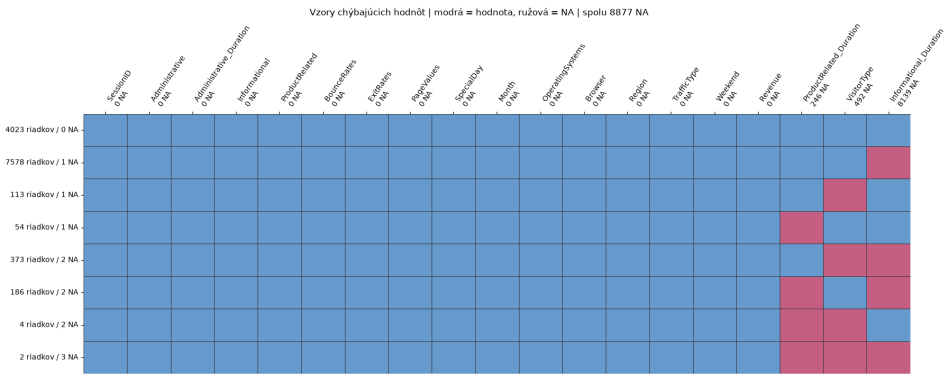

SpecialDay
Boxplot
Histogram
SpecialDay
1
0.0 0.2 0.4 0.6 0.8 1.0
0 2000 4000 6000 8000 10000
Počet


OperatingSystems
Boxplot
Histogram
OperatingSystems
1
1 2 3 4 5 6 7 8
0 1000 2000 3000 4000 5000 6000
Počet









V cca 2/3 (8139/12334) dát chýba hodnota (NA) v poslednom stĺpci Informational_Duration, čo není ani vhodné dopĺňať/nahrádzať, preto tento stĺpec je jednoduchšie a lepšie dropnúť. Riadky s chýbajúcim Product

Related_Duration a VisitorType odstraňujem pre chýbajúce hodnotu, čo predstavuje 732 riadkov.

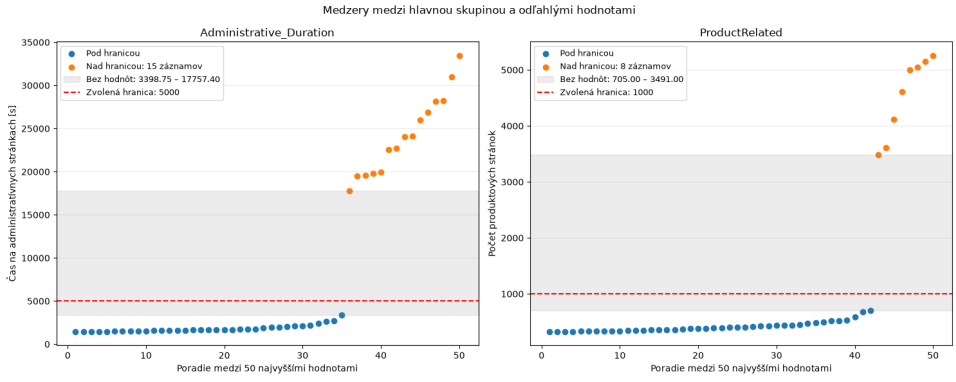
	count	mean	std
Administrative	11601.000000	2.326437	3.327508
Administrative_ Duration	11601.000000	112.502691	901.008974
Informational	11601.000000	0.507801	1.270743
ProductRelated	11601.000000	35.006637	127.664326
ProductRelated_ Duration	11601.000000	1199.481299	1918.490414
BounceRates	11601.000000	0.004117	0.748188
ExitRates	11601.000000	0.042697	0.048397
PageValues	11601.000000	6.154971	19.006150
SpecialDay	11601.000000	0.061546	0.199062
OperatingSystems	11601.000000	2.122662	0.910592
Browser	11601.000000	2.351608	1.708669
Region	11601.000000	3.140160	2.394896
TrafficType	11601.000000	4.077752	4.027833

	min	25%	50%
Administrative	0.000000	0.000000	1.000000
Administrative_ Duration	-214.548633	0.000000	8.000000
Informational	0.000000	0.000000	0.000000
ProductRelated	0.000000	7.000000	18.000000
ProductRelated_ Duration	-6423.973010	185.000000	604.000000
BounceRates	-42.953427	0.000000	0.003014
ExitRates	0.000000	0.014251	0.025000
PageValues	0.000000	0.000000	0.000000
SpecialDay	0.000000	0.000000	0.000000
OperatingSystems	1.000000	2.000000	2.000000
Browser	1.000000	2.000000	2.000000
Region	1.000000	1.000000	3.000000
TrafficType	1.000000	2.000000	2.000000

	75%	max
Administrative	4.000000	27.000000
Administrative_ Duration	94.600000	33466.707646
Informational	0.000000	24.000000

	75%	max
ProductRelated	38.000000	5258.000000
ProductRelated_ Duration	1467.654221	63973.522230
BounceRates	0.016667	0.200000
ExitRates	0.050000	0.200000
PageValues	0.000000	361.763742
SpecialDay	0.000000	1.000000
OperatingSystems	3.000000	8.000000
Browser	2.000000	13.000000
Region	4.000000	9.000000
TrafficType	4.000000	20.000000

removing outliers

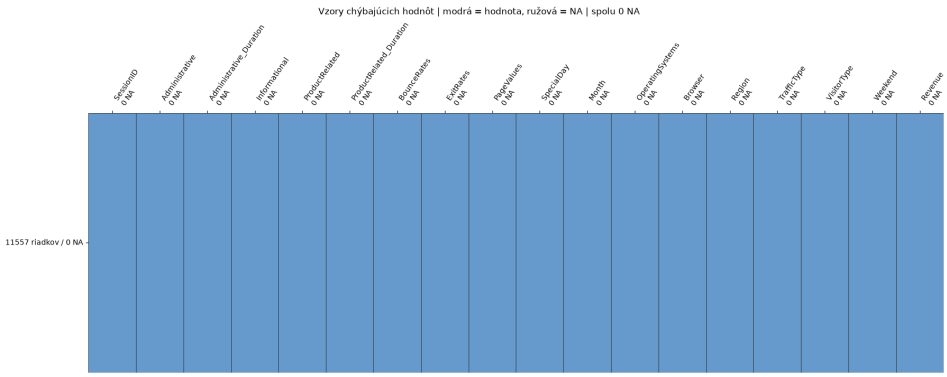


odľahlé záznamy

Počty riadkov: 11601, 11557.

Hranice 5 000s a 1 000 stránok ležia v medzerách medzi ostatnými hodnotami a dvoma odľahlými skupinami. Drop duplicates odstráni úplne identické riadky, pričom návštevy s rôznymi SessionID ponechá. Vysoké PageValues a dlhé ProductRelated_Duration ponechávam, lebo samotná veľkosť hodnoty nepreukazuje chybu a môže predstavovať hodnotný nákup alebo dlhú návštevu.

Po vyčistení sa počet riadkov znížil z 11 601 na 11 557, kde sa odstráni 18 neplatných záznamov, 23 kladných outlierov a 3 duplicity.



VisitorType vs ProductRelated a PageValues

VisitorType

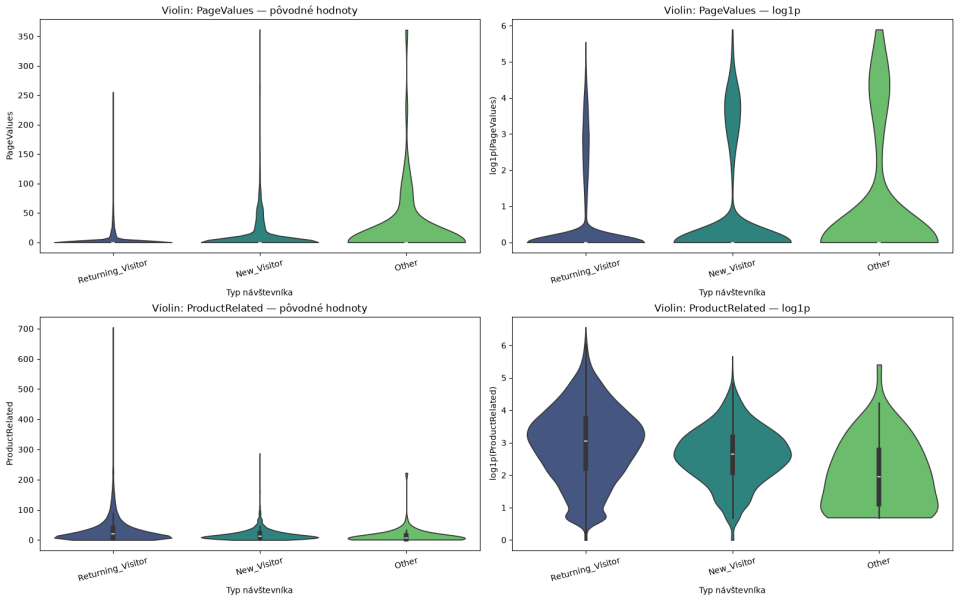
Returning_Visitor: 9887.

New_Visitor: 1592.

Other: 78.

Názov: count. Typ údajov: int64.

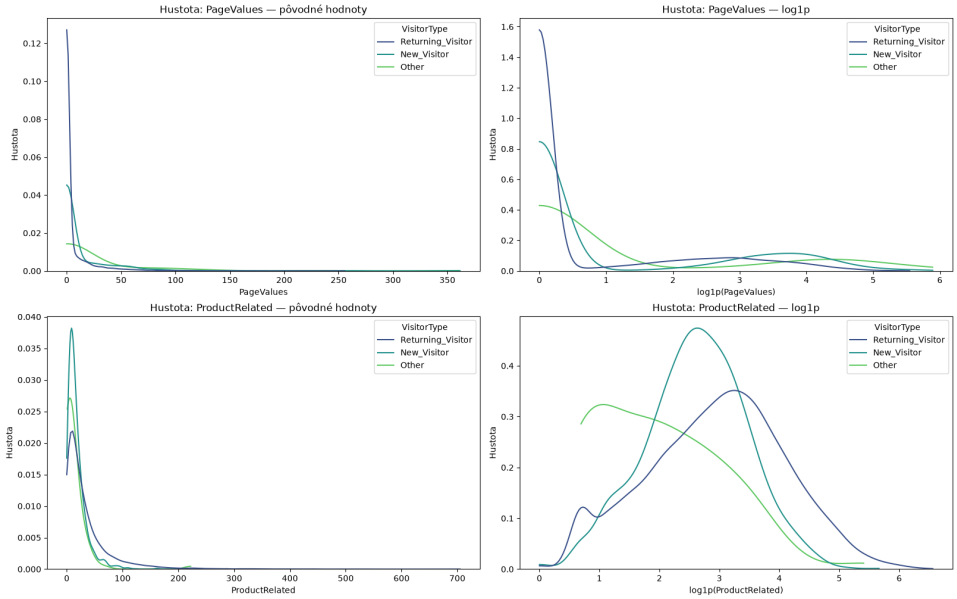
použitý log(1 + x) (log1p), kvôli normalizácii veľmi odľahlých hodnôt a obsahovaní 0 hodnôt, logaritmus 1+x zachová 0 na 0, normalizácia zachovaná aj kvôli porovnaniu rôznych skupín



Pri PageValues sa vo všetkých skupinách väčšina hodnôt sústreďuje pri nule. Rozdelenia majú dlhé chvosty, kde sa ťahajú k vysokým hodnotám. Transformácia log1p zlepšuje zobrazenie hodnôt, kde je vidno že v skupine

Other je hustota posunutá k vyšším hodnotám než pri vracajúcich sa návštevníkov.

Pri ProductRelated pôvodnú mierku výrazne ovplyvňujú extrémne hodnoty vracajúcich sa návštevníkov. Po transformácii sú rozdiely čitateľnejšie, kde vracajúci sa návštevníci majú najvyšší medián a najnižší ostatný typ návštevníkov. Vracajúci návštevníci navštevujú viac produktovo súvisiacich stránok.



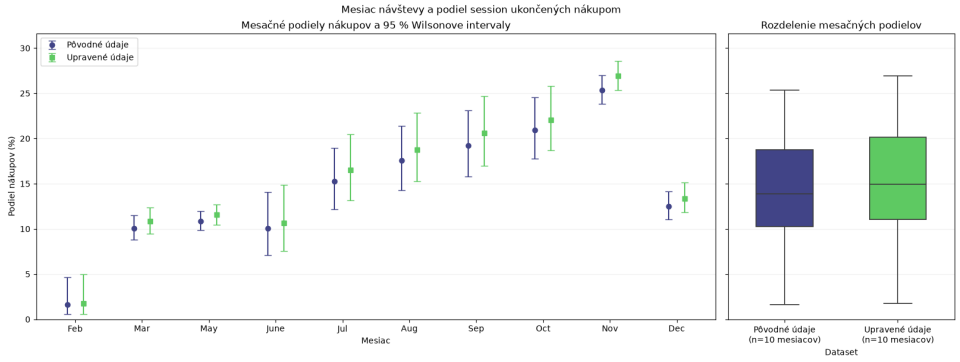
Pri PageValues vidíme výrazný vrchol pri nule a dlhý chvost pri všetkých skupinách. Pri nule je najhustejšia skupina vracajúcich sa zákazníkov, pri skupinách New_Visitor a Other sú hodnoty širšie.

Pri ProductRelated je najvyššia hodnota v skupine nových zákazníkov v oblasti medzi 2 a 4 (os logaritmu skupiny). Skupina Other má najhustejšiu hodnotu bližšie k nule a vracajúci sa zákazníci majú najhustejšiu hodnotu vo vyšších hodnotách.

Month (mesiac poslednej návštevy) a Revenue

Porovnávam podiel sessionov ukončených nákupom v jednotlivých mesiacoch. Počet nákupov / počet sessions v danom mesiaci. Mesačné podiely a chybové úsečky, v ich 95% Wilson intervaloch spoľahlivosti, čo vyjadruje neistotu odhadu pri predpoklade nezávislých sessionov. V datasete chýbajú dáta za mesiac január a apríl.

Boxplot sumarizuje rozdelenie mesačných podielov.



Month	Feb	Mar	May
Pôvodné údaje / sessions	185	1907	3365
Pôvodné údaje / purchases	3	192	365
Pôvodné údaje / purchase_rate	1.62	10.07	10.85
Pôvodné údaje / ci_lower	0.55	8.80	9.84
Pôvodné údaje / ci_upper	4.66	11.50	11.94
Upravené údaje / sessions	173	1771	3161
Upravené údaje / purchases	3	192	365
Upravené údaje / purchase_rate	1.73	10.84	11.55
Upravené údaje / ci_lower	0.59	9.48	10.48
Upravené údaje / ci_upper	4.97	12.37	12.71

Month	June	Jul	Aug
Pôvodné údaje / sessions	288	432	433
Pôvodné údaje / purchases	29	66	76
Pôvodné údaje / purchase_rate	10.07	15.28	17.55
Pôvodné údaje / ci_lower	7.10	12.19	14.26

Month	June	Jul	Aug
Pôvodné údaje / ci_ upper	14.09	18.98	21.42
Upravené údaje / sessions	272	400	405
Upravené údaje / purchases	29	66	76
Upravené údaje / purchase_rate	10.66	16.50	18.77
Upravené údaje / ci_ lower	7.53	13.18	15.26
Upravené údaje / ci_ upper	14.89	20.45	22.85

Month	Sep	Oct	Nov
Pôvodné údaje / sessions	448	549	2999
Pôvodné údaje / purchases	86	115	761
Pôvodné údaje / purchase_rate	19.20	20.95	25.38
Pôvodné údaje / ci_ lower	15.82	17.75	23.85
Pôvodné údaje / ci_ upper	23.10	24.55	26.96
Upravené údaje / sessions	418	522	2821
Upravené údaje / purchases	86	115	760
Upravené údaje / purchase_rate	20.57	22.03	26.94
Upravené údaje / ci_ lower	16.98	18.69	25.34
Upravené údaje / ci_ upper	24.71	25.78	28.61

Month	Dec
Pôvodné údaje / sessions	1727
Pôvodné údaje / purchases	216

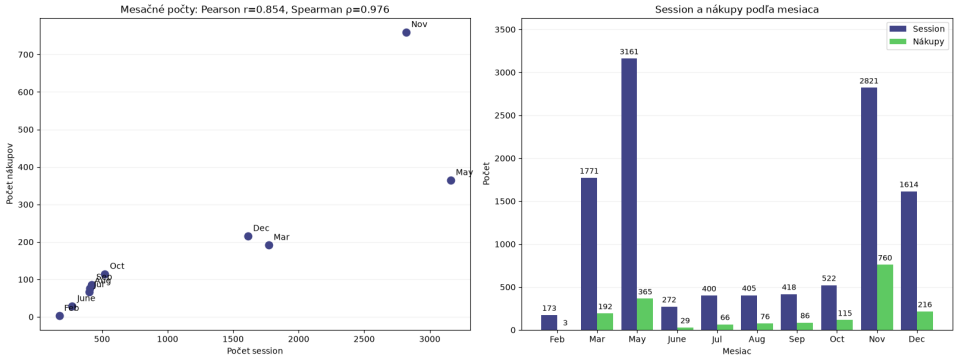
Month	Dec
Pôvodné údaje / purchase_rate	12.51
Pôvodné údaje / ci_lower	11.03
Pôvodné údaje / ci_upper	14.15
Upravené údaje / sessions	1614
Upravené údaje / purchases	216
Upravené údaje / purchase_rate	13.38
Upravené údaje / ci_lower	11.81
Upravené údaje / ci_upper	15.13

Najvyšší podiel nákupov je za mesiac november, približne 25.4% v neupravených a v upravených 26.9% dátach. Najnižšie je za mesiac február, kde dosahuje podiel iba 1.6% a 1.7%.

Intervaly spoľahlivosti spresňujú informáciu o presnosti odhadov, kde závisí od počtu sessions aj od podielu nákupov. Máj má užší interval ako mesiac august, ktorý obsahuje menej sessionov.

Pri čistení boli odstránené iba sessiony bez nákupu, počet nákupov preto ostal rovnaký, zatiaľ čo sessiony klesli, čo zvýšilo podiel nákupov v upravených dátach.

Correlation of session and purchase by month



Mesiac	Počet session	Počet nákupov	Podiel nákupov (%)
Feb	173	3	1.73
Mar	1771	192	10.84
May	3161	365	11.55
June	272	29	10.66
Jul	400	66	16.50
Aug	405	76	18.77
Sep	418	86	20.57
Oct	522	115	22.03
Nov	2821	760	26.94
Dec	1614	216	13.38
Spolu / priemerný podiel / korelácie medzi mesiacmi	11557	1908	15.30

Mesiac	Pearson	Spearman
Feb	—	—
Mar	—	—
May	—	—
June	—	—
Jul	—	—
Aug	—	—
Sep	—	—
Oct	—	—
Nov	—	—
Dec	—	—
Spolu / priemerný podiel / korelácie medzi mesiacmi	0.854	0.976

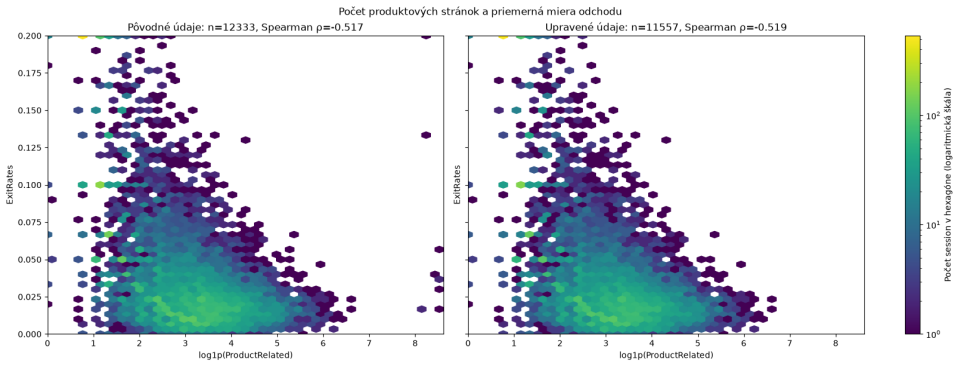
Pearsonova korelácia r = 0.853 naznačuje silný lineárny vzťah. Spearmanova korelácia $\rho = 0.976$ ukazuje, že mesiace s vyššou návštevnosťou majú takmer vždy aj vyšší počet nákupov.

Máj mal najviac sessionov 3 171 ale nákupom skončilo 365, podiel 11.5%. November mal menej sessionov 2 826 no najviac nákupov 756, čo je aj najvyšší podiel nákupov 26.9%. Najnižší podiel dosiahol za mesiac február a to 1.7%.

ProductRelated a ExitRates

Hexbin graf ukazuje počet produktových stránok oproti priemernej miere odchodu zo stránok navštívených v sessions. Používam log1p, čo zachová

nuly a zlepšuje čitateľnosť veľkého rozsahu. Farba vyjadruje počet sessionov v hexagóne.



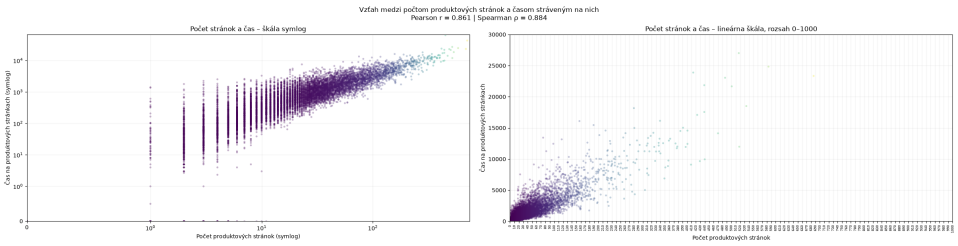
Dataset	Počet session	Spearman	Medián Exit Rates (0–1 produktových stránok)
Pôvodné údaje	12333	-0.517	0.2
Upravené údaje	11557	-0.519	0.2

Dataset	Medián ExitRates (>50 produktových stránok)
Pôvodné údaje	0.017
Upravené údaje	0.017

S rastúcim počtom navštívených produktových stránok má priemerná miera odchodu sa znižovať. Vzťah ostáva podobný pred aj po čistení, kde to naznačuje Spearmanova korelácia, ktorá je približne -0.52. Nepreukazuje sa, že viac produktových stránok priamo spôsobuje nižšiu mieru odchodu. Medián pre ExitRates pri 0-1 produktových stránkach je 0.2 ale 0.017 pri viac ako 50 produktových stránkach.

Correlation of ProductRelated and time on them

Počet session: 11557 | Pearson r = 0.861 | Spearman ρ = 0.884



Počet session s časom nad 30 000: 2

	SessionID	Product Related	Product Related_ Duration
0	S-108071	449.0	63973.52223
1	S-105152	705.0	43171.23338

Graf ukazuje, že s rastúcim počtom navštívených produktových stránok rastie aj čas strávený na nich. Pearsonova korelácia je 0.304, čo naznačuje slabšiu lineárnu závislosť. Spearmanova korelácia 0.883 ukazuje silný vzťah, vyššiemu počtu stránok väčšinou pripadá dlhší čas, hoci tento rast nie je rovnomerný.

Graf so škálou symlog umožňuje ukázať extrémne hodnoty a lepšie odhaľuje rastúci trend. Lineárny graf ukazuje, že väčšina sessionov sa sústreďuje pri nižších počtoch stránok a kratšom čase.

Pri rovnakom počte stránok sa čas medzi sessionami výrazne líši. Viditeľné sú aj extrémne hodnoty s vysokým počtom stránok a pomerne krátkym časom, ktoré môžu ovplyvňovať Pearsonovu koreláciu. Počet produktových stránok súvisí s časom návštevy, ale sám nestačí na jeho presný odhad.

Classification

data separation

Rozmery vstupov: 11557 riadkov a 16 stĺpcov.

Rozmery cieľa: 11557 hodnôt.

Kategorické stĺpce: Month, VisitorType, OperatingSystems, Browser, Region, TrafficType.

Binárne stĺpce: Weekend.

Revenue

0: 0.834905.

1: 0.165095.

Názov: proportion. Typ údajov: float64.

train, val, test split

Počty vzoriek: train 8089, val 1734, test 1734.

Rozdelenie dát na trénovacie, testovacie a validačné, kde využijem aj stratify na zachovanie pomeru voči Revenue (zachovanie tak istého pomeru nákupu v train, val a test množine). Počty sa môžu mierne líšiť od pomerov pre zaokrúhlenie na celé riadky.

encoding discrete cols

One-Hot encoder vytvorí samostatné binárne stĺpce pre každú kategóriu, čo je vhodné pre diskrétne dáta (kategorické). Nezachováva vzťah, závislosť, poradie ani vzdialenosť od ostatných kategórií - mali by byť nezávislé, ale nezaručuje sa to. handle unknown umožní spracovať aj kategóriu, ktorá sa v tréningu nevyskytla a imputer doplní prípadne chýbajúce hodnoty najčastejšou kategóriou, ktorá sa vyskytla v tréningu.

scaling

StandardScaler škáluje číselné vlastnosti na približne nulový priemer a jednotkový rozptyl (napríklad aby sa čas v sekundách neprevažoval nad mierami odchodu pri fitovaní logistickej regresii). Diskrétne stĺpce ponechávam v 0/1, prípadne chýbajúce hodnoty sa doplnia modusom.

Všetko je organizované v Pipeline, aby sa kódovanie, škálovanie, imputácia využívalo pri každom folde trénovania.

modely

RandomForest: 64 kombinácií
LogisticRegression: 12 kombinácií
DecisionTree: 10 kombinácií

GridSearchCV

Pri cross-validation sa vyberajú parametre podľa priemernej accuracy v 5 stratified k-folds tréningovej množiny.

experiments, fit and eval

fit

Rozdelenie 70/15/15 | RandomForest
Počet foldov: 1. Počet kandidátov: 64. Celkový počet trénovaní: 64.
Najlepšie parametre GridSearchCV: maximálna hĺbka 15, počet zvažovaných vlastností 10, minimálny počet vzoriek v liste 3.
Najlepšie skóre GridSearchCV: 0.8967704728950404.
Rozdelenie 70/15/15 | LogisticRegression
Počet foldov: 1. Počet kandidátov: 12. Celkový počet trénovaní: 12.
Najlepšie parametre GridSearchCV: parameter C 0.1 (typ float64), váženie tried žiadne.
Najlepšie skóre GridSearchCV: 0.8748558246828143.
Rozdelenie 70/15/15 | DecisionTree
Počet foldov: 1. Počet kandidátov: 10. Celkový počet trénovaní: 10.

Najlepšie parametre GridSearchCV: maximálna hĺbka 5, minimálny počet vzoriek v liste 1.

Najlepšie skóre GridSearchCV: 0.8927335640138409.

Rozdelenie 80/10/10 | RandomForest

Počet foldov: 1. Počet kandidátov: 64. Celkový počet trénovaní: 64.

Najlepšie parametre GridSearchCV: maximálna hĺbka 15, počet zvažovaných vlastností 13, minimálny počet vzoriek v liste 3.

Najlepšie skóre GridSearchCV: 0.8987889273356401.

Rozdelenie 80/10/10 | LogisticRegression

Počet foldov: 1. Počet kandidátov: 12. Celkový počet trénovaní: 12.

Najlepšie parametre GridSearchCV: parameter C 0.1 (typ float64), váženie tried žiadne.

Najlepšie skóre GridSearchCV: 0.879757785467128.

Rozdelenie 80/10/10 | DecisionTree

Počet foldov: 1. Počet kandidátov: 10. Celkový počet trénovaní: 10.

Najlepšie parametre GridSearchCV: maximálna hĺbka 3, minimálny počet vzoriek v liste 1.

Najlepšie skóre GridSearchCV: 0.8875432525951558.

Rozdelenie 70/10/20 | RandomForest

Počet foldov: 1. Počet kandidátov: 64. Celkový počet trénovaní: 64.

Najlepšie parametre GridSearchCV: maximálna hĺbka 10, počet zvažovaných vlastností 13, minimálny počet vzoriek v liste 1.

Najlepšie skóre GridSearchCV: 0.9117647058823529.

Rozdelenie 70/10/20 | LogisticRegression

Počet foldov: 1. Počet kandidátov: 12. Celkový počet trénovaní: 12.

Najlepšie parametre GridSearchCV: parameter C 1.0 (typ float64), váženie tried žiadne.

Najlepšie skóre GridSearchCV: 0.8780276816608996.

Rozdelenie 70/10/20 | DecisionTree

Počet foldov: 1. Počet kandidátov: 10. Celkový počet trénovaní: 10.

Najlepšie parametre GridSearchCV: maximálna hĺbka 3, minimálny počet vzoriek v liste 1.

Najlepšie skóre GridSearchCV: 0.9013840830449827.

Rozdelenie 60/10/30 | RandomForest

Počet foldov: 1. Počet kandidátov: 64. Celkový počet trénovaní: 64.

Najlepšie parametre GridSearchCV: maximálna hĺbka 10, počet zvažovaných vlastností 10, minimálny počet vzoriek v liste 3.

Najlepšie skóre GridSearchCV: 0.8996539792387543.

Rozdelenie 60/10/30 | LogisticRegression

Počet foldov: 1. Počet kandidátov: 12. Celkový počet trénovaní: 12.

Najlepšie parametre GridSearchCV: parameter C 0.1 (typ float64), váženie tried žiadne.

Najlepšie skóre GridSearchCV: 0.8719723183391004.

Rozdelenie 60/10/30 | DecisionTree

Počet foldov: 1. Počet kandidátov: 10. Celkový počet trénovaní: 10.

Najlepšie parametre GridSearchCV: maximálna hĺbka 5, minimálny počet vzoriek v liste 5.

Najlepšie skóre GridSearchCV: 0.8953287197231834.

	0	1	2
Rozdelenie	70/15/15	70/15/15	70/15/15
Model	Random Forest	Logistic Regression	DecisionTree
Train n	8089	8089	8089
Val n	1734	1734	1734
Test n	1734	1734	1734
Train accuracy	0.9498	0.8795	0.9119
Val accuracy	0.8968	0.8749	0.8927
Grid accuracy	0.8968	0.8749	0.8927
Grid std	0.0	0.0	0.0
Test accuracy	0.8899	0.8760	0.8795
Test balanced accuracy	0.7404	0.6634	0.7146
Test F1	0.6078	0.4794	0.5618
Test recall	0.5175	0.3462	0.4685
Baseline test accuracy	0.8351	0.8351	0.8351
Train-test rozdiel	0.0600	0.0035	0.0324

	3	4	5
Rozdelenie	80/10/10	80/10/10	80/10/10
Model	Random Forest	Logistic Regression	DecisionTree
Train n	9245	9245	9245
Val n	1156	1156	1156
Test n	1156	1156	1156
Train accuracy	0.9562	0.8792	0.8982
Val accuracy	0.8988	0.8798	0.8875
Grid accuracy	0.8988	0.8798	0.8875
Grid std	0.0	0.0	0.0
Test accuracy	0.8867	0.8780	0.8832
Test balanced accuracy	0.7432	0.6708	0.7516
Test F1	0.6066	0.4946	0.6110
Test recall	0.5288	0.3613	0.5550
Baseline test accuracy	0.8348	0.8348	0.8348
Train-test rozdiel	0.0695	0.0012	0.0150

	6	7	8
Rozdelenie	70/10/20	70/10/20	70/10/20
Model	Random Forest	Logistic Regression	DecisionTree
Train n	8089	8089	8089
Val n	1156	1156	1156
Test n	2312	2312	2312
Train accuracy	0.9478	0.8796	0.8971
Val accuracy	0.9118	0.8780	0.9014
Grid accuracy	0.9118	0.8780	0.9014
Grid std	0.0	0.0	0.0
Test accuracy	0.8966	0.8763	0.8854
Test balanced accuracy	0.7607	0.6666	0.7602
Test F1	0.6406	0.4856	0.6230
Test recall	0.5576	0.3534	0.5733
Baseline test accuracy	0.8348	0.8348	0.8348
Train-test rozdiel	0.0512	0.0033	0.0118

	9	10	11
Rozdelenie	60/10/30	60/10/30	60/10/30
Model	Random Forest	Logistic Regression	DecisionTree
Train n	6933	6933	6933
Val n	1156	1156	1156
Test n	3468	3468	3468
Train accuracy	0.9358	0.8798	0.9091
Val accuracy	0.8997	0.8720	0.8953
Grid accuracy	0.8997	0.8720	0.8953
Grid std	0.0	0.0	0.0
Test accuracy	0.8971	0.8760	0.8950
Test balanced accuracy	0.7613	0.6703	0.7524
Test F1	0.6419	0.4917	0.6293
Test recall	0.5585	0.3630	0.5393
Baseline test accuracy	0.8348	0.8348	0.8348
Train-test rozdiel	0.0388	0.0038	0.0141

Vybraný model a rozdelenie: 70/10/20, RandomForest.

Vybrané parametre: maximálna hĺbka 10, počet zvažovaných vlastností 13, minimálny počet vzoriek v liste 1.

Grid accuracy znamená accuracy na validačnej množine

Grid std s hodnotou 0 znamená jediný validačný split, nie nulovú neistotu.

Tabuľka má 12 riadkov s rôznymi kombináciami experimentovania. Vyhodnocujú sa 3 modely na 4 rozdeleniach s trénovacou, validačnou a testovacou úspešnosťou. Najlepší model vyberám podľa validation accuracy a pri zhode podľa výsledku z grid searchu.

Rozdelenie 70/15/15 | RandomForest

Počet foldov: 1. Počet kandidátov: 64. Celkový počet trénovaní: 64.

Najlepšie parametre GridSearchCV: maximálna hĺbka 15, počet zvažovaných vlastností 10, minimálny počet vzoriek v liste 3.

Najlepšie skóre GridSearchCV: 0.8967704728950404.

Rozdelenie 70/15/15 | LogisticRegression

Počet foldov: 1. Počet kandidátov: 12. Celkový počet trénovaní: 12.

Najlepšie parametre GridSearchCV: parameter C 0.1 (typ float64), váženie tried žiadne.

Najlepšie skóre GridSearchCV: 0.8748558246828143.

Rozdelenie 70/15/15 | DecisionTree

Počet foldov: 1. Počet kandidátov: 10. Celkový počet trénovaní: 10.

Najlepšie parametre GridSearchCV: maximálna hĺbka 5, minimálny počet vzoriek v liste 1.

Najlepšie skóre GridSearchCV: 0.8927335640138409.

Rozdelenie 80/10/10 | RandomForest

Počet foldov: 1. Počet kandidátov: 64. Celkový počet trénovaní: 64.

Najlepšie parametre GridSearchCV: maximálna hĺbka 15, počet zvažovaných vlastností 13, minimálny počet vzoriek v liste 3.

Najlepšie skóre GridSearchCV: 0.8987889273356401.

Rozdelenie 80/10/10 | LogisticRegression

Počet foldov: 1. Počet kandidátov: 12. Celkový počet trénovaní: 12.

Najlepšie parametre GridSearchCV: parameter C 0.1 (typ float64), váženie tried žiadne.

Najlepšie skóre GridSearchCV: 0.879757785467128.

Rozdelenie 80/10/10 | DecisionTree

Počet foldov: 1. Počet kandidátov: 10. Celkový počet trénovaní: 10.

Najlepšie parametre GridSearchCV: maximálna hĺbka 3, minimálny počet vzoriek v liste 1.

Najlepšie skóre GridSearchCV: 0.8875432525951558.

Rozdelenie 70/10/20 | RandomForest

Počet foldov: 1. Počet kandidátov: 64. Celkový počet trénovaní: 64.

Najlepšie parametre GridSearchCV: maximálna hĺbka 10, počet zvažovaných vlastností 13, minimálny počet vzoriek v liste 1.

Najlepšie skóre GridSearchCV: 0.9117647058823529.

Rozdelenie 70/10/20 | LogisticRegression

Počet foldov: 1. Počet kandidátov: 12. Celkový počet trénovaní: 12.

Najlepšie parametre GridSearchCV: parameter C 1.0 (typ float64), váženie tried žiadne.

Najlepšie skóre GridSearchCV: 0.8780276816608996.

Rozdelenie 70/10/20 | DecisionTree

Počet foldov: 1. Počet kandidátov: 10. Celkový počet trénovaní: 10.

Najlepšie parametre GridSearchCV: maximálna hĺbka 3, minimálny počet vzoriek v liste 1.

Najlepšie skóre GridSearchCV: 0.9013840830449827.

Rozdelenie 60/10/30 | RandomForest

Počet foldov: 1. Počet kandidátov: 64. Celkový počet trénovaní: 64.

Najlepšie parametre GridSearchCV: maximálna hĺbka 10, počet zvažovaných vlastností 10, minimálny počet vzoriek v liste 3.

Najlepšie skóre GridSearchCV: 0.8996539792387543.

Rozdelenie 60/10/30 | LogisticRegression

Počet foldov: 1. Počet kandidátov: 12. Celkový počet trénovaní: 12.

Najlepšie parametre GridSearchCV: parameter C 0.1 (typ float64), váženie tried žiadne.

Najlepšie skóre GridSearchCV: 0.8719723183391004.

Rozdelenie 60/10/30 | DecisionTree

Počet foldov: 1. Počet kandidátov: 10. Celkový počet trénovaní: 10.

Najlepšie parametre GridSearchCV: maximálna hĺbka 5, minimálny počet vzoriek v liste 5.

Najlepšie skóre GridSearchCV: 0.8953287197231834.

cross-validation

	0	1	2
Rozdelenie	70/15/15	70/15/15	70/15/15
Model	Random Forest	Logistic Regression	DecisionTree
Počet foldov	5	5	5
CV train accuracy (%)	92.58	87.96	91.23
CV val accuracy (%)	90.54	87.86	90.04
CV std (p. b.)	0.56	0.07	0.47
CV train-val rozdiel (p. b.)	2.04	0.10	1.19
Najlepšie parametre	maximálna hĺbka 10, počet zvažovaných vlastností...	parameter C 0.1, váženie tried žiadne	maximálna hĺbka 5, min_ samples_le...

	3	4	5
Rozdelenie	80/10/10	80/10/10	80/10/10
Model	Random Forest	Logistic Regression	DecisionTree

	3	4	5
Počet foldov	5	5	5
CV train accuracy (%)	93.40	87.99	90.86
CV val accuracy (%)	90.33	87.82	89.91
CV std (p. b.)	0.86	0.43	0.61
CV train-val rozdiel (p. b.)	3.07	0.16	0.95
Najlepšie parametre	maximálna hĺbka 15, počet zvažovaných vlastností...	parameter C 1.0, váženie tried žiadne	maximálna hĺbka 5, min_ samples_le...

	6	7	8
Rozdelenie	70/10/20	70/10/20	70/10/20
Model	Random Forest	Logistic Regression	DecisionTree
Počet foldov	5	5	5
CV train accuracy (%)	92.77	88.05	91.10
CV val accuracy (%)	90.16	87.84	89.73
CV std (p. b.)	0.53	0.78	0.17
CV train-val rozdiel (p. b.)	2.61	0.22	1.37
Najlepšie parametre	maximálna hĺbka 10, počet zvažovaných vlastností...	parameter C 1.0, váženie tried žiadne	maximálna hĺbka 5, min_ samples_le...

	9	10	11
Rozdelenie	60/10/30	60/10/30	60/10/30
Model	Random Forest	Logistic Regression	DecisionTree
Počet foldov	5	5	5
CV train accuracy (%)	99.00	88.02	89.89
CV val accuracy (%)	90.21	87.91	89.48
CV std (p. b.)	0.65	0.84	0.88
CV train-val rozdiel (p. b.)	8.80	0.11	0.41

	9	10	11
Najlepšie parametre	maximálna hĺbka 15, počet zvažovaných vlastností...	parameter C 0.1, váženie tried žiadne	maximálna hĺbka 3, min_ samples_le...

Každý riadok vyhodnocuje najlepšiu konfiguráciu (najlepšie parametre) modelu, kde je 5 foldov. Vyhodnocuje sa priemerná trénovacia a validačná accuracy, štandardná odchýlka validačnej accuracy v percentách a rozdiel train-val, ktorý môže značiť pretrénovanie.

Rozdelenie 70/15/15 | RandomForest

Počet foldov: 5. Počet kandidátov: 64. Celkový počet trénovaní: 320.

Najlepšie parametre GridSearchCV: maximálna hĺbka 10, počet zvažovaných vlastností 13, minimálny počet vzoriek v liste 7.

Najlepšie skóre GridSearchCV: 0.9054284934560407.

Rozdelenie 70/15/15 | LogisticRegression

Počet foldov: 5. Počet kandidátov: 12. Celkový počet trénovaní: 60.

Najlepšie parametre GridSearchCV: parameter C 0.1 (typ float64), váženie tried žiadne.

Najlepšie skóre GridSearchCV: 0.8786004389394819.

Rozdelenie 70/15/15 | DecisionTree

Počet foldov: 5. Počet kandidátov: 10. Celkový počet trénovaní: 50.

Najlepšie parametre GridSearchCV: maximálna hĺbka 5, minimálny počet vzoriek v liste 5.

Najlepšie skóre GridSearchCV: 0.9003591323033315.

Rozdelenie 80/10/10 | RandomForest

Počet foldov: 5. Počet kandidátov: 64. Celkový počet trénovaní: 320.

Najlepšie parametre GridSearchCV: maximálna hĺbka 15, počet zvažovaných vlastností 13, minimálny počet vzoriek v liste 7.

Najlepšie skóre GridSearchCV: 0.9032990805840996.

Rozdelenie 80/10/10 | LogisticRegression

Počet foldov: 5. Počet kandidátov: 12. Celkový počet trénovaní: 60.

Najlepšie parametre GridSearchCV: parameter C 1.0 (typ float64), váženie tried žiadne.

Najlepšie skóre GridSearchCV: 0.8782044348296376.

Rozdelenie 80/10/10 | DecisionTree

Počet foldov: 5. Počet kandidátov: 10. Celkový počet trénovaní: 50.

Najlepšie parametre GridSearchCV: maximálna hĺbka 5, minimálny počet vzoriek v liste 5.

Najlepšie skóre GridSearchCV: 0.8990805840995133.

Rozdelenie 70/10/20 | RandomForest

Počet foldov: 5. Počet kandidátov: 64. Celkový počet trénovaní: 320.

Najlepšie parametre GridSearchCV: maximálna hĺbka 10, počet zvažovaných vlastností 13, minimálny počet vzoriek v liste 7.

Najlepšie skóre GridSearchCV: 0.9015951498028135.

Rozdelenie 70/10/20 | LogisticRegression

Počet foldov: 5. Počet kandidátov: 12. Celkový počet trénovaní: 60.

Najlepšie parametre GridSearchCV: parameter C 1.0 (typ float64), váženie tried žiadne.

Najlepšie skóre GridSearchCV: 0.8783545196930328.

Rozdelenie 70/10/20 | DecisionTree

Počet foldov: 5. Počet kandidátov: 10. Celkový počet trénovaní: 50.

Najlepšie parametre GridSearchCV: maximálna hĺbka 5, minimálny počet vzoriek v liste 1.

Najlepšie skóre GridSearchCV: 0.8972682094525639.

Rozdelenie 60/10/30 | RandomForest

Počet foldov: 5. Počet kandidátov: 64. Celkový počet trénovaní: 320.

Najlepšie parametre GridSearchCV: maximálna hĺbka 15, počet zvažovaných vlastností 10, minimálny počet vzoriek v liste 1.

Najlepšie skóre GridSearchCV: 0.902060880719857.

Rozdelenie 60/10/30 | LogisticRegression

Počet foldov: 5. Počet kandidátov: 12. Celkový počet trénovaní: 60.

Najlepšie parametre GridSearchCV: parameter C 0.1 (typ float64), váženie tried žiadne.

Najlepšie skóre GridSearchCV: 0.8791267292348763.

Rozdelenie 60/10/30 | DecisionTree

Počet foldov: 5. Počet kandidátov: 10. Celkový počet trénovaní: 50.

Najlepšie parametre GridSearchCV: maximálna hĺbka 3, minimálny počet vzoriek v liste 1.

Najlepšie skóre GridSearchCV: 0.8948481623319402.

vyhodnotenie modelov

	params	mean_train_score	mean_test_score
0	maximálna hĺbka 10, počet zvažovaných vlastností...	0.9478	0.9118
1	maximálna hĺbka 20, počet zvažovaných vlastností...	0.9318	0.9083

	params	mean_train_ score	mean_test_ score
2	maximálna hĺbka 20, počet zvažovaných vlastností...	0.9581	0.9083
3	maximálna hĺbka 10, počet zvažovaných vlastností...	0.9304	0.9083
4	maximálna hĺbka 15, počet zvažovaných vlastností...	0.9522	0.9083
...	...	...	...
59	maximálna hĺbka 5, počet zvažovaných vlastností ...	0.8432	0.8417
60	maximálna hĺbka 5, počet zvažovaných vlastností ...	0.8350	0.8348
61	maximálna hĺbka 5, počet zvažovaných vlastností ...	0.8350	0.8348
62	maximálna hĺbka 5, počet zvažovaných vlastností ...	0.8350	0.8348
63	maximálna hĺbka 5, počet zvažovaných vlastností ...	0.8350	0.8348

	std_test_score	rank_test_score
0	0.0	1
1	0.0	2
2	0.0	2
3	0.0	2
4	0.0	2
...	...	...
59	0.0	60
60	0.0	61
61	0.0	61
62	0.0	61
63	0.0	61

64 riadkov × 5 stĺpcov

Najlepšia konfigurácia: 0.9118

Parametre: maximálna hĺbka 10, počet zvažovaných vlastností 13, minimálny počet vzoriek v liste 1.

Najhoršia konfigurácia: 0.8348

Parametre: maximálna hĺbka 5, počet zvažovaných vlastností 4, minimálny počet vzoriek v liste 1.

Najlepšia validácia: RandomForest, 70/10/20 | validačná accuracy 0.9118, testovacia accuracy 0.8966

Najhoršia validácia: LogisticRegression, 60/10/30 | validačná accuracy 0.8720, testovacia accuracy 0.8760

Najlepší test (opis výsledkov): RandomForest, 60/10/30 | validačná accuracy 0.8997, testovacia accuracy 0.8971

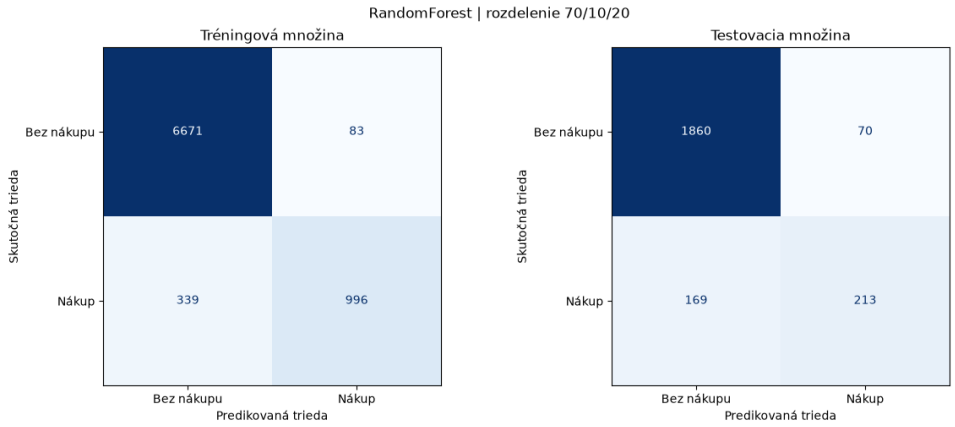
Najhorší test (opis výsledkov): LogisticRegression, 70/15/15 | validačná accuracy 0.8749, testovacia accuracy 0.8760

Najväčší rozdiel train-test: RandomForest, 80/10/10 | 6.95 percentuálneho bodu

RandomForest: najvyššia test accuracy 0.8971 pri 60/10/30; najnižšia 0.8867 pri 80/10/10.

LogisticRegression: najvyššia test accuracy 0.8780 pri 80/10/10; najnižšia 0.8760 pri 70/15/15.

DecisionTree: najvyššia test accuracy 0.8950 pri 60/10/30; najnižšia 0.8795 pri 70/15/15.



	precision	recall	f1-score
Bez nákupu	0.92	0.96	0.94
Nákup	0.75	0.56	0.64
accuracy			0.90
macro avg	0.83	0.76	0.79
weighted avg	0.89	0.90	0.89

	support
Bez nákupu	1930
Nákup	382
accuracy	2312
macro avg	2312
weighted avg	2312

Najlepším modelom podľa validácie bol Random Forest pri rozdelení 70/10/20, s validačnou accuracy 91.18% a testovacou accuracy 89.66%. Najvyššiu testovaciu accuracy dosiahol Random Forest pri 60/10/30 a to 89.71% čo je rozdiel 0.05%.

Najhorším modelom podľa validácie bola Logistic Regression pri 60/10/30, s validačnou accuracy 87.2% a testovacou 87.6%. Zachytila iba 36.3% správne klasifikovaných nákupov.

Najlepšia konfigurácia Random Forestu mal maximálna hĺbka 10, počet zvažovaných vlastností 13 a minimálny počet vzoriek v liste 1. Jedna z najhorších mala maximálna hĺbka 5, počet zvažovaných vlastností 4 a minimálny počet vzoriek v liste 1, s validačnou accuracy 83.48%. Takéto parametre vytvárajú plytké stromy, čo má za príčinu nedostatočné zachytávanie vzťahov v dátach.

Najväčší rozdiel medzi tréningom a testom mal Random Forest pri 80/10/10, kde trénovacia accuracy bola 96.62% a testovacia 88.67%, teda

rozdiel 6.95. Pri 60/10/30 bol rozdiel iba 3.88. Výsledky z rozdelenia 80/10/10 naznačujú pretrénovanie.

Vybraný Random Forest správne rozpoznal 213 nákupov, ale 169 nákupov prehliadol pri testovaní. Precision bola 75.27% (213/283) a recall 55.76% (213/382) a F1 61.04%.

Pri rovnakom rozdelení 70/10/20 prekonal Random Forest logistickú regresiu v accuracy o 2.03 ale recall až o 20.42.

Neural Network

Rozdelenie: 70/15/15

Počet vstupov po predspracovaní: 72

Počty vzoriek: train 8089, val 1734, test 1734.

Podiel nákupov v tréningu: 16.52%

net, EarlyStopping a vyhodnotenie

Používam plne prepojenú sieť s ReLU v skrytých vrstvách. Výstupný neurón vracia logit. BCEWithLogitsLoss spája sigmoid a binárnu krížovú entropiu stabilne. Pri predikcii používam sigmoid a pevný prah 0.5. Adam aktualizuje váhy po minibatchoch. Všetky behy používajú rovnaký seed, batch size s 128 a maximálne 300 epoch. Dropout ani penalizáciu nepoužívam.

EarlyStopping sleduje validačnú stratu. Ak počas 20 epoch nepríde zlepšenie väčšie než 0.0001 oproti poslednému významnému minimu, zastaví tréning. Obnoví váhy z absolútne najnižšej validačnej straty. Pri modeli bez EarlyStoppingu hodnotím posledné váhy, aby sa pretrénovanie neskrylo obnovením skoršej epochy.

Kombinácie trénovania

O demonštruje pretrénovanie veľkej siete s vrstvami 256, 128 a 64 neurónov pri learning rate 0.001 počas 300 epoch. ES opakuje rovnakú konfiguráciu ale pridáva EarlyStopping.

E1-E3 menia learning rate pri rovnakých vrstvách 64 a 32 neurónov. E4 a E5 menia architektúru pri learning rate 0.001. Tým porovnávam 5 konfigurácií a aspoň 2 druhy nastavení.

Veľká sieť bez EarlyStopping | epocha 1: tréningová strata 0.2882, validačná strata 0.3001

Veľká sieť bez EarlyStopping | epocha 50: tréningová strata 0.0155, validačná strata 0.9478

Veľká sieť bez EarlyStopping | epocha 100: tréningová strata 0.0029, validačná strata 1.3070

Veľká sieť bez EarlyStopping | epocha 150: tréningová strata 0.0021, validačná strata 1.3768

Veľká sieť bez EarlyStopping | epocha 200: tréningová strata 0.0007, validačná strata 1.3407

Veľká sieť bez EarlyStopping | epocha 250: tréningová strata 0.0044, validačná strata 1.4861

Veľká sieť bez EarlyStopping | epocha 300: tréningová strata 0.0012, validačná strata 1.1467

Veľká sieť bez EarlyStopping: vykonaných 300 epoch, hodnotené váhy z epochy 300.

Veľká sieť s EarlyStopping | epocha 1: tréningová strata 0.2882, validačná strata 0.3001

Veľká sieť s EarlyStopping: vykonaných 26 epoch, hodnotené váhy z epochy 6.

E1 | epocha 1: tréningová strata 0.6273, validačná strata 0.6269

E1 | epocha 50: tréningová strata 0.2480, validačná strata 0.2701

E1 | epocha 100: tréningová strata 0.2232, validačná strata 0.2566

E1: vykonaných 149 epoch, hodnotené váhy z epochy 129.

E2 | epocha 1: tréningová strata 0.3488, validačná strata 0.3528

E2: vykonaných 34 epoch, hodnotené váhy z epochy 14.

E3 | epocha 1: tréningová strata 0.2563, validačná strata 0.2817

E3: vykonaných 25 epoch, hodnotené váhy z epochy 5.

E4 | epocha 1: tréningová strata 0.4568, validačná strata 0.4555

E4 | epocha 50: tréningová strata 0.2067, validačná strata 0.2542

E4: vykonaných 66 epoch, hodnotené váhy z epochy 46.

E5 | epocha 1: tréningová strata 0.3181, validačná strata 0.3255

E5: vykonaných 28 epoch, hodnotené váhy z epochy 8.

Hotovo: 7 tréningov na rozdelení 70/15/15

vyhodnotenie výsledkov a experimentov

Tréning	O	ES	E1
Skryté vrstvy	$256 \rightarrow 128 \rightarrow 64$	$256 \rightarrow 128 \rightarrow 64$	$64 \rightarrow 32$
Learning rate	0.0010	0.0010	0.0001
EarlyStopping	False	True	True
Vykonané epochy	300	26	149
Hodnotená epocha	300	6	129
Train accuracy (%)	99.9753	90.5180	90.9630
Val accuracy (%)	87.6586	88.9273	89.5040
Val loss	1.1467	0.2578	0.2542
Test accuracy (%)	86.8512	88.8697	89.0427
Train balanced accuracy (%)	99.9251	83.1832	81.3783

Tréning	O	ES	E1
Test balanced accuracy (%)	73.8887	79.3062	77.3053
Train F1 nákup	0.9993	0.7156	0.7103
Test F1 nákup	0.5778	0.6584	0.6429
Baseline train accuracy (%)	83.4837	83.4837	83.4837
Baseline test accuracy (%)	83.5063	83.5063	83.5063
Train-test rozdiel (p. b.)	13.1241	1.6483	1.9204

Tréning	E2	E3	E4
Skryté vrstvy	$64 \rightarrow 32$	$64 \rightarrow 32$	32
Learning rate	0.0010	0.0100	0.0010
EarlyStopping	True	True	True
Vykonané epochy	34	25	66
Hodnotená epocha	14	5	46
Train accuracy (%)	90.7281	90.9507	91.1979
Val accuracy (%)	89.5617	89.3310	89.2157
Val loss	0.2541	0.2542	0.2533
Test accuracy (%)	89.0427	88.9273	88.4660
Train balanced accuracy (%)	82.1083	79.8999	81.2488
Test balanced accuracy (%)	77.4456	75.1318	75.6974
Train F1 nákup	0.7115	0.6983	0.7136
Test F1 nákup	0.6442	0.6190	0.6183
Baseline train accuracy (%)	83.4837	83.4837	83.4837
Baseline test accuracy (%)	83.5063	83.5063	83.5063
Train-test rozdiel (p. b.)	1.6855	2.0233	2.7319

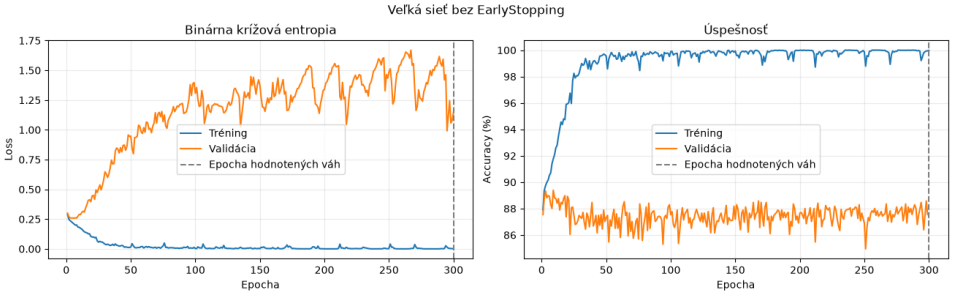
Tréning	E5
Skryté vrstvy	$128 \rightarrow 64 \rightarrow 32$
Learning rate	0.0010
EarlyStopping	True
Vykonané epochy	28
Hodnotená epocha	8
Train accuracy (%)	90.4067

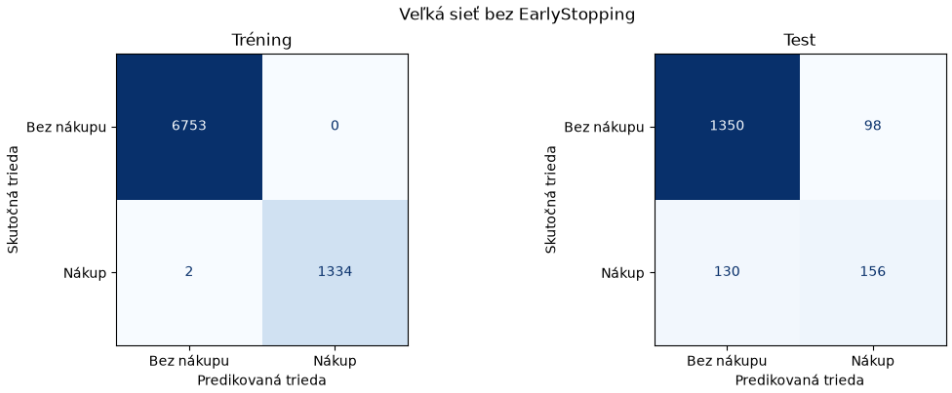
Tréning	E5
Val accuracy (%)	88.6967
Val loss	0.2559
Test accuracy (%)	88.6967
Train balanced accuracy (%)	84.4375
Test balanced accuracy (%)	80.3249
Train F1 nákup	0.7223
Test F1 nákup	0.6644
Baseline train accuracy (%)	83.4837
Baseline test accuracy (%)	83.5063
Train-test rozdiel (p. b.)	1.7101

Najlepší experiment podľa validácie: E2
Najhorší experiment podľa validácie: E5
Bez EarlyStopping: minimum val loss 0.2578 v epoche 6, na konci 1.1467.
Train loss v rovnakých epochách: 0.2085 → 0.0012.
EarlyStopping obnovil epochu 6 po 26 vykonaných epochách.
Rozdiel train-test pred/po EarlyStopping (p. b.): 13.12 1.65

Množina	Loss	Accuracy (%)	Balanced accuracy (%)
train	0.0012	99.9753	99.9251
test	1.3414	86.8512	73.8887

Množina	F1 nákup	Baseline accuracy (%)
train	0.9993	83.4837
test	0.5778	83.5063





Veľká sieť bez EarlyStopping – train

	precision	recall	f1-score
Bez nákupu	1.00	1.00	1.00
Nákup	1.00	1.00	1.00
accuracy			1.00
macro avg	1.00	1.00	1.00
weighted avg	1.00	1.00	1.00

	support
Bez nákupu	6753
Nákup	1336
accuracy	8089
macro avg	8089
weighted avg	8089

Veľká sieť bez EarlyStopping – test

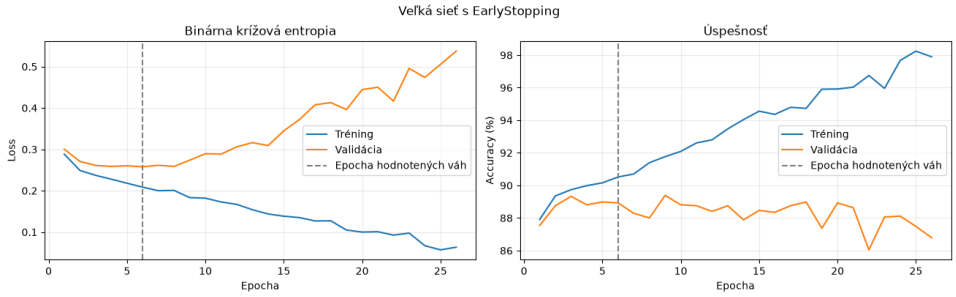
	precision	recall	f1-score
Bez nákupu	0.91	0.93	0.92
Nákup	0.61	0.55	0.58
accuracy			0.87
macro avg	0.76	0.74	0.75
weighted avg	0.86	0.87	0.87

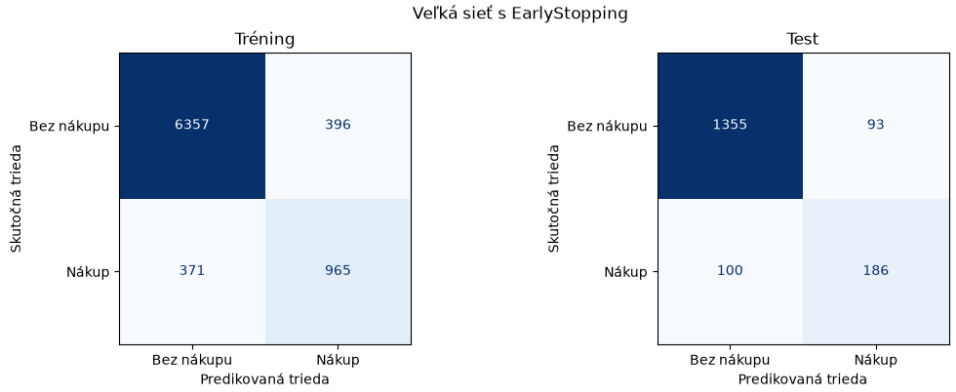
	support
Bez nákupu	1448
Nákup	286
accuracy	1734
macro avg	1734

	support
weighted avg	1734

Množina	Loss	Accuracy (%)	Balanced accuracy (%)
train	0.2085	90.5180	83.1832
test	0.2611	88.8697	79.3062

Množina	F1 nákup	Baseline accuracy (%)
train	0.7156	83.4837
test	0.6584	83.5063





Veľká sieť s EarlyStopping – train

	precision	recall	f1-score
Bez nákupu	0.94	0.94	0.94
Nákup	0.71	0.72	0.72
accuracy			0.91
macro avg	0.83	0.83	0.83
weighted avg	0.91	0.91	0.91

	support
Bez nákupu	6753
Nákup	1336
accuracy	8089
macro avg	8089
weighted avg	8089

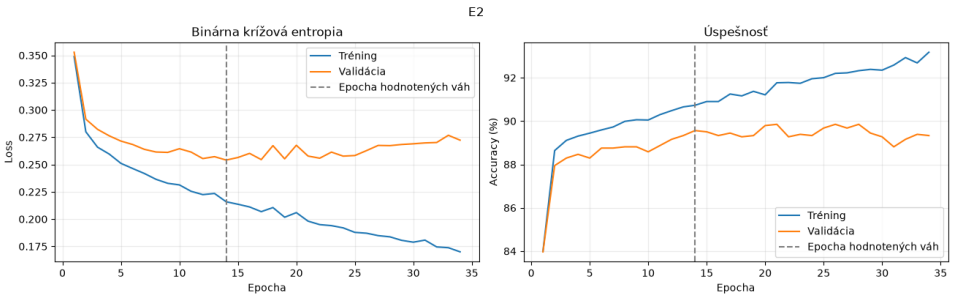
Veľká sieť s EarlyStopping – test

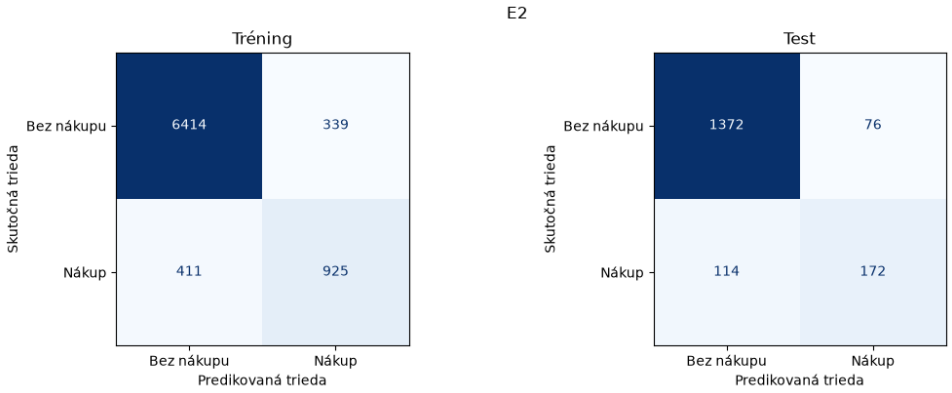
	precision	recall	f1-score
Bez nákupu	0.93	0.94	0.93
Nákup	0.67	0.65	0.66
accuracy			0.89
macro avg	0.80	0.79	0.80
weighted avg	0.89	0.89	0.89

	support
Bez nákupu	1448
Nákup	286
accuracy	1734
macro avg	1734
weighted avg	1734

Množina	Loss	Accuracy (%)	Balanced accuracy (%)
train	0.2159	90.7281	82.1083
test	0.2596	89.0427	77.4456

Množina	F1 nákup	Baseline accuracy (%)
train	0.7115	83.4837
test	0.6442	83.5063





E2 – train

	precision	recall	f1-score
Bez nákupu	0.94	0.95	0.94
Nákup	0.73	0.69	0.71
accuracy			0.91
macro avg	0.84	0.82	0.83
weighted avg	0.91	0.91	0.91

	support
Bez nákupu	6753
Nákup	1336
accuracy	8089
macro avg	8089
weighted avg	8089

E2 – test

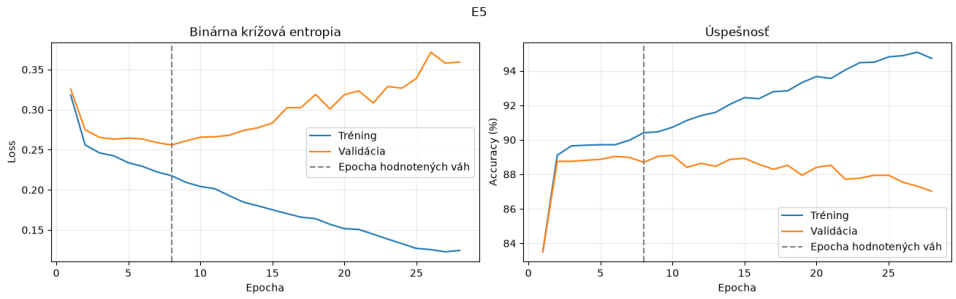
	precision	recall	f1-score
Bez nákupu	0.92	0.95	0.94
Nákup	0.69	0.60	0.64
accuracy			0.89
macro avg	0.81	0.77	0.79
weighted avg	0.89	0.89	0.89

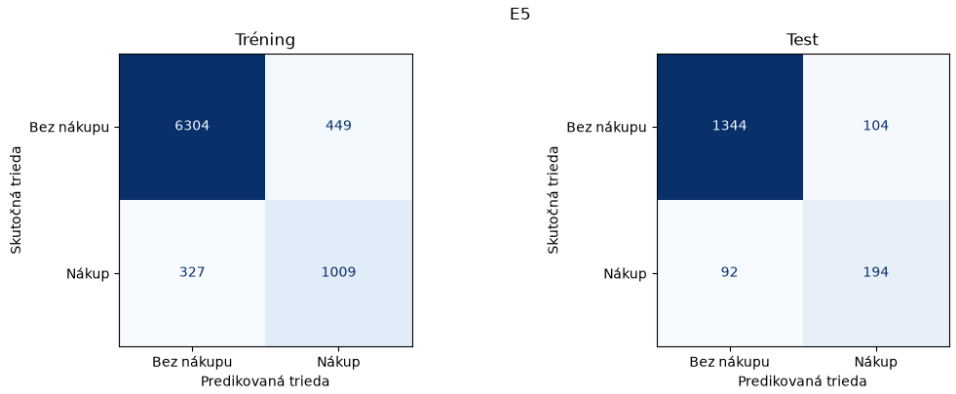
	support
Bez nákupu	1448
Nákup	286
accuracy	1734
macro avg	1734

	support
weighted avg	1734

Množina	Loss	Accuracy (%)	Balanced accuracy (%)
train	0.2176	90.4067	84.4375
test	0.2607	88.6967	80.3249

Množina	F1 nákup	Baseline accuracy (%)
train	0.7223	83.4837
test	0.6644	83.5063





E5 – train

	precision	recall	f1-score
Bez nákupu	0.95	0.93	0.94
Nákup	0.69	0.76	0.72
accuracy			0.90
macro avg	0.82	0.84	0.83
weighted avg	0.91	0.90	0.91

	support
Bez nákupu	6753
Nákup	1336
accuracy	8089
macro avg	8089
weighted avg	8089

E5 – test

	precision	recall	f1-score
Bez nákupu	0.94	0.93	0.93
Nákup	0.65	0.68	0.66
accuracy			0.89
macro avg	0.79	0.80	0.80
weighted avg	0.89	0.89	0.89

	support
Bez nákupu	1448
Nákup	286
accuracy	1734
macro avg	1734
weighted avg	1734

Neurónovú sieť som trénoval na rozdelení 70 % tréningových, 15 % validačných a 15 % testovacích dát. Všetkých sedem tréningov používalo rovnaké vzorky a predspracovanie naučené iba na tréningovej množine. Výsledky sú preto medzi jednotlivými konfiguráciami porovnateľné. Validáciu som použil na EarlyStopping a výber konfigurácie, testovacie dáta na záverečné vyhodnotenie.

Pri veľkej sieti bez EarlyStopping sa jasne prejavilo pretrénovanie. Tréningová strata postupne klesala takmer k nule a tréningová accuracy dosiahla 99,98 %. Validačná strata však po minime v 6. epoche začala rásť. Sieť sa teda stále lepšie prispôsobovala tréningovým príkladom, ale jej schopnosť pracovať s nevidenými dátami sa zhoršovala. Potvrdila to testovacia accuracy 86,85 %, ktorá bola oproti tréningovej nižšia o 13,12 percentuálneho bodu. Tréningová konfúzna matica mala takmer všetky predikcie na diagonále, zatiaľ čo testovacia obsahovala podstatne viac nesprávnych predikcií.

EarlyStopping výrazne obmedzil pretrénovanie. Pri rovnakej architektúre zastavil tréning po 26 epochách a obnovil váhy zo 6. epochy, v ktorej bola validačná strata najnižšia. Tréningová accuracy klesla na 90,52 %, ale testovacia sa zvýšila na 88,87 %. Rozdiel medzi nimi sa zmenšil na 1,65 percentuálneho bodu. Zlepšila sa aj testovacia balanced accuracy a F1 nákupov. Nižšia tréningová úspešnosť teda predstavovala prijateľný kompromis

za lepšiu generalizáciu. Graf stále zobrazuje zhoršovanie počas ďalších epoch čakania, no výsledné metriky a konfúzne matice patria obnoveným váham zo 6. epochy.

V experimentoch E1–E5 som menil rýchlosť učenia a architektúru siete. Podľa validačnej accuracy bol najlepší E2, ktorý používal skryté vrstvy so 64 a 32 neurónmi a learning rate 0,001. Dosiahol tréningovú accuracy 90,73 %, validačnú 89,56 % a testovaciu 89,04 %. E1 dosiahol rovnakú testovaciu accuracy, ale potreboval 149 epoch oproti 34 pri E2. Vyšší learning rate v E3 skrátil tréning, no nepriniesol lepšiu testovaciu úspešnosť. Ani zmena veľkosti siete nezaručila zlepšenie, preto väčšia kapacita sama osebe nie je dôvodom na výber modelu.

Konfúzna matica E2 ukazuje, že sieť správne rozpoznáva obe triedy, ale úspešnejšia je pri návštevách bez nákupu. Na teste správne označila 1 372 návštev bez nákupu a 172 nákupov. Zároveň nesprávne predikovala nákup pri 76 návštevách a nezachytila 114 skutočných nákupov. Zachytila teda približne 60,14 % nákupov. Výrazná diagonála potvrdzuje užitočnosť modelu, ale accuracy blízka 90 % neznamená, že sieť rozpoznáva takmer všetky nákupy.

Podľa validačnej accuracy bol najhorší E5, jeho výsledky však ukazujú význam sledovania viacerých metrík. Mal nižšiu testovaciu accuracy než E2, ale vyššiu balanced accuracy aj F1 nákupov. Označenie „najhorší“ preto platí iba pre zvolené validačné kritérium. Ak by hlavným cieľom bolo zachytiť viac nákupov, bolo by vhodné vopred zvoliť tomu zodpovedajúcu validačnú metriku.

Za výslednú konfiguráciu pri použitom kritériu považujem E2. Prekonala väčšinový baseline s testovacou accuracy 83,51 % a vykazovala podstatne menší rozdiel medzi tréningom a testom než zámerne pretrénovaná sieť. Výsledky podporujú použitie EarlyStopping a ukazujú, že vhodná kombinácia architektúry a rýchlosti učenia je dôležitejšia než samotné zväčšovanie siete. Rozdiely medzi experimentmi sú však malé a pochádzajú z jediného rozdelenia a seedu, preto ich nemožno považovať za dôkaz všeobecnej nadradenosti jednej konfigurácie.