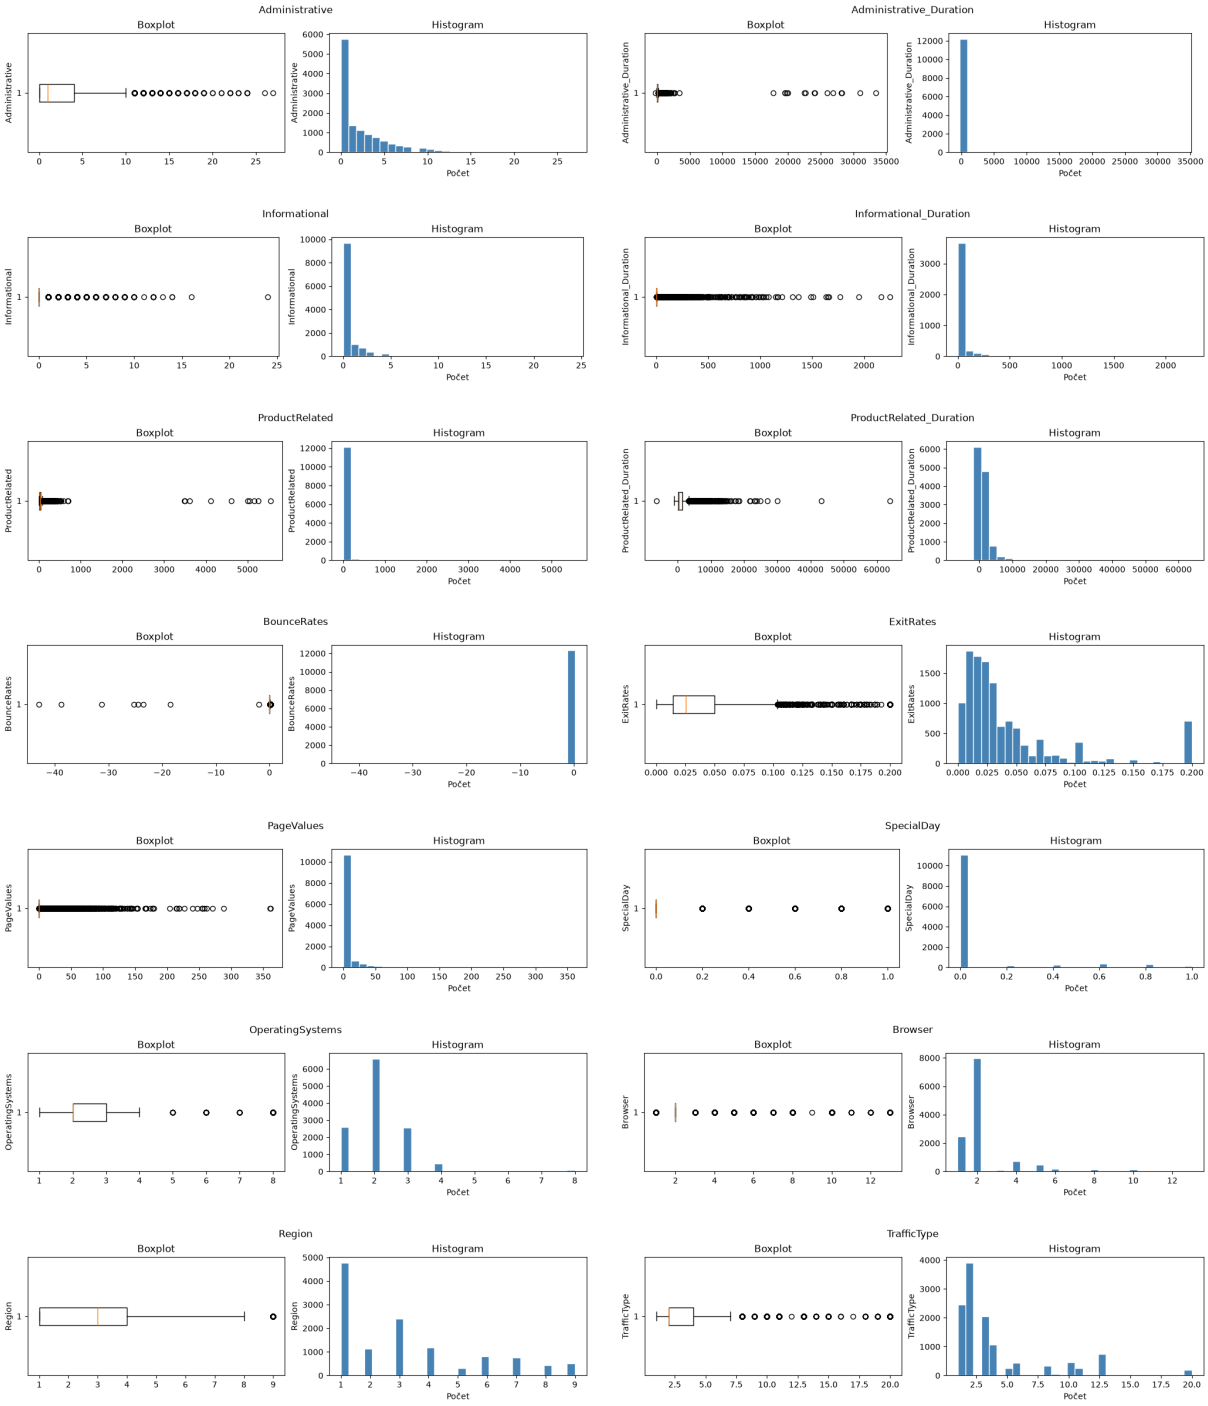
Zadanie 1: SUNS

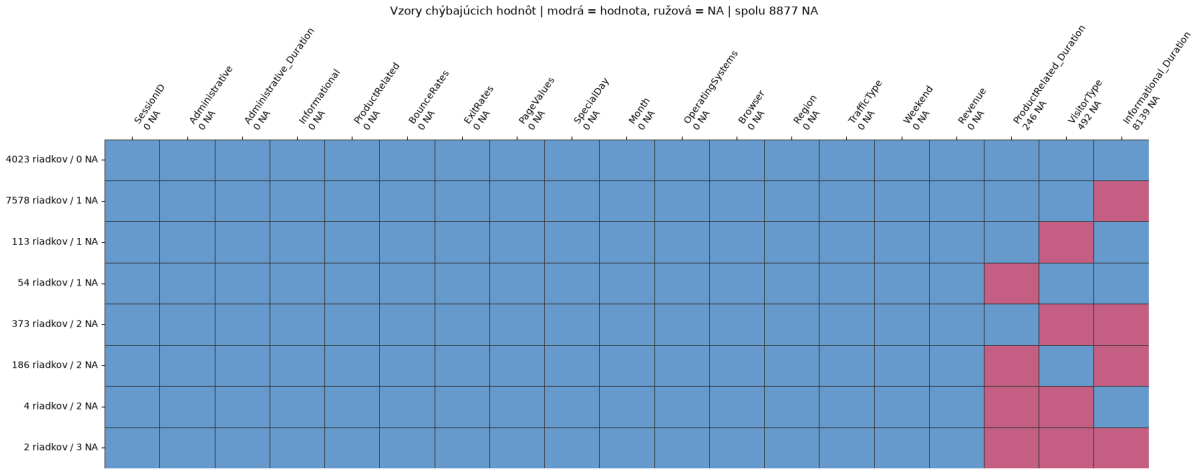
Samuel Bagín

13. októbra 2026

data load and EDA

Typ údajov: str.

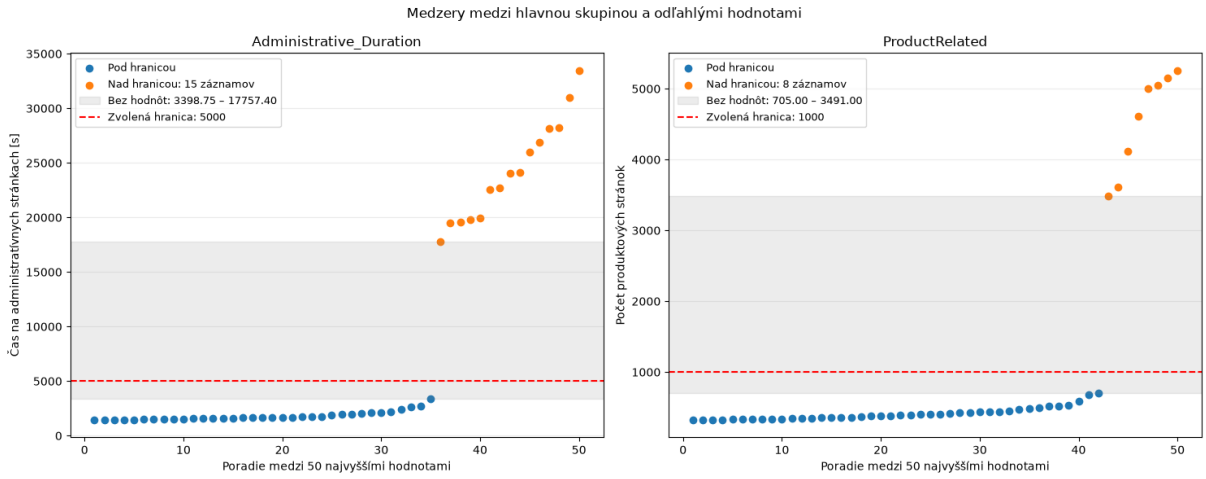

Administrative
Boxplot
Histogram
Administrative
Počet
Administrative_Duration
Boxplot
Histogram
Administrative_Duration
Počet
Informational
Boxplot
Histogram
Informational
Počet
Informational_Duration
Boxplot
Histogram
Informational_Duration
Počet
ProductRelated
Boxplot
Histogram
ProductRelated
Počet
ProductRelated_Duration
Boxplot
Histogram
ProductRelated_Duration
Počet
BounceRates
Boxplot
Histogram
BounceRates
Počet
ExitRates
Boxplot
Histogram
ExitRates
Počet
PageValues
Boxplot
Histogram
PageValues
Počet
SpecialDay
Boxplot
Histogram
SpecialDay
Počet
OperatingSystems
Boxplot
Histogram
OperatingSystems
Počet
Browser
Boxplot
Histogram
Browser
Počet
Region
Boxplot
Histogram
Region
Počet
TrafficType
Boxplot
Histogram
TrafficType
Počet



V cca 2/3 (8139/12334) dát chýba hodnota (NA) v poslednom stĺpci Informational_Duration, čo není ani vhodné dopĺňať/nahrádzať, preto tento stĺpec je jednoduchšie a lepšie dropnúť. Riadky s chýbajúcim ProductRelated_Duration a VisitorType odstraňujem pre chýbajúce hodnotu, čo predstavuje 732 riadkov.

	Administrative	Administrative_Duration	Informational	ProductRelated	ProductRelated_Duration	BounceRates	ExitRates	PageValues	SpecialDay	OperatingSystems	Browser	Region	TrafficType
count	11601.000000	11601.000000	11601.000000	11601.000000	11601.000000	11601.000000	11601.000000	11601.000000	11601.000000	11601.000000	11601.000000	11601.000000	11601.000000
mean	2.326437	112.502691	0.507801	35.006637	1199.481299	0.004117	0.042697	6.154971	0.061546	2.122662	2.351608	3.140160	4.077752
std	3.327508	901.008974	1.270743	127.664326	1918.490414	0.748188	0.048397	19.006150	0.199062	0.910592	1.708669	2.394896	4.027833
min	0.000000	-214.548633	0.000000	0.000000	-6423.973010	-42.953427	0.000000	0.000000	0.000000	1.000000	1.000000	1.000000	1.000000
25%	0.000000	0.000000	0.000000	7.000000	185.000000	0.000000	0.014251	0.000000	0.000000	2.000000	2.000000	1.000000	2.000000
50%	1.000000	8.000000	0.000000	18.000000	604.000000	0.003014	0.025000	0.000000	0.000000	2.000000	2.000000	3.000000	2.000000
75%	4.000000	94.600000	0.000000	38.000000	1467.654221	0.016667	0.050000	0.000000	0.000000	3.000000	2.000000	4.000000	4.000000
max	27.000000	33466.707646	24.000000	5258.000000	63973.522230	0.200000	0.200000	361.763742	1.000000	8.000000	13.000000	9.000000	20.000000

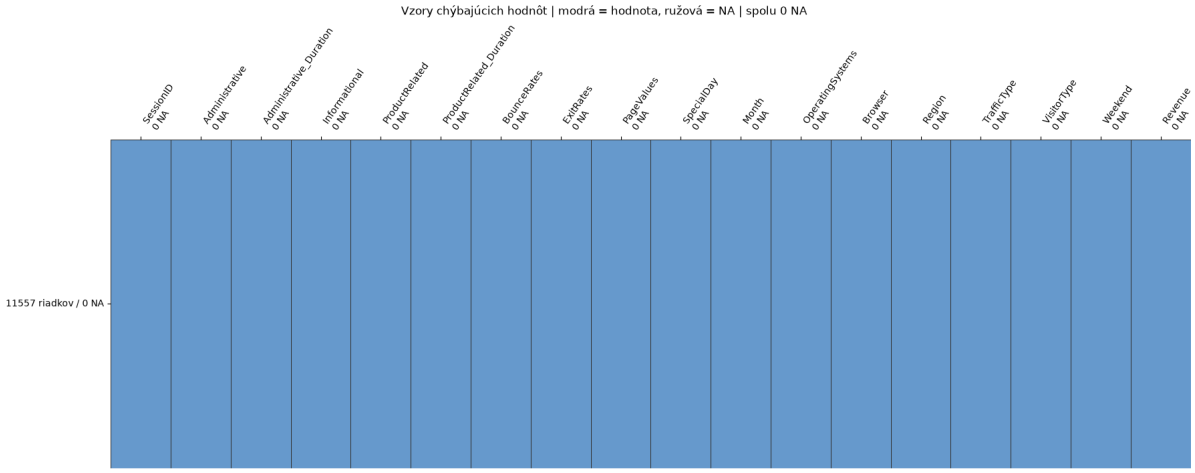
removing outliers



Odľahlé záznamy, počty riadkov: 11601, 11557.

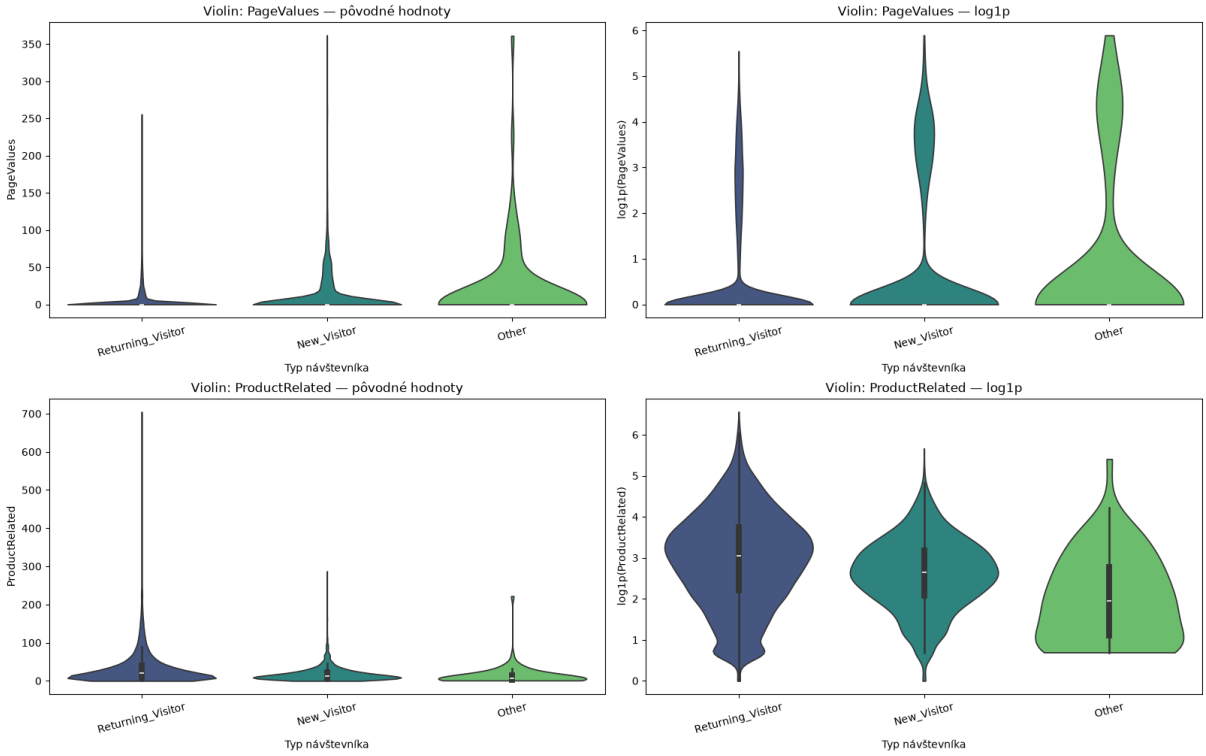
Hranice 5 000s a 1 000 stránok ležia v medzerách medzi ostatnými hodnotami a dvoma odľahlými skupinami. Drop duplicates odstráni úplne identické riadky, pričom návštevy s rôznymi SessionID ponechá. Vysoké PageValues a dlhé ProductRelated_Duration ponechávam, lebo samotná veľkosť hodnoty nepreukazuje chybu a môže predstavovať hodnotný nákup alebo dlhú návštevu.

Po vyčistení sa počet riadkov znížil z 11 601 (12 334 - 734 NA riadkov) na 11 557, kde sa odstráni 18 neplatných záznamov, 23 kladných outlierov a 3 duplicity.



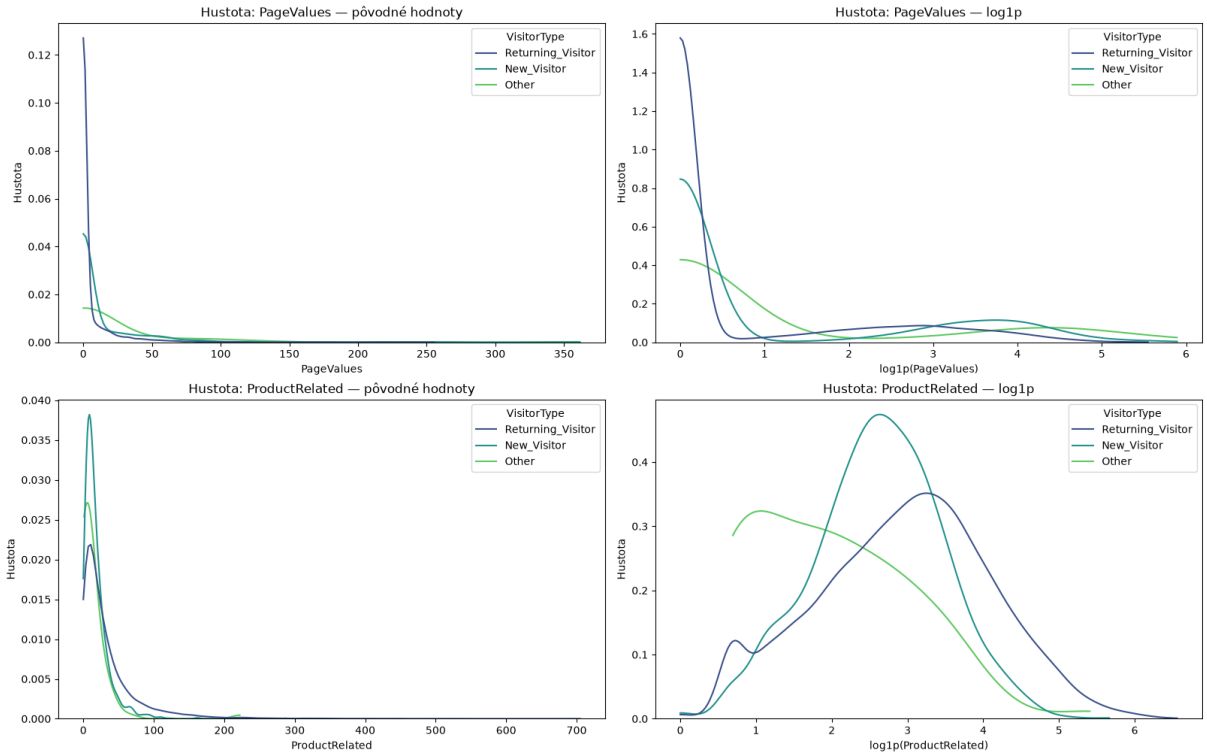
VisitorType vs ProductRelated a PageValues

Použitý log(1 + x) (log1p), kvôli normalizácii veľmi odľahlých hodnôt a obsahovaní 0 hodnôt, logaritmus 1+x zachová 0 na 0, normalizácia zachovaná aj kvôli porovnaniu rôznych skupín



Pri PageValues sa vo všetkých skupinách väčšina hodnôt sústreďuje pri nule. Rozdelenia majú dlhé chvosty, kde sa ťahajú k vysokým hodnotám. Transformácia log1p zlepšuje zobrazenie hodnôt, kde je vidno že v skupine Other je hustota posunutá k vyšším hodnotám než pri vracajúcich sa návštevníkov.

Pri ProductRelated pôvodnú mierku výrazne ovplyvňujú extrémne hodnoty vracajúcich sa návštevníkov. Po transformácii sú rozdiely čitateľnejšie, kde vracajúci sa návštevníci majú najvyšší medián a najnižší ostatný typ návštevníkov. Vracajúci návštevníci navštevujú viac produktovo súvisiacich stránok.



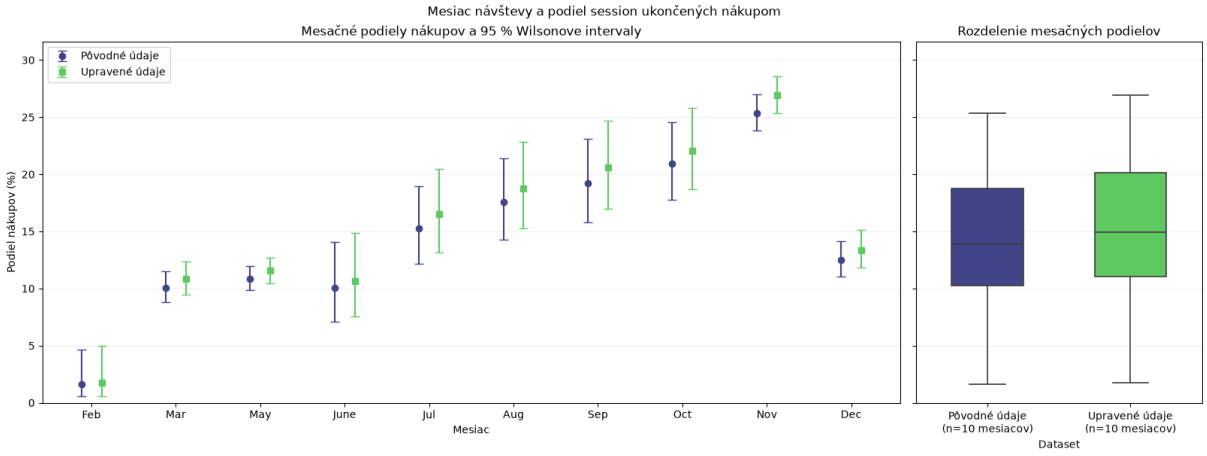
Pri PageValues vidíme výrazný vrchol pri nule a dlhý chvost pri všetkých skupinách. Pri nule je najhustejšia skupina vracajúcich sa zákazníkov, pri skupinách New_Visitor a Other sú hodnoty širšie.

Pri ProductRelated je najvyššia hodnota v skupine nových zákazníkov v oblasti medzi 2 a 4 (os logaritmu skupiny). Skupina Other má najhustejšiu hodnotu bližšie k nule a vracajúci sa zákazníci majú najhustejšiu hodnotu vo vyšších hodnotách.

Month (mesiac poslednej návštevy) a Revenue

Porovnávam podiel sessionov ukončených nákupom v jednotlivých mesiacoch. Počet nákupov / počet sessions v danom mesiaci. Mesačné podiely a chybové úsečky, v ich 95% Wilson intervaloch spoľahlivosti, čo vyjadruje neistotu odhadu pri predpoklade nezávislých sessionov. V datasete chýbajú dáta za mesiac január a apríl.

Boxplot sumarizuje rozdelenie mesačných podielov.



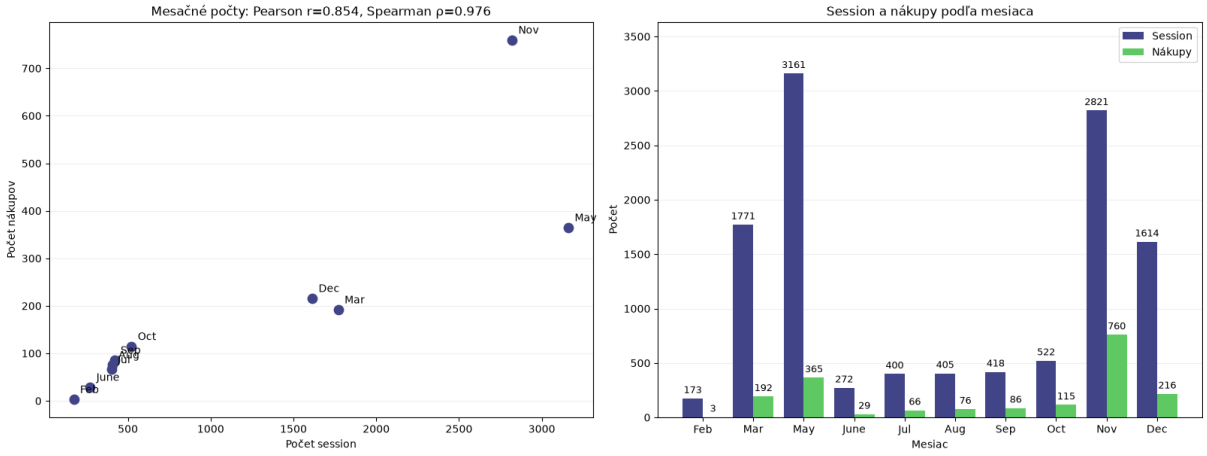
	Pôvodné údaje					Upravené údaje				
	sessions	purchases	purchase_rate	ci_lower	ci_upper	sessions	purchases	purchase_rate	ci_lower	ci_upper
Month										
Feb	185	3	1.62	0.55	4.66	173	3	1.73	0.59	4.97
Mar	1907	192	10.07	8.80	11.50	1771	192	10.84	9.48	12.37
May	3365	365	10.85	9.84	11.94	3161	365	11.55	10.48	12.71
June	288	29	10.07	7.10	14.09	272	29	10.66	7.53	14.89
Jul	432	66	15.28	12.19	18.98	400	66	16.50	13.18	20.45
Aug	433	76	17.55	14.26	21.42	405	76	18.77	15.26	22.85
Sep	448	86	19.20	15.82	23.10	418	86	20.57	16.98	24.71
Oct	549	115	20.95	17.75	24.55	522	115	22.03	18.69	25.78
Nov	2999	761	25.38	23.85	26.96	2821	760	26.94	25.34	28.61
Dec	1727	216	12.51	11.03	14.15	1614	216	13.38	11.81	15.13

Najvyšší podiel nákupov je za mesiac november, približne 25.4% v neupravených a v upravených 26.9% dátach. Najnižšie je za mesiac február, kde dosahuje podiel iba 1.6% a 1.7%.

Intervaly spoľahlivosti spresňujú informáciu o presnosti odhadov, kde závisí od počtu sessions aj od podielu nákupov. Máj má užší interval ako mesiac august, ktorý obsahuje menej sessionov.

Pri čistení boli odstránené iba sessiony bez nákupu, počet nákupov preto ostal rovnaký, zatiaľ čo sessiony klesli, čo zvýšilo podiel nákupov v upravených dátach.

Correlation of session and purchase by month



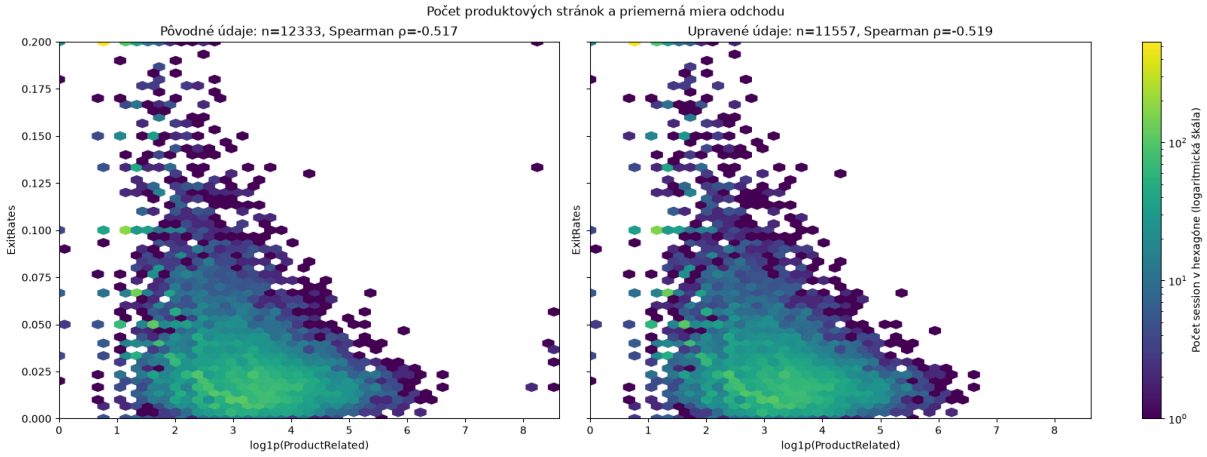
Mesiac	Počet session	Počet nákupov	Podiel nákupov (%)	Pearson	Spearman
Feb	173	3	1.73	—	—
Mar	1771	192	10.84	—	—
May	3161	365	11.55	—	—
June	272	29	10.66	—	—
Jul	400	66	16.50	—	—
Aug	405	76	18.77	—	—
Sep	418	86	20.57	—	—
Oct	522	115	22.03	—	—
Nov	2821	760	26.94	—	—
Dec	1614	216	13.38	—	—
Spolu / priemerný podiel / korelácie medzi mesiacmi	11557	1908	15.30	0.854	0.976

Pearsonova korelácia r = 0.853 naznačuje silný lineárny vzťah. Spearmanova korelácia $\rho = 0.976$ ukazuje, že mesiace s vyššou návštevnosťou majú takmer vždy aj vyšší počet nákupov.

Máj mal najviac sessionov 3 171 ale nákupom skončilo 365, podiel 11.5%. November mal menej sessionov 2 826 no najviac nákupov 756, čo je aj najvyšší podiel nákupov 26.9%. Najnižší podiel dosiahol za mesiac február a to 1.7%.

ProductRelated a ExitRates

Hexbin graf ukazuje počet produktových stránok oproti priemernej miere odchodu zo stránok navštívených v sessions. Používam log1p, čo zachová nuly a zlepšuje čitateľnosť veľkého rozsahu. Farba vyjadruje počet sessionov v hexagóne.

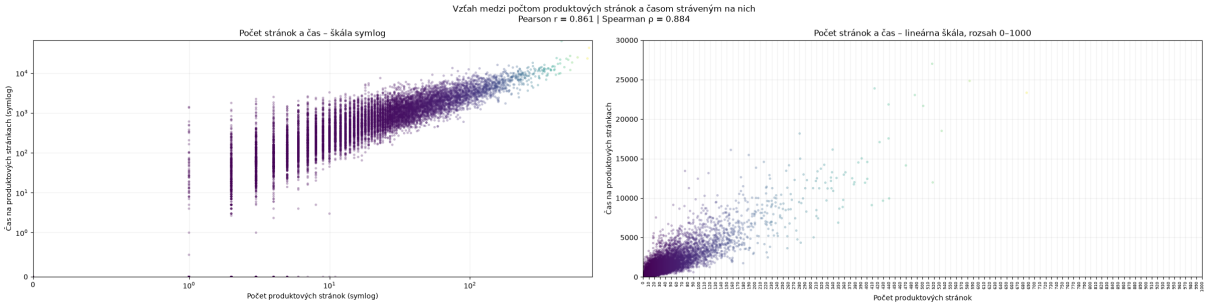


Dataset	Počet session	Spearman	Medián ExitRates (0–1 produktových stránok)	Medián ExitRates (>50 produktových stránok)
Pôvodné údaje	12333	-0.517	0.2	0.017
Upravené údaje	11557	-0.519	0.2	0.017

S rastúcim počtom navštívených produktových stránok má priemerná miera odchodu sa znižovať. Vzťah ostáva podobný pred aj po čistení, kde to naznačuje Spearmanova korelácia, ktorá je približne -0.52. Nepreukazuje sa, že viac produktových stránok priamo spôsobuje nižšiu mieru odchodu. Medián pre ExitRates pri 0-1 produktových stránkach je 0.2 ale 0.017 pri viac ako 50 produktových stránkach.

Correlation of ProductRelated and time on them

Počet session: 11557 | Pearson r = 0.861 | Spearman $\rho = 0.884$



Počet session s časom nad 30 000: 2

	SessionID	ProductRelated	ProductRelated_Duration
0	S-108071	449.0	63973.52223
1	S-105152	705.0	43171.23338

Graf ukazuje, že s rastúcim počtom navštívených produktových stránok rastie aj čas strávený na nich. Pearsonova korelácia je 0.304, čo naznačuje slabšiu lineárnu závislosť. Spearmanova korelácia 0.883 ukazuje silný vzťah, vyššiemu počtu stránok väčšinou pripadá dlhší čas, hoci tento rast nie je rovnomerný.

Graf so škálou symlog umožňuje ukázať extrémne hodnoty a lepšie odhaľuje rastúci trend. Lineárny graf ukazuje, že väčšina sessionov sa sústreďuje pri nižších počtoch stránok a kratšom čase.

Pri rovnakom počte stránok sa čas medzi sessionami výrazne líši. Viditeľné sú aj extrémne hodnoty s vysokým počtom stránok a pomerne krátkym časom, ktoré môžu ovplyvňovať Pearsonovu koreláciu. Počet produktových stránok súvisí s časom návštevy, ale sám nestačí na jeho presný odhad.

Classification

Data separation

- Rozmery vstupov: 11557 riadkov a 16 stĺpcov.
- Kategorické stĺpce: Month, VisitorType, OperatingSystems, Browser, Region, TrafficType.
- Binárne stĺpce: Weekend.
- Revenue:
  - **0**: 0.834905
  - **1**: 0.165095

Train, val, test split

```
SPLIT_RATIOS = {
    "70/15/15": (0.70, 0.15, 0.15),
    "80/10/10": (0.80, 0.10, 0.10),
    "70/10/20": (0.70, 0.10, 0.20),
    "60/10/30": (0.60, 0.10, 0.30),
}
```

Rozdelenie dát na trénovacie, validačné a testovacie, kde využijem aj stratify na zachovanie pomeru voči Revenue (zachovanie tak istého pomeru nákupu v train, val a test množine). Počty sa môžu mierne líšiť od pomerov pre zaokrúhlenie na celé riadky.

Encoding discrete cols

```
categorical_preparation = Pipeline([
    ("imputer", SimpleImputer(strategy="most_frequent")),
    ("onehot", OneHotEncoder(handle_unknown="ignore", sparse_output=False)),
])
```

One-Hot encoder vytvorí samostatné binárne stĺpce pre každú kategóriu, čo je vhodné pre diskrétne dáta (kategorické). Nezachováva vzťah, závislosť, poradie ani vzdialenosť od ostatných kategórií - mali by byť nezávislé, ale nezaručuje sa to. handle unknown umožní spracovať aj kategóriu, ktorá sa v tréningu nevyskytla a imputer doplní prípadne chýbajúce hodnoty najčastejšou kategóriou, ktorá sa vyskytla v tréningu.

Scaling

StandardScaler škáluje číselné vlastnosti na približne nulový priemer a jednotkový rozptyl (napríklad aby sa čas v sekundách neprevažoval nad mierami odchodu pri fitovaní logistickej regresii). Diskrétne stĺpce ponechávam v 0/1, prípadne chýbajúce hodnoty sa doplnia modusom.

Všetko je organizované v Pipeline, aby sa kódovanie, škálovanie, imputácia využívalo pri každom folde trénovania.

Modely

- Random Forest: 64 kombinácií - hľadajú sa kombinácie hyperparametrov, kde max features je v rozmedzí 4 až 13, najmenej listov je v rozmedzí 1 až 7 a najväčšia hĺbka od 5 do 20.
- Logistic Regression: 12 kombinácií - regularizácia C od silnej 0,00001 až po slabú 1. Pri class_weight skúša None, kde majú všetky vzorky rovnakú váhu a balanced, kde má zvýšenú váhu menej početná trieda. (sigmoid, probability, weighted sum, Maximum Likelihood Estimation)
- Decision Tree: 10 kombinácií - skúša maximálnu hĺbku od 3 až po 15 ale taktiež None, a minimálny počet listov 1 alebo 5.

```python
parameters = {
    "max_features": [4, 7, 10, 13],
    "min_samples_leaf": [1, 3, 5, 7],
    "max_depth": [5, 10, 15, 20],
}

model_configs = {
    "RandomForest": {
        "classifier": RandomForestClassifier(
            n_estimators=100,
            random_state=RANDOM_STATE, n_jobs=1,
        ),
        # Prefix model__ je potrebný, pretože klasifikátor je v Pipeline.
        "grid": {f"model__{name}": values for name, values in parameters.items()},
    },
    "LogisticRegression": {
        "classifier": LogisticRegression(
            solver="lbfgs", max_iter=3000, random_state=RANDOM_STATE,
        ),
        "grid": {
            "model__C": np.logspace(-5, 0, 6),
            "model__class_weight": [None, "balanced"],
        },
    },
    "DecisionTree": {
        "classifier": DecisionTreeClassifier(random_state=RANDOM_STATE),
        "grid": {
            "model__max_depth": [3, 5, 10, 15, None],
            "model__min_samples_leaf": [1, 5],
        },
    },
}
```

Trénovanie a na hľadanie parametrov využívam GridSearcbCV, kde pre každý model su preddefinované parametre a grid search vyhľadáva na základe ich kombinácii. Modely sa trénuju na trénovacej množine a vyhodnocuju na validačnej množine pomocou accuracy. Najúspeši model na validačnej množine vráti najlepšie hyperparametre na ktorých sa natrénuje výsledný model.

Vyhodnotenie modelov

Tabuľka má 12 riadkov s rôznymi kombináciami experimentovania. Vyhodnocujú sa 3 modely na 4 rozdeleniach s trénovacou, validačnou a testovacou úspešnosťou. Najlepší model vyberám podľa validation accuracy a pri zhode podľa výsledku z grid searchu.

	Rozdelenie	Model	Train n	Val n	Test n	Train accuracy	Val accuracy	Grid accuracy	Grid std	Test accuracy	Test balanced accuracy	Test F1	Test recall	Baseline test accuracy	Train-test rozdiel
0	70/15/15	RandomForest	8089	1734	1734	0.9498	0.8968	0.8968	0.0	0.8899	0.7404	0.6078	0.5175	0.8351	0.0600
1	70/15/15	LogisticRegression	8089	1734	1734	0.8795	0.8749	0.8749	0.0	0.8760	0.6634	0.4794	0.3462	0.8351	0.0035
2	70/15/15	DecisionTree	8089	1734	1734	0.9119	0.8927	0.8927	0.0	0.8795	0.7146	0.5618	0.4685	0.8351	0.0324
3	80/10/10	RandomForest	9245	1156	1156	0.9562	0.8988	0.8988	0.0	0.8867	0.7432	0.6066	0.5288	0.8348	0.0695
4	80/10/10	LogisticRegression	9245	1156	1156	0.8792	0.8798	0.8798	0.0	0.8780	0.6708	0.4946	0.3613	0.8348	0.0012
5	80/10/10	DecisionTree	9245	1156	1156	0.8982	0.8875	0.8875	0.0	0.8832	0.7516	0.6110	0.5550	0.8348	0.0150
6	70/10/20	RandomForest	8089	1156	2312	0.9478	0.9118	0.9118	0.0	0.8966	0.7607	0.6406	0.5576	0.8348	0.0512
7	70/10/20	LogisticRegression	8089	1156	2312	0.8796	0.8780	0.8780	0.0	0.8763	0.6666	0.4856	0.3534	0.8348	0.0033
8	70/10/20	DecisionTree	8089	1156	2312	0.8971	0.9014	0.9014	0.0	0.8854	0.7602	0.6230	0.5733	0.8348	0.0118
9	60/10/30	RandomForest	6933	1156	3468	0.9358	0.8997	0.8997	0.0	0.8971	0.7613	0.6419	0.5585	0.8348	0.0388
10	60/10/30	LogisticRegression	6933	1156	3468	0.8798	0.8720	0.8720	0.0	0.8760	0.6703	0.4917	0.3630	0.8348	0.0038
11	60/10/30	DecisionTree	6933	1156	3468	0.9091	0.8953	0.8953	0.0	0.8950	0.7524	0.6293	0.5393	0.8348	0.0141

```
Vybraný model a rozdelenie: ('70/10/20', 'RandomForest')
Vybrané parametre: {'model__max_depth': 10, 'model__max_features': 13, 'model__min_samples_leaf': 1}
Grid accuracy = accuracy na validačnej množine
Grid std = 0 znamená jediný validačný split, nie nulovú neistotu.
```

Najlepším modelom podľa validácie bol Random Forest pri rozdelení 70/10/20, s validačnou accuracy 91.18% a testovacou accuracy 89.66%. Najvyššiu testovaciu accuracy dosiahol Random Forest pri 60/10/30 a to 89.71% čo je rozdiel 0.05%.

Najhorším modelom podľa validácie bola Logistic Regression pri 60/10/30, s validačnou accuracy 87.2% a testovacou 87.6%. Zachytila iba 36.3% správne klasifikovaných nákupov.

Random Forest

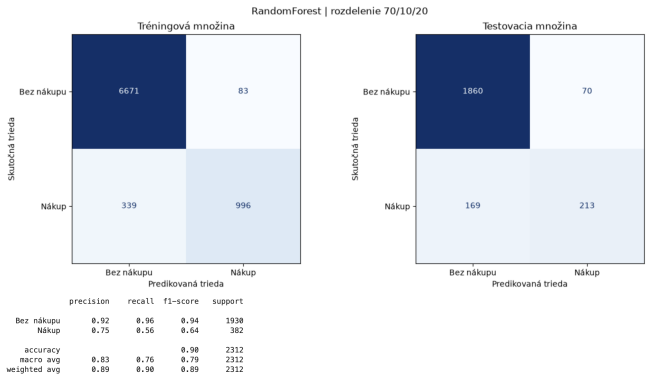
	Model	Rozdelenie	params	mean_train_score	mean_test_score	std_test_score	rank_test_score	Best features
0	RandomForest	70/10/20	{'model__max_depth': 10, 'model__max_features': 13, 'model__min_samples_leaf': 1}	0.9478	0.9118	0.0	1	numeric__PageValues: 0.5204, numeric__ExitRates: 0.0661, numeric__ProductRelated_Duration: 0.0649, numeric__ProductRelated: 0.0498, numeric__BounceRates: 0.0478
1	RandomForest	70/10/20	{'model__max_depth': 20, 'model__max_features': 10, 'model__min_samples_leaf': 7}	0.9318	0.9083	0.0	2	numeric__PageValues: 0.5204, numeric__ExitRates: 0.0661, numeric__ProductRelated_Duration: 0.0649, numeric__ProductRelated: 0.0498, numeric__BounceRates: 0.0478
2	RandomForest	70/10/20	{'model__max_depth': 20, 'model__max_features': 10, 'model__min_samples_leaf': 3}	0.9581	0.9083	0.0	2	numeric__PageValues: 0.5204, numeric__ExitRates: 0.0661, numeric__ProductRelated_Duration: 0.0649, numeric__ProductRelated: 0.0498, numeric__BounceRates: 0.0478
3	RandomForest	70/10/20	{'model__max_depth': 10, 'model__max_features': 13, 'model__min_samples_leaf': 5}	0.9304	0.9083	0.0	2	numeric__PageValues: 0.5204, numeric__ExitRates: 0.0661, numeric__ProductRelated_Duration: 0.0649, numeric__ProductRelated: 0.0498, numeric__BounceRates: 0.0478
4	RandomForest	70/10/20	{'model__max_depth': 15, 'model__max_features': 10, 'model__min_samples_leaf': 3}	0.9522	0.9083	0.0	2	numeric__PageValues: 0.5204, numeric__ExitRates: 0.0661, numeric__ProductRelated_Duration: 0.0649, numeric__ProductRelated: 0.0498, numeric__BounceRates: 0.0478
...	...	...	...	...	...	...	...	...
59	RandomForest	70/10/20	{'model__max_depth': 5, 'model__max_features': 7, 'model__min_samples_leaf': 3}	0.8432	0.8417	0.0	60	numeric__PageValues: 0.5204, numeric__ExitRates: 0.0661, numeric__ProductRelated_Duration: 0.0649, numeric__ProductRelated: 0.0498, numeric__BounceRates: 0.0478
60	RandomForest	70/10/20	{'model__max_depth': 5, 'model__max_features': 4, 'model__min_samples_leaf': 7}	0.8350	0.8348	0.0	61	numeric__PageValues: 0.5204, numeric__ExitRates: 0.0661, numeric__ProductRelated_Duration: 0.0649, numeric__ProductRelated: 0.0498, numeric__BounceRates: 0.0478
61	RandomForest	70/10/20	{'model__max_depth': 5, 'model__max_features': 4, 'model__min_samples_leaf': 5}	0.8350	0.8348	0.0	61	numeric__PageValues: 0.5204, numeric__ExitRates: 0.0661, numeric__ProductRelated_Duration: 0.0649, numeric__ProductRelated: 0.0498, numeric__BounceRates: 0.0478
62	RandomForest	70/10/20	{'model__max_depth': 5, 'model__max_features': 4, 'model__min_samples_leaf': 3}	0.8350	0.8348	0.0	61	numeric__PageValues: 0.5204, numeric__ExitRates: 0.0661, numeric__ProductRelated_Duration: 0.0649, numeric__ProductRelated: 0.0498, numeric__BounceRates: 0.0478
63	RandomForest	70/10/20	{'model__max_depth': 5, 'model__max_features': 4, 'model__min_samples_leaf': 1}	0.8350	0.8348	0.0	61	numeric__PageValues: 0.5204, numeric__ExitRates: 0.0661, numeric__ProductRelated_Duration: 0.0649, numeric__ProductRelated: 0.0498, numeric__BounceRates: 0.0478

64 rows × 8 columns

```
Najlepšia konfigurácia: 0.9118
{'model__max_depth': 10, 'model__max_features': 13, 'model__min_samples_leaf': 1}
Najhoršia konfigurácia: 0.8348
{'model__max_depth': 5, 'model__max_features': 4, 'model__min_samples_leaf': 7}
```

	Model	Rozdelenie	Train accuracy	Val accuracy	Test accuracy	Train-test rozdiel
0	RandomForest	70/15/15	0.9498	0.8968	0.8899	0.0600
1	RandomForest	80/10/10	0.9562	0.8988	0.8867	0.0695
2	RandomForest	70/10/20	0.9478	0.9118	0.8966	0.0512
3	RandomForest	60/10/30	0.9358	0.8997	0.8971	0.0388

```
Najlepšia validácia: RandomForest, 70/10/20 | val=0.9118, test=0.8966
Najhoršia validácia: RandomForest, 70/15/15 | val=0.8968, test=0.8899
Najlepší test (opis výsledkov): RandomForest, 60/10/30 | val=0.8997, test=0.8971
Najhorší test (opis výsledkov): RandomForest, 80/10/10 | val=0.8988, test=0.8867
Najväčší rozdiel train-test: RandomForest, 80/10/10 | 6.95 percentuálneho bodu
```




```
              precision    recall  f1-score   support

Bez nákupu       0.92      0.96      0.94      1930
     Nákup       0.75      0.56      0.64       382

    accuracy                         0.90      2312
   macro avg       0.83      0.76      0.79      2312
weighted avg       0.89      0.90      0.89      2312
```

Najlepšia konfigurácia Random Forestu mal maximálna hĺbka 10, počet zvažovaných vlastností 13 a minimálny počet vzoriek v liste 1. Jedna z najhorších mala maximálna hĺbka 5, počet zvažovaných vlastností 4 a minimálny počet vzoriek v liste 1, s validačnou accuracy 83.48%. Takéto parametre vytvárajú plytké stromy, čo má za príčinu nedostatočné zachytávanie vzťahov v dátach.

Najväčší rozdiel medzi tréningom a testom mal Random Forest pri 80/10/10, kde trénovacia accuracy bola 96.62% a testovacia 88.67%, teda rozdiel 6.95. Pri 60/10/30 bol rozdiel iba 3.88. Výsledky z rozdelenia 80/10/10 naznačujú pretrénovanie.

Vybraný Random Forest správne rozpoznal 213 nákupov, ale 169 nákupov prehliadol pri testovaní. Precision bola 75.27% (213/283) a recall 55.76% (213/382) a F1 61.04%.

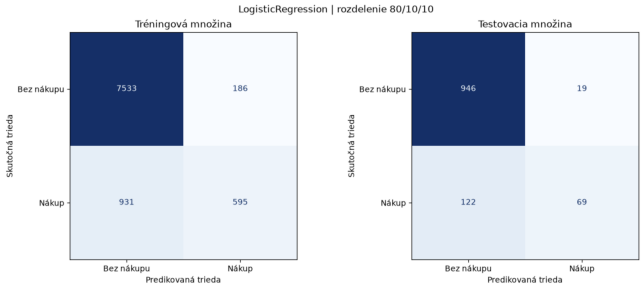
Logistic Regression

	Model	Rozdelenie	params	mean_train_score	mean_test_score	std_test_score	rank_test_score	Best features
0	LogisticRegression	80/10/10	{'model__C': 0.1, 'model__class_weight': None}	0.8792	0.8798	0.0	1	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368
1	LogisticRegression	80/10/10	{'model__C': 1.0, 'model__class_weight': None}	0.8795	0.8789	0.0	2	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368
2	LogisticRegression	80/10/10	{'model__C': 0.01, 'model__class_weight': None}	0.8747	0.8772	0.0	3	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368
3	LogisticRegression	80/10/10	{'model__C': 0.01, 'model__class_weight': 'balanced'}	0.8540	0.8599	0.0	4	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368
4	LogisticRegression	80/10/10	{'model__C': 0.001, 'model__class_weight': None}	0.8548	0.8573	0.0	5	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368
5	LogisticRegression	80/10/10	{'model__C': 0.1, 'model__class_weight': 'balanced'}	0.8485	0.8495	0.0	6	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368
6	LogisticRegression	80/10/10	{'model__C': 1.0, 'model__class_weight': 'balanced'}	0.8477	0.8452	0.0	7	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368
7	LogisticRegression	80/10/10	{'model__C': 0.001, 'model__class_weight': 'balanced'}	0.8485	0.8408	0.0	8	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368
8	LogisticRegression	80/10/10	{'model__C': 0.0001, 'model__class_weight': None}	0.8353	0.8365	0.0	9	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368
9	LogisticRegression	80/10/10	{'model__C': 1e-05, 'model__class_weight': None}	0.8349	0.8348	0.0	10	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368
10	LogisticRegression	80/10/10	{'model__C': 0.0001, 'model__class_weight': 'balanced'}	0.8266	0.8235	0.0	11	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368
11	LogisticRegression	80/10/10	{'model__C': 1e-05, 'model__class_weight': 'balanced'}	0.8161	0.8114	0.0	12	numeric__PageValues: 1.4656, categorical__Month_Nov: 0.6808, numeric__ExitRates: 0.6650, categorical__TrafficType_13: 0.4797, categorical__Month_Dec: 0.4368

```
Najlepšia konfigurácia: 0.8798
{'model__C': np.float64(0.1), 'model__class_weight': None}
Najhoršia konfigurácia: 0.8114
{'model__C': np.float64(1e-05), 'model__class_weight': 'balanced'}
```

	Model	Rozdelenie	Train accuracy	Val accuracy	Test accuracy	Train-test rozdiel
0	LogisticRegression	70/15/15	0.8795	0.8749	0.8760	0.0035
1	LogisticRegression	80/10/10	0.8792	0.8798	0.8780	0.0012
2	LogisticRegression	70/10/20	0.8796	0.8780	0.8763	0.0033
3	LogisticRegression	60/10/30	0.8798	0.8720	0.8760	0.0038

```
Najlepšia validácia: LogisticRegression, 80/10/10 | val=0.8798, test=0.8780
Najhoršia validácia: LogisticRegression, 60/10/30 | val=0.8720, test=0.8760
Najlepší test (opis výsledkov): LogisticRegression, 80/10/10 | val=0.8798, test=0.8780
Najhorší test (opis výsledkov): LogisticRegression, 70/15/15 | val=0.8749, test=0.8760
Najväčší rozdiel train-test: LogisticRegression, 60/10/30 | 0.38 percentuálneho bodu
```




```
              precision    recall  f1-score   support

  Bez nákupu       0.89      0.98      0.93       965
      Nákup        0.78      0.36      0.49       191

    accuracy                           0.88      1156
   macro avg       0.83      0.67      0.71      1156
weighted avg       0.87      0.88      0.86      1156
```

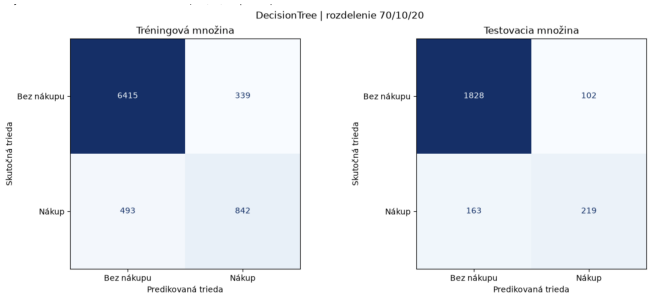
Decision Tree

	Model	Rozdelenie	params	mean_train_score	mean_test_score	std_test_score	rank_test_score	Best features
0	DecisionTree	70/10/20	{'model__max_depth': 3, 'model__min_samples_leaf': 1}	0.8971	0.9014	0.0	1	numeric__PageValues: 0.8573, numeric__BounceRates: 0.0905, categorical__Month_Nov: 0.0388, numeric__ProductRelated_Duration: 0.0110, numeric__Administrative_Duration: 0.0025
1	DecisionTree	70/10/20	{'model__max_depth': 3, 'model__min_samples_leaf': 5}	0.8971	0.9014	0.0	1	numeric__PageValues: 0.8573, numeric__BounceRates: 0.0905, categorical__Month_Nov: 0.0388, numeric__ProductRelated_Duration: 0.0110, numeric__Administrative_Duration: 0.0025
2	DecisionTree	70/10/20	{'model__max_depth': 5, 'model__min_samples_leaf': 1}	0.9104	0.8789	0.0	3	numeric__PageValues: 0.8573, numeric__BounceRates: 0.0905, categorical__Month_Nov: 0.0388, numeric__ProductRelated_Duration: 0.0110, numeric__Administrative_Duration: 0.0025
3	DecisionTree	70/10/20	{'model__max_depth': 5, 'model__min_samples_leaf': 5}	0.9098	0.8789	0.0	3	numeric__PageValues: 0.8573, numeric__BounceRates: 0.0905, categorical__Month_Nov: 0.0388, numeric__ProductRelated_Duration: 0.0110, numeric__Administrative_Duration: 0.0025
4	DecisionTree	70/10/20	{'model__max_depth': 10, 'model__min_samples_leaf': 1}	0.9517	0.8780	0.0	5	numeric__PageValues: 0.8573, numeric__BounceRates: 0.0905, categorical__Month_Nov: 0.0388, numeric__ProductRelated_Duration: 0.0110, numeric__Administrative_Duration: 0.0025
5	DecisionTree	70/10/20	{'model__max_depth': 10, 'model__min_samples_leaf': 5}	0.9356	0.8720	0.0	6	numeric__PageValues: 0.8573, numeric__BounceRates: 0.0905, categorical__Month_Nov: 0.0388, numeric__ProductRelated_Duration: 0.0110, numeric__Administrative_Duration: 0.0025
6	DecisionTree	70/10/20	{'model__max_depth': 15, 'model__min_samples_leaf': 1}	0.9869	0.8581	0.0	7	numeric__PageValues: 0.8573, numeric__BounceRates: 0.0905, categorical__Month_Nov: 0.0388, numeric__ProductRelated_Duration: 0.0110, numeric__Administrative_Duration: 0.0025
7	DecisionTree	70/10/20	{'model__max_depth': 15, 'model__min_samples_leaf': 5}	0.9489	0.8573	0.0	8	numeric__PageValues: 0.8573, numeric__BounceRates: 0.0905, categorical__Month_Nov: 0.0388, numeric__ProductRelated_Duration: 0.0110, numeric__Administrative_Duration: 0.0025
8	DecisionTree	70/10/20	{'model__max_depth': None, 'model__min_samples_leaf': 1}	1.0000	0.8573	0.0	8	numeric__PageValues: 0.8573, numeric__BounceRates: 0.0905, categorical__Month_Nov: 0.0388, numeric__ProductRelated_Duration: 0.0110, numeric__Administrative_Duration: 0.0025
9	DecisionTree	70/10/20	{'model__max_depth': None, 'model__min_samples_leaf': 5}	0.9501	0.8564	0.0	10	numeric__PageValues: 0.8573, numeric__BounceRates: 0.0905, categorical__Month_Nov: 0.0388, numeric__ProductRelated_Duration: 0.0110, numeric__Administrative_Duration: 0.0025

```
Najlepšia konfigurácia: 0.9014
{'model__max_depth': 3, 'model__min_samples_leaf': 1}
Najhoršia konfigurácia: 0.8564
{'model__max_depth': None, 'model__min_samples_leaf': 5}
```

	Model	Rozdelenie	Train accuracy	Val accuracy	Test accuracy	Train-test rozdiel
0	DecisionTree	70/15/15	0.9119	0.8927	0.8795	0.0324
1	DecisionTree	80/10/10	0.8982	0.8875	0.8832	0.0150
2	DecisionTree	70/10/20	0.8971	0.9014	0.8854	0.0118
3	DecisionTree	60/10/30	0.9091	0.8953	0.8950	0.0141

```
Najlepšia validácia: DecisionTree, 70/10/20 | val=0.9014, test=0.8854
Najhoršia validácia: DecisionTree, 80/10/10 | val=0.8875, test=0.8832
Najlepší test (opis výsledkov): DecisionTree, 60/10/30 | val=0.8953, test=0.8950
Najhorší test (opis výsledkov): DecisionTree, 70/15/15 | val=0.8927, test=0.8795
Najväčší rozdiel train-test: DecisionTree, 70/15/15 | 3.24 percentuálneho bodu
```



	precision	recall	f1-score	support
Bez nákupu	0.92	0.95	0.93	1930
Nákup	0.68	0.57	0.62	382
accuracy			0.89	2312
macro avg	0.80	0.76	0.78	2312
weighted avg	0.88	0.89	0.88	2312

Pri rovnakom rozdelení 70/10/20 prekonal Random Forest logistickú regresiu v accuracy o 2.03 ale recall až o 20.42.

Neural Network

- Rozdelenie dát (train/val/test): 70/15/15
- Počet vstupov po predspracovaní: 72
- Počty vzoriek: train 8089, val 1734, test 1734.
- Podiel nákupov v tréningu: 16.52%

net, EarlyStopping a vyhodnotenie

Používam plne prepojenú sieť s ReLU aktivačnou funckiou v skrytých vrstvách. Výstupný neurón vracia logit. BCEWith-Logits-Loss spája sigmoid a binárnu krížovú entropiu stabilne. Pri predikcii používam sigmoid a pevný prah 0.5. Adam aktualizuje váhy po minibatchoch. Všetky behy používajú rovnaký seed, batch size s 128 a maximálne 300 epoch. Dropout ani penalizáciu nepoužívam.

Early-Stopping sleduje validačnú stratu. Ak počas 20 epoch nepríde zlepšenie väčšie než 0.0001 oproti poslednému významnému minimu, zastaví tréning. Obnoví váhy z absolútne najnižšej validačnej straty. Pri modeli bez Early-Stoppingu hodnotím posledné váhy, aby sa pretrénovanie neskrylo obnovením skoršej epochy.

Kombinácie trénovania

O demonštruje pretrénovanie veľkej siete s vrstvami 256, 128 a 64 neurónov pri learning rate 0.001 počas 300 epoch. ES opakuje rovnakú konfiguráciu ale pridáva EarlyStopping.

E1-E3 menia learning rate pri rovnakých vrstvách 64 a 32 neurónov. E4 a E5 menia architektúru pri learning rate 0.001. Tým porovnávam 5 konfigurácií a aspoň 2 druhy nastavení.

vyhodnotenie výsledkov a experimentov

Neurónovú sieť som trénoval na rozdelení 70 % tréningových, 15 % validačných a 15 % testovacích dát. Všetkých sedem tréningov používalo rovnaké vzorky a predspracovanie naučené iba na tréningovej množine. Výsledky sú preto medzi jednotlivými konfiguráciami porovnateľné. Validáciu som použil na EarlyStopping a výber konfigurácie, testovacie dáta na záverečné vyhodnotenie.

Pri veľkej sieti bez EarlyStopping sa jasne prejavilo pretrénovanie. Tréningová strata postupne klesala takmer k nule a tréningová accuracy dosiahla 99,98 %. Validačná strata však po minime v 6. epoche začala rásť. Sieť sa teda stále lepšie prispôsobovala tréningovým príkladom, ale jej schopnosť pracovať s nevidenými dátami sa zhoršovala. Potvrdila to testovacia accuracy

86,85 %, ktorá bola oproti tréningovej nižšia o 13,12 percentuálneho bodu. Tréningová konfúzna matica mala takmer všetky predikcie na diagonále, zatiaľ čo testovacia obsahovala podstatne viac nesprávnych predikcií.

EarlyStopping výrazne obmedzil pretrénovanie. Pri rovnakej architektúre zastavil tréning po 26 epochách a obnovil váhy zo 6. epochy, v ktorej bola validačná strata najnižšia. Tréningová accuracy klesla na 90,52 %, ale testovacia sa zvýšila na 88,87 %. Rozdiel medzi nimi sa zmenšil na 1,65 percentuálneho bodu. Zlepšila sa aj testovacia balanced accuracy a F1 nákupov. Nižšia tréningová úspešnosť teda predstavovala prijateľný kompromis za lepšiu generalizáciu. Graf stále zobrazuje zhoršovanie počas ďalších epoch čakania, no výsledné metriky a konfúzne matice patria obnoveným váham zo 6. epochy.

V experimentoch E1–E5 som menil rýchlosť učenia a architektúru siete. Podľa validačnej accuracy bol najlepší E2, ktorý používal skryté vrstvy so 64 a 32 neurónmi a learning rate 0,001. Dosiahol tréningovú accuracy 90,73 %, validačnú 89,56 % a testovaciu 89,04 %. E1 dosiahol rovnakú testovaciu accuracy, ale potreboval 149 epoch oproti 34 pri E2. Vyšší learning rate v E3 skrátil tréning, no nepriniesol lepšiu testovaciu úspešnosť. Ani zmena veľkosti siete nezaručila zlepšenie, preto väčšia kapacita sama osebe nie je dôvodom na výber modelu.

Konfúzna matica E2 ukazuje, že sieť správne rozpoznáva obe triedy, ale úspešnejšia je pri návštevách bez nákupu. Na teste správne označila 1 372 návštev bez nákupu a 172 nákupov. Zároveň nesprávne predikovala nákup pri 76 návštevách a nezachytila 114 skutočných nákupov. Zachytila teda približne 60,14 % nákupov. Výrazná diagonála potvrdzuje užitočnosť modelu, ale accuracy blízka 90 % neznamená, že sieť rozpoznáva takmer všetky nákupy.

Podľa validačnej accuracy bol najhorší E5, jeho výsledky však ukazujú význam sledovania viacerých metrík. Mal nižšiu testovaciu accuracy než E2, ale vyššiu balanced accuracy aj F1 nákupov. Označenie „najhorší“ preto platí iba pre zvolené validačné kritérium. Ak by hlavným cieľom bolo zachytiť viac nákupov, bolo by vhodné vopred zvoliť tomu zodpovedajúcu validačnú metriku.

Za výslednú konfiguráciu pri použitom kritériu považujem E2. Prekonala väčšinový baseline s testovacou accuracy 83,51 % a vykazovala podstatne menší rozdiel medzi tréningom a testom než zámerne pretrénovaná sieť. Výsledky podporujú použitie EarlyStopping a ukazujú, že vhodná kombinácia architektúry a rýchlosti učenia je dôležitejšia než samotné zväčšovanie siete. Rozdiely medzi experimentmi sú však malé a pochádzajú z jediného rozdelenia a seedu, preto ich nemožno považovať za dôkaz všeobecnej nadradenosti jednej konfigurácie.