

I-SUNS: Zadanie č.1

NEURÓNOVÉ SIETE

Vo vybranom programovacom jazyku implementujte program, ktorý bude predpovedať, či návštevník e-shopu na základe údajov o svojej návšteve (session) a technických parametrov dokončí nákup alebo nie. V tomto zadaní budete pracovať s dátami z AIS. Čas odovzdania je určený časom vloženia do AIS. Deadline pre získanie 10 bodov je **16.10.2026 o 8:00/10:00(pred vaším cvičením)**. Každý týždeň omeškania je penalizovaný stratou troch bodov. Dáta sa nachádzajú v AIS a na Discorde. Zadanie je rozdelené na 3 časti:

- Načítajte dáta, predspracujte ich, natrénujte jednoduchý model a vyhodnoťte ho (spolu 4b):
 - Prezrite si stĺpce v databáze (popis stĺpcov na konci tohto zadania). Podľa popisu zistite, či sa v jednotlivých stĺpcoch nachádzajú outliers (neobvyklé hodnoty) a odstráňte ich. **0.5b**
 - Odstráňte stĺpce, ktoré sa nedajú použiť pri ďalšom spracovaní a *null* resp. *undefined* hodnoty (pozor na odstraňovanie *null* resp. *undefined* hodnôt - aby ste neprišli o príliš veľa dát, ak v stĺpci chýba príliš veľa hodnôt, zvážte, či nie je rozumnejšie odstrániť celý stĺpec). **0.5b**
 - Nečíselné stĺpce vhodne zakódujte. **0.5b**
 - Vytvorte vstupné (X) a výstupné (y) dátové množiny. Vo vhodnom pomere rozdeľte dáta na trénovaciu, validačnú a testovaciu množinu. **0.5b**
 - Dáta správne normalizujte alebo škálujte. **0.5b**
 - Natrénujte jednoduchý klasifikačný model (tu Vám stačí Sklearn). **0.5b**
 - Experimentujte s rozdelením dátových množín. Natrénujte model a vyhodnoťte na trénovacej **A** testovacej množine viackrát. Vytvorte **1** tabuľku s aspoň 4 experimentami s dosiahnutými úspešnosťami. Zamyslite sa nad jednotlivými výsledkami a zhodnoťte, ako rozdelenie vplýva na celkovú úspešnosť. **0.5b**
 - Pre najlepšie natrénovaný model vykreslite konfúznú maticu pre **trénovaciu aj testovaciu množinu**. **0.5b**
- Analyzujte dataset cez EDA. Pracujte s upraveným aj pôvodným datasetom, aby ste mali k dispozícii všetky údaje (pracujte s dátami po odstránení outlierov a

chýbajúcich hodnôt, ale použite hodnoty pred kódovaním, aby ste vedeli použiť slovné hodnoty). Niektoré vzťahy sa Vám budú hľadať lepšie predtým, než dáta upravíte. Nájdite aspoň 5 zaujímavých vzťahov v dátach (každý za 0.5b), vizualizujte ich pomocou grafov (nie 5x rovnaký), inšpirujte sa ukážkami z iných projektov (**spolu 2.5b**):

- grafy bez slovného popisu nebudú hodnotené plným počtom bodov,
 - histogramy, minimálne a maximálne hodnoty nebudú hodnotené plným počtom bodov,
 - ak budú všetky nájdené vzťahy len voči cieľovej premennej, nebudú hodnotené plným počtom bodov.
- Natrénujte neurónovú sieť. Pre splnenie tejto časti zadania odporúčame použiť sofistikovanejšiu knižnicu (Keras, Pytorch, ...), prípadne doplniť funkcionalitu knižnice Sklearn tak, aby ste boli schopní splniť všetky nasledovné body (**spolu 3.5b**):
 - Zvoľte architektúru a nastavenia hyperparametrov tak, aby ste dosiahli pretrénovanie. Demonštrujte pomocou grafov priebehu tréovania, vyhodnotenia úspešností a konfúznej matice pre tréovaciu aj testovaciu množinu. **0.5b**
 - Odstráňte pretrénovanie tak, že do tréovania zavediete EarlyStopping pre skoré zastavenie tréovania. Demonštrujte pomocou grafov priebehu tréovania, vyhodnotenia úspešností a konfúznej matice pre tréovaciu aj testovaciu množinu. **1b**
 - V tomto bode by ste už mali mať správne natrénovanú sieť¹. Skúste zmeniť niektoré hyperparametre, prípadne architektúru siete (aspoň 2) tak, aby ste natrénovali sieť aspoň 5x (napr. v prvých 3 experimentoch zmeníte hodnotu parametra rýchlosti učenia, v ďalších 2 počet neurónov v skrytej vrstve siete). Body budú udelené nasledovne:
 - * Jednotlivé konfigurácie sú prehľadne zapísané v JEDNEJ tabuľke (stačí zapísať rozdiely v experimentoch, netreba pre každý experiment uvádzať všetky parametre, ak ostali zachované). **0.5b**
 - * Pre všetky tréovania sú v tabuľke vyhodnotené dosiahnuté úspešnosti pre tréovaciu aj testovaciu množinu. **0.5b**
 - * Pre najlepšie a najhoršie tréovanie je navyše zobrazený priebeh tréovania a konfúzne matice pre tréovaciu aj testovaciu množinu. **1b**

¹Správne natrénovaná sieť - nepozorovať známky pretrénovania, úspešnosť presahuje náhodnú úspešnosť (v tomto prípade 50%), na konfúznej matici sa dá pozorovať správne vyfarbená diagonála.

Na čo si dať pozor!

- Nezabudnite zo vstupnej množiny odstrániť sledovanú výstupnú hodnotu, vo vašom prípade stĺpec *Revenue*.
- Pri normalizácii/škálovaní dbajte na to, aby ste pri nastavení scaler-a (prípadne manuálnom výpočte použitých minimálnych/maximálnych hodnôt, priemeru a smerodajnej odchýlky) použili trénovacie dáta a následne už nastavený scaler (príp. vypočítané hodnoty) použili pre validačnú a testovaciu množinu.
- Na analýzu výsledkov používame vyhodnotenie úspešnosti, konfúznú maticu, ... pre trénovacie aj testovacie dáta. Keď je v zadaní požiadavka na vyhodnotenie úspešnosti alebo konfúznej matice (prípadne inej metriky v ďalších zadaniach) vždy chceme tieto výsledky pre trénovaciu aj testovaciu množinu (nie validačnú, tú používame len na vyhodnotenie priebehu trénovania).
- Každý bod zadania musí byť zkodumentovaný, t.j. ak máte napr. demonštrovať pretrénovanie a následne ho odstrániť pridaním EarlyStopping-u, je potrebné dať do dokumentácie aj priebeh trénovania, dosiahnuté výsledky a nastavenia pred jeho použitím, inak nemáme možnosť vyhodnotiť, či ste splnili daný bod zadania.

Nepovinné úlohy

- Dobré parametre hľadajte pomocou Grid-searchu, prehľadávajte aspoň 10 rôznych kombinácií parametrov - dosiahnuté výsledky analyzujte (najlepší/najhorší výsledok, pretrénovanie, ...). **1b**
- Porovnajzte rôzne modely založené na rôznych metódach z knižnice Sklearn (aj vysvetliť). **1-2b**

Popis stĺpcov

- Administrative: Počet administratívnych stránok (napr. účet, platobné údaje), ktoré návštevník v danej session navštívil (číselná hodnota).
- Administrative_Duration: Celkový čas strávený na administratívnych stránkach v danej session, v sekundách (číselná hodnota).
- Informational: Počet informačných stránok (napr. o firme, kontakt), ktoré návštevník v danej session navštívil (číselná hodnota).
- Informational_Duration: Celkový čas strávený na informačných stránkach v danej session, v sekundách (číselná hodnota).

- **ProductRelated:** Počet stránok súvisiacich s produktom, ktoré návštevník v danej session navštívil (číselná hodnota).
- **ProductRelated_Duration:** Celkový čas strávený na stránkach súvisiacich s produktom v danej session, v sekundách (číselná hodnota).
- **BounceRates:** Priemerná miera okamžitého opustenia stránok navštívených v session, metrika Google Analytics vyjadrujúca percento návštevníkov, ktorí prídu na danú stránku ako prvú a odídu bez akejkoľvek ďalšej interakcie. Hodnoty v rozsahu $[0, 1]$.
- **ExitRates:** Priemerná miera odchodu zo stránok navštívených v session, percento zobrazení danej stránky, pri ktorých bola táto stránka poslednou v danej session. Hodnoty v rozsahu $[0, 1]$.
- **PageValues:** Priemerná hodnota stránky pred dokončením e-commerce transakcie (číselná hodnota).
- **SpecialDay:** Vzdialenosť daného dátumu od sviatku (napr. Deň matiek, Valentín), kedy je vyššia pravdepodobnosť dokončenia nákupu (číselná hodnota v rozsahu $[0, 1]$).
- **Month:** Mesiac poslednej návštevy. V datasete sa vyskytujú hodnoty: Feb, Mar, May, June, Jul, Aug, Sep, Oct, Nov, Dec (mesiace Jan a Apr sa v datasete nenachádzajú).
- **OperatingSystems:** Operačný systém použitý návštevníkom (kódovaná číselná hodnota, 1-8).
- **Browser:** Webový prehliadač použitý návštevníkom (kódovaná číselná hodnota, 1-13).
- **Region:** Geografický región návštevníka (kódovaná číselná hodnota, 1-9).
- **TrafficType:** Typ zdroja návštevnosti (kódovaná číselná hodnota, 1-20).
- **VisitorType:** Typ návštevníka. Možné hodnoty: Returning_Visitor, New_Visitor, Other.
- **Weekend:** Booleovská hodnota, či návšteva prebehla cez víkend.
- **Revenue:** Cieľová premenná - či session skončila nákupom. Možné hodnoty: True, False.