SUNS: zadanie 2

Samuel Bagin

1. Úprava dát

Predikcia priemernej hodinovej koncentrácie CO pomocou regresných modelov. Výstup `co` je v mg/m^3. Do vstupov modelov nevstupuje.

1.1. Načítanie a význam stĺpcov

Načítal som **9,507 riadkov a 14 stĺpcov**. Merania pokrývajú obdobie **2004-03-10 až 2005-04-04**.

`instant` je identifikátor, `date` označuje deň merania. Päť senzorov poskytuje odozvy bez fyzikálnej jednotky. Nejde o priamo zmerané koncentrácie jednotlivých plynov. `co` pochádza z referenčného analyzátora. Teplota je v °C a relatívna vlhkosť v %. Dátum nebudem kódovať stovkami one-hot stĺpcov: časové informácie už obsahujú mesiac, hodinu, deň v týždni a ročné obdobie.

1.2. Kvalita dát

Odstraňujem riadky s NA, a nerobím imputáciu. Duplicity skontrolujem ešte pred rozdelením, aby rovnaké meranie neskončilo v tréningu aj teste. Pri dátume overím parsovanie a súlad s mesiacom a dňom v týždni. Uvedené rozsahy senzorov v PDF sú približné, preto ich nepoužívam ako tvrdé limity.

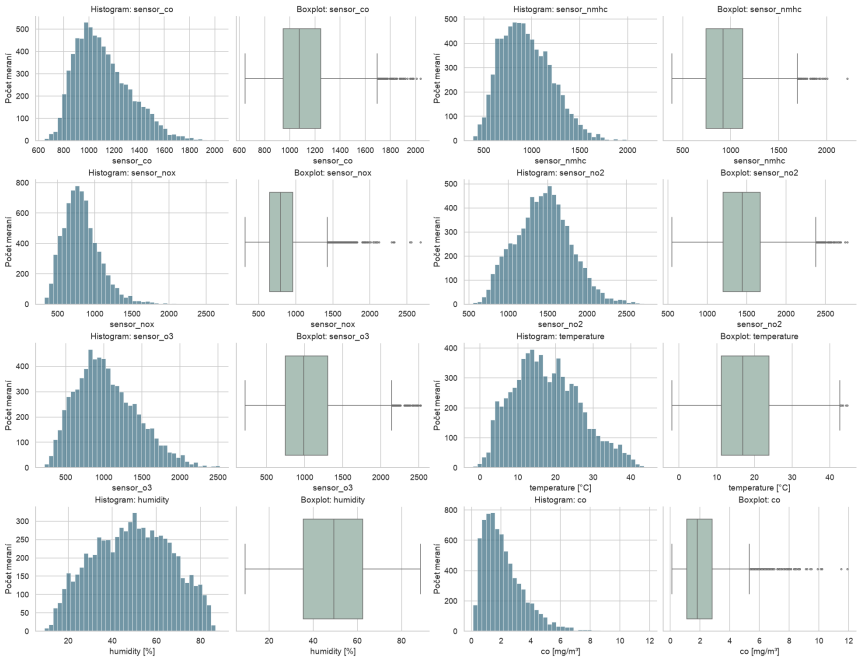
Dataset obsahuje **150 úplných duplicít**, bez identifikátora je ich 150. Cieľ chýba v **1716 riadkoch**. Spoločné vzory chýbania senzorov naznačujú výpadky merania.

	Krok	Zostáva	Odstránené v kroku
0	Pôvodné údaje	9507	0
1	Po odstránení duplicít	9357	150
2	Po odstránení NA	7344	2013
3	Po kontrole platnosti	7344	0

Po čistení zostalo **7,344 úplných a platných meraní** (77.2% pôvodných riadkov). Teploty nad približných 40 °C automaticky nemažem: stále môžu byť reálnym meraním. Štatistické outliery odstránim až z tréningových dát pomocou hraníc naučených výhradne na danom tréningu.

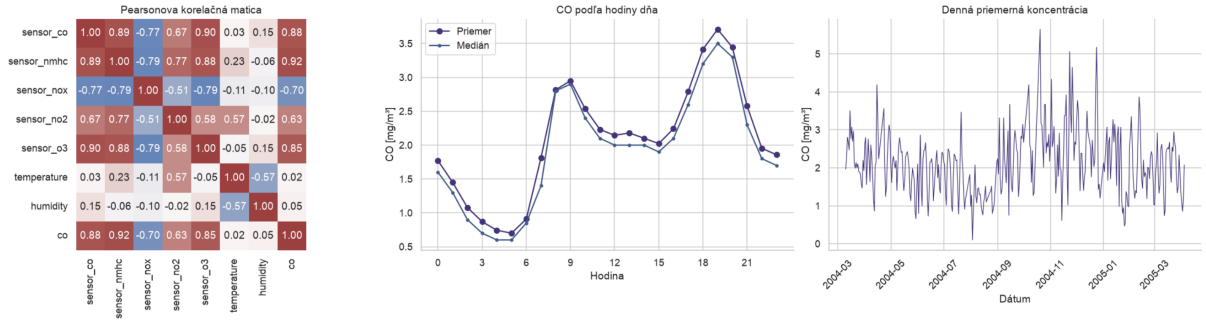
2. EDA – bonus

2.1. Rozdelenia senzorov a koncentrácie



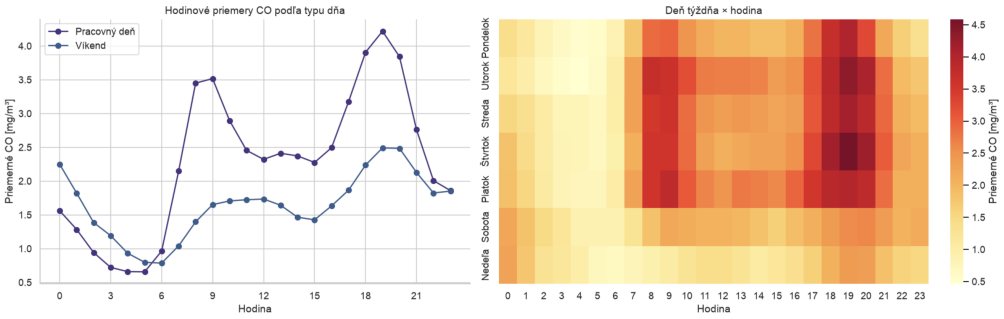
CO má medián **1.80** mg/m^3, priemer 2.13 mg/m^3 a výberovú šikmosť **1.36**. Dlhší pravý chvost znamená menej časté vysoké koncentrácie. MSE tieto veľké chyby silno penalizuje. Senzor NOx dosahuje maximum 2683. Odľahlosť v grafe sama nepreukazuje poruchu.

2.2. Súvislosti a časový priebeh



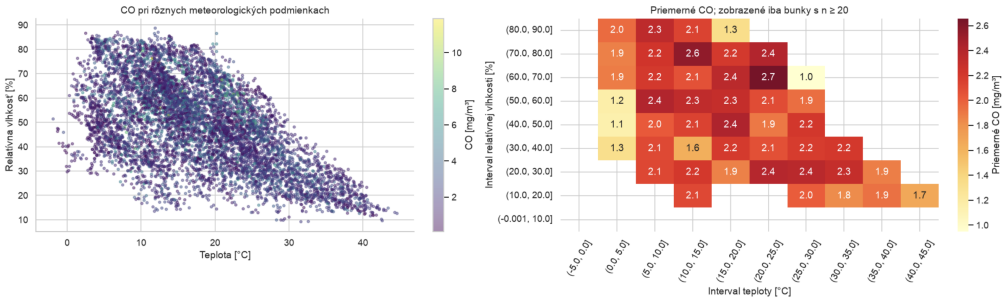
Najsilnejšiu absolútnu Pearsonovu koreláciu s CO má **sensor_nmhc**, $r = 0.92$, a **sensor_o3** voči **sensor_co** $r = 0.90$. Najvyšší hodinový priemer je o **19:00** (3.71 mg/m^3), najnižší o 5:00 (0.70 mg/m^3). Rozdiely sú zlučiteľné s denným cyklom emisií, ale bez údajov o doprave a počasí z grafu nemožno potvrdiť jeho príčinu. Denný priebeh ukazuje aj časovú závislosť, ktorú obyčajné náhodné rozdelenie úplne neodstraňuje.

2.3. Hodinový priebeh CO v pracovných dňoch a cez víkend



Pracovné dni majú priemerné CO **2.333 mg/m³**, víkend **1.658 mg/m³**. Najvyšší hodinový priemer nastáva v pracovných dňoch o **19:00**, cez víkend o **19:00**. Priemery sú ovplyvnené aj zastúpením ročných období a počasia. Samy nepotvrdzujú príčinný vplyv dopravy.

2.4. Teplota, vlhkosť a koncentrácia CO



Spearmanova korelácia CO s teplotou je **0.069**, s vlhkosťou **-0.006**. Zo zobrazených buniek s aspoň 20 meraniami má najvyššie priemerné CO kombinácia teploty **(20.0, 25.0] °C** a vlhkosti **(60.0, 70.0] %** (**2.658 mg/m³**), najnižší priemer je **0.950 mg/m³**. Agregovaný graf ukazuje spoločný vzťah dvoch premenných, ale nenahrádza kontrolu sezónnosti ani dôkaz príčiny. Biele bunky nemajú dosť meraní na zobrazenie.

	temperature	humidity	co
temperature	1.000	-0.532	0.069
humidity	-0.532	1.000	-0.006
co	0.069	-0.006	1.000

teplota_interval

vlhkost_interval	(-5.0, 0.0]	(0.0, 5.0]	(5.0, 10.0]	(10.0, 15.0]	(15.0, 20.0]
(-0.001, 10.0]	0	0	0	0	0
(10.0, 20.0]	0	0	4	40	15
(20.0, 30.0]	1	4	23	83	77
(30.0, 40.0]	3	53	133	178	190
(40.0, 50.0]	8	104	198	175	301
(50.0, 60.0]	1	116	186	351	385
(60.0, 70.0]	0	92	196	435	232
(70.0, 80.0]	0	53	215	242	189
(80.0, 90.0]	0	55	81	75	21

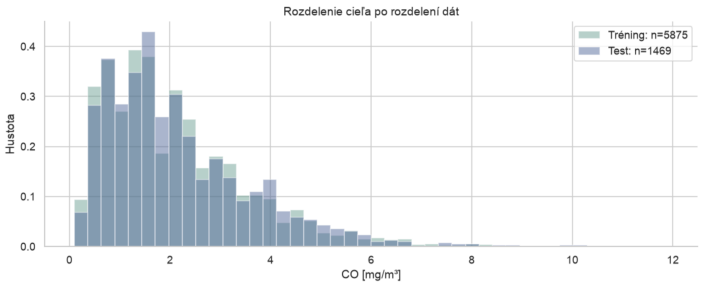
vlhkost_interval	(20.0, 25.0]	(25.0, 30.0]	(30.0, 35.0]	(35.0, 40.0]	(40.0, 45.0]
(-0.001, 10.0]	0	3	2	0	1
(10.0, 20.0]	14	42	76	114	45
(20.0, 30.0]	117	199	208	138	1
(30.0, 40.0]	269	246	110	14	0
(40.0, 50.0]	369	216	16	0	0
(50.0, 60.0]	276	98	0	0	0
(60.0, 70.0]	198	28	0	0	0
(70.0, 80.0]	27	0	0	0	0
(80.0, 90.0]	2	0	0	0	0

3. Rozdelenie dát

Použijem jedno rozdelenie **80 % tréning / 20 % test**. Tréning zahŕňa aj vnútorné CV foldy, preto samostatnú vonkajšiu validačnú množinu nepotrebujem. Seed 2026 je stanovený pred týmto experimentom. `instant` a `date` sa do modelov nedostanú. Rovnaké testovacie riadky zachovám aj pri redukcii príznakov a zhlukovaní.

Tréning obsahuje **5875** a test **1469** meraní. Rozdelenie je náhodné bez stratifikácie regresného cieľa.

	Počet	Priemer CO	SD CO
Tréning	5875	2.1212	1.4356
Test	1469	2.1636	1.4398



3.1. Kódovanie a normalizácia

3.1.1. Cyklické kalendárne premenné

Mesiac, hodinu a deň v týždni prevediem na sínus a kosínus. Susedné hodnoty 23 a 0 hodín tak zostanú blízko aj v kódovaní. Sezóna má iba štyri kategórie, preto použijem one-hot kódovanie. Dátum nepridáva stovky stĺpcov. Po kódovaní štandardizujem **všetky vstupy**, vrátane one-hot stĺpcov, aby PCA a vzdialenostné modely neovládla pôvodná mierka senzorov. Cieľ `co` nemením.

$$\sin_t = \sin\left(\frac{2\pi t}{T}\right), \quad \cos_t = \cos\left(\frac{2\pi t}{T}\right)$$

$$z = \frac{x - \mu_{\text{tréning}}}{\sigma_{\text{tréning}}}$$

3.1.2. Odstránenie odľahlých tréningových záznamov

Pre sedem spojitých vstupov použijem hranice $[Q_1 - 3 \times \text{IQR}, Q_3 + 3 \times \text{IQR}]$, kde $\text{IQR} = Q_3 - Q_1$. Záznam odstránim, ak mimo nich leží aspoň jeden vstup. Kvartily sa učia pri každom `fit` iba z príslušného tréningového foldu. CO ani diskrétne časové stĺpce nefiltrované podľa IQR. Pri `predict` sa neodstraňuje žiadny riadok.

Na trénovacích dátach toto pravidlo odstraňuje **23 riadkov**, model sa učí na **5852 meraniach**. Test zostáva so všetkými 1469 riadkami.

Kódovaním vzniká **17 vstupov**, 10 nových stĺpcov, ktoré nahradili 4 pôvodné.

- month (cyclic): `month_sin`, `month_cos`
- hour (cyclic): `hour_sin`, `hour_cos`
- weekday (cyclic): `weekday_sin`, `weekday_cos`
- season (one-hot): `season_autumn`, `season_spring`, `season_summer`, `season_winter`

4. Trénovanie ML modelov

Reziduál definujem ako skutočná mínus predpovedaná. Kladný reziduál znamená podhodnotenie, záporný nadhodnotenie.

Model vyberiem podľa najnižšej priemernej **CV MSE**. CV smerodajná odchýlka je variabilita medzi foldmi, nie interval spoľahlivosti.

Pri strome ladím hĺbku a minimálny počet vzoriek v liste. Random Forest priemeruje bootstrapové stromy, ExtraTrees (Extremely Randomized Trees) navyše náhodne volí prahy. XGBoost a histogramový boosting pridávajú stromy postupne na opravu predchádzajúcich chýb. Pri SVR volím regresnú verziu SVM s RBF jadrom, penalizáciou C, šírkou jadra gamma a toleranciou epsilon.

Pri 3-fold CV sa každá konfigurácia trénuje trikrát na dvoch foldoch a hodnotí na zostávajúcom.

Model	CV MSE	CV RMSE	CV tréning R^2	CV tréning SD R^2	CV R^2	CV SD R^2	CV SD MSE	Čas [s]
SVR	0.1046	0.3234	0.9843	0.0006	0.9492	0.0028	0.0063	119.2210
HistGradientBoosting	0.1256	0.3544	0.9805	0.0010	0.9388	0.0046	0.0070	21.5343
XGBoost	0.1284	0.3583	0.9846	0.0009	0.9376	0.0040	0.0076	6.4054
ExtraTrees	0.1297	0.3602	1.0000	0.0000	0.9370	0.0034	0.0095	17.0656
RandomForest	0.1499	0.3872	0.9898	0.0004	0.9272	0.0022	0.0088	47.0679
DecisionTree	0.2346	0.4843	0.9364	0.0016	0.8860	0.0012	0.0099	1.1703

Pred otvorením testovacích výsledkov vyberám **SVR** podľa CV MSE 0.1046. Jeho CV RMSE je 0.3234 mg/m^3. Tento model a jeho hyperparametre ďalej nemením podľa testovacieho poradia.

DecisionTree, RandomForest, ExtraTrees a XGBoost používajú natívnu dôležitosť kódovaných vstupov. HistGradientBoosting a SVR používajú permutáciu pôvodných stĺpcov.

4.1. DecisionTree

Najlepší strom podľa CV má hĺbku **8** a aspoň **8** vzoriek v liste.

Množina	MSE	RMSE	MAE	R^2
Tréning	0.1404	0.3747	0.2509	0.9319
Test	0.2007	0.4480	0.3004	0.9031

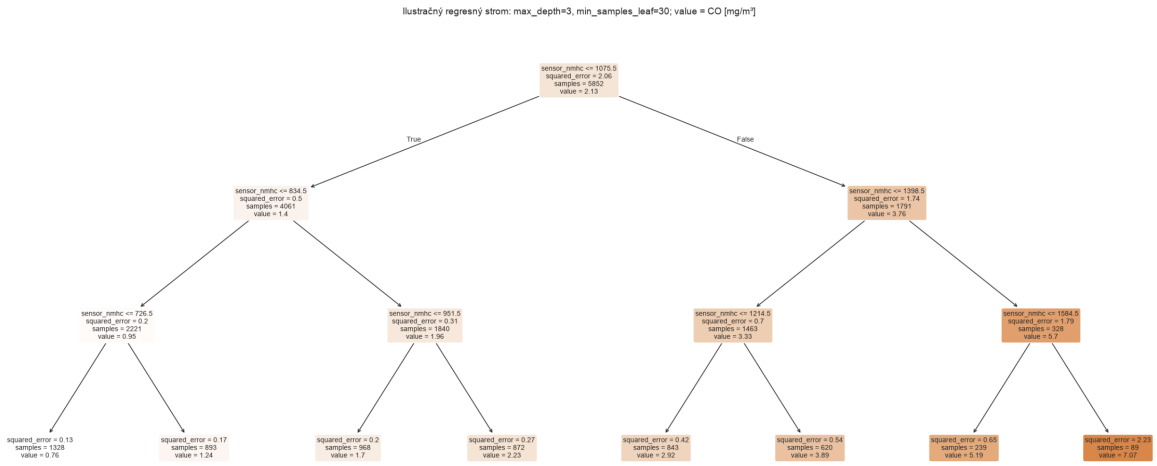
Poradie	Príznak	Feature importance
1	sensor_nmhc	0.93027
2	temperature	0.02870
3	sensor_co	0.01004
4	sensor_nox	0.00710
5	hour_sin	0.00547
6	hour_cos	0.00507
7	sensor_o3	0.00402
8	humidity	0.00213
9	month_sin	0.00191
10	weekday_sin	0.00145

DecisionTree má tréningové R^2 **0.9319** a testovacie R^2 **0.9031**. Testovacia RMSE je **0.4480** mg/m^3, MAE 0.3004 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0288. Rozdiel je menší než pri výrazne preučených ensemble modeloch.

Najvyššiu natívnu dôležitosť modelu **DecisionTree** má **sensor_nmhc**, MDI **0.93027**. Prvé tri vstupy spolu získali **96.90%** relatívnej dôležitosti.

4.1.1. Vizualizácia malého rozhodovacieho stromu

Pre čitateľnosť natrénujem samostatný ilustračný strom s hĺbkou 3 a minimálne 30 meraniami v liste. Použijem sedem pôvodných spojitých vstupov bez škálovania, aby prahy mali zrozumiteľné jednotky. Jeho parametre a výsledok sú odlíšené od ladeného stromu. V liste `value` znamená priemerné CO a `squared_error` priemernú štvorcovú odchýlku cieľa v danom uzle.



Koreň delí podľa sensor_nmhc ≤ 1075.50. Ľavá vetva zodpovedá splneniu podmienky, pravá jej nesplneniu. Ilustračný strom dosahuje testovacie R^2 **0.8394** a RMSE 0.5769 mg/m^3. Je plytký, preto ukazuje hlavné pravidlá, ale nezachytáva všetky jemné interakcie.

Tabuľka pri výsledkoch ladeného **DecisionTree** opisuje ladený model. Samostatná tabuľka pri obrázku patrí **malému ilustračnému stromu**, ktorý používa pôvodné spojité vstupy. Tieto modely majú odlišnú hĺbku aj výsledky, preto ich dôležitosti rozlišujem.

Poradie	Príznak	Feature importance
1	sensor_nmhc	1.0
2	sensor_co	0.0
3	sensor_nox	0.0
4	sensor_no2	0.0
5	sensor_o3	0.0
6	temperature	0.0
7	humidity	0.0

4.2. Ensemble

Súborové modely kombinujú viac stromov. Random Forest a ExtraTrees ich predikcie priemerujú. XGBoost a HistGradientBoosting vytvárajú postupnosť korekcií.

4.2.1. RandomForest

Množina	MSE	RMSE	MAE	R^2
Tréning	0.0190	0.1380	0.0855	0.9908
Test	0.1402	0.3744	0.2354	0.9323

Poradie	Príznak	Feature importance
1	sensor_nmhc	0.61618
2	sensor_co	0.13985
3	sensor_o3	0.13340
4	sensor_nox	0.03025
5	temperature	0.02226
6	sensor_no2	0.01479
7	hour_sin	0.01011
8	humidity	0.00875
9	hour_cos	0.00654
10	month_cos	0.00550

RandomForest má tréningové R^2 **0.9908** a testovacie R^2 **0.9323**. Testovacia RMSE je **0.3744** mg/m^3, MAE 0.2354 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0584. Rozdiel upozorňuje na preučenie oproti prispôsobeniu tréningu.

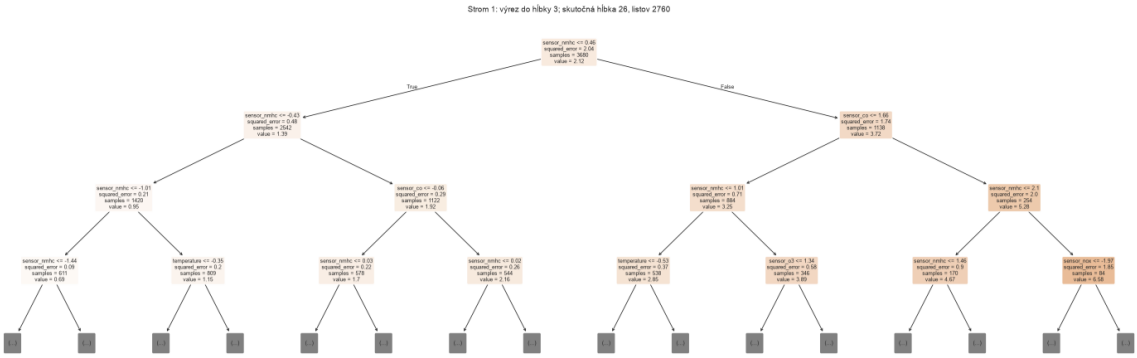
Les obsahuje **200 stromov**.

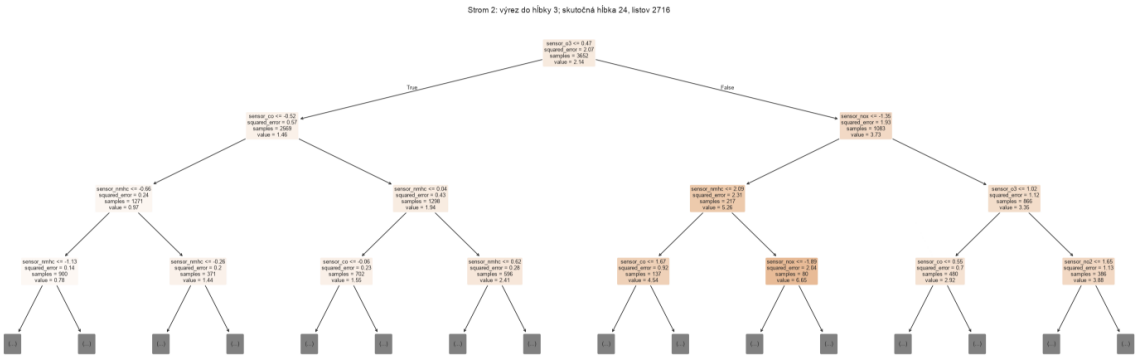


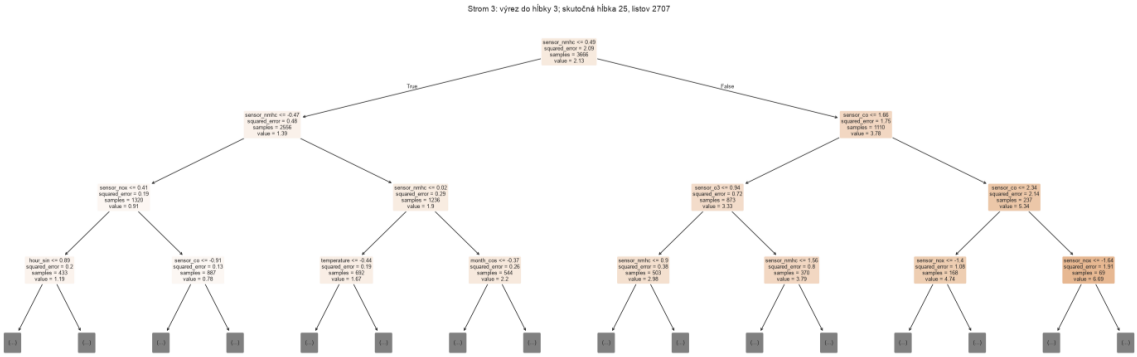
Po premiešaní **sensor_nmhc** klesne testovacie R^2 modelu **RandomForest** v priemere o **1.1055** $\pm$ **0.0166**. Táto hodnota je rozdiel R^2, nie percento. Chybové úsečky opisujú päť náhodných premiešaní pri nezmenenom modeli. Korelované vstupy môžu časť informácie navzájom nahrádzať. Testový rebríček nepoužívam na výber príznakov.

Viacero stromov z ladeného Random Forestu

Zobrazím tri skutočné stromy lesa. Každý obrázok ukazuje výrez do hĺbky 3, `(...)` označuje pokračovanie. Prahy sú v štandardizovaných jednotkách z. Číslo stromu je jeho poradie v lese, nie poradie kvality. Predikcia lesa je priemer predikcií všetkých 200 stromov.







Strom	Koreňový príznak	Prah koreňa [z]	Hĺbka	Počet listov
1	sensor_nmhc	0.457	26	2760
2	sensor_o3	0.465	24	2716
3	sensor_nmhc	0.487	25	2707

Päť najdôležitejších príznakov v každom zobrazenom strome (MDI)

Strom	Poradie	Príznak	Feature importance
1	1	sensor_nmhc	0.75629
1	2	sensor_co	0.13213
1	3	temperature	0.02299
1	4	sensor_nox	0.02046
1	5	sensor_o3	0.01529
2	1	sensor_o3	0.56805
2	2	sensor_nmhc	0.13582
2	3	sensor_co	0.11203
2	4	sensor_nox	0.09974
2	5	sensor_no2	0.02640
3	1	sensor_nmhc	0.72613
3	2	sensor_co	0.14648
3	3	sensor_o3	0.03034
3	4	sensor_nox	0.02801
3	5	temperature	0.01652

Les obsahuje **200 stromov**. Zobrazené stromy majú skutočné hĺbky **26, 24, 25** a korene podľa **sensor_nmhc, sensor_o3, sensor_nmhc**. Tabuľka porovnáva aj prahy a počty listov. Rozdiely vznikajú bootstrapovými vzorkami a náhodným výberom príznakov. Obrázky ukazujú iba začiatky stromov. Výslednú predikciu tvorí priemer celého lesa.

4.2.2. ExtraTrees

Množina	MSE	RMSE	MAE	R^2
Tréning	0.0000	0.0035	0.0002	1.0000
Test	0.1216	0.3486	0.2221	0.9413

Poradie	Príznak	Feature importance
1	sensor_nmhc	0.34091
2	sensor_o3	0.22274
3	sensor_co	0.20393
4	sensor_nox	0.09293
5	sensor_no2	0.03755
6	hour_sin	0.02440
7	temperature	0.01245
8	hour_cos	0.01125
9	month_cos	0.00882
10	humidity	0.00866

ExtraTrees má tréningové R^2 **1.0000** a testovacie R^2 **0.9413**. Testovacia RMSE je **0.3486** mg/m^3, MAE 0.2221 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0587. Takmer nulová tréningová chyba pri nenulovej testovacej ukazuje silné zapamätanie tréningových meraní.

Najvyššiu natívnu dôležitosť modelu **ExtraTrees** má **sensor_nmhc**, MDI **0.34091**. Prvé tri vstupy spolu získali **76.76%** relatívnej dôležitosti.

4.2.3. XGBoost

Množina	MSE	RMSE	MAE	R^2
Tréning	0.0429	0.2072	0.1453	0.9792
Test	0.1204	0.3470	0.2241	0.9419

Poradie	Príznak	Feature importance
1	sensor_nmhc	0.59537
2	sensor_o3	0.10499
3	sensor_co	0.09860
4	season_summer	0.03393
5	season_winter	0.02666
6	hour_sin	0.01987
7	temperature	0.01919
8	month_cos	0.01780
9	hour_cos	0.01371
10	month_sin	0.01147

XGBoost má tréningové R^2 **0.9792** a testovacie R^2 **0.9419**. Testovacia RMSE je **0.3470** mg/m^3, MAE 0.2241 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0373. Rozdiel je menší než pri výrazne preučených súborových modeloch.

Najvyššiu natívnu dôležitosť modelu **XGBoost** má **sensor_nmhc**, normalizovaný gain **0.59537**. Prvé tri vstupy spolu získali **79.90%** relatívnej dôležitosti.

4.2.4. HistGradientBoosting

Množina	MSE	RMSE	MAE	R^2
Tréning	0.0488	0.2208	0.1544	0.9763
Test	0.1210	0.3478	0.2283	0.9416

Poradie	Príznak	Feature importance	SD
1	sensor_nmhc	1.25915	0.01659
2	temperature	0.06651	0.00349
3	hour	0.03505	0.00216
4	sensor_co	0.03456	0.00167
5	month	0.02931	0.00251
6	sensor_o3	0.01168	0.00027
7	humidity	0.00880	0.00154
8	weekday	0.00850	0.00069
9	sensor_no2	0.00758	0.00119
10	sensor_nox	0.00620	0.00083

HistGradientBoosting má tréningové R^2 **0.9763** a testovacie R^2 **0.9416**. Testovacia RMSE je **0.3478** mg/m^3, MAE 0.2283 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0347. Rozdiel je menší než pri výrazne preučených súborových modeloch.

Po premiešaní **sensor_nmhc** klesne testovacie R^2 modelu **HistGradientBoosting** v priemere o **1.2591** $\pm$ **0.0166**. Táto hodnota je rozdiel R^2, nie percento. Chybové úsečky opisujú päť náhodných premiešaní pri nezmenenom modeli. Korelované vstupy môžu časť informácie navzájom nahrádzať. Testový rebríček nepoužívam na výber príznakov.

4.3. SVM (SVR)

Pri SVR volím regresnú verziu SVM s RBF jadrom, penalizáciou C, šírkou jadra gamma a toleranciou epsilon.

SVR vybral **C=100.0**, **gamma=scale**, **epsilon=0.1**.

Množina	MSE	RMSE	MAE	R^2
Tréning	0.0350	0.1870	0.1199	0.9830
Test	0.0947	0.3077	0.1994	0.9543

Poradie	Príznak	Feature importance	SD
1	sensor_nmhc	1.04514	0.01663
2	month	0.44694	0.01783
3	sensor_no2	0.42665	0.00854
4	temperature	0.33007	0.01338
5	season	0.32260	0.01466
6	sensor_o3	0.27786	0.00831
7	sensor_co	0.24115	0.00678
8	humidity	0.14862	0.00538
9	sensor_nox	0.12299	0.00333
10	hour	0.10691	0.00546

SVR má tréningové R^2 **0.9830** a testovacie R^2 **0.9543**. Testovacia RMSE je **0.3077** mg/m^3, MAE 0.1994 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0287. Rozdiel je menší než pri výrazne preučených súborových modeloch.

Po premiešaní **sensor_nmhc** klesne testovacie R^2 modelu **SVR** v priemere o **1.0451** ± **0.0166**. Táto hodnota je rozdiel R^2, nie percento. Chybové úsečky opisujú päť náhodných premiešaní pri nezmenenom modeli. Korelované vstupy môžu časť informácie navzájom nahrádzať. Testový rebríček nepoužívam na výber príznakov.

4.4. Porovnanie reziduálov

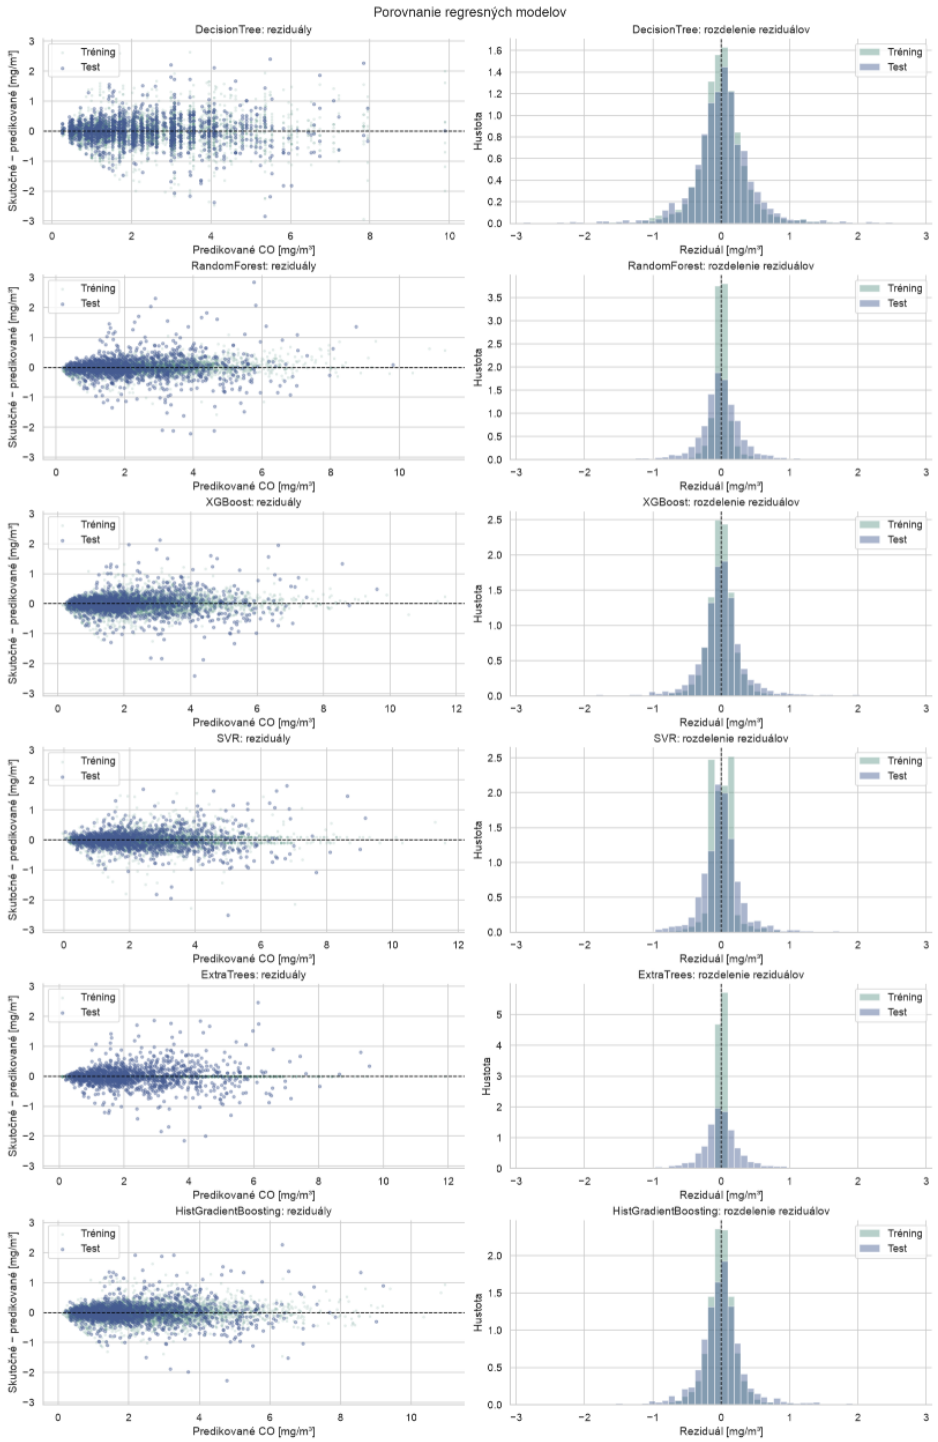
Všetky modely predikujú rovnakých 1 469 testovacích meraní.

	MSE		RMSE		R²
Množina	Test	Tréning	Test	Tréning	Test	Tréning
Model						
DecisionTree	0.2007	0.1404	0.4480	0.3747	0.9031	0.9319
ExtraTrees	0.1216	0.0000	0.3486	0.0035	0.9413	1.0000
HistGradientBoosting	0.1210	0.0488	0.3478	0.2208	0.9416	0.9763
RandomForest	0.1402	0.0190	0.3744	0.1380	0.9323	0.9908
SVR	0.0947	0.0350	0.3077	0.1870	0.9543	0.9830
XGBoost	0.1204	0.0429	0.3470	0.2072	0.9419	0.9792

CV víťaz **SVR** dosiahol na teste $R^2 = 0.9543$, RMSE = **0.3077 mg/m^3**.

4.4.1. Reziduál oproti predikcii a rozdelenie chýb

Na zvislej osi bodových grafov je **reziduál** (skutočná hodnota - predikovaná hodnota), nie očakávaná koncentrácia. Ideálne body tvoria pás okolo nuly bez krivky či lievika. Histogram porovnáva chyby v tréningu a teste. Všetky modely kreslím s rovnakou mierkou reziduálov, aby porovnanie neskreslili osi.

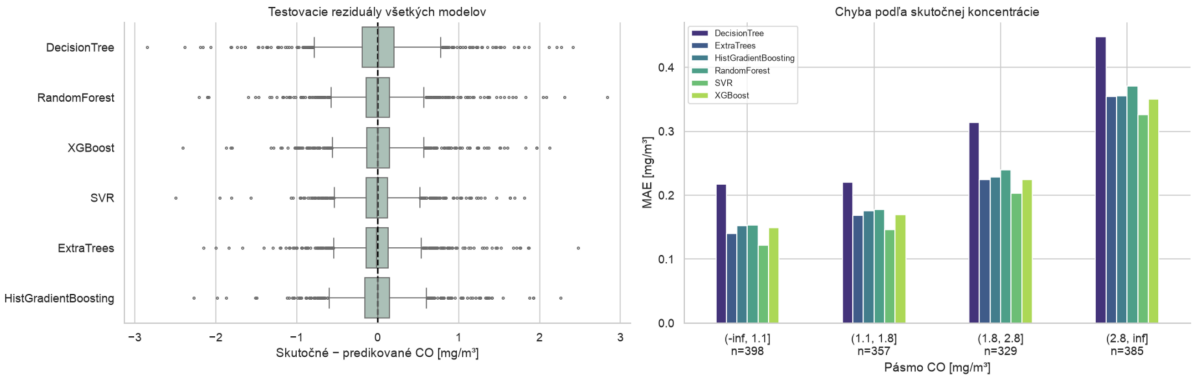


SVR: priemerný testovací reziduál 0.0019 mg/m^3 znamená podhodnotenie v priemere. 95 % absolútnych chýb neprekračuje **0.650** mg/m^3. Korelácia veľkosti chyby s predikciou je 0.427. Chyby majú tendenciu rásť s predikovanou koncentráciou.

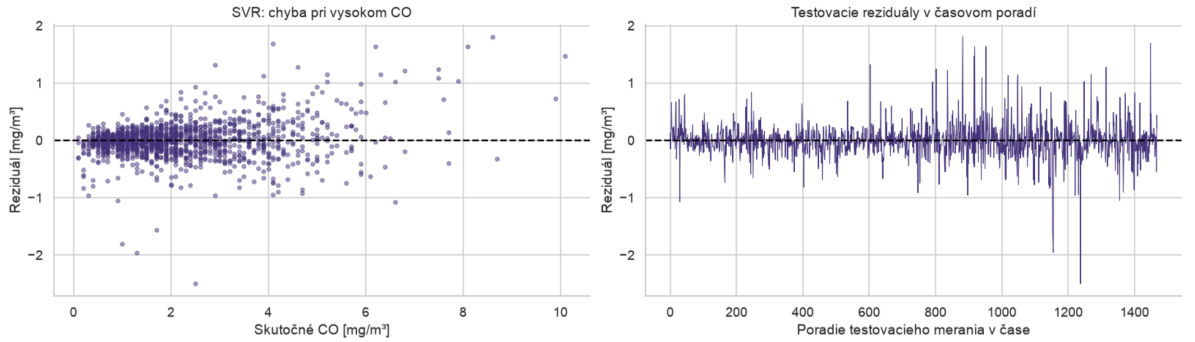
4.4.2. Rozptyl reziduálov a chyby podľa skutočného CO

Model	Priemer reziduála	Medián reziduála	95. percentil |e|	Korelácia |e| a predikcie
DecisionTree	0.0116	0.0125	0.8701	0.3486
RandomForest	0.0048	-0.0060	0.7453	0.3463
XGBoost	0.0059	0.0022	0.7190	0.3496
SVR	0.0019	-0.0040	0.6502	0.4270
ExtraTrees	0.0026	-0.0115	0.7079	0.3557
HistGradientBoosting	0.0033	0.0028	0.7279	0.3460

Boxplot porovná rozdelenia testovacích reziduálov. Pásma CO určím podľa tréningových kvartilov. Testové merania ich nemenia. Pri každom pásme uvediem počet testovacích bodov.



Pri modeli **SVR** je MAE v najnižšom pásme CO **0.1216 mg/m³**, v najvyššom **0.3256 mg/m³**. Najvyššie pásmo obsahuje **385** testovacích meraní a jeho priemerný reziduál je **0.0716 mg/m³**. Boxplot dopĺňa súhrnné metriky: posun mediánu ukazuje systematickú chybu, široký box a dlhé fúzy väčšie rozptýlenie reziduálov. Extrémne body ostávajú súčasťou hodnotenia.



Pri skutočnom CO aspoň **4.00** mg/m^3 (hranica z tréningu) je priemerný reziduál 0.137 mg/m^3 na 182 testovacích bodoch. Tým priamo kontrolujem podhodnocovanie vysokých koncentrácií. Časový graf ukazuje poradie vybraných testovacích hodín. Vzdialenosť bodov na osi nie je rovnaký časový odstup. Nulový priemer reziduálov sám nezaručuje, že sú chyby nezávislé alebo normálne rozdelené.

5. Redukcia dimenzie

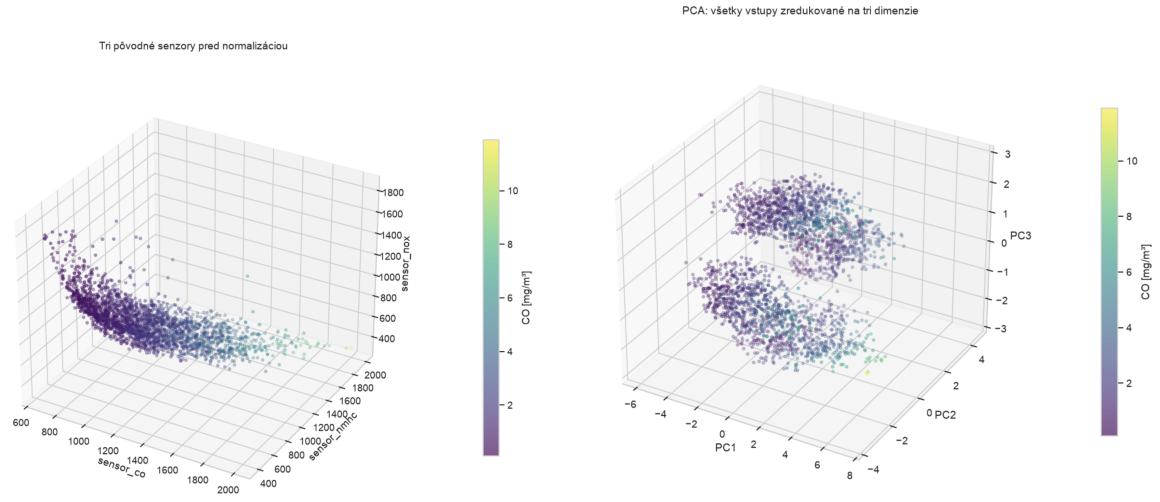
PCA vytvára nové osi ako lineárne kombinácie vstupov. PC1 zachytáva najväčší rozptyl, ďalšie kolmé osi zachytávajú zostávajúcu variabilitu. PCA nepozná cieľ CO, maximalizuje rozptyl vstupov, nie kvalitu regresie. Pred jej učením vstupy štandardizujem, pretože samotná PCA ich iba centruje.

5.1. Vykreslenie príznakov – vyčítanie závislostí

Vyberám `sensor_co`, `sensor_nmhc` a `sensor_nox`. Použijem rovnakú podvzorku najviac 2 500 tréningových inlierov a rovnakú farebnú škálu ako v nasledujúcej PCA projekcii.

5.2. Minimalizácia na 3 dimenzie

Kódovanie, štandardizáciu a PCA učím iba na tréningových inlieroch. Transformácia prevádza 17 vstupných stĺpcov na PC1, PC2 a PC3. Rovnaké parametre následne transformujú test. Cieľ sa do PCA nedostane.



Tri komponenty zachovávajú **60.2% vstupnej variability** (jednotlivo 26.0%, 20.4%, 13.8%). Korelácie PC1, PC2 a PC3 s CO sú 0.848, -0.310, 0.068. V pôvodnom grafe sú vyššie koncentrácie sústredené pri vyšších odozvách sensor_co a sensor_nmhc a pri nižších odozvách sensor_nox. Farebný prechod teda odhaľuje súvislosť viacerých senzorov s CO. V PCA sa hlavný farebný gradient orientuje najmä pozdĺž PC1, čo podporuje aj jeho korelácia s CO.

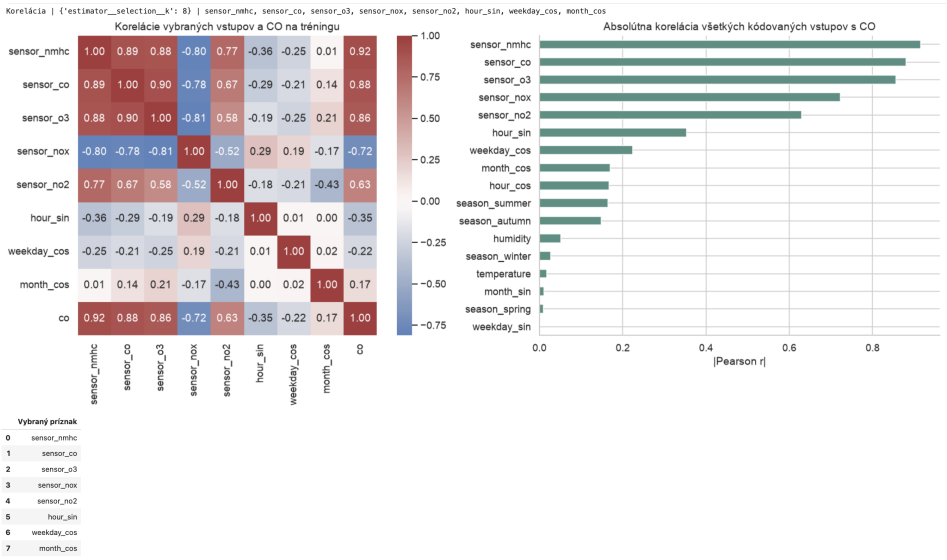
Tri PC zachovávajú približne **60,22 %** vstupného rozptylu, zvyšných **39,78 %** tento obrázok nezobrazuje. Viditeľné pásy nie sú triedy CO. Ani čitateľnejší obraz sám nepreukazuje lepšiu regresiu.

6. Trénovanie modelu na zmenšenej množine

Používam rovnaký typ a hyperparametre modelu vybraného v prvej časti podľa CV. Počet ponechaných príznakov alebo prah PCA vyberám vo vnútri tréningovej CV. Každý selector sa učí iba na tréningovej časti daného foldu. Test zostáva spoločný pre všetky stratégie.

6.1. Korelačná matica

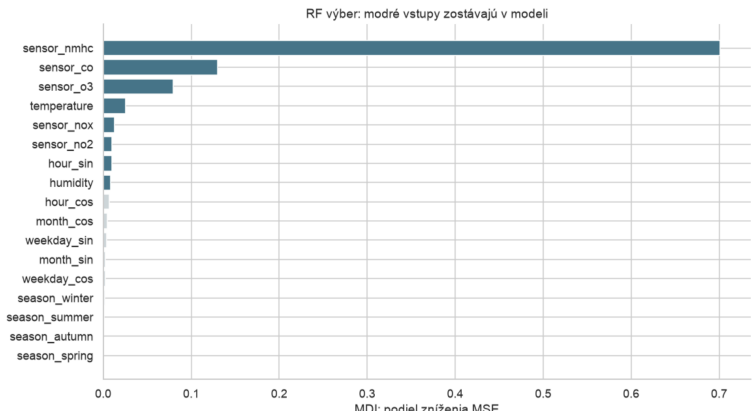
Zoradím vstupy podľa absolútnej Pearsonovej korelácie s CO a vynechám príznaky s absolútnou koreláciou aspoň 0,95 s už vybraným vstupom. CV vyberá najviac 4 alebo 8 príznakov. Heatmapa nižšie je opis finálneho tréningového výberu, nie podklad na výber podľa testu.



Korelácia: 8 vstupov, testovacie R^2 **0.9248**, RMSE **0.3946** mg/m^3, rozdiel RMSE oproti plnému modelu +0.0869 mg/m^3.

6.2. Dôležitosť príznakov z ensemble

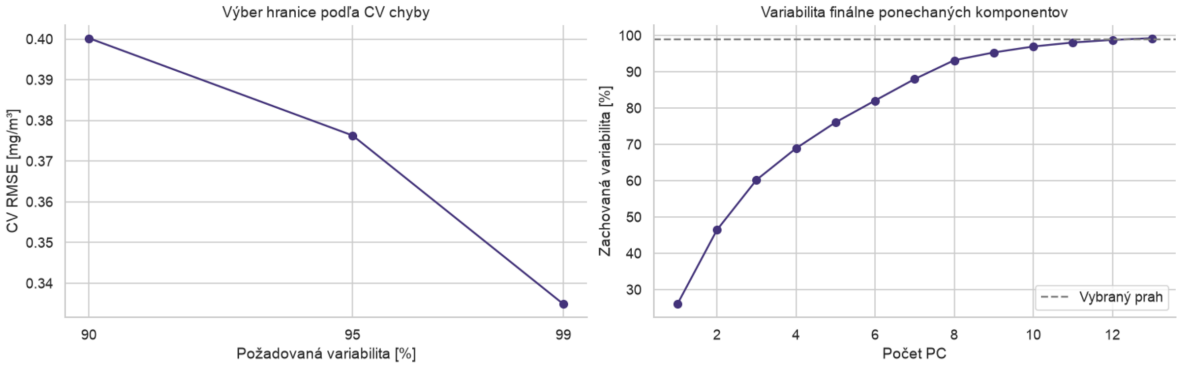
Pomocný Random Forest sa učí v každom CV folde od začiatku. CV vyberá 4 alebo 8 vstupov podľa jeho natívnych dôležitostí. Finálny graf ukazuje tréningový rebríček, farebne odlišuje ponechané a vynechané vstupy.



RF dôležitosť: 8 vstupov, testovacie R^2 **0.9314**, RMSE **0.3770** mg/m^3, rozdiel RMSE oproti plnému modelu +0.0693 mg/m^3.

6.3. Podľa variancie

PCA skúša hranice vysvetlenej variability 90 %, 95 % a 99 %. Počet komponentov vyplynie z dát. Ide o inú úlohu než pevné tri komponenty pre 3D zobrazenie. Zachovanie 99 % rozptylu vstupov neznamená zachovanie 99 % informácie o CO.



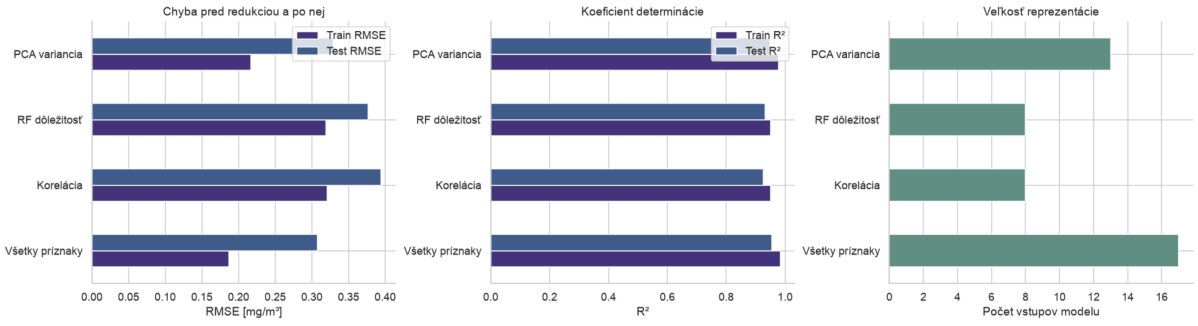
Prah 99%: 13 komponentov ponechá **99.25 %** a zahodí **0.75 %** vstupnej variability. Rekonštrukčná RMSE je 0.0866 v z jednotkách. Percento je skutočne dosiahnutý podiel: pre diskrétny počet komponentov môže presiahnuť zadaný prah.

PCA variancia: 13 vstupov, testovacie R^2 **0.9478**, RMSE **0.3289** mg/m^3, rozdiel RMSE oproti plnému modelu +0.0213 mg/m^3. Zmenšenie tu neprinieslo nižšiu chybu. Úspora rozmerov môže stáť predikčnú informáciu.

6.4. Porovnanie

Porovnám pôvodný model a všetky tri stratégie na totožných testovacích meraniach. Okrem výsledných chýb sledujem aj počet vstupov a reziduály.

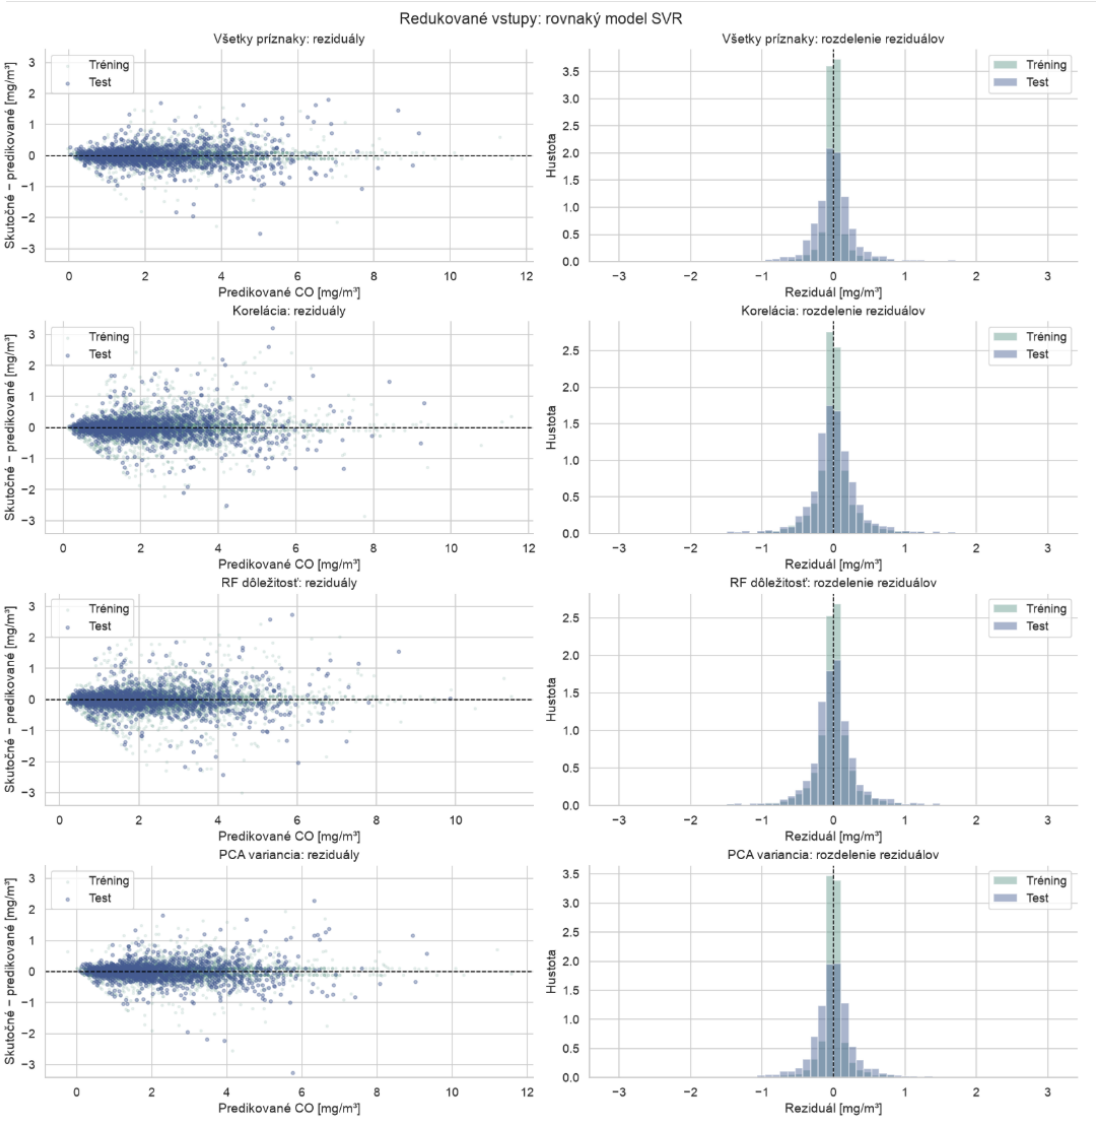
Stratégia	Počet vstupov	CV MSE	Test MSE	Test RMSE	Test MAE	Test R²	Train MSE	Train RMSE	Train MAE	Train R²
Všetky príznaky	17	0.1046	0.0947	0.3077	0.1994	0.9543	0.0350	0.1870	0.1199	0.9830
Korelácia	8	0.1533	0.1557	0.3946	0.2478	0.9248	0.1032	0.3212	0.1928	0.9499
RF dôležitosť	8	0.1506	0.1421	0.3770	0.2324	0.9314	0.1018	0.3191	0.1889	0.9506
PCA variancia	13	0.1121	0.1082	0.3289	0.2093	0.9478	0.0470	0.2168	0.1342	0.9772



V tomto experimente PCA s hranicou 99 % ponechalo 13 komponentov a skutočne zachovalo približne 99,25 % vstupnej variability. Aj tak testovacia RMSE SVR vzrástla približne z 0,3077 na 0,3289 mg/m^3. Strata len 0,75 % vstupného rozptylu teda **neznamená** rovnakú relatívnu zmenu regresnej chyby. PCA nepozná CO a nemôže zaručiť, že zahodí iba nepotrebnú informáciu. Naproti tomu tri komponenty pre obrázok zachovávajú len približne 60,2 %, preto ich nepovažujem za rovnocennú náhradu zvolenej 13D regresnej reprezentácie.

6.4.1. Reziduály po redukcii

Rovnaké testovacie riadky a spoločné osi umožňujú porovnať, či redukcia zväčšuje rozptyl alebo podhodnotenie pri vysokom CO. Korelačný výber zachytáva lineárny vzťah s cieľom, ensemble aj nelinearity, PCA predovšetkým veľké smery variability. Preto ich poradie podľa zachovanej variability nemusí súhlasiť s poradím predikčnej chyby.



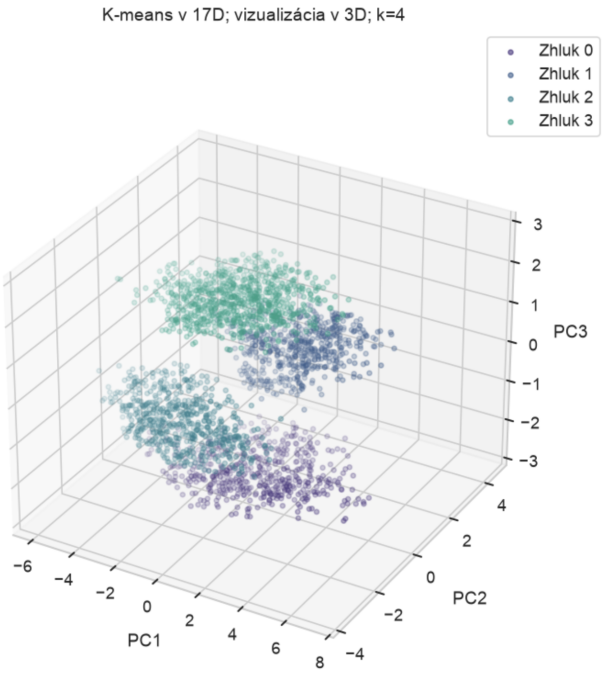
Model	Priemer reziduála	Medián reziduála	95. percentil |e|	Korelácia |e| a predikcie
Všetky príznaky	0.0019	-0.0040	0.6502	0.4270
Korelácia	0.0149	-0.0027	0.7978	0.3659
RF dôležitosť	0.0030	-0.0006	0.7707	0.3580
PCA variancia	0.0001	-0.0023	0.6800	0.3972

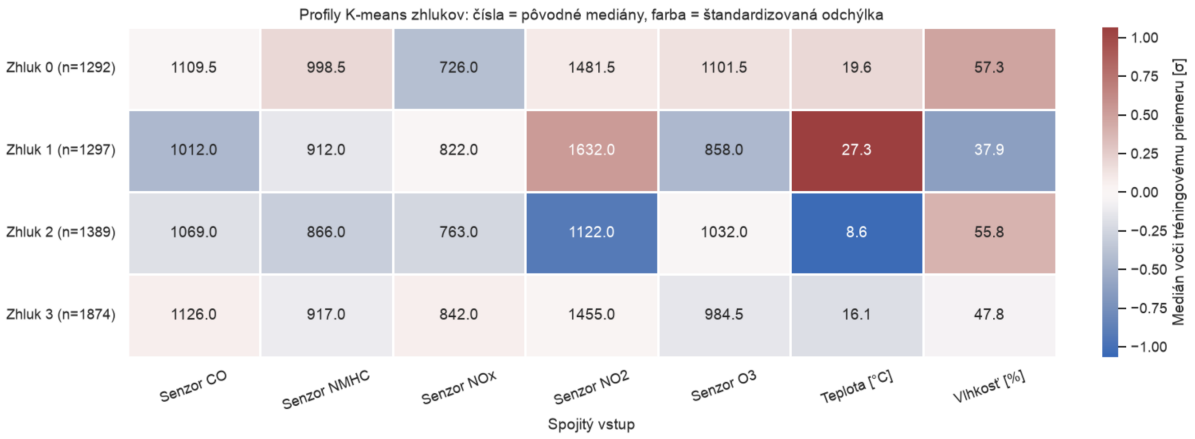
7. Zhlukovanie – bonus

7.1. Vizualizácia

K-means naučím na **všetkých 17 štandardizovaných vstupoch**, bez CO a iba z tréningových inlierov. Porovnám 3, 4 a 5 zhlukov pomocou silhouette skóre na rovnakej tréningovej podvzorke. Vyberiem najvyššie skóre, nie najlepšiu regresiu na teste. Každý bod na 3D grafe má farbu zhluku. Osi sú iba tri PCA súradnice, takže zhlukovanie využíva viac príznakov než vizualizácia. Prekryv v projekcii nemusí znamenať prekryv v plnom priestore.

Vybral som **4 zhluky** so silhouette **0.252**. Hodnota blízko nule by znamenala slabé oddelenie, blízko jednej kompaktné oddelené skupiny. Profily ukazujú mediány pôvodných senzorov a počasia. Čísla zhlukov sú ľubovoľné označenia, nie triedy zdravotnej bezpečnosti a ani intervaly CO. Cieľ sa pri ich vytváraní nepoužil.





Zhluky predstavujú režimy merania, nie automaticky úrovne zdravotného rizika.

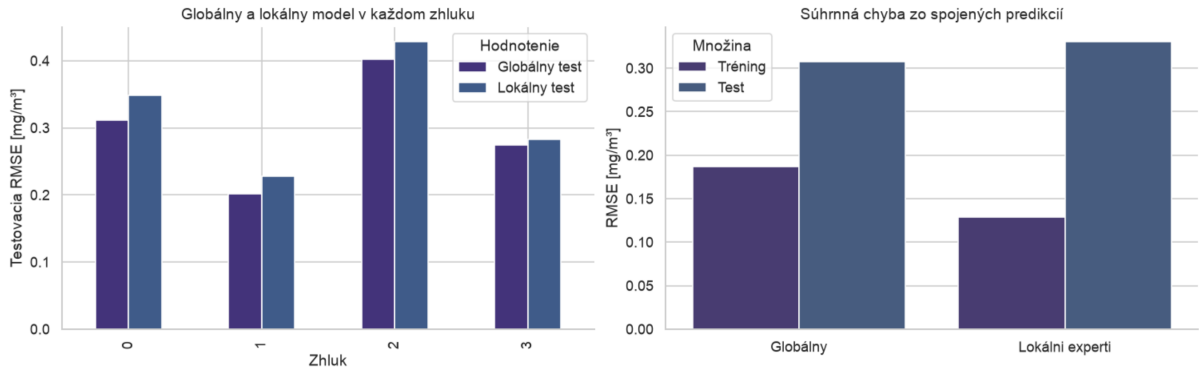
7.2. Trénovanie

7.2.1. Globálny model oproti lokálnym expertom

Pre každý zhluk natrénujem model **rovnakého typu a s rovnakými hyperparametrami** ako CV víťaz prvej časti. Predspracovanie a pravidlo outlierov sa znovu učia len z tréningových bodov daného zhluku. Testovací bod priradí do zhluku tréningový škálovač a K-means. Potom dostane predikciu príslušného lokálneho modelu. Na porovnanie vypočítam aj chybu pôvodného globálneho modelu na presne tých istých bodoch každého zhluku. R^2 v podskupine môže klesnúť aj pre menší rozsah CO. Rozhodujúce je tiež spoločné MSE všetkých bodov.

	Zhluk	Hodnotenie	n	MSE	RMSE	MAE	R²
0	0	Lokálny tréning	1298	0.0165	0.1284	0.0971	0.9945
1	0	Lokálny test	328	0.1217	0.3488	0.2185	0.9564
2	0	Globálny test	328	0.0973	0.3119	0.2005	0.9652
3	1	Lokálny tréning	1298	0.0119	0.1089	0.0825	0.9889
4	1	Lokálny test	295	0.0518	0.2275	0.1527	0.9570
5	1	Globálny test	295	0.0408	0.2019	0.1405	0.9661
6	2	Lokálny tréning	1401	0.0238	0.1541	0.1087	0.9886
7	2	Lokálny test	364	0.1840	0.4289	0.2911	0.9195
8	2	Globálny test	364	0.1618	0.4022	0.2648	0.9292
9	3	Lokálny tréning	1878	0.0148	0.1216	0.0943	0.9919
10	3	Lokálny test	482	0.0802	0.2832	0.1906	0.9535
11	3	Globálny test	482	0.0752	0.2742	0.1852	0.9565

	Model	Množina	MSE	RMSE	MAE	R²
0	Globálny	Tréning	0.0350	0.1870	0.1199	0.9830
1	Lokálni experti	Tréning	0.0167	0.1291	0.0957	0.9919
2	Globálny	Test	0.0947	0.3077	0.1994	0.9543
3	Lokálni experti	Test	0.1095	0.3309	0.2141	0.9472



Všetci lokálni experti spolu dosahujú $R^2 = 0.9472$, RMSE = $\mathbf{0.3309\ mg/m^3}$, oproti globálnym 0.3077 mg/m^3. Zmena RMSE je $+0.0232$ mg/m^3. Spoločné metriky sú počítané zo všetkých spojených predikcií, nie priemerovaním R^2 zhlukov. Lokálne modely majú menej dát a nevidia susedné režimy. Segmentácia preto nemusí pomôcť ani pri viditeľných zhlukoch. Priemerný reziduál lokálnych predikcií je 0.0055 mg/m^3.

Lokálne modely majú nižšiu tréningovú chybu, ale v každom zo štyroch zhlukov vyššiu testovaciu RMSE než globálny model. Rozdelenie vstupov na zhluky preto v tomto experimente nezlepšilo predikciu CO. Súhrnná RMSE je vypočítaná zo všetkých spojených predikcií, nie priemerom zhlukových RMSE.

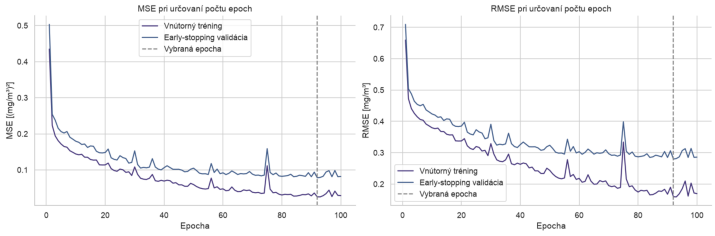
8. Neurónová sieť – bonus

Sieť má jeden **lineárny výstup koncentrácie**, bez sigmoidy a bez tried. Minimalizuje MSE v pôvodných jednotkách CO pomocou AdamW.

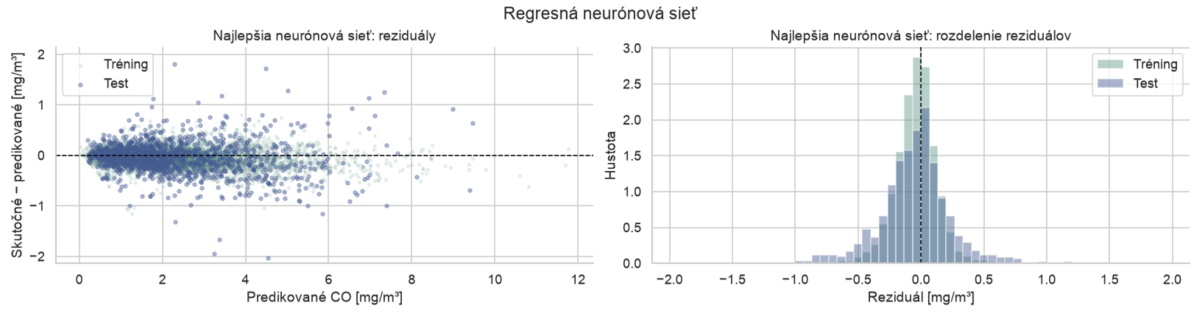
`GridSearchCV` porovná štyri architektúry **64 → 32**, **256 → 128**, **1028 → 256 → 128** a **512 → 512 → 256 → 128**, tri aktivácie **ReLU, GELU, Tanh** a learning rate **0,001 / 0,003**. Ide o **24 konfigurácií**. Z dôvodu výpočtovej náročnosti neurónová časť používa 2-fold CV a CPU s jedným vláknom. Klasické modely používali 3-fold CV, preto ich CV skóre nie sú úplne rovnocenné. Test je spoločný.

Víťazná sieť má skryté vrstvy **1028 → 256 → 128**, aktiváciu **RELU** a learning rate **0.001**. CV RMSE je **0.3430** mg/m^3, finálne testovacie R^2 **0.9544** a RMSE **0.3072** mg/m^3. Tréningové R^2 je 0.9862. Výsledok vychádza z CV výberu, nie z výberu najlepšej siete podľa testu. Väčšia architektúra automaticky neznamená lepšiu generalizáciu, najmä na niekoľkých tisícoch meraní.

Množina	MSE	RMSE	MAE	R²
Tréning	0.0284	0.1684	0.1248	0.9862
Test	0.0944	0.3072	0.2113	0.9544



Early stopping vybral **92. epochu** z 100 vykonaných. V nej bola vnútorná tréningová MSE 0.0255 a validačná MSE 0.0783. Finálna sieť sa potom učila od začiatku na všetkých tréningových inlieroch. Jej testovacie metriky preto nemusia zodpovedať minimu tejto vnútornej krivky.



Model	Priemer reziduála	Medián reziduála	95. percentil |e|	Korelácia |e| a predikcie
Najlepšia neurónová sieť	-0.0473	-0.0311	0.6438	0.4249

Najlepšia neurónová sieť: priemerný testovací reziduál -0.0473 mg/m^3 znamená nadhodnotenie v priemere. 95 % absolútnych chýb neprekračuje **0.644** mg/m^3. Korelácia veľkosti chyby s predikciou je 0.425. Chyby majú tendenciu rásť s predikovanou koncentráciou.

Neurónová sieť a SVR majú na tomto teste veľmi blízku RMSE. Rozdiel jedného rozdelenia nemožno považovať za stabilné poradie bez ďalších nezávislých experimentov. Hlavný klasický model zostáva vybraný podľa tréningovej CV, nie podľa testu.