SUNS: zadanie 2

Samuel Bagin

1. Úprava dát

Predikcia priemernej hodinovej koncentrácie CO pomocou regresných modelov. Výstup `co` je v mg/m^3. Do vstupov modelov nevstupuje.

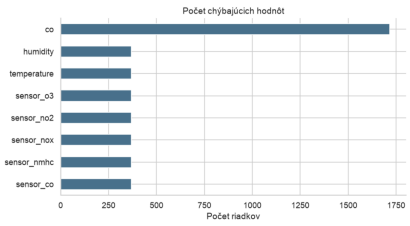
Načítal som **9,507 riadkov a 14 stĺpcov**. Merania pokrývajú obdobie **2004-03-10 až 2005-04-04**.

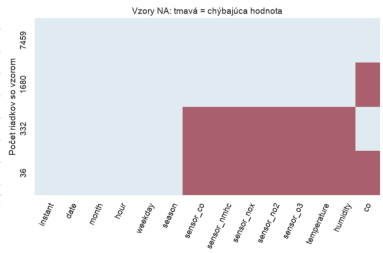
1.1. Kvalita dát

Odstraňujem riadky s NA, a nerobím imputáciu. Duplicity skontrolujem ešte pred rozdelením, aby rovnaké meranie neskončilo v tréningu aj teste. Pri dátume overím parsovanie a súlad s mesiacom a dňom v týždni.

Dataset obsahuje **150 duplicít**. Cieľový stlpec chýba v **1716 riadkoch**.

	Krok	Zostáva	Odstránené v kroku
0	Pôvodné údaje	9507	0
1	Po odstránení duplicít	9357	150
2	Po odstránení NA	7344	2013
3	Po kontrole platnosti	7344	0





Po čistení zostalo **7,344 úplných a platných meraní** (77.2% pôvodných riadkov). Teploty nad približných 40 °C automaticky nemažem: stále môžu byť reálnym meraním. Štatistické outliery odstránim až z tréningových dát pomocou hraníc naučených výhradne na danom tréningu.

	Typ	NA	Unikátne
instant	int64	0	9357
date	str	0	391
month	int64	0	12
hour	int64	0	24
weekday	int64	0	7
season	str	0	4
sensor_co	float64	368	1041
sensor_nmhc	float64	368	1245
sensor_nox	float64	368	1221
sensor_no2	float64	368	1603
sensor_o3	float64	368	1743
temperature	float64	368	436
humidity	float64	368	753
co	float64	1716	96



Tabuľka kvality uvádza stav po odstránení duplicít, pred odstránením NA.

1.1.1. Ukážka dát a opisná štatistika

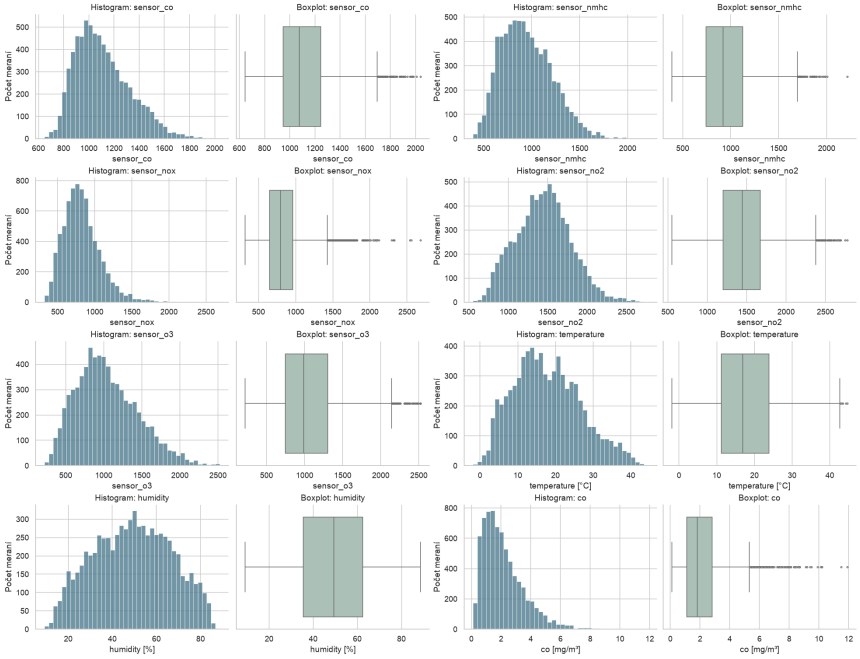
Ukážka riadkov a opisná štatistika zachytávajú pôvodné načítané údaje pred čistením.

	instant	date	month	hour	weekday	season	sensor_co	sensor_nmhc	sensor_nox	sensor_no2	sensor_o3	temperature	humidity	co
0	1	2004-03-10	3	18	3	spring	1360.0	1046.0	1056.0	1692.0	1268.0	13.6	48.9	2.6
1	2	2004-03-10	3	19	3	spring	1292.0	955.0	1174.0	1559.0	972.0	13.3	47.7	2.0
2	3	2004-03-10	3	20	3	spring	1402.0	939.0	1140.0	1555.0	1074.0	11.9	54.0	2.2
3	4	2004-03-10	3	21	3	spring	1376.0	948.0	1092.0	1584.0	1203.0	11.0	60.0	2.2
4	5	2004-03-10	3	22	3	spring	1272.0	836.0	1205.0	1490.0	1110.0	11.2	59.6	1.6

	count	mean	std	min	25%	50%	75%	max
instant	9507.0	4681.998	2700.183	1.0	2345.5	4683.0	7016.5	9357.0
month	9507.0	6.317	3.439	1.0	3.0	6.0	9.0	12.0
hour	9507.0	11.505	6.926	0.0	5.5	12.0	18.0	23.0
weekday	9507.0	3.004	2.003	0.0	1.0	3.0	5.0	6.0
sensor_co	9139.0	1099.538	217.088	647.0	936.0	1063.0	1231.0	2040.0
sensor_nmhc	9139.0	938.890	266.843	383.0	734.0	909.0	1117.0	2214.0
sensor_nox	9139.0	835.881	257.021	322.0	658.0	806.0	969.5	2683.0
sensor_no2	9139.0	1455.835	346.719	551.0	1224.5	1463.0	1674.0	2775.0
sensor_o3	9139.0	1022.488	398.597	221.0	731.0	962.0	1274.0	2523.0
temperature	9139.0	18.325	8.842	-1.9	11.8	17.8	24.4	44.6
humidity	9139.0	49.210	17.314	9.2	35.8	49.5	62.5	88.7
co	7791.0	2.151	1.452	0.1	1.1	1.8	2.9	11.9

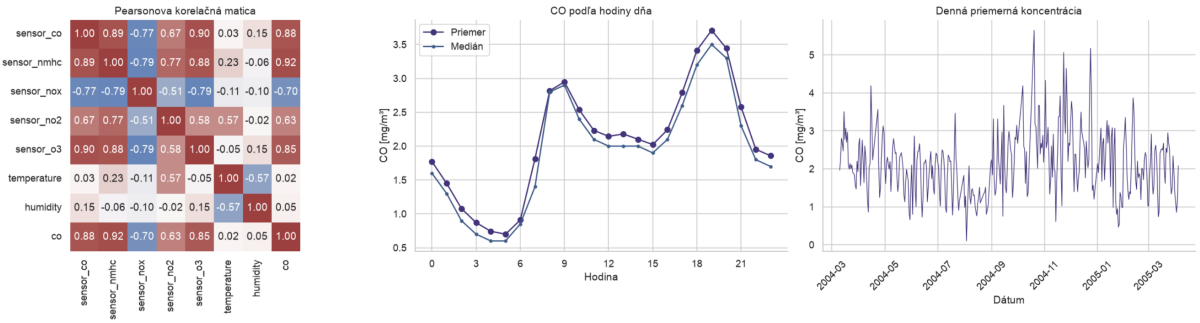
2. EDA – bonus

2.1. Rozdelenia senzorov a koncentrácie



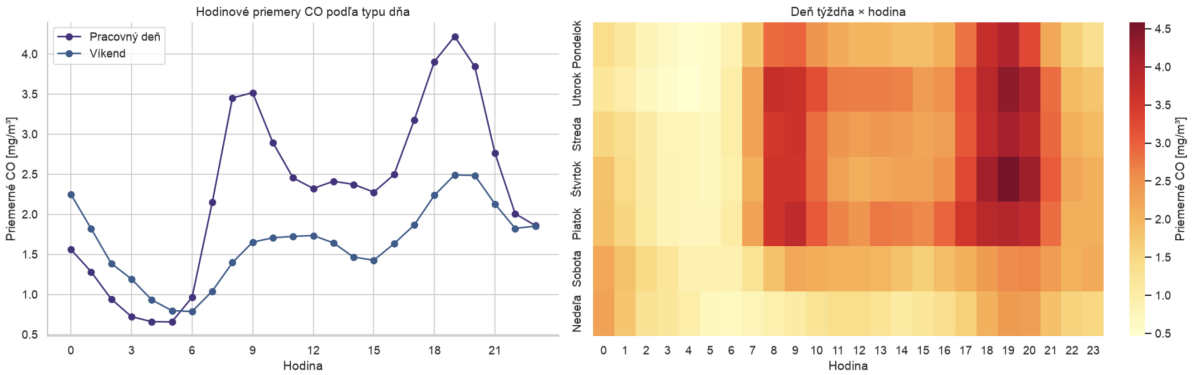
CO má medián **1.80** mg/m^3, priemer 2.13 mg/m^3 a výberovú šikmosť **1.36**. Dlhší pravý chvost znamená menej časté vysoké koncentrácie. MSE tieto veľké chyby silno penalizuje. Senzor NOx dosahuje maximum 2683. Odľahlosť v grafe sama nepreukazuje poruchu.

2.2. Súvislosti a časový priebeh



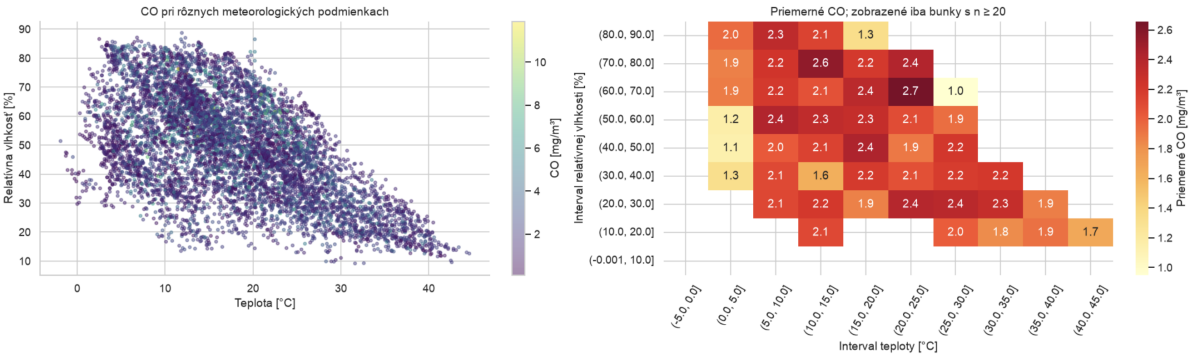
Najsilnejšiu absolútnu Pearsonovu koreláciu s CO má **sensor_nmhc**, $r = 0.92$, a **sensor_o3** voči **sensor_co** $r = 0.90$. Najvyšší hodinový priemer je o **19:00** (3.71 mg/m^3), najnižší o 5:00 (0.70 mg/m^3). Rozdiely sú zlučiteľné s denným cyklom emisií, ale bez údajov o doprave a počasí z grafu nemožno potvrdiť jeho príčinu. Denný priebeh ukazuje aj časovú závislosť, ktorú obyčajné náhodné rozdelenie úplne neodstraňuje.

2.3. Hodinový priebeh CO v pracovných dňoch a cez víkend



Pracovné dni majú priemerné CO **2.333 mg/m^3**, víkend **1.658 mg/m^3**. Najvyšší hodinový priemer nastáva v pracovných dňoch o **19:00**, cez víkend o **19:00**. Priemery sú ovplyvnené aj zastúpením ročných období a počasia. Samy nepotvrdzujú príčinný vplyv dopravy.

2.4. Teplota, vlhkosť a koncentrácia CO



Spearmanova korelácia CO s teplotou je **0.069**, s vlhkosťou **-0.006**. Zo zobrazených buniek s aspoň 20 meraniami má najvyššie priemerné CO kombinácia teploty **(20.0, 25.0] °C** a vlhkosti **(60.0, 70.0] %** (**2.658 mg/m^3**), najnižší priemer je **0.950 mg/m^3**. Agregovaný graf ukazuje

spoločný vzťah dvoch premenných, ale nenahrádza kontrolu sezónnosti ani dôkaz príčiny. Biele bunky nemajú dosť meraní na zobrazenie.

	temperature	humidity	co
temperature	1.000	-0.532	0.069
humidity	-0.532	1.000	-0.006
co	0.069	-0.006	1.000

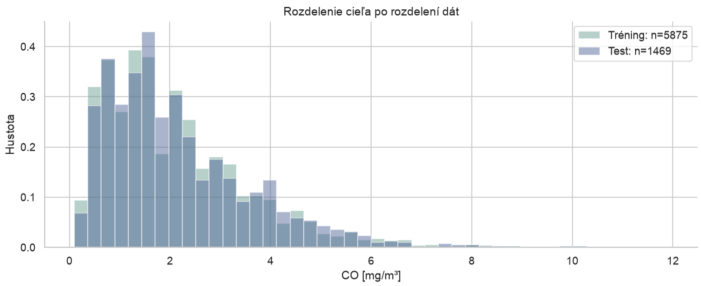
teplota_interval vlhkost_interval	(-5.0, 0.0]	(0.0, 5.0]	(5.0, 10.0]	(10.0, 15.0]	(15.0, 20.0]	(20.0, 25.0]	(25.0, 30.0]	(30.0, 35.0]	(35.0, 40.0]	(40.0, 45.0]
(-0.001, 10.0]	0	0	0	0	0	0	3	2	0	1
(10.0, 20.0]	0	0	4	40	15	14	42	76	114	45
(20.0, 30.0]	1	4	23	83	77	117	199	208	138	1
(30.0, 40.0]	3	53	133	178	190	269	246	110	14	0
(40.0, 50.0]	8	104	198	175	301	369	216	16	0	0
(50.0, 60.0]	1	116	186	351	385	276	98	0	0	0
(60.0, 70.0]	0	92	196	435	232	198	28	0	0	0
(70.0, 80.0]	0	53	215	242	189	27	0	0	0	0
(80.0, 90.0]	0	55	81	75	21	2	0	0	0	0

3. Rozdelenie dát

Použijem jedno rozdelenie **80 % tréning / 20 % test**. Tréning zahŕňa aj vnútorné CV foldy, preto samostatnú vonkajšiu validačnú množinu nepotrebujem. Seed 2026 je stanovený pred týmto experimentom. `instant` a `date` sa do modelov nedostanú. Rovnaké testovacie riadky zachovám aj pri redukcii príznakov a zhlukovaní.

Tréning obsahuje **5875** a test **1469** meraní. Rozdelenie je náhodné bez stratifikácie regresného cieľa.

	Počet	Priemer CO	SD CO
Tréning	5875	2.1212	1.4356
Test	1469	2.1636	1.4398



3.1. Kódovanie a normalizácia

3.1.1. Cyklické kalendárne premenné

Mesiac, hodinu a deň v týždni prevediem na sínus a kosínus. Susedné hodnoty 23 a 0 hodín tak zostanú blízko aj v kódovaní. Sezóna má iba štyri kategórie, preto použijem one-hot kódovanie. Dátum nepridáva stovky stĺpcov. Po kódovaní štandardizujem **všetky vstupy**, vrátane one-hot stĺpcov, aby PCA a vzdialenostné modely neovládla pôvodná mierka senzorov. Cieľ `co` nemením.

$$\sin_t = \sin\left(\frac{2\pi t}{T}\right), \quad \cos_t = \cos\left(\frac{2\pi t}{T}\right)$$

$$z = \frac{x - \mu_{\text{tréning}}}{\sigma_{\text{tréning}}}$$

Kódovaním vzniká **17 vstupov**, 10 nových stĺpcov, ktoré nahradili 4 pôvodné.

- month (cyclic): `month_sin`, `month_cos`
- hour (cyclic): `hour_sin`, `hour_cos`
- weekday (cyclic): `weekday_sin`, `weekday_cos`
- season (one-hot): `season_autumn`, `season_spring`, `season_summer`, `season_winter`

3.1.2. Odstránenie odľahlých tréningových záznamov

Pre sedem spojitých vstupov použijem hranice $[Q_1 - 3 \times \mathrm{IQR}, Q_3 + 3 \times \mathrm{IQR}]$, kde $\mathrm{IQR} = Q_3 - Q_1$. Záznam odstránim, ak mimo nich leží aspoň jeden vstup. Kvartily sa učia pri každom `fit` iba z príslušného tréningového foldu. CO ani diskrétne časové stĺpce nefiltrované podľa IQR. Pri `predict` sa neodstraňuje žiadny riadok.

	Dolná hranica	Horná hranica
sensor_co	43.0	2143.0
sensor_nmhc	-400.0	2267.0
sensor_nox	-288.0	1903.0
sensor_no2	-204.5	3082.0
sensor_o3	-944.0	2983.0
temperature	-26.2	61.3
humidity	-44.3	141.9

Na trénovacích dátach toto pravidlo odstraňuje **23 riadkov**, model sa učí na **5852 meraniach**. Test zostáva so všetkými 1469 riadkami.
Hranice v tabuľke boli naučené na finálnej tréningovej množine. Vo vnútornej CV sa počítajú osobitne pre každý tréningový fold.

4. Trénovanie ML modelov

Reziduál definujem ako skutočná mínus predpovedaná. Kladný reziduál znamená podhodnotenie, záporný nadhodnotenie.

Model vyberiem podľa najnižšej priemernej **CV MSE**. CV smerodajná odchýlka je variabilita medzi foldmi, nie interval spoľahlivosti.

Pri strome ladím hĺbku a minimálny počet vzoriek v liste. Random Forest priemeruje bootstrapové stromy, ExtraTrees (Extremely Randomized Trees) navyše náhodne volí prahy. XGBoost a histogramový boosting pridávajú stromy postupne na opravu predchádzajúcich chýb. Pri SVR volím regresnú verziu SVM s RBF jadrom, penalizáciou C, šírkou jadra gamma a toleranciou epsilon.

Pri 3-fold CV sa každá konfigurácia trénuje trikrát na dvoch foldoch a hodnotí na zostávajúcom.

Model	CV MSE	CV RMSE	CV tréning R^2	CV tréning SD R^2	CV R^2	CV SD R^2	CV SD MSE	Čas [s]
SVR	0.1046	0.3234	0.9843	0.0006	0.9492	0.0028	0.0063	119.2210
HistGradientBoosting	0.1256	0.3544	0.9805	0.0010	0.9388	0.0046	0.0070	21.5343
XGBoost	0.1284	0.3583	0.9846	0.0009	0.9376	0.0040	0.0076	6.4054
ExtraTrees	0.1297	0.3602	1.0000	0.0000	0.9370	0.0034	0.0095	17.0656
RandomForest	0.1499	0.3872	0.9898	0.0004	0.9272	0.0022	0.0088	47.0679
DecisionTree	0.2346	0.4843	0.9364	0.0016	0.8860	0.0012	0.0099	1.1703

DecisionTree, RandomForest, ExtraTrees a XGBoost používajú natívnu dôležitosť kódovaných vstupov. HistGradientBoosting a SVR používajú permutáciu pôvodných stĺpcov.

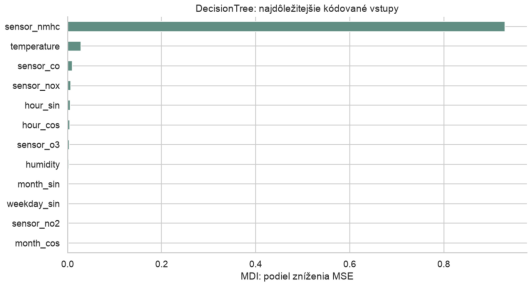
4.1. DecisionTree

Najlepší strom podľa CV má hĺbku **8** a aspoň **8** vzoriek v liste.

```
Najlepšie parametre: {'max_depth': 8, 'min_samples_leaf': 8}
Najhoršie CV parametre: {'estimator__model__max_depth': None, 'estimator__model__min_samples_leaf': 2}
Najhoršia CV MSE: 0.292
```

	params	mean_train_mse	mean_test_mse	std_test_mse	mean_train_r2	std_train_r2	mean_test_r2	std_test_r2	rank_test_mse
0	{'estimator__model__max_depth': 8, 'estimator__model__min_samples_leaf': 8}	0.1310	0.2346	0.0099	0.9364	0.0016	0.8860	0.0012	1
1	{'estimator__model__max_depth': 8, 'estimator__model__min_samples_leaf': 20}	0.1592	0.2352	0.0133	0.9227	0.0016	0.8857	0.0051	2
2	{'estimator__model__max_depth': 12, 'estimator__model__min_samples_leaf': 20}	0.1538	0.2353	0.0139	0.9253	0.0016	0.8857	0.0050	3

Množina	MSE	RMSE	MAE	R^2
Tréning	0.1404	0.3747	0.2509	0.9319
Test	0.2007	0.4480	0.3004	0.9031



Dôležitosť príznakov

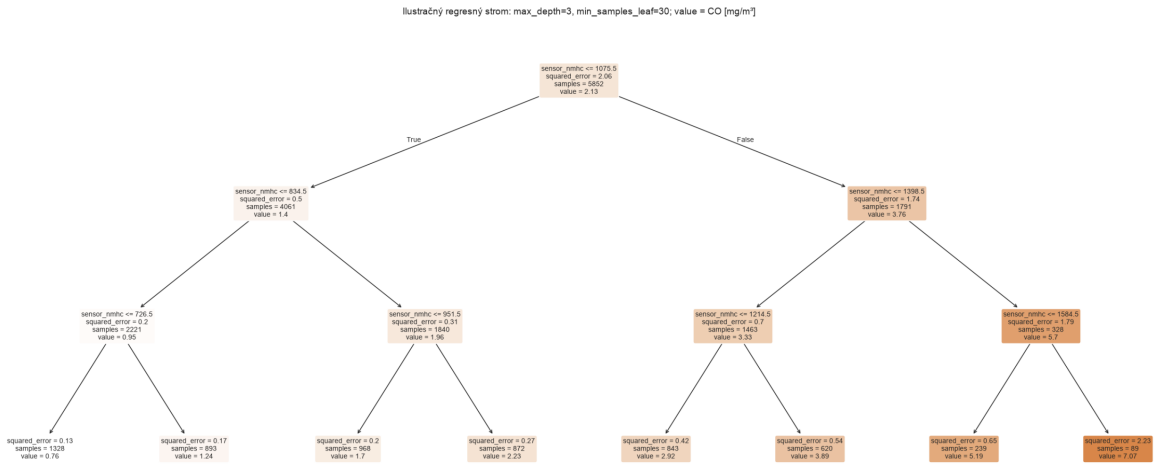
Poradie	Príznak	Feature importance
1	sensor_nmhc	0.93027
2	temperature	0.02870
3	sensor_co	0.01004
4	sensor_nox	0.00710
5	hour_sin	0.00547
6	hour_cos	0.00507
7	sensor_o3	0.00402
8	humidity	0.00213
9	month_sin	0.00191
10	weekday_sin	0.00145

DecisionTree má tréningové R^2 **0.9319** a testovacie R^2 **0.9031**. Testovacia RMSE je **0.4480** mg/m^3, MAE 0.3004 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0288. Rozdiel je menší než pri výrazne preučených ensemble modeloch.

Najvyššiu natívnu dôležitosť modelu **DecisionTree** má **sensor_nmhc**, MDI **0.93027**. Prvé tri vstupy spolu získali **96.90%** relatívnej dôležitosti.

4.1.1. Vizualizácia malého rozhodovacieho stromu

Pre čitateľnosť natrénujem samostatný ilustračný strom s hĺbkou 3 a minimálne 30 meraniami v liste. Použijem sedem pôvodných spojitých vstupov bez škálovania, aby prahy mali zrozumiteľné jednotky. Jeho parametre a výsledok sú odlíšené od ladeného stromu. V liste `value` znamená priemerné CO a `squared_error` priemernú štvorcovú odchýlku cieľa v danom uzle.



Koreň delí podľa sensor_nmhc ≤ 1075.50. Ľavá vetva zodpovedá splneniu podmienky, pravá jej nesplneniu. Ilustračný strom dosahuje testovacie R^2 **0.8394** a RMSE 0.5769 mg/m^3. Je plytký, preto ukazuje hlavné pravidlá, ale nezachytáva všetky jemné interakcie.

Tabuľka pri výsledkoch ladeného **DecisionTree** opisuje ladený model. Malý ilustračný strom používa pôvodné spojité vstupy. Má inú hĺbku aj výsledky než ladený model, preto ich interpretáciu rozlišujem.

4.2. Ensemble

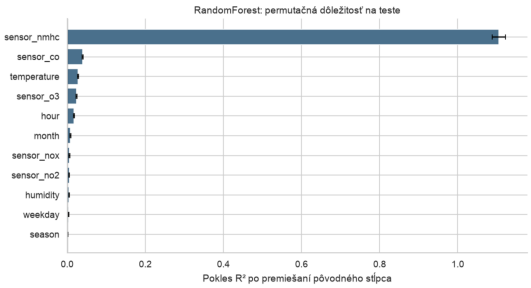
Súborové modely kombinujú viac stromov. Random Forest a ExtraTrees ich predikcie priemerujú. XGBoost a HistGradientBoosting vytvárajú postupnosť korekcií.

4.2.1. RandomForest

```
Najlepšie parametre: {'max_depth': None, 'max_features': 0.7, 'min_samples_leaf': 1}
Najhoršie CV parametre: {'estimator__model__max_depth': 12, 'estimator__model__max_features': 1.0, 'estimator__model__min_samples_leaf': 3}
Najhoršia CV MSE: 0.1614
```

	params	mean_train_mse	mean_test_mse	std_test_mse	mean_train_r2	std_train_r2	mean_test_r2	std_test_r2	rank_test_mse
0	{'estimator__model__max_depth': None, 'estimator__model__max_features': 0.7, 'estimator__model__...	0.0210	0.1499	0.0088	0.9898	0.0004	0.9272	0.0022	1
1	{'estimator__model__max_depth': 12, 'estimator__model__max_features': 0.7, 'estimator__model__mi...	0.0306	0.1517	0.0074	0.9852	0.0006	0.9263	0.0018	2
2	{'estimator__model__max_depth': None, 'estimator__model__max_features': 1.0, 'estimator__model__...	0.0221	0.1556	0.0066	0.9893	0.0004	0.9244	0.0013	3

Množina	MSE	RMSE	MAE	R^2
Tréning	0.0190	0.1380	0.0855	0.9908
Test	0.1402	0.3744	0.2354	0.9323



Dôležitosť príznakov

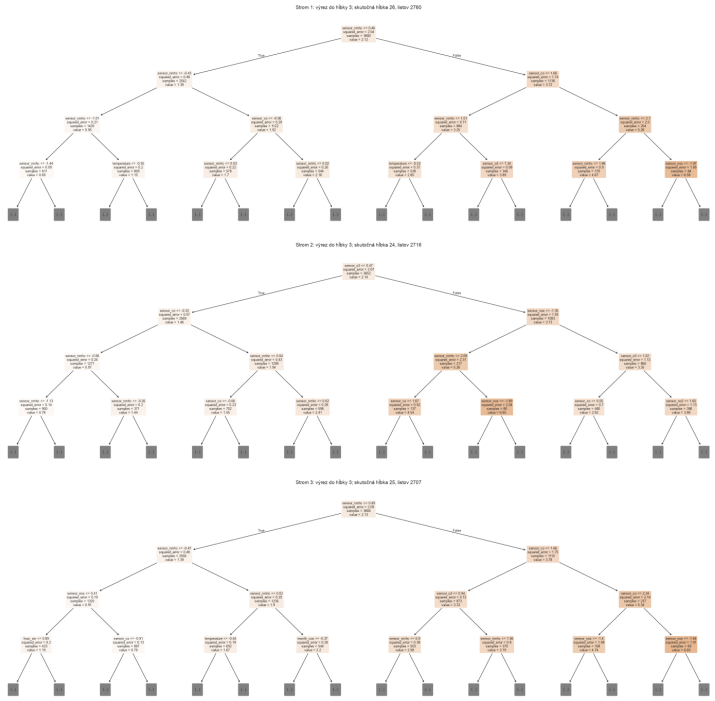
Poradie	Príznak	Feature importance
1	sensor_nmhc	0.61618
2	sensor_co	0.13985
3	sensor_o3	0.13340
4	sensor_nox	0.03025
5	temperature	0.02226
6	sensor_no2	0.01479
7	hour_sin	0.01011
8	humidity	0.00875
9	hour_cos	0.00654
10	month_cos	0.00550

RandomForest má tréningové R^2 **0.9908** a testovacie R^2 **0.9323**. Testovacia RMSE je **0.3744** mg/m^3, MAE 0.2354 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0584. Rozdiel upozorňuje na preučenie oproti prispôsobeniu tréningu.

Les obsahuje **200 stromov**.

4.2.2. Viacero stromov z ladeného Random Forestu

Zobrazím tri skutočné stromy lesa. Každý obrázok ukazuje výrez do hĺbky 3, `(...)` označuje pokračovanie. Prahy sú v štandardizovaných jednotkách z. Číslo stromu je jeho poradie v lese. Predikcia lesa je priemer predikcií všetkých 200 stromov.



Strom	Koreňový príznak	Prah koreňa [z]	Hĺbka	Počet listov
1	sensor_nmhc	0.457	26	2760
2	sensor_o3	0.465	24	2716
3	sensor_nmhc	0.487	25	2707

Päť najdôležitejších príznakov v každom zobrazenom strome (MDI)

Strom	Poradie	Príznak	Feature importance
1	1	sensor_nmhc	0.75629
	2	sensor_co	0.13213
	3	temperature	0.02299
	4	sensor_nox	0.02046
	5	sensor_o3	0.01529
2	1	sensor_o3	0.56805
	2	sensor_nmhc	0.13582
	3	sensor_co	0.11203
	4	sensor_nox	0.09974
	5	sensor_no2	0.02640
3	1	sensor_nmhc	0.72613
	2	sensor_co	0.14648
	3	sensor_o3	0.03034
	4	sensor_nox	0.02801
	5	temperature	0.01652

Les obsahuje **200 stromov**. Zobrazené stromy majú hĺbky **26, 24, 25** a korene podľa **sensor_nmhc, sensor_o3, sensor_nmhc**. Tabuľka porovnáva aj prahy a počty listov. Rozdiely vznikajú bootstrapovými vzorkami a náhodným výberom príznakov. Obrázky ukazujú iba začiatky stromov. Výslednú predikciu tvorí priemer celého lesa.

4.2.3. ExtraTrees

```
Najlepšie parametre: {'max_features': 0.7, 'min_samples_leaf': 1}
Najhoršie CV parametre: {'estimator__model__max_features': 0.7, 'estimator__model__min_samples_leaf': 3}
Najhoršia CV MSE: 0.1437
```

	params	mean_train_mse	mean_test_mse	std_test_mse	mean_train_r2	std_train_r2	mean_test_r2	std_test_r2	rank_test_mse
0	{'estimator__model__max_features': 0.7, 'estimator__model__min_samples_leaf': 1}	0.000	0.1297	0.0095	1.000	0.0000	0.9370	0.0034	1
1	{'estimator__model__max_features': 1.0, 'estimator__model__min_samples_leaf': 1}	0.000	0.1319	0.0079	1.000	0.0000	0.9359	0.0027	2
2	{'estimator__model__max_features': 1.0, 'estimator__model__min_samples_leaf': 3}	0.033	0.1430	0.0092	0.984	0.0007	0.9306	0.0018	3

Množina	MSE	RMSE	MAE	R^2
Tréning	0.0000	0.0035	0.0002	1.0000
Test	0.1216	0.3486	0.2221	0.9413

Dôležitosť príznakov

Poradie	Príznak	Feature importance
1	sensor_nmhc	0.34091
2	sensor_o3	0.22274
3	sensor_co	0.20393
4	sensor_nox	0.09293
5	sensor_no2	0.03755
6	hour_sin	0.02440
7	temperature	0.01245
8	hour_cos	0.01125
9	month_cos	0.00882
10	humidity	0.00866

ExtraTrees má tréningové R^2 **1.0000** a testovacie R^2 **0.9413**. Testovacia RMSE je **0.3486** mg/m^3, MAE 0.2221 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0587. Takmer nulová tréningová chyba pri nenulovej testovacej ukazuje silné zapamätanie tréningových meraní.

Najvyššiu natívnu dôležitosť modelu **ExtraTrees** má **sensor_nmhc**, MDI **0.34091**. Prvé tri vstupy spolu získali **76.76%** relatívnej dôležitosti.

4.2.4. XGBoost

```
Najlepšie parametre: {'learning_rate': 0.05, 'max_depth': 5, 'n_estimators': 400, 'reg_lambda': 1.0}
Najhoršie CV parametre: {'estimator__model__learning_rate': 0.05, 'estimator__model__max_depth': 3, 'estimator__model__n_estimators': 200, 'estimator__model__reg_lambd
a': 5.0}
Najhoršia CV MSE: 0.157
```

	params	mean_train_mse	mean_test_mse	std_test_mse	mean_train_r2	std_train_r2	mean_test_r2	std_test_r2	rank_test_mse
0	{'estimator__model__learning_rate': 0.05, 'estimator__model__max_depth': 5, 'estimator__model__n...	0.0317	0.1284	0.0076	0.9846	0.0009	0.9376	0.0040	1
1	{'estimator__model__learning_rate': 0.1, 'estimator__model__max_depth': 5, 'estimator__model__n_...	0.0183	0.1290	0.0069	0.9911	0.0006	0.9373	0.0035	2
2	{'estimator__model__learning_rate': 0.1, 'estimator__model__max_depth': 5, 'estimator__model__n_...	0.0127	0.1292	0.0083	0.9939	0.0003	0.9372	0.0038	3

Množina	MSE	RMSE	MAE	R^2
Tréning	0.0429	0.2072	0.1453	0.9792
Test	0.1204	0.3470	0.2241	0.9419

Dôležitosť príznakov

Poradie	Príznak	Feature importance
1	sensor_nmhc	0.59537
2	sensor_o3	0.10499
3	sensor_co	0.09860
4	season_summer	0.03393
5	season_winter	0.02666
6	hour_sin	0.01987
7	temperature	0.01919
8	month_cos	0.01780
9	hour_cos	0.01371
10	month_sin	0.01147

XGBoost má tréningové R^2 **0.9792** a testovacie R^2 **0.9419**. Testovacia RMSE je **0.3470** mg/m^3, MAE 0.2241 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0373. Rozdiel je menší než pri výrazne preučených súborových modeloch.

Najvyššiu natívnu dôležitosť modelu **XGBoost** má **sensor_nmhc**, normalizovaný gain **0.59537**. Prvé tri vstupy spolu získali **79.90%** relatívnej dôležitosti.

4.2.5. HistGradientBoosting

```
Najlepšie parametre: {'l2_regularization': 0.0, 'learning_rate': 0.1, 'max_leaf_nodes': 15}
Najhoršie CV parametre: {'estimator__model__l2_regularization': 1.0, 'estimator__model__learning_rate': 0.05, 'estimator__model__max_leaf_nodes': 15}
Najhoršia CV MSE: 0.131
```

	params	mean_train_mse	mean_test_mse	std_test_mse	mean_train_r2	std_train_r2	mean_test_r2	std_test_r2	rank_test_mse
0	{'estimator__model__l2_regularization': 0.0, 'estimator__model__learning_rate': 0.1, 'estimator_...	0.0402	0.1256	0.0070	0.9805	0.0010	0.9388	0.0046	1
1	{'estimator__model__l2_regularization': 1.0, 'estimator__model__learning_rate': 0.1, 'estimator_...	0.0411	0.1257	0.0065	0.9800	0.0012	0.9388	0.0038	2
2	{'estimator__model__l2_regularization': 0.0, 'estimator__model__learning_rate': 0.1, 'estimator_...	0.0167	0.1282	0.0063	0.9919	0.0005	0.9377	0.0026	3

Množina	MSE	RMSE	MAE	R^2
Tréning	0.0488	0.2208	0.1544	0.9763
Test	0.1210	0.3478	0.2283	0.9416

Permutačná dôležitosť

Poradie	Príznak	Feature importance	SD
1	sensor_nmhc	1.25915	0.01659
2	temperature	0.06651	0.00349
3	hour	0.03505	0.00216
4	sensor_co	0.03456	0.00167
5	month	0.02931	0.00251
6	sensor_o3	0.01168	0.00027
7	humidity	0.00880	0.00154
8	weekday	0.00850	0.00069
9	sensor_no2	0.00758	0.00119
10	sensor_nox	0.00620	0.00083

HistGradientBoosting má tréningové R^2 **0.9763** a testovacie R^2 **0.9416**. Testovacia RMSE je **0.3478** mg/m^3, MAE 0.2283 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0347. Rozdiel je menší než pri výrazne preučených súborových modeloch.

Po premiešaní **sensor_nmhc** klesne testovacie R^2 modelu **HistGradientBoosting** v priemere o $\mathbf{1.2591 \pm 0.0166}$.

4.3. SVR

Pri SVR volím regresnú verziu SVM s RBF jadrom, penalizáciou C, šírkou jadra gamma a toleranciou epsilon.

SVR vybral **C=100.0**, **gamma=scale**, **epsilon=0.1**.

```
Najlepšie parametre: {'C': 100.0, 'epsilon': 0.1, 'gamma': 'scale'}
Najhoršie CV parametre: {'estimator__model__C': 10.0, 'estimator__model__epsilon': 0.05, 'estimator__model__gamma': 0.01}
Najhoršia CV MSE: 0.1503
```

	params	mean_train_mse	mean_test_mse	std_test_mse	mean_train_r2	std_train_r2	mean_test_r2	std_test_r2	rank_test_mse
0	{'estimator__model__C': 100.0, 'estimator__model__epsilon': 0.1, 'estimator__model__gamma': 'sca...	0.0324	0.1046	0.0063	0.9843	0.0006	0.9492	0.0028	1
1	{'estimator__model__C': 100.0, 'estimator__model__epsilon': 0.05, 'estimator__model__gamma': 'sc...	0.0320	0.1055	0.0049	0.9845	0.0006	0.9487	0.0029	2
2	{'estimator__model__C': 10.0, 'estimator__model__epsilon': 0.1, 'estimator__model__gamma': 0.1}	0.0461	0.1071	0.0040	0.9776	0.0006	0.9479	0.0026	3

Množina	MSE	RMSE	MAE	R^2
Tréning	0.0350	0.1870	0.1199	0.9830
Test	0.0947	0.3077	0.1994	0.9543

Permutačná dôležitosť

Poradie	Príznak	Feature importance	SD
1	sensor_nmhc	1.04514	0.01663
2	month	0.44694	0.01783
3	sensor_no2	0.42665	0.00854
4	temperature	0.33007	0.01338
5	season	0.32260	0.01466
6	sensor_o3	0.27786	0.00831
7	sensor_co	0.24115	0.00678
8	humidity	0.14862	0.00538
9	sensor_nox	0.12299	0.00333
10	hour	0.10691	0.00546

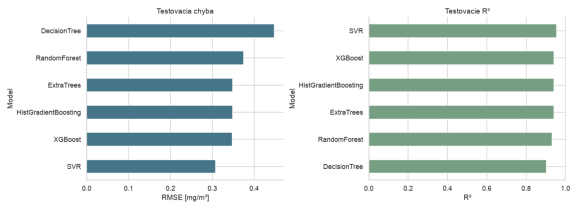
SVR má tréningové R^2 **0.9830** a testovacie R^2 **0.9543**. Testovacia RMSE je **0.3077** mg/m^3, MAE 0.1994 mg/m^3. Rozdiel tréningového a testovacieho R^2 je 0.0287. Rozdiel je menší než pri výrazne preučených súborových modeloch.

Po premiešaní **sensor_nmhc** klesne testovacie R^2 modelu **SVR** v priemere o **1.0451** $\pm$ **0.0166**.

4.4. Porovnanie reziduálov

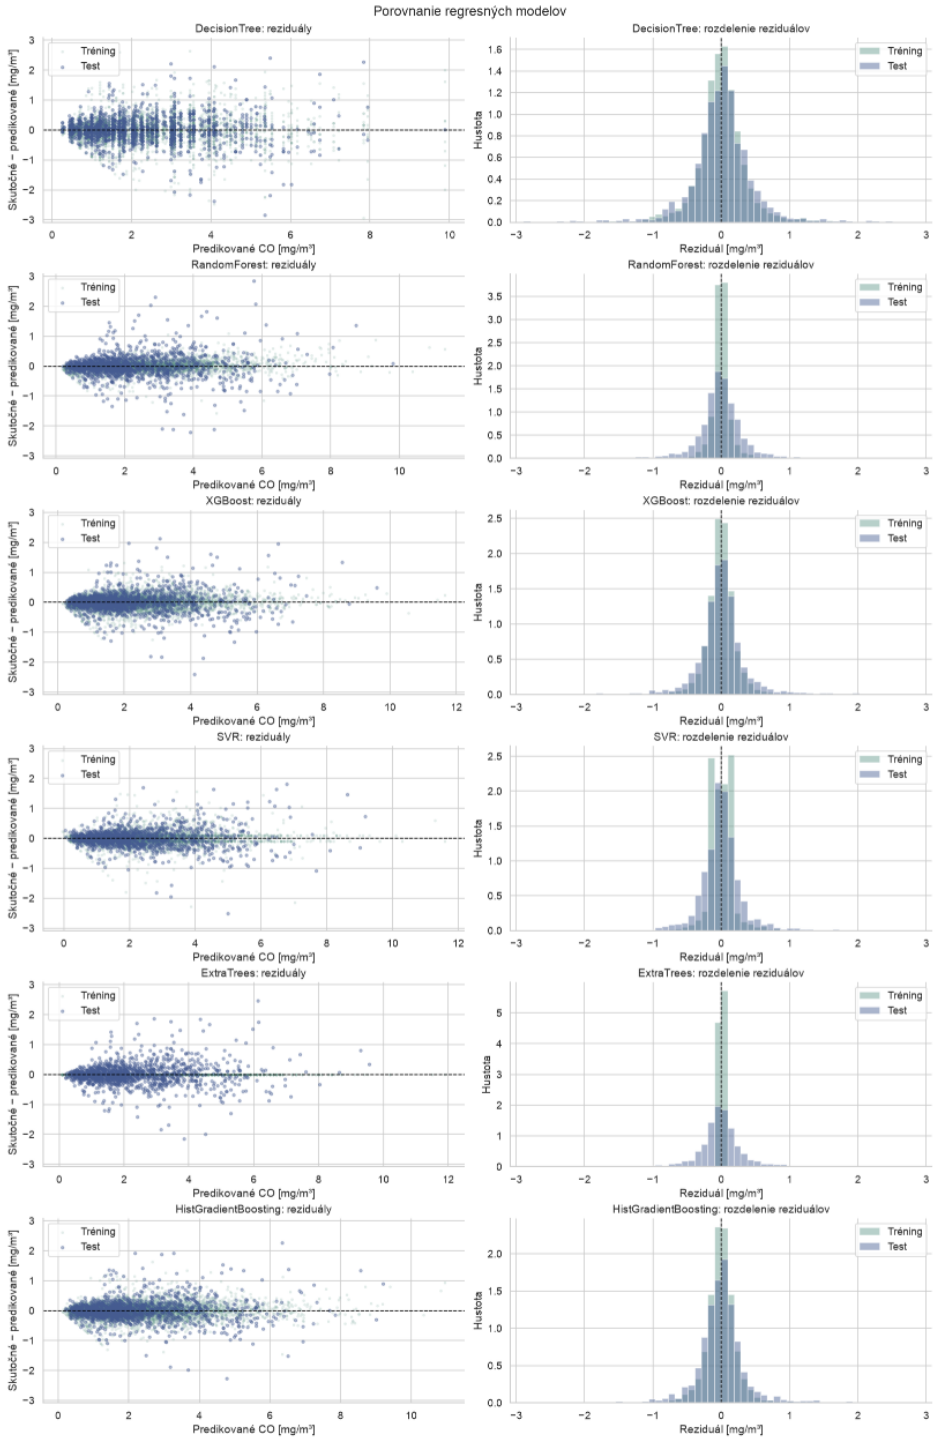
Všetky modely predikujú rovnakých 1 469 testovacích meraní.

	MSE		RMSE		R^2	
Množina	**Test**	**Tréning**	**Test**	**Tréning**	**Test**	**Tréning**
Model						
DecisionTree	0.2007	0.1404	0.4480	0.3747	0.9031	0.9319
ExtraTrees	0.1216	0.0000	0.3486	0.0035	0.9413	1.0000
HistGradientBoosting	0.1210	0.0488	0.3478	0.2208	0.9416	0.9763
RandomForest	0.1402	0.0190	0.3744	0.1380	0.9323	0.9908
SVR	0.0947	0.0350	0.3077	0.1870	0.9543	0.9830
XGBoost	0.1204	0.0429	0.3470	0.2072	0.9419	0.9792



CV víťaz **SVR** dosiahol na teste $R^2 = 0.9543$, RMSE = **0.3077 mg/m^3**.

Na zvislej osi bodových grafov je **reziduál** (skutočná hodnota - predikovaná hodnota). Ideálne body tvoria pás okolo nuly bez krivky či lievika. Histogram porovnáva chyby v tréningu a teste.

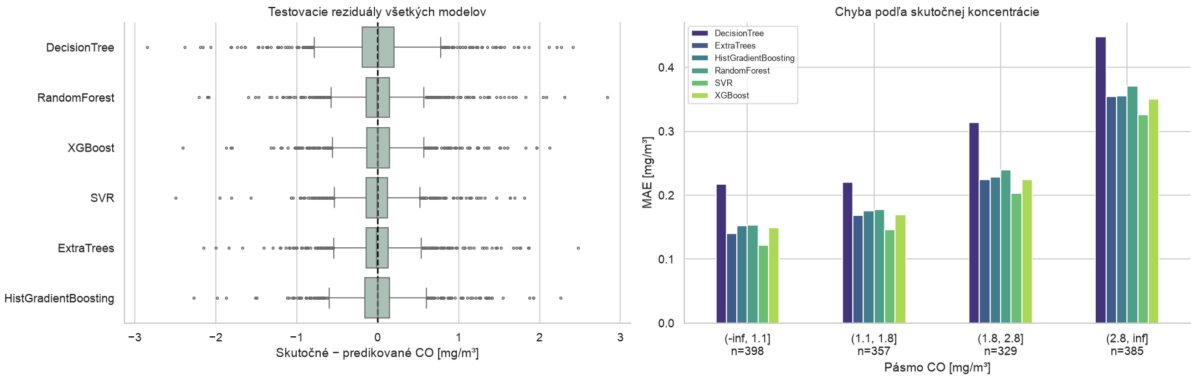


SVR: priemerný testovací reziduál 0.0019 mg/m^3 znamená podhodnotenie v priemere. 95 % absolútnych chýb neprekračuje **0.650** mg/m^3. Korelácia veľkosti chyby s predikciou je 0.427. Chyby majú tendenciu rásť s predikovanou koncentráciou.

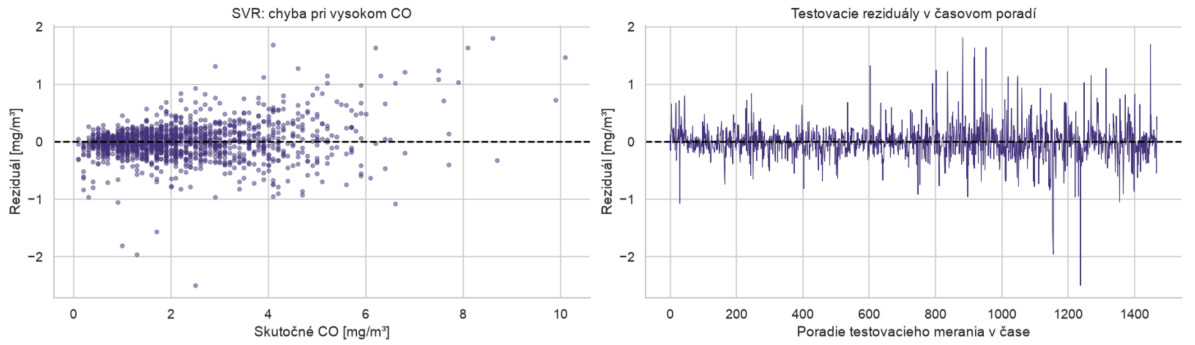
4.4.1. Rozptyl reziduálov a chyby podľa skutočného CO

Model	Priemer reziduála	Medián reziduála	95. percentil |e|	Korelácia |e| a predikcie
DecisionTree	0.0116	0.0125	0.8701	0.3486
RandomForest	0.0048	-0.0060	0.7453	0.3463
XGBoost	0.0059	0.0022	0.7190	0.3496
SVR	0.0019	-0.0040	0.6502	0.4270
ExtraTrees	0.0026	-0.0115	0.7079	0.3557
HistGradientBoosting	0.0033	0.0028	0.7279	0.3460

Boxplot porovná rozdelenia testovacích reziduálov. Pásma CO určím podľa tréningových kvartilov. Testové merania ich nemenia. Pri každom pásme uvediem počet testovacích bodov.



Pri modeli **SVR** je MAE v najnižšom pásme CO **0.1216 mg/m³**, v najvyššom **0.3256 mg/m³**. Najvyššie pásmo obsahuje **385** testovacích meraní a jeho priemerný reziduál je **0.0716 mg/m³**. Boxplot dopĺňa súhrnné metriky: posun mediánu ukazuje systematickú chybu, široký box a dlhé fúzy väčšie rozptýlenie reziduálov. Extrémne body ostávajú súčasťou hodnotenia.



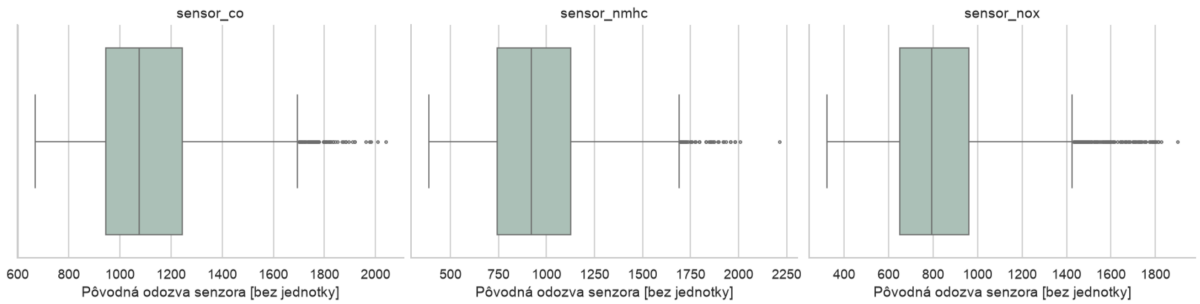
Pri skutočnom CO aspoň **4.00** mg/m^3 (hranica z tréningu) je priemerný reziduál 0.137 mg/m^3 na 182 testovacích bodoch. Tým priamo kontrolujem podhodnocovanie vysokých koncentrácií. Časový graf ukazuje poradie vybraných testovacích hodín. Vzdialenosť bodov na osi nie je rovnaký časový odstup. Nulový priemer reziduálov sám nezaručuje, že sú chyby nezávislé alebo normálne rozdelené.

5. Redukcia dimenzie

PCA vytvára nové osi ako lineárne kombinácie vstupov. PC1 zachytáva najväčší rozptyl, ďalšie kolmé osi zachytávajú zostávajúcu variabilitu. PCA nepozná cieľ CO, maximalizuje rozptyl vstupov, nie kvalitu regresie. Pred jej učením vstupy štandardizujem, pretože samotná PCA ich iba centruje.

5.1. Vykreslenie príznakov – vyčítanie závislostí

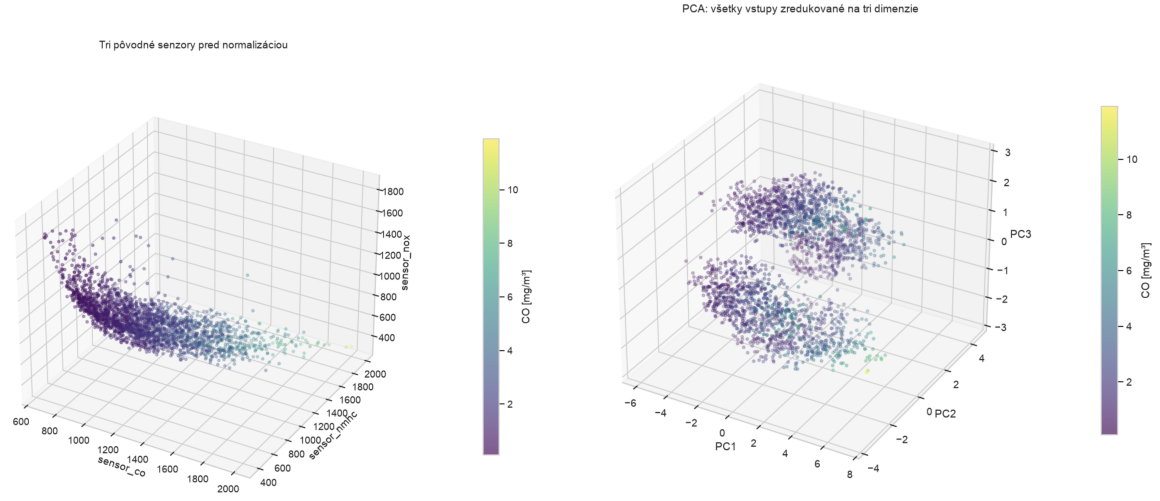
Vyberám `sensor_co`, `sensor_nmhc` a `sensor_nox`. Použijem rovnakú podvzorku najviac 2 500 tréningových inlierov.



	mean	median	var	std	min	max	Q1	Q3	IQR
sensor_co	1110.731	1076.0	47817.785	218.673	667.0	2040.0	945.0	1245.0	300.0
sensor_nmhc	947.448	920.5	70179.451	264.914	387.0	2214.0	744.0	1124.0	380.0
sensor_nox	823.791	795.0	59793.983	244.528	322.0	1900.0	650.0	961.0	311.0

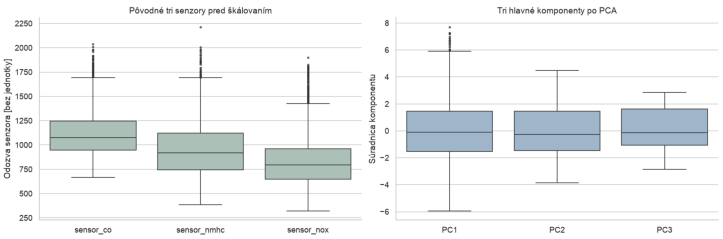
5.2. Minimalizácia na 3 dimenzie

Kódovanie, štandardizáciu a PCA učím iba na tréningových inlieroch. Transformácia prevádza 17 vstupných stĺpcov na PC1, PC2 a PC3. Rovnaké parametre následne transformujú test.



Tri komponenty zachovávajú **60.2% vstupnej variability** (jednotlivo 26.0%, 20.4%, 13.8%). Korelácie PC1, PC2 a PC3 s CO sú 0.848, -0.310, 0.068. V pôvodnom grafe sú vyššie koncentrácie sústredené pri vyšších odozvách sensor_co a sensor_nmhc a pri nižších odozvách sensor_nox. Farebný prechod teda odhaľuje súvislosť viacerých senzorov s CO. V PCA sa hlavný farebný gradient orientuje najmä pozdĺž PC1, čo podporuje aj jeho korelácia s CO.

Tri PC zachovávajú približne **60,22 %** vstupného rozptylu, zvyšných **39,78 %** tento obrázok nezobrazuje. Viditeľné pásy nie sú triedy CO. Ani čitateľnejší obraz sám nepreukazuje lepšiu regresiu.



	mean	median	var	std	min	max	Q1	Q3	IQR
PC1	0.0	-0.0904	4.4218	2.1028	-5.9379	7.7072	-1.5381	1.4511	2.9892
PC2	-0.0	-0.2603	3.4725	1.8635	-3.8580	4.4762	-1.4541	1.4693	2.9234
PC3	0.0	-0.1472	2.3449	1.5313	-2.8489	2.8580	-1.0541	1.6397	2.6938

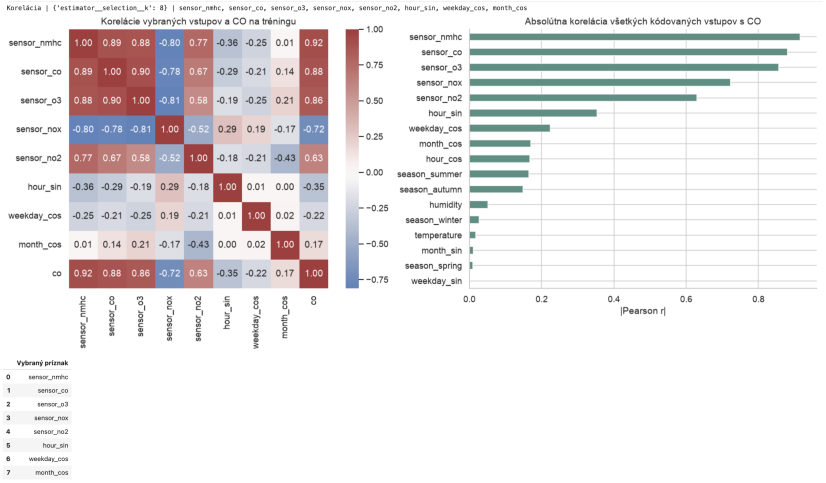
Vľavo sú tri vybrané pôvodné senzory, komponenty však vznikli zo všetkých 17 štandardizovaných vstupov. Ich súradnice majú inú mierku než pôvodné odozvy senzorov.

6. Trénovanie modelu na zmenšenej množine

Používam rovnaký typ a hyperparametre modelu vybraného v prvej časti podľa CV. Počet ponechaných príznakov alebo prah PCA vyberám vo vnútri tréningovej CV. Každý selector sa učí iba na tréningovej časti daného foldu. Test zostáva spoločný pre všetky stratégie.

6.1. Korelačná matica

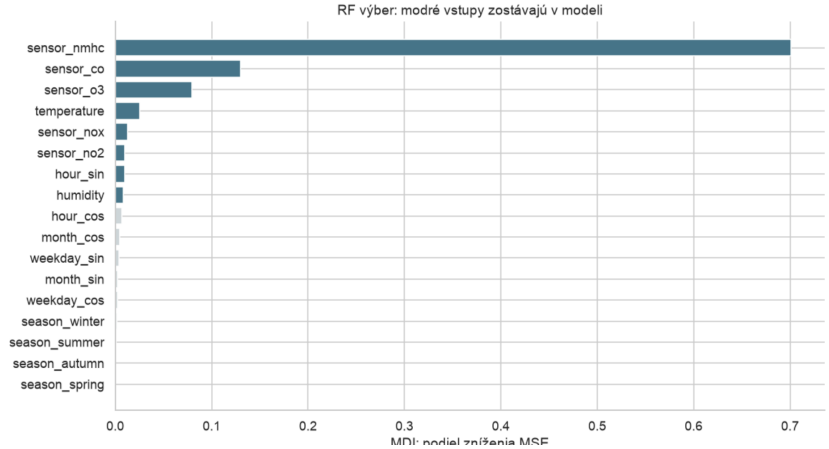
Zoradím vstupy podľa absolútnej Pearsonovej korelácie s CO a vynechám príznaky s absolútnou koreláciou aspoň 0,95 s už vybraným vstupom. CV vyberá najviac 4 alebo 8 príznakov. Heatmapa nižšie je opis finálneho tréningového výberu, nie podklad na výber podľa testu.



Korelácia: 8 vstupov, testovacie R^2 **0.9248**, RMSE **0.3946** mg/m^3, rozdiel RMSE oproti plnému modelu +0.0869 mg/m^3.

6.2. Dôležitosť príznakov z ensemble

Pomocný Random Forest sa v každom CV folde učí od začiatku a podľa jeho natívnych dôležitostí vyberám 4 alebo 8 príznakov. Na vybraných príznakoch následne od začiatku trénujem SVR s pôvodnými hyperparametrami, počet príznakov volím podľa jeho CV MSE.

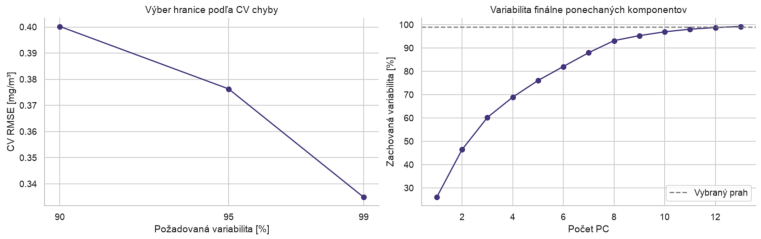


	Dôležitosť	Vybraný
sensor_nmhc	0.70083	True
sensor_co	0.12986	True
sensor_o3	0.07970	True
temperature	0.02528	True
sensor_nox	0.01289	True
sensor_no2	0.00993	True
hour_sin	0.00971	True
humidity	0.00859	True
hour_cos	0.00664	False
month_cos	0.00495	False
weekday_sin	0.00386	False
month_sin	0.00250	False
weekday_cos	0.00244	False
season_winter	0.00144	False
season_summer	0.00062	False
season_autumn	0.00045	False
season_spring	0.00031	False

RF dôležitosť: 8 vstupov, testovacie R^2 **0.9314**, RMSE **0.3770** mg/m^3, rozdiel RMSE oproti plnému modelu +0.0693 mg/m^3.

6.3. Podľa variancie

PCA skúša hranice vysvetlenej variability 90 %, 95 % a 99 %. Počet komponentov vyplynie z dát.



CV výsledky prahov

	Prah	CV RMSE	CV R²
0	0.90	0.40020	0.92211
1	0.95	0.37631	0.93110
2	0.99	0.33488	0.94552

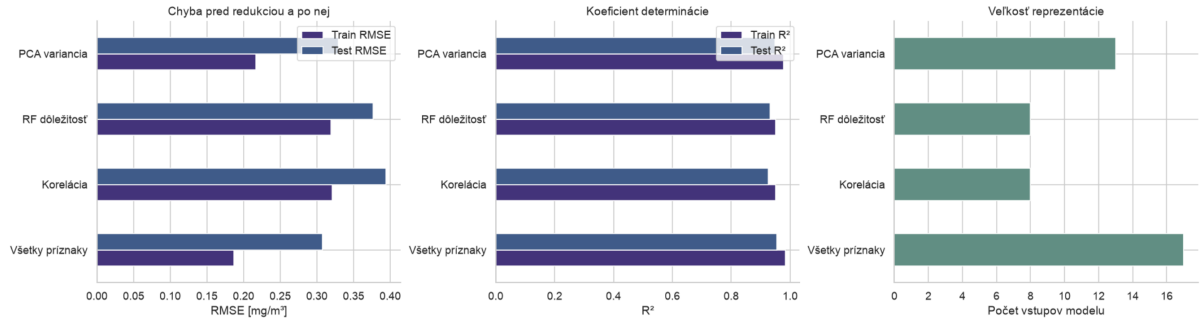
Prah 99%: 13 komponentov ponechá **99.25 %** a zahodí **0.75 %** vstupnej variability. Rekonštrukčná RMSE je 0.0866 v z jednotkách. Percento je skutočne dosiahnutý podiel: pre diskrétny počet komponentov môže presiahnuť zadaný prah.

PCA variancia: 13 vstupov, testovacie R^2 **0.9478**, RMSE **0.3289** mg/m^3, rozdiel RMSE oproti plnému modelu +0.0213 mg/m^3. Zmenšenie tu neprinieslo nižšiu chybu. Úspora rozmerov môže stáť predikčnú informáciu.

6.4. Porovnanie

Porovnám pôvodný model a všetky tri stratégie na totožných testovacích meraniach. Okrem výsledných chýb sledujem aj počet vstupov a reziduály.

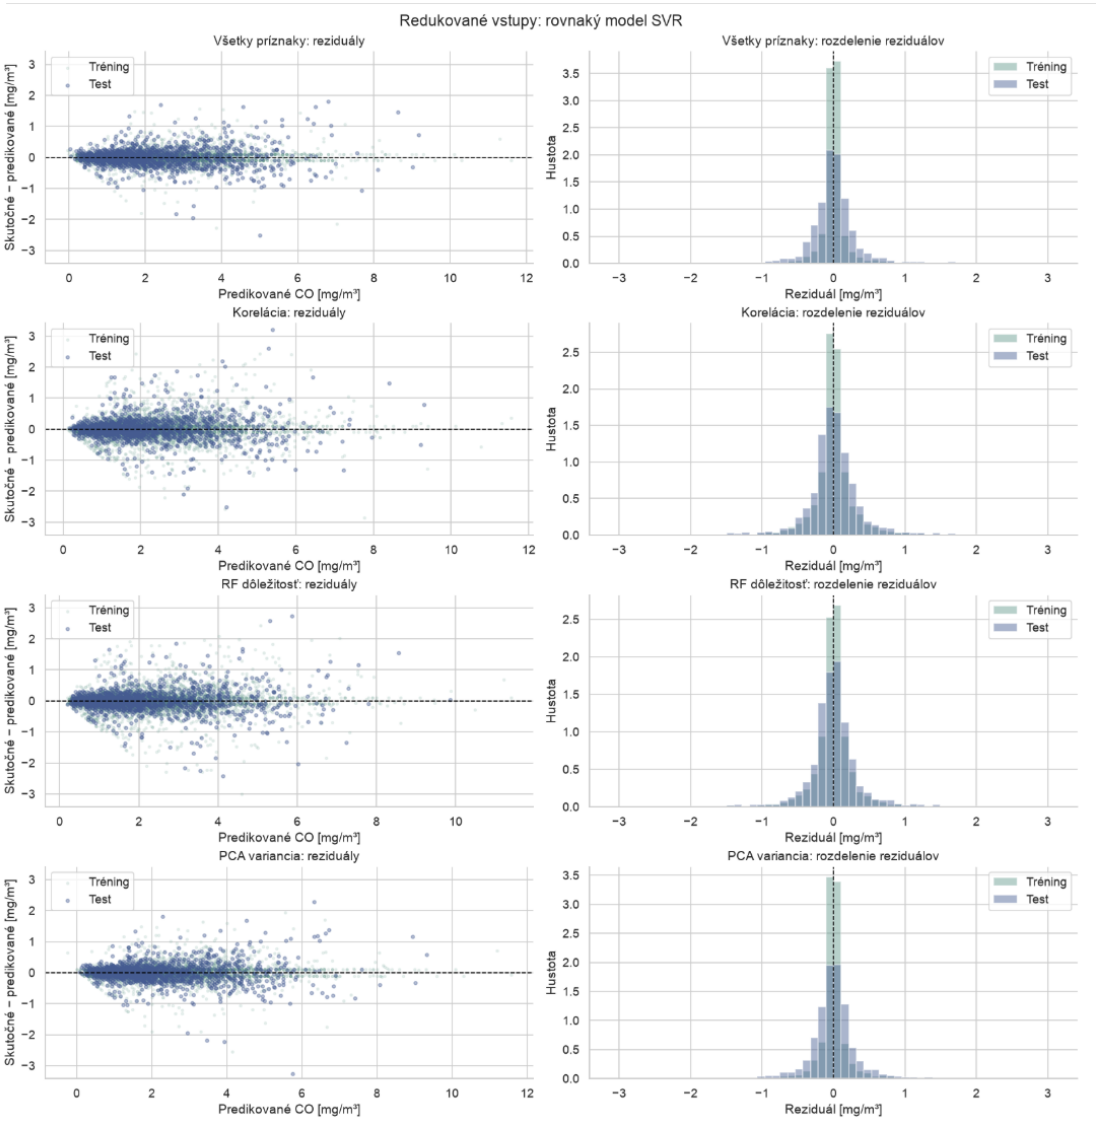
Stratégia	Počet vstupov	CV MSE	Test MSE	Test RMSE	Test MAE	Test R^2	Train MSE	Train RMSE	Train MAE	Train R^2
Všetky príznaky	17	0.1046	0.0947	0.3077	0.1994	0.9543	0.0350	0.1870	0.1199	0.9830
Korelácia	8	0.1533	0.1557	0.3946	0.2478	0.9248	0.1032	0.3212	0.1928	0.9499
RF dôležitosť	8	0.1506	0.1421	0.3770	0.2324	0.9314	0.1018	0.3191	0.1889	0.9506
PCA variancia	13	0.1121	0.1082	0.3289	0.2093	0.9478	0.0470	0.2168	0.1342	0.9772



V tomto experimente PCA s hranicou 99 % ponechalo 13 komponentov a skutočne zachovalo približne 99,25 % vstupnej variability. Aj tak testovacia RMSE SVR vzrástla približne z 0,3077 na 0,3289 mg/m^3. Strata len 0,75 % vstupného rozptylu teda **neznamená** rovnakú relatívnu zmenu regresnej chyby. PCA nepozná CO a nemôže zaručiť, že zahodí iba nepotrebnú informáciu. Naproti tomu tri komponenty pre obrázok zachovávajú len približne 60,2 %, preto ich nepovažujem za rovnocennú náhradu zvolenej 13D regresnej reprezentácie.

6.4.1. Reziduály po redukcii

Rovnaké testovacie riadky a spoločné osi umožňujú porovnať, či redukcia zväčšuje rozptyl alebo podhodnotenie pri vysokom CO. Korelačný výber zachytáva lineárny vzťah s cieľom, ensemble aj nelinearity, PCA predovšetkým veľké smery variability. Preto ich poradie podľa zachovanej variability nemusí súhlasiť s poradím predikčnej chyby.



Model	Priemer reziduála	Medián reziduála	95. percentil |e|	Korelácia |e| a predikcie
Všetky príznaky	0.0019	-0.0040	0.6502	0.4270
Korelácia	0.0149	-0.0027	0.7978	0.3659
RF dôležitosť	0.0030	-0.0006	0.7707	0.3580
PCA variancia	0.0001	-0.0023	0.6800	0.3972

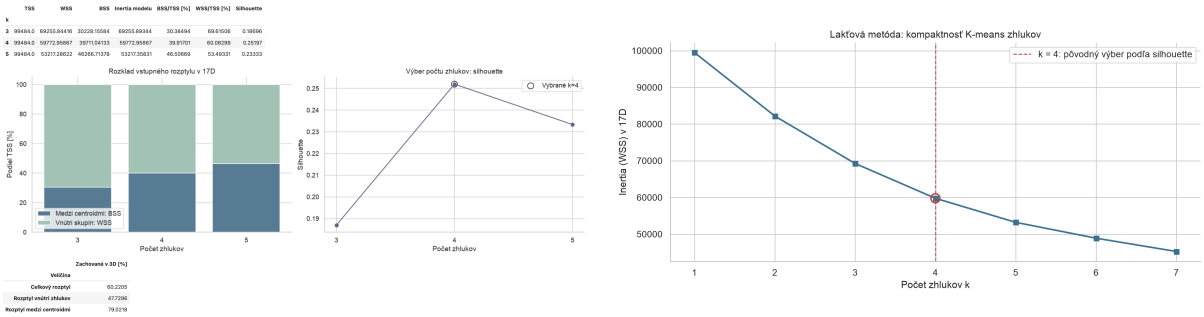
7. Zhlukovanie – bonus

7.1. Vizualizácia

K-means sa učí na **všetkých 17 štandardizovaných vstupoch**, bez CO a iba z tréningových inlierov. Porovnávam 3, 4 a 5 zhlukov pomocou silhouette skóre na rovnakej tréningovej podvzorke. Vyberám najvyššie skóre, nie najlepšiu regresiu na teste.

Vybral som **4 zhluky** so silhouette **0.252**. Hodnota blízko nule znamená slabé oddelenie, hodnota blízko jednej kompaktné a oddelené skupiny. Vedľa porovnania silhouette skóre je lakťová metóda: inertia je súčet štvorcov vzdialeností k centroidom v 17D. Lakeť hľadám tam, kde ďalšie

zhluky prinášajú už len malý pokles. Prerušovaná čiara označuje $k = 4$, vybrané podľa silhouette spomedzi 3, 4 a 5.

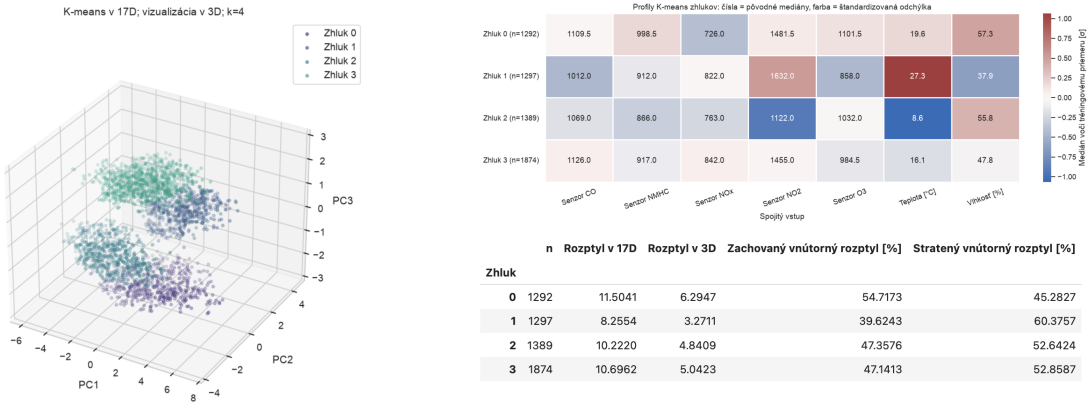


Grafy nižšie zobrazujú tie isté štyri zhluky z viacerých pohľadov a prvé kroky algoritmu K-means. Farba bodu označuje zhluk, čísla zhlukov sú ľubovoľné označenia. V 3D grafe sú osi tri PCA súradnice, preto prekryv v projekcii nemusí znamenať prekryv v plnom priestore.



Výpočty a WSS používajú všetky tréningové inliery v 17D. V priebehu iterácií sú zobrazené iba PC1 a PC2 a rovnaká podvzorka najviac 2 000 bodov. Priradenie farby preto nemusí zodpovedať najbližšiemu centroidu v tejto 2D projekcii. Profily v nasledujúcej časti ukazujú mediány pôvodných senzorov a počasia.

7.1.1. Profily zhlukov a strata rozptylu v projekcii



Zhluk	n	Rozptyl v 17D	Rozptyl v 3D	Zachovaný vnútorný rozptyl [%]	Stratený vnútorný rozptyl [%]
0	1292	11.5041	6.2947	54.7173	45.2827
1	1297	8.2554	3.2711	39.6243	60.3757
2	1389	10.2220	4.8409	47.3576	52.6424
3	1874	10.6962	5.0423	47.1413	52.8587

Tabuľka profilov uvádza mediány v pôvodných jednotkách. Druhá tabuľka porovnáva vnútorný rozptyl každého zhluku v 17D a jeho zachovanú časť v troch PCA súradniciach. Projekcia preto nezobrazuje celú vnútornú štruktúru zhlukov.

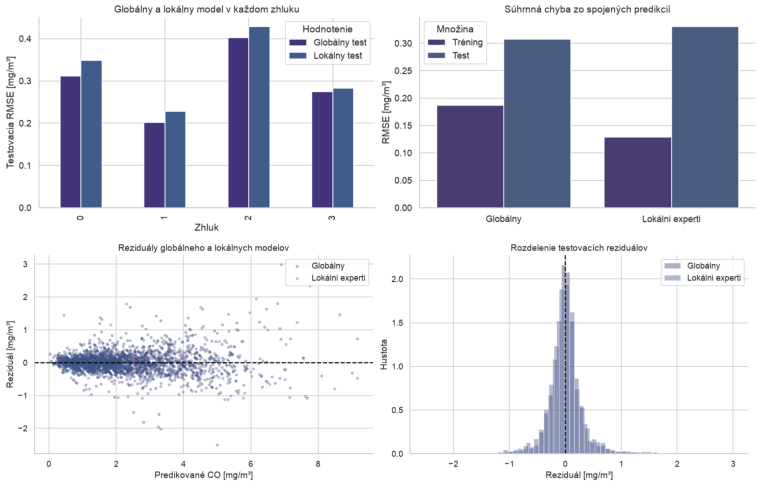
7.2. Trénovanie

7.2.1. Globálny model oproti lokálnym expertom

Pre každý zhluk natrénujem model **rovnakého typu a s rovnakými hyperparametrami** ako CV víťaz prvej časti. Predspracovanie a pravidlo outlierov sa znovu učia len z tréningových bodov daného zhluku. Testovací bod priradí do zhluku tréningový škálovač a K-means. Potom dostane predikciu príslušného lokálneho modelu. Na porovnanie vypočítam aj chybu pôvodného globálneho modelu na presne tých istých bodoch každého zhluku. R^2 v podskupine môže klesnúť aj pre menší rozsah CO. Rozhodujúce je tiež spoločné MSE všetkých bodov.

	Zhluk	Hodnotenie	n	MSE	RMSE	MAE	R^2
0	0	Lokálny tréning	1298	0.0165	0.1284	0.0971	0.9945
1	0	Lokálny test	328	0.1217	0.3488	0.2185	0.9564
2	0	Globálny test	328	0.0973	0.3119	0.2005	0.9652
3	1	Lokálny tréning	1298	0.0119	0.1089	0.0825	0.9889
4	1	Lokálny test	295	0.0518	0.2275	0.1527	0.9570
5	1	Globálny test	295	0.0408	0.2019	0.1405	0.9661
6	2	Lokálny tréning	1401	0.0238	0.1541	0.1087	0.9886
7	2	Lokálny test	364	0.1840	0.4289	0.2911	0.9195
8	2	Globálny test	364	0.1618	0.4022	0.2648	0.9292
9	3	Lokálny tréning	1878	0.0148	0.1216	0.0943	0.9919
10	3	Lokálny test	482	0.0802	0.2832	0.1906	0.9535
11	3	Globálny test	482	0.0752	0.2742	0.1852	0.9565

	Model	Množina	MSE	RMSE	MAE	R^2
0	Globálny	Tréning	0.0350	0.1870	0.1199	0.9830
1	Lokálni experti	Tréning	0.0167	0.1291	0.0957	0.9919
2	Globálny	Test	0.0947	0.3077	0.1994	0.9543
3	Lokálni experti	Test	0.1095	0.3309	0.2141	0.9472



Všetci lokálni experti spolu dosahujú $R^2 = 0.9472$, RMSE = $\mathbf{0.3309\ mg/m^3}$, oproti globálnym 0.3077 mg/m^3. Zmena RMSE je $+0.0232$ mg/m^3. Spoločné metriky sú počítané zo všetkých spojených predikcií, nie priemerovaním R^2 zhlukov. Lokálne modely majú menej dát a nevidia susedné režimy. Segmentácia preto nemusí pomôcť ani pri viditeľných zhlukoch. Priemerný reziduál lokálnych predikcií je 0.0055 mg/m^3.

Lokálne modely majú nižšiu tréningovú chybu, ale v každom zo štyroch zhlukov vyššiu testovaciu RMSE než globálny model. Rozdelenie vstupov na zhluky preto v tomto experimente nezlepšilo predikciu CO. Súhrnná RMSE je vypočítaná zo všetkých spojených predikcií, nie priemerom zhlukových RMSE.

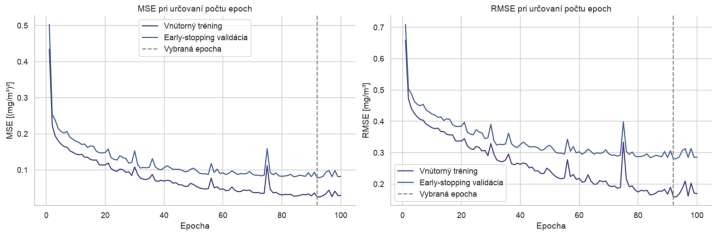
8. Neurónová sieť – bonus

Sieť má jeden **lineárny výstup koncentrácie**, bez sigmoidy a bez tried. Minimalizuje MSE v pôvodných jednotkách CO pomocou AdamW.

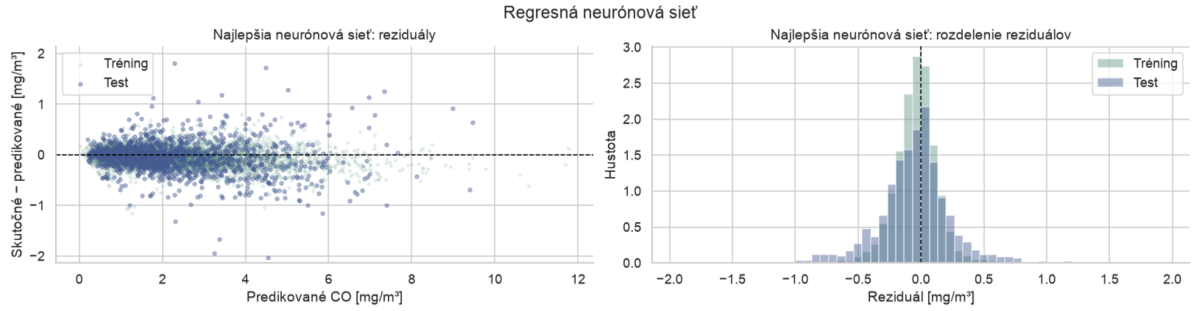
`GridSearchCV` porovná štyri architektúry **64 → 32**, **256 → 128**, **1028 → 256 → 128** a **512 → 512 → 256 → 128**, tri aktivácie **ReLU, GELU, Tanh** a learning rate **0,001 / 0,003**. Ide o **24 konfigurácií**. Z dôvodu výpočtovej náročnosti neurónová časť používa 2-fold CV a CPU s jedným vláknom. Klasické modely používali 3-fold CV, preto ich CV skóre nie sú úplne rovnocenné. Test je spoločný.

Víťazná sieť má skryté vrstvy **1028 → 256 → 128**, aktiváciu **RELU** a learning rate **0.001**. CV RMSE je **0.3430** mg/m^3, finálne testovacie R^2 **0.9544** a RMSE **0.3072** mg/m^3. Tréningové R^2 je 0.9862. Výsledok vychádza z CV výberu, nie z výberu najlepšej siete podľa testu.

Množina	MSE	RMSE	MAE	R²
Tréning	0.0284	0.1684	0.1248	0.9862
Test	0.0944	0.3072	0.2113	0.9544



Early stopping vybral **92. epochu** z 100 vykonaných. V nej bola vnútorná tréningová MSE 0.0255 a validačná MSE 0.0783. Finálna sieť sa potom učila od začiatku na všetkých tréningových inlieroch. Jej testovacie metriky preto nemusia zodpovedať minimu tejto vnútornej krivky.



Model	Priemer reziduála	Medián reziduála	95. percentil |e|	Korelácia |e| a predikcie
Najlepšia neurónová sieť	-0.0473	-0.0311	0.6438	0.4249

Najlepšia neurónová sieť: priemerný testovací reziduál -0.0473 mg/m^3 znamená nadhodnotenie v priemere. 95 % absolútnych chýb neprekračuje **0.644** mg/m^3. Korelácia veľkosti chyby s predikciou je 0.425. Chyby majú tendenciu rásť s predikovanou koncentráciou.

Neurónová sieť a SVR majú na tomto teste veľmi blízku RMSE.