I-SUNS: Zadanie č.2

Stromy, stroje, hlasovania a redukcia dimenzie

Vo vybranom programovacom jazyku implementujte program, ktorý bude predpovedať koncentráciu oxidu uhoľnatého (CO) vo vzduchu. V tomto zadaní budete pracovať s dátami z AIS. Výstupný stĺpec pre toto zadanie je *CO*.

Čas odovzdania je určený časom vloženia do AIS. Deadline pre získanie 10 bodov je **06.11.2026 o 8:00/10:00 (pred vaším cvičením)**. Každý týždeň omeškania je penalizovaný stratou troch bodov.

- Načítajte dáta a pripravte ich na spracovanie modelmi ML - odstráňte stĺpce s identifikátormi, odstráňte null hodnoty, duplikáty, outliery, správne spracujte textové hodnoty (pozor: použite vhodné kódovanie, myslite pri tom na to, že spracovanie stĺpca, ktorý má príliš veľa unikátnych hodnôt môže pridať do vášho datasetu príliš veľa nových stĺpcov. Modely s ktorými budete robiť na tomto zadaní pracujú ťažšie s veľkým počtom stĺpcov). **1b**

- Rozdeľte dáta na trénovaciu a testovaciu množinu (validačnú Vám v tomto zadaní netreba), následne na vstupnú a výstupnú množinu, potom normalizujte (výstup nenormalizujete).

- Trénujte nasledujúce modely (pre každý model dosiahnite kladné R2 skóre[1] - pri najlepšom modeli aspoň 0.7):

  - rozhodovací strom **0.5b**:
    - jeden strom z výsledkov aj zobrazte do dokumentácie - ak budú Vaše stromy príliš veľké, pre vizualizáciu natrénujte menší strom, aj keby mal mať horšie výsledky, je potrebné ho vedieť analyzovať; **0.5b**
  - Vami vybraný stromový súborový (*ensemble*) model **0.5b**:
    - vizualizujte dôležitosť vstupných parametrov - ak ich bude príliš veľa, zredukujte ich na podmnožinu najdôležitejších; **0.5b**
  - model SVM. **1b**

  Modely vyhodnoťte na trénovacej a testovacej množine pomocou MSE (príp. RMSE), R2 a výsledky vizualizujte tak, aby ste mohli analyzovať reziduály (pozor: treba vizualizovať reziduály, tj. **nie** očakávanú hodnotu vs. predpovedanú hodnotu). Navzájom porovnajte modely. **1b**

[1] Nezamieňajte si túto metriku s úspešnosťou, R2 skóre môže byť záporné, neuvádzajte ho v %!

- Sledujte, čo s dátami spraví redukcia dimenzie (pomocou 3D bodových grafov - scatter plot):
  - Vyberte si 3 príznaky (pred normalizáciou), ktoré budú na osiach. Snažte sa nájsť také príznaky, pri ktorých budete vedieť graf analyzovať. Dáta vyfarbite podľa výstupného parametra (count). Pokúste sa z grafu vyčítať nejakú závislosť. **1b**
  - Minimalizujte množinu (po normalizácii, bez výstupného parametra) na 3 dimenzie (pomocou PCA, UMAP ...), tie vyneste na osi, dáta opäť zafarbite podľa výstupného parametra (count). **1b**

  Grafy navzájom porovnajte.

- Vyberte podmnožinu príznakov , vyberte si najúspešnejší model z prvej časti zadania a opäť ho natrénujte pre zmenšenú množinu:
  - podľa korelačnej matice; **1b**
  - podľa dôležitosti príznakov z ensemble modelu; **1b**
  - podľa variancie pomocou PCA (zvoľte si hodnotu variancie, nie počet príznakov - t.j. nie 3). **1b**

  Výsledky porovnajte medzi sebou aj s pôvodným trénovaním pomocou MSE (príp. RMSE), R2 a reziduálov.

Nepovinné úlohy

Body za nepovinné úlohy sú udelené len v prípade, že sú vypracované správne:

- EDA. **1b**
- Zhlukujte vaše dáta (minimálne 3 kategórie):
  - Výsledky vizualizujte na 3D grafe (pozor: pri zhlukovaní použite viac príznakov než pri zobrazovaní v grafe; nepoužívajte výstupný parameter - count). **1b**
  - Natrénujte Váš najlepší model pre jednotlivé kategórie vzniknuté zhlukovaním a porovnajte ho s pôvodným výsledkom. **1b**
- Natrénujte umelú neurónovú sieť - pozor na zmenu typu problému, nejedná sa o klasifikáciu. Je potrebné prispôsobiť sieť aj analýzu výsledkov. **1b**

Popis stĺpcov

- instant: Index záznamu - ID (číselná hodnota).
- date: Dátum záznamu vo formáte YYYY-MM-DD.
- month: Mesiac v roku. Možné hodnoty: 1 až 12.
- hour: Hodina dňa. Možné hodnoty: 0 až 23.
- weekday: Deň v týždni. Možné hodnoty: 0 až 6. (0 = nedeľa)
- season: Ročné obdobie. Možné hodnoty: winter, spring, summer, autumn.
- sensor-co: Priemerná hodinová odozva chemického senzora, nominálne zameraného na oxid uhoľnatý (celé číslo, bez jednotky). Vyššia hodnota znamená silnejší signál senzora. Rozsah hodnôt: približne 600 až 2 100.
- sensor-nmhc: Priemerná hodinová odozva chemického senzora, nominálne zameraného na nemetánové uhľovodíky (celé číslo, bez jednotky). Rozsah hodnôt: približne 350 až 2 250.
- sensor-nox: Priemerná hodinová odozva chemického senzora, nominálne zameraného na oxidy dusíka (celé číslo, bez jednotky). Rozsah hodnôt: približne 300 až 2 700.
- senso-no2: Priemerná hodinová odozva chemického senzora, nominálne zameraného na oxid dusičitý (celé číslo, bez jednotky). Rozsah hodnôt: približne 550 až 2 800.
- sensor-o3: Priemerná hodinová odozva chemického senzora, nominálne zameraného na ozón (celé číslo, bez jednotky). Rozsah hodnôt: približne 200 až 2 550.
- temperature: Teplota vzduchu v stupňoch Celzia (reálne číslo). Rozsah hodnôt: -5 až 40 °C.
- humidity: Relatívna vlhkosť vzduchu v percentách (reálne číslo). Rozsah hodnôt: 0 až 100 %.
- co: Cieľová premenná – priemerná hodinová koncentrácia oxidu uhoľnatého vo vzduchu v mg/m^3 (reálne číslo), nameraná referenčným analyzátorom.