I-SUNS: Zadanie č.3

Konvolučné siete a prenos vedomostí

Vo vybranom programovacom jazyku implementujte program, ktorý bude odhadovať kalorickú hodnotu jedla z fotografie taniera. Dáta sú dostupné na Google Drive. Dataset obsahuje približne 3 000 fotografií tanierov z jedální spoločnosti Google snímaných zhora (podmnožina datasetu Nutrition5k). Ku každému obrázku je v súbore `metadata.csv` uvedená cesta k obrázku (`file_name`) a celková kalorická hodnota jedla (`total_calories`), ktorá je cieľovou premennou. Ostatné stĺpce **nepoužívajte ako vstup**.

Čas odovzdania je určený časom vloženia do AIS. Deadline pre získanie 10 bodov je **4.12.2026 o 8:00/10:00** (pred vaším cvičením).

- **Pracujte so všetkými 3 farebnými kanálmi - za konverziu na šedotónové obrázky bude zo získaného počtu bodov udelená len polovica!**
- Spoznajte dáta:
  - Analyzujte, čo všetko dataset obsahuje: počet obrázkov a ich rozlíšenie, štruktúru súboru `metadata.csv` (aké stĺpce obsahuje a čo popisujú, vrátane zoznamu ingrediencií), chýbajúce hodnoty a či ku každému obrázku existuje práve jeden záznam v metadátach. Načítajte metadáta, spárujte každý obrázok s jeho hodnotou `total_calories` (cez stĺpec `file_name`). Dáta rozdeľte na trénovaciu, validačnú a testovaciu množinu (X-obrázky, Y-`total_calories`). Pri rozdeľovaní zabezpečte, aby boli dáta správne spárované a vzájomne konzistentné. **0.5b**
- Vytvorte a natrénujte konvolučnú neurónovú sieť na odhad kalorickej hodnoty jedla **(bez vypracovania tejto časti bude zadanie hodnotené 0 bodmi!)**, výsledný (najlepší) model nesmie trpieť podtrénovaním ani pretrénovaním:
  - Pre trénovaciu, validačnú a testovaciu množinu, si pripravte generátor dát, nezabudnite dáta normalizovať a vhodne im zmeniť veľkosť - pozor na zamiešanie (shuffle) dát pri použití generátorov. **0.5b**
  - Navrhnite sieť s aspoň 2 konvolučnými vrstvami **a** využite niektoré z regularizačných alebo normalizačných techník aby ste zabránili pretrénovaniu (aspoň 2). Skúste niekoľko (aspoň 5) cielených konfigurácií hyperparametrov, všetky úspešnosti **(MSE, MAE, RMSE a R2)** pre **trénovaciu** aj **testovaciu** množinu zobrazte **v 1 tabuľke**. **1.5b**

  - Nezabúdajte na dobré praktiky zo zadania 1 a 2 - sledujte a zobrazte priebehy trénovania, poriadne evaluujte na **trénovacej** a **testovacej** množine (analyzujte reziduály, vykreslite aj predikované vs skutočné hodnoty). Grafy a reziduály stačí zobraziť pre najlepšie trénovanie. **1b**
  - Vzhľadom na náročnosť výpočtov si nezabudnite vytvárať checkpointy počas trénovania (nie je povinné).

- Zhlukujte vaše výsledky pomocou princípov *transfer learning*:
  - Jednu sieť predtrénovanú na datasete ImageNet (MobileNet, Resnet, EfficientNET...) využite na extrakciu príznakov z obrazových dát (miesto konkrétneho čísla výslednej regresie bude vracať vektor popisujúci obraz). Pozrite sa na množstvo parametrov (čím menej parametrov tým budú výpočty rýchlejšie). Zakódujte celý dataset, do dataframe-u si uložte vyextrahované príznaky (každý do samostatného stĺpca), cestu k obrázku (pre ďalšiu analýzu) a pridajte stĺpec s výstupnou hodnotou (`total_calories`). **1b**
  - **Príznaky** (iba príznaky!) zhlukujte a analyzujte výsledky - môžete si pomôcť aj zmenšením dimenzie. Body budú udelené nasledovne (ak budete mať viac než 10 zhlukov, dajte do dokumentácie len tie najzaujímavejšie):
    * Využitie zhlukovacieho algoritmu na vytvorenie zhlukov. **0.5b**
    * Zobrazenie (pod)množiny obrázkov pre všetky zhluky - obrázky si kľudne zmenšite, aby sa Vám zmestili na menšiu plochu. **0.5b**
    * Zobrazenie priemerného obrázku pre všetky zhluky. **0.5b**
    * Analýza výsledkov zhlukovania [1]. **0.5b**

- Natrénujte sieť na vygenerovaných príznakoch. Môžete si **vybrať** jeden z dvoch spôsobov **(bez vypracovania tejto časti bude zadanie hodnotené 0 bodmi!)** - v tejto časti je potrebné dosiahnuť lepšie výsledky ako pri vytvorení vlastnej konvolučnej siete:
  - **Možnosť 1** Na pripravených príznakoch trénujte ľubovoľný regresor z predošlých zadaní (t.j. neurónovú sieť, SVM, rozhodovací strom, model využívajúci súborové učenie) - môžete si pomôcť aj zmenšením dimenzie. Dajte si pozor na výber modelu - je potrebné dosiahnuť lepšie výsledky ako pri vlastnej konvolučnej sieti z prvej časti zadania.

[1] analýza výsledkov znamená, že budete vedieť povedať, aké obrázky sú vo vnútri clustrov - napr. šaláty a zelenina; plné taniere s mäsom; tanier s malým množstvom jedla; iný typ riadu (misky, farebné taniere) a pod. - malo by sa to odzrkadliť aj na priemerných obrázkoch. Porovnajte aj priemernú kalorickú hodnotu jednotlivých zhlukov.

- **Možnosť 2** Dotrénujte posledné vrstvy predtrénovanej ImageNet siete (ostatné budú zamrazené!).

Body budú udelené nasledovne:

- Natrénovanie modelu **1.5b**
- Zobrazenie priebehov trénovania (povinne, ak je to možné - t.j. neurónové siete v oboch prípadoch), reziduály, úspešnosti na **trénovacej** a **testovacej** množine + **analýza**: Kde sa model mýli? Prečo? (napr. zobrazte obrázky s najväčšou chybou a porovnajte chybu pre nízko a vysokokalorické jedlá) **2b**

Nepovinné úlohy

- Zobrazte filtre z konvolučných vrstiev - farebne. Filtre je potrebné vedieť popísať t.j. čo zachytávajú v jednotlivých častiach. **0.5b**
- Vytvorte si vlastnú malú (aspoň 5 obrázkov) databázu fotografií vlastných jedál (nie obrázky stiahnuté z internetu!) a otestujte vašu sieť na nich. **0.5b**
- Použite na regresiu model založený na architektúre Transformerov. **1b**
- Rozšírte úlohu na viacvýstupovú regresiu: **jeden** model (vlastná CNN alebo model z časti transfer learning) bude z obrázka naraz odhadovať `total_calories`, `total_mass`, `total_fat`, `total_carb` a `total_protein`. Výstupné premenné vhodne normalizujte (majú rôzne rozsahy). Úspešnosti (MSE, MAE, RMSE a R2) pre trénovaciu aj testovaciu množinu uveďte pre každú premennú zvlášť v 1 tabuľke a porovnajte, ktoré premenné sa z obrázka odhadujú najlepšie a prečo. **1b**